

# MSSACT-Net 遥感土地覆盖分割

## 项目报告

**数据集：**LoveDA 公开基准（0.3 m 航空正射影像，7 类土地覆盖，官方人工标注） **模型：**MSSACT-Net（多尺度自注意力 ConvTransformer，light 配置 6.10M 参数） **代码：**  
<https://github.com/eugenewang5425/mssact-loveda>

## 摘要

本项目在公开基准 **LoveDA** 上系统训练与评估自研的 **MSSACT-Net**，完成了 7 个主流分割模型的对比、8 个模块消融、架构缺陷的数值检验、数据量与裁剪策略的扫描、随机种子噪声底线的实测，以及标签质量上限的专项验证。

**一、方法学层面最重要的产出是"误差底线"。** 同配置换随机种子 ( $n=4$ ) 得到  $\sigma_{\text{seed}} = 0.0050$ 、极差 0.0094。以此为尺度衡量全部实验差异后，可分辨的效应屈指可数——这为后续所有结论提供了统一的判据（详见 §5.11）。

**二、预训练主干是本任务上最大的单项杠杆，且它曾造成一处严重误判。** 在公平的从零对照下，自研 6.10M 与 DeepLabV3+ 39.63M 不可分辨 ( $\Delta = +0.0039$ ,  $0.78\sigma$ )。而同一模型仅切换权重初始化，Kappa 即相差  $+0.054 \sim +0.154$  (§5.6.6)。项目早期因 `weights=None` 未关闭主干预训练，使 DeepLabV3+ 基线实际带着 ImageNet 预训练主干，导致"+0.0720 架构优势"的错误归因——该错误已定位、更正并记录取证过程。

**三、消融实验"全部无差异"的真因是实现缺陷，不是模块设计无效。数值检验证实四处结构性缺陷：** FPN 的多尺度融合未被使用（其 1,828,352 个参数 = 全模型 29.98% 不参与前向，实测归零后输出逐位不变）、解码器无跳连（仅凭  $8\times$  下采样特征上采样）、Transformer 无位置编码（置换等变，实测差  $7.15e-07$ ）、以及 `ecsam[0]` 是死模块（1,040 个参数，占 0.017%）。8 个消融变体的散布仅 0.008，落在  $\sigma_{\text{seed}}$  带内。四处缺陷已于 2026-09-13 修复并给出可复现证据 (§5.6.12)。

**四、训练策略的收益可分辨，架构模块增删不可分辨。** 256 随机裁剪比固定中心裁剪高  $+0.0192$  ( $3.8\sigma$ )； $384^2$  比  $256^2$  高  $+0.0223$  ( $4.5\sigma$ )；而全部模块消融都  $\leq 1.13\sigma$ 。**杠杆排序：预训练主干 >> 训练策略 > 架构模块。**

**五、基线并非"领先"。** 协议内从零对比下，自研 6.10M 与 DeepLabV3+ 39.63M 在主协议不可分辨；在预算受限（15 轮）与 1,000 张档位下自研更高；仅在 n=250/500 的极小数据档显著更低——说明自研模型**更依赖数据量**。

**六、标签质量仍是评价上限的约束。** 6 个模型（2.4M–39.6M）逐像素分析：模型间一致率 **0.7589** 显著高于模型与人工标签的 **0.6495**。但 2.4% 的边界像素仅值 +0.016 Kappa，而 78.4% 的内部像素值 +0.29——**聚合指标几乎看不见边界质量** (§5.6.8) 。

**关键词：** 高分辨率遥感；土地覆盖分类；语义分割；自注意力；LoveDA；误差底线；标签质量；消融实验；可复现性

## 0. 项目状态

| 项                       | 状态                                                                                    |
|-------------------------|---------------------------------------------------------------------------------------|
| 数据集                     | LoveDA 官方训练区全量获取 (2,522 张)                                                            |
| 数据筛选与划分                 | ✔ no-data ≤10% 筛选 → MD5 去重 → 8:1:1 (train 1768 / val 221 / test 221 / test_clean 141) |
| 泄漏校验                    | ✔ 三集两两互斥；test_clean 与历史训练集零重叠                                                         |
| 主模型训练                   | ✔ full_all_v2 (60 轮) + post_all_v2 (后训练 30 轮)                                         |
| 对比实验 (7 基线)             | ✔ 完成 (含 <b>协议内从零</b> DeepLabV3+ 对照)                                                   |
| 消融实验 (8 变体)             | ✔ 完成 (散布 0.008；实测 $\sigma_{\text{seed}}=0.0050 \rightarrow$ 不可分辨)                     |
| 架构缺陷数值检验                | ✔ 完成 (FPN 死支路 / 无跳连 / 无位置编码)                                                          |
| 架构变体 D1–D4              | ✔ 完成 (同管线同协议，两条管线互证)                                                                  |
| 随机种子噪声底线                | ✔ 完成 ( $\sigma_{\text{seed}} = 0.0050$ )                                              |
| 训练策略 (裁剪尺度/随机)          | ✔ 完成 (效应 3.8–4.5 $\sigma$ )                                                           |
| 数据量阶梯<br>(250/500/1000) | ✔ 完成                                                                                  |
| 预算攻击 (15 轮)             | ✔ 完成                                                                                  |
| DeepLabV3+ 从零对照         | ✔ 完成 (推翻原 +0.0720 的架构归因)                                                              |
| 硬件效率优化                  | ✔ 完成 (GPU 利用率中位 6% $\rightarrow$ 75%，零性能损失)                                           |
| 等效性检验 (TOST)            | ✔ 完成 ( results/artifacts/tost_equivalence.json )                                      |
| 四处架构缺陷修复                | ✔ 已实现并验证 (§5.6.12) ；性能效果由 IgR120 组测定中                                                 |
| 预训练主干 / 域内预训练           | 📄 后续方向 (见 §8.1)                                                                       |

| 项          | 状态                                                                                             |
|------------|------------------------------------------------------------------------------------------------|
| 跨数据集与多光谱适配 |  后续方向（见 §8.2） |

## 1. 项目背景

### 1.1 研究目标

在公开、可复现的遥感基准上，系统评估自研 MSSACT-Net 的：

- 土地覆盖分类精度**——以 Kappa 为主指标（理由见 §3.3），并与主流分割模型横向对比；
- 各设计模块的实际贡献**——通过逐模块消融，并先用数值手段检验模块是否 **真的在工作**（这一步发现了三处实现缺陷，见 §5.6）；
- 训练策略与数据规模的影响**——裁剪尺度、随机/固定裁剪、数据量阶梯；
- 评价本身的可靠性**——实测随机种子噪声底线  $\sigma_{\text{seed}}$ ，并用它给所有差异定级。

### 1.2 为什么改用公开数据集

早期工作选用的研究区（内蒙古根河市，GF-1 影像）存在两个不可回避的问题：**类别体系与影像分辨率不匹配**（2.4 m GSD 下大量类别在光谱与空间上不可分），以及**缺少可公开核验的逐像素标注**。

因此改用 **LoveDA**：0.3 m 航空正射影像、7 类、官方人工逐像素标注、有公开基准 与论文可对照。这一更换使全部结论建立在**他人可复现**的数据之上，是本项目最重要 的一次方法论更正。

## 2. 数据

### 2.1 官方类别体系（依据官方文档核对）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**; and the **no-data regions were assigned 0 which should be ignored**.

| 标签值 | 类别                   | 本项目索引      |
|-----|----------------------|------------|
| 0   | no-data              | 必须忽略（→255） |
| 1–7 | 背景/建筑/道路/水域/裸地/森林/农田 | 0–6        |

⚠️ 早期实现曾把 0 (no-data) 错误映射为"背景"参与训练与评估，使指标虚高 约 0.007–0.009 Kappa。该缺陷已修复 (§3.4) 。

2.2 数据演进三阶段

| 阶段 | 数据               | 标签处理              | 结论地位 |
|----|------------------|-------------------|------|
| A  | 957 张 (镜像子集)     | ⚠️ 含 no-data 映射缺陷 | 历史参考 |
| B  | 2,257 张 (官方全量去重) | ⚠️ 仍含缺陷           | 中间结果 |
| C  | 1,768 张 (筛选后)    | ✅ 已修复             | 结论依据 |

**必须诚实说明的一点：**A→B→C 的对比**不是纯粹的数据量效应**。阶段 C 的 1,768 张比阶段 B 的 2,257 张**更少**，却取得更高 Kappa，说明该对比同时 包含了"数据量、标签修复、低质量样本剔除"三项变化，三者**无法分离**。真正的数据量效应由 §5.9 的阶梯实验 (同协议、同管线的 250/500/1000 张) 给出。

2.3 筛选与划分 (阶段 C)

流程：**no-data 占比 ≤10% 筛选** (剔除 312 张) → **MD5 去重** → **8:1:1 划分**。


| 集合         | 图像数  | 用途               |
|------------|------|------------------|
| train      | 1768 | 训练               |
| val        | 221  | 早停 / 选优 (不参与梯度)  |
| test       | 221  | 评估               |
| test_clean | 141  | 结论用途 (与历史训练集零重叠) |

2.4 类别分布 (已按实测更正)

| 划分    | 图像数  | 背景占比 (最大类) | ignore 占比 |
|-------|------|------------|-----------|
| 训练集   | 1768 | 36.09%     | 0.17%     |
| 验证集   | 221  | 37.15%     | 0.13%     |
| 干净测试集 | 141  | 41.54%     | 0.40%     |

**验证集逐类占比：**背景 37.1%、建筑 9.3%、道路 5.2%、水域 6.4%、裸地 6.4%、森林 17.5%、农田 18.0%


**勘误：**早期报告称"验证集最大类 (背景) 占 **45.6%**"，并据此论证 "全预测背景的 OA=45.6%"。实测该值为 **37.15%** (train 36.1%、test\_clean 41.5%) 。论证方向不变 (OA 会被单类支配、故采用 Kappa 选优) ，但**数值已更正**。



### 3. 方法与协议

#### 3.1 模型架构

##### 3.1.1 整体数据流



输入为  $256 \times 256 \times 3$  的 RGB patch，逐级变换如下（括号内为分辨率与通道）：

| 阶段                 | 输出                                                                                                    | 说明                          |
|--------------------|-------------------------------------------------------------------------------------------------------|-----------------------------|
| Stem               | $256^2 \times 32$                                                                                     | $3 \times 3$ 卷积 + BN + ReLU |
| EMR 编码器 $\times 4$ | $256^2 \times 32 \rightarrow 128^2 \times 64 \rightarrow 64^2 \times 128 \rightarrow 32^2 \times 256$ | 每阶段后 max-pool 下采样（最后一级不下采样） |
| ECSAM 坐标注意力        | 同上（仅第 2-4 阶段）                                                                                         | 见 §3.1.3                    |
| FPN 多尺度融合          | $32^2 \times 256$ （仅最深层进入前向）                                                                          | 见 §5.6.2 的缺陷说明              |

| 阶段                     | 输出                                                     | 说明             |
|------------------------|--------------------------------------------------------|----------------|
| Transformer 编码器        | $32^2 \rightarrow 1024 \text{ token} \rightarrow 32^2$ | 见 §5.6.4 的缺陷说明 |
| 解码器 (转置卷积 $\times 3$ ) | $64^2 \rightarrow 128^2 \rightarrow 256^2 \times 64$   | 无跳连, 见 §5.6.3  |
| 分类头 ( $1 \times 1$ 卷积) | $256^2 \times 7$                                       | 逐像素类别 logits   |

### 3.1.2 各模块职责

- **EMR (Enhanced Multi-scale Residual)** : 两个  $3 \times 3$  卷积 + 短路连接, 构成 残差基本块。作用是逐阶段扩大感受野、提取多尺度空间特征。
- **ECSAM (Enhanced Coordinate Spatial Attention Module)** : 坐标注意力 (Hou et al., CVPR 2021) 。沿水平与垂直方向分别做 1D 池化, 得到方向感知的 特征向量, 经共享  $1 \times 1$  变换后重加权。其设计意图是编码长程空间位置信息。
- **FPN (Feature Pyramid Network)** : 自顶向下把深层语义与浅层细节融合, 输出 4 个尺度的特征图。
- **Transformer 编码器 + Adapter-Scale**: 对最深层特征做全局自注意力, 以捕捉长程上下文; Adapter 是一个低秩 ( $d/4$ ) 残差分支, 配合可学习的 `scale_factor` 控制其贡献强度。
- **解码器**: 3 次 stride=2 的转置卷积, 把  $32^2$  恢复到  $256^2$ 。

### 3.1.3 配置与参数量账目

| 配置             | embed_dims          | Transformer | 参数量     |
|----------------|---------------------|-------------|---------|
| light (本报告主模型) | [32, 64, 128, 256]  | 2 层 4 头     | 6.10M   |
| large (D4 实验)  | [64, 128, 256, 512] | 2 层 4 头     | 24.237M |

本报告主模型 light 配置的**模块参数账目** (直读 checkpoint 张量求和, 非估算) :


| 模块            | 参数量       | 占比     |
|---------------|-----------|--------|
| FPN           | 2,484,224 | 40.73% |
| Transformer   | 1,612,609 | 26.44% |
| EMR 编码器       | 1,224,576 | 20.08% |
| 解码器           | 721,863   | 11.84% |
| ECSAM (坐标注意力) | 54,912    | 0.90%  |
| Stem          | 960       | 0.02%  |

口径说明：以上为 `nn.Parameter` 计数，不含 BatchNorm 的

`running_mean / running_var / num_batches_tracked`。早前版本引用的 6,101,784 是 `state_dict` 总元素数，含 16 层 BN 的 2,640 个 buffer，高估 **0.0433%**，已更正。FPN 与 Transformer 无 BN，其计数不受影响。| 合计 | **6,099,144** | 100% |

## 两点直接推论：

1. **FPN + Transformer 合计占 67.17% 的参数**，但 §5.6 将证明二者在实现上**未执行其声明的功能**。
2. **ECSAM（坐标注意力）仅占 0.90%**——对占比不足 1% 的模块 期待显著增益，在容量意义上本就不合理。



## 3.2 训练协议（所有实验一致）

| 项    | 设置                                                                       |
|------|--------------------------------------------------------------------------|
| 优化器  | AdamW, lr = 2e-4, weight_decay = 0.02                                    |
| 调度   | OneCycleLR, 最大学习率 2e-4, warmup 占 6%, 余弦退火, 总 60 轮                        |
| 批大小  | 8 (裁剪 384 <sup>2</sup> 时为 4, 512 <sup>2</sup> 时为 2, 按面积下调以避免显存溢出)        |
| 精度   | 混合精度 (AMP) + 梯度裁剪 (max-norm = 1.0)                                       |
| 权重平滑 | EMA, decay = 0.999, 评估用 EMA 权重                                           |
| 损失   | 类别加权交叉熵, 权重 $\propto 1/\sqrt{\text{频率}}$ (见下)                            |
| 早停   | 验证集 Kappa 连续 20 轮不升则停                                                    |
| 数据增强 | 每轮每图随机裁剪 1 个 patch (位置固定为 epoch_seed 决定) ; 随机 90° 旋转 $\times 4$ 、水平/垂直翻转 |

**类别权重公式：**设第  $c$  类像素数为  $n_c$ ，则

$$w_c = \left( (n_c / N)^{-1/2} \right) / \text{mean}_k \left( (n_k / N)^{-1/2} \right)$$

即取频率的**负平方根**并归一化到均值为 1。用负平方根而非倒数，是为了避免 极稀有类（如道路）获得过大的权重而使训练不稳定。

**EMA 更新公式：**设模型参数为  $\theta$ ，影子参数为  $\theta'$ ，decay 为  $\lambda$ ：

$$\theta' \leftarrow \lambda * \theta' + (1 - \lambda) * \theta \quad (\lambda = 0.999)$$

即影子参数是历史参数的指数滑动平均；用其评估可显著降低验证指标的抖动。

### 3.3 评价指标

全部指标在 **255 (no-data) 像素上屏蔽**后计算。

设混淆矩阵  $CM$ ， $CM_{ij}$  = 真值为  $i$ 、预测为  $j$  的像素数， $N = \sum_{ij} CM_{ij}$ 。

**OA (总体精度)**

$$OA = \sum_i CM_{ii} / N$$

**Kappa (本报告的主指标与选优/早停依据)**

$$\begin{aligned} po &= \sum_i CM_{ii} / N && \# \text{ 观测一致率} \\ pe &= \sum_i (row_i * col_i) / N^2 && \# \text{ 随机一致率} \\ Kappa &= (po - pe) / (1 - pe) \end{aligned}$$

**为什么用 Kappa 而非 OA：**LoveDA 背景类占比约 37%，一个"全部预测背景"的 平凡模型即可取得  $OA \approx 0.37$ ，但其  $Kappa = 0$ 。Kappa 扣除了随机一致率，在不平衡数据上不会被单类支配。

**F1 / mF1 (按类)**

$$\begin{aligned} precision_i &= CM_{ii} / col_i && \# \text{ 亦称 UA (用户精度)} \\ recall_i &= CM_{ii} / row_i && \# \text{ 亦称 PA (生产者精度)} \\ F1_i &= 2 * precision_i * recall_i / (precision_i + recall_i) \\ mF1 &= \text{mean}_i F1_i \end{aligned}$$

**IoU / mIoU**

```
IoU_i = CM_ii / ( row_i + col_i - CM_ii )
mIoU = mean_i IoU_i
```

**数据使用协议：**val 仅用于早停与选优（在 `torch.no_grad()` 内评估，不参与 梯度更新）；**全部结论以 test / test\_clean 为准。**

**误差底线  $\sigma_{\text{seed}}$** （本项目新增）：同配置、同数据、仅换随机种子重复训练，Kappa 的标准差。它给出"差异是否可分辨"的尺度： $|\Delta| < 1\sigma$  视为不可分辨， $1-2\sigma$  为弱证据， $> 2\sigma$  才认为可分辨（详见 \$5.7 与 \$5.11）。

3.4 no-data 处理与缺陷修复

| 问题     | 表现                            | 修复                                      |
|--------|-------------------------------|-----------------------------------------|
| 标签映射缺陷 | 官方 0 = no-data 被当作"背景"参与训练与评估 | REMAP：0 及一切非 1-7 值 → 255 (ignore)，评估时屏蔽 |
| 低质量样本  | 部分图像 no-data 占比过高             | 训练集剔除 no-data > 10% 的图像 (312 张)         |
| 评估数据泄漏 | 早期 val/test 可能与训练集重叠          | MD5 去重 + 三集两两互斥校验 + test_clean 隔离       |

3.5 可复现性设计

- **路径集中：**全部路径由 `paths.py` 提供，脚本内**零绝对路径**；本地数据路径只写在 `.env`（不入库）。
- **管线世代隔离：**不同数据投递后端（PNG / memmap）的训练结果**分别标记、禁止跨世代比较 Kappa**（详见附录 A.2）。
- **产物登记：**`experiments_index.json` 登记全部实验（参数量直读 checkpoint 张量、架构由形状反推、出处指向启动它的队列脚本）。
- **推送前审核：**`verify/pre_push_audit.py` 检查本机路径、内部语境词、大文件与误提交。

4. 实验结果

4.1 阶段 A：早期实验（957 张，含缺陷） — 历史结果

主模型 Kappa **0.4065**，基线中 DeepLabV3+ 最高 (0.3806)、SegFormer-Lite 最低 (0.1775)。120 轮消融中 w/o Adapter 反而最好 (0.4621)。

本阶段结果不作为结论依据，原因有三：数据量不足（957 张）、标签映射含 no-data 缺陷、且当时的 DeepLabV3+ 基线带预训练主干（见 §5.6.6）。该阶段的图已全部撤出本报告（原图基于上述缺陷数据），仅保留文字记录。

## 4.2 阶段 B：扩大数据（2,257 张）— 中间结果


主模型 Kappa **0.6155**，后训练 **0.6239**。相比阶段 A 有大幅提升，但 **REMAP 缺陷仍未修复**，故同样不作为结论依据。

## 4.3 阶段 C：最终实验（1,768 张筛选 + 修复）— 结论依据

### 4.3.1 主模型与后训练

| 模型                             | Kappa         | OA     | 说明          |
|--------------------------------|---------------|--------|-------------|
| full_all_v2 (60 轮)             | <b>0.6312</b> | 0.7030 | 主模型         |
| post_all_v2 (+30 轮微调, lr=5e-5) | <b>0.6413</b> | 0.7112 | 在已收敛模型上继续训练 |

后训练带来 **+0.0101** Kappa ( $2.02\sigma$ ，属可分辨的小幅提升)。




图中可见两点：① DeepLabV3+ 的**从零版本收敛晚于**自研模型（起势更慢），与 §5.2 的累计学习量分析一致；② 带预训练主干的那条曲线早在第 11 轮即越过 Kappa 0.5——这正是早期报告误判“架构学习效率更高”的来源。

### 4.3.2 对比实验（7 个基线）

| 模型                           | 参数量    | Kappa         | OA     | 最优轮/总轮 |
|------------------------------|--------|---------------|--------|--------|
| MSSACT-Net light（自研）         | 6.10M  | <b>0.6312</b> | 0.7030 | 54/60  |
| DeepLabV3+（从零，协议内）           | 39.63M | <b>0.6281</b> | 0.7018 | 60/60  |
| DeepLabV3+（预训练主干，旁证 ⚠️ 非协议内） | 39.63M | <b>0.6876</b> | 0.7497 | 60/60  |
| FPN-Seg                      | 27.15M | <b>0.6151</b> | 0.6912 | 60/60  |
| FCN                          | 23.72M | <b>0.6144</b> | 0.6903 | 60/60  |
| U-Net                        | 2.44M  | <b>0.6054</b> | 0.6833 | 60/60  |
| Swin-Unet-Lite               | 32.67M | <b>0.5859</b> | 0.6693 | 60/60  |
| PSPNet                       | 13.59M | <b>0.5175</b> | 0.6160 | 60/60  |
| SegFormer-Lite               | 1.23M  | <b>0.3043</b> | 0.4441 | 60/60  |


分析：



- 协议内（全部从零训练）的公平对比下，DeepLabV3+（39.63M）与自研 6.10M 不可分辨（ $\Delta = +0.0039$ ， $0.78\sigma$ ），而后者参数仅为其 1/6.5。
- 表中 DeepLabV3+ 的预训练版本已明确标注为"旁证 ⚠️ 非协议内"，**不作为基线**。它比从零版高出的 0.06，正是预训练的贡献（\$5.6.6\$）。
- 自研模型以 6.10M 参数达到与 23–27M 级别模型相当的水平。



### 4.3.3 混淆矩阵与逐类 IoU

MSSACT-Net light (自研)






**读图要点：**自研模型与 DeepLabV3+（预训练）的混淆**结构相似**——两者的主要 混淆都发生在 **裸地 ↔ 农田/森林 与 背景 ↔ 建筑** 之间，说明困难来自 **类间光谱相似性**与**标注边界模糊**，而非某个模型特有的缺陷。逐类看，DeepLabV3+（预训练）在 7 个类上均更高——但如 §5.6.6 所示，该优势主要来自预训练主干。

4.3.4 消融实验（8 个变体）

| 变体                         | Kappa  | $\Delta$ Kappa vs 完整 (0.6312)  | 可分辨性 |
|----------------------------|--------|--------------------------------|------|
| Bilinear-Up（可学习上采样 → 双线性）  | 0.6369 | +0.0057 (1.14 $\sigma$ , 弱)    |      |
| Transformer 2 层 → 4 层      | 0.6362 | +0.0050 (1.00 $\sigma$ , 弱)    |      |
| w/o EMR（改用标准 ResBlock）     | 0.6355 | +0.0043 (0.86 $\sigma$ , 不可分辨) |      |
| w/o Adapter-Scale          | 0.6342 | +0.0030 (0.60 $\sigma$ , 不可分辨) |      |
| Transformer 2 层 → 6 层      | 0.6335 | +0.0023 (0.46 $\sigma$ , 不可分辨) |      |
| w/o FPN（直接用最深层特征）          | 0.6314 | +0.0002 (0.04 $\sigma$ , 不可分辨) |      |
| w/o Transformer（含 Adapter） | 0.6302 | -0.0010 (0.20 $\sigma$ , 不可分辨) |      |
| w/o ECSAM（去掉坐标注意力）         | 0.6272 | -0.0040 (0.80 $\sigma$ , 不可分辨) |      |

**关键发现：**8 个变体的散布仅 0.008，全部落在  $\pm 1.6\sigma_{\text{seed}}$  内——即在统计上 **不可分辨**。其中 5 个变体（含把可学习上采样换成双线性的 Bilinear-Up）**反而略优于完整模型**。



**重要限定：这不等于**"这五个模块没有设计价值"。§5.6 的数值检验证明，其中若干模块在实现上并未执行其声明的功能（FPN 的多尺度融合被丢弃、Transformer 无位置编码）。因此本节正确解读是 **"移除它们没有影响，因为它们在数值上接近什么都不做"**。

4.3.5 模块移除的架构适配说明

消融并非简单删除调用，部分变体需要架构层面的适配：

| 变体              | 适配方式                                   |
|-----------------|----------------------------------------|
| w/o EMR         | EMR 残差块 → 标准 ResBlock 替换               |
| w/o ECSAM       | 前向直接跳过坐标注意力（参数量 −0.055M）               |
| w/o FPN         | 跳过 FPN，最深层特征直送 Transformer/解码器         |
| w/o Transformer | 移除全局自注意力与 Adapter（参数量 −1.6M）           |
| w/o Adapter     | 仅移除 Adapter-Scale（低秩残差 + scale_factor） |
| Bilinear-Up     | 转置卷积 → 双线性插值 + 1×1 卷积                  |

5. 深入分析

5.1 数据规模与标签质量：三项同时变化的混合效应

| 数据量             | 主模型 Kappa | 同时发生的变化              |
|-----------------|-----------|----------------------|
| 957 张（阶段 A）     | 0.4065    | 原始状态                 |
| 2,257 张（阶段 B）   | 0.6155    | 仅扩数据                 |
| 1,768 张筛选（阶段 C） | 0.6312    | 扩数据 + 标签修复 + 剔除低质量样本 |

这三项在阶段 C 是同时发生的，无法分离。特别是阶段 C 的图像数比阶段 B 更少 却更好，直接说明"数据量"不是唯一变量。

若要单独度量数据量效应，必须固定其他一切——这正是 §5.9 阶梯实验的设计：同一管线、同一协议、同一验证集，只改训练集规模（250/500/1000 张）。

**少数类是否获益更多？** 阶段 B 的逐类 F1 显示道路 +0.390、水域 +0.385、裸地 +0.324、建筑 +0.255，但**阶段 B 的标签映射仍有缺陷**，其逐类数值只宜 作为趋势参考。阶段 C 的逐类 IoU 见 §4.3.3。

5.2 收敛速度的归因：调度 vs 架构

**方法（以及它为什么能分离两者）：** OneCycleLR 的学习率轨迹是**解析已知**的——给定 max\_lr、总步数 T、warmup 比例，任一时刻的  $\eta$  可由公式算出，**与模型无关**。定义**累计学习量**：

$$S(t) = \sum_{\tau \leq t} \eta_{\tau}$$

若两个模型在同一水平上所需的 S 相同，则差异来自架构；若几乎所有模型都在相近的 S 比例处达到同一水平，则说明"第几轮收敛"只是**调度曲线形状的映射**。

**结果**（达 Kappa 0.5 所需累计学习量占比；全部为 P-PNG 管线同协议）：


| 模型                      | 达 K0.5 轮次 | 累计学习量        |
|-------------------------|-----------|--------------|
| DeepLabV3+（预训练主干）       | 11        | <b>30.3%</b> |
| Swin-Unet               | 14        | 39.7%        |
| w/o ECSAM               | 16        | 45.7%        |
| MSSACT-light / Trans-4L | 21        | <b>59.7%</b> |
| w/o EMR                 | 22        | 62.2%        |
| <b>DeepLabV3+（从零）</b>   | <b>28</b> | <b>75.9%</b> |
| PSPNet                  | 47        | 98.2%        |
| SegFormer-Lite          | 未达到       | —            |

**结论（已更正）：**

早期报告称"唯一例外是 DeepLabV3+（31.8%），其多尺度空洞卷积结构确实学习效率更高"。**该结论是错的**——31.8% 来自带 **ImageNet 预训练主干**的那一次运行。换成本项目自己训练的**从零版本**后，DeepLabV3+ 需要 **75.9%** 的累计学习量，**比自研模型的 59.7% 还慢**。

因此：**预训练带来的是早期收敛加速，而非该架构的学习效率优势**；在公平的 从零条件下，DeepLabV3+ 的收敛速度**不优于**自研模型。


绝大多数模型（11/16）集中在 40%–76% 区间，支持"第几轮收敛主要由调度曲线决定" 这一判断。



### 5.3 标签质量上限的专项验证

6 个架构/容量差异极大的模型 (2.4M-39.6M) 在 test\_clean (141 张) 上逐像素分析：


| 判据             | 数值     |
|----------------|--------|
| 平均模型间一致率       | 0.7589 |
| 平均模型-人工标签一致率   | 0.6495 |
| 多数投票共识 vs 人工标签 | 0.6815 |



**解读：**模型之间的互相认同（0.7589）显著高于它们与人工标签的认同（0.6495），说明模型在**彼此一致地 偏离人工标注**。

**必须声明的限定：**共识法（Warfield et al., 2004 的 STAPLE 一脉）要求 **各模型的误差相互独立**（Bouix et al., 2007）。本项目 6 个模型**共享训练集、损失函数与训练协议**，误差必然相关，因此共识评估会**偏向同族约定**。故本节结论应视为**提示性证据**，不能单独作为“标签上限已被证实”的依据。更强的证据来自 §5.6.8 的 Kappa 归属分析（与参考标准无关的纯数学量）。

## 5.4 过拟合诊断



以训练/验证 logits 的预测熵差  $\Delta H = H_{\text{train}} - H_{\text{val}}$  衡量： $\Delta H$  为负说明模型在训练集上更“自信”（预测更集中）。阶段 A 的主模型  $\Delta H = -0.241$ ，是所测模型中偏离最大的；而 SegFormer-Lite 接近 0（-0.0003）——但那是因为它**几乎没学到东西**（Kappa 0.3043）。

**判读要点：** $\Delta H$  单独看会误读。它必须与**绝对性能**联合解读： $\Delta H$  大且性能高 = 记忆了训练集； $\Delta H \approx 0$  且性能低 = 欠拟合。本项目主模型属于前者，与 §5.9 的结论（自研模型更依赖数据量）互相印证。

## 5.5 训练基础设施与硬件效率优化

### 5.5.1 问题诊断

训练时 GPU 利用率仅 49.9%，**34.6% 的时间 GPU 完全空闲**。

### 5.5.2 瓶颈定位

关键判据是**参数量与每轮耗时的无关性**：1.55M 参数（144 s/轮）与 24.237M 参数（121–176 s/轮）耗时接近——说明瓶颈**不在计算**，而在数据侧。

根因：每样本解码**两张 1024<sup>2</sup> PNG**，却只裁出 256<sup>2</sup>，**94% 的解码结果被丢弃**；且 `num_workers=0` 时代码在主进程串行解码，GPU 全程等数据。


### 5.5.3 优化措施（四项）


| 措施         | 做法                                                               |
|------------|------------------------------------------------------------------|
| 预解码 memmap | 一次性把 1024 <sup>2</sup> PNG 解码为 <code>uint8</code> memmap，训练时随机切片 |

| 措施       | 做法                                                                                               |
|----------|--------------------------------------------------------------------------------------------------|
| 多进程加载    | <code>num_workers &gt; 0</code> + <code>persistent_workers</code> + <code>prefetch_factor</code> |
| EMA 实现优化 | 改为直接遍历 <code>parameters()</code> ，避免每步构造 <code>state_dict()</code>                               |
| 损失累积     | 用张量累加损失，去掉每步 <code>.item()</code> 造成的 GPU-CPU 同步                                                 |

### 5.5.4 优化效果

| 指标           | 优化前       | 优化后             |
|--------------|-----------|-----------------|
| GPU 利用率 (均值) | 49.9%     | <b>84.3%</b>    |
| 每轮耗时         | 144 s     | <b>12–15 s</b>  |
| 数据阶梯每张图成本    | ≈170 ms/张 | <b>≈24 ms/张</b> |





上图右为**后来补测**的数据：切到 memmap 后每轮耗时随参数量单调增长， 正面确认瓶颈已从"数据受限"转为"计算受限"。

5.5.5 零性能损失验证

优化过程中逐项验证，**仅保留不改变训练语义的措施**：

| # | 措施                   | 结论                                                    |
|---|----------------------|-------------------------------------------------------|
| 1 | memmap 预解码           | ✅ 数据内容与 PNG 路径 <b>逐位一致</b> ( verify/bench_parity.py ) |
| 2 | EMA 实现重写             | ✅ 数学等价 (同一滑动平均公式)                                     |
| 3 | 损失张量累积               | ✅ 仅去掉同步，数值不变                                          |
| 4 | 多进程加载                | ✅ 不影响增强语义                                             |
| 5 | ~~增强改确定性 generator~~ | ❌ <b>已回退</b> ：导致 Kappa 0.6277 → 0.6031 ( -0.0246 )    |
| 6 | ~~batch 8 → 16/32~~  | ❌ 主动放弃 (需重调学习率，破坏可比性；且 batch=32 需 9.16 GB 显存会 OOM)    |
| 7 | ~~学习率/调度再调优~~        | ❌ 主动放弃 (会破坏与已完成实验的可比性)                                |

**回退验证**（同配置、同数据、同协议）：

| 配置                             | Kappa         | 每轮耗时          |
|--------------------------------|---------------|---------------|
| 旧管线（原始增强）                      | 0.6277        | 144 s         |
| 确定性增强版                         | 0.6031        | 12 s          |
| 回退版（memmap + 原始增强 + workers=0） | <b>0.6293</b> | <b>14.7 s</b> |

结论：回退后性能完全恢复（+0.0016，在噪声内），同时保留约 10 倍加速——加速的真实来源是 memmap 预解码，而非增强或并发改动。

## 5.6 架构有效性分析：为什么消融实验全部"无差异"

本节是对自研架构的否定性发现，也是本项目最重要的技术结论之一。

三处结构性缺陷（均由可复现的数值实验证实）：

| #  | 缺陷                         | 验证方式                                                             | 结果                                                              |
|----|----------------------------|------------------------------------------------------------------|-----------------------------------------------------------------|
| D1 | FPN 的多尺度融合是死计算             | 归零 <code>lateral_convs[0..2]</code> ；把整个 FPN 换成"仅第 4 支路"的等价算子    | 两次输出差恰好 0.0（逐位相同）                                               |
| D2 | 解码器无跳连                     | 前向路径 + 分辨率链追踪 + 边缘密度/FFT 实测                                      | 高分辨率特征从未到达输出；预测边缘密度达标签 4.56×，且周期 k=8 功率超额 1.66×                 |
| D3 | Transformer 无位置编码          | 置换 token 后按逆置换还原                                                 | 差 7.15e-07 → 置换等变，无空间感知                                         |
| D5 | <code>ecsam[0]</code> 是死模块 | 构造时 4 个阶段全建，前向条件是 <code>i &gt; 0</code> ；查各张量 <code>.grad</code> | 第 0 个恒不执行，其 7 个张量的 <code>.grad</code> is None；1,040 个参数（0.017%） |

### 5.6.1 参数账目

见表 §3.1.3。关键结论：FPN 的 1,828,352 个参数（真实参数的 29.98%）不参与前向，实际参与前向的有效参数仅 4,270,792（70.02%）；另有 `ecsam[0]` 的 1,040 个参数（0.017%）同样不参与前向。（更正说明：此前记 29.96% / 4,273,432 / 70.04%，分母误用了含 BN buffer 的 `state_dict` 总数 6,101,784；以真实参数 6,099,144 为分母的正确值为上述数字。）

### 5.6.2 D1：FPN 的多尺度融合未被使用

`MSSACTNet.forward` 只取 `fpn_features[-1]`；而 `FPN.forward` 的自顶向下融合循环写入索引 `i-1`（即 2/1/0），最深层 `laterals[3]` 从未被融合增强。两者叠加的结果：`laterals[0..2]` 及其对应的 `fpn_convs[0..2]` 算完就被丢弃。

因此"w/o FPN"消融的真实含义是：移除"最深尺度上的一个 1×1 卷积 + 一个 3×3 卷积，外加 3 条被丢弃的支路"。

**这不是"FPN 冗余"的证据，而是"这个 FPN 没有在工作"的证据。**前者是多尺度融合的一般性结论，后者是本实现的缺陷结论——科学含义完全不同。

5.6.3 D2：解码器无跳连 → 细节为"合成"而非"测量"，并伴生棋盘伪影

必须精确表述：三次转置卷积上采样**能够**产生高频结构（转置卷积可学习上采样核），因此**不能说**"输出被限制在 8 像素粒度"。正确表述是：**没有任何通路让高频的输入 证据到达输出**——输出中的细节是解码器**合成的**，而非在高分辨率上**测量**到的。


实测（逐图 2D 计算，有效相邻像素对  $2.94 \times 10^8$ ）：

| 模型                | 边缘密度           | 相对标签         | 周期超额比峰值           |
|-------------------|----------------|--------------|-------------------|
| 标签（参照）            | 0.00771        | 1.000        | —                 |
| MSSACT-Net 6.10M  | <b>0.03516</b> | <b>4.563</b> | <b>k=8: 1.66×</b> |
| DeepLabV3+ 39.63M | 0.00884        | 1.147        | 无                 |
| U-Net 2.4M        | 0.02139        | 2.776        | k=16: 1.17×       |

**所有模型都过度碎裂**（ $1.15\times\text{--}4.56\times$ ），而 **MSSACT-Net 最严重（4.56×**）。且其伪影**具有周期性**：水平边缘图的 FFT 在周期 **k=8** 附近功率占比为标签的 **1.66 倍**，而 8 正是解码器（ $32^2 \rightarrow 256^2$ ，三次 stride-2 转置卷积）的总上采样倍数——这与堆叠转置卷积的**棋盘伪影**机制一致。

**可证伪的预测**：若伪影确由转置卷积造成，则 `nd_abl_bilinear`（双线性替代 转置卷积）应同时具备更低的边缘密度与更小的 k=8 超额。该变体的实测 Kappa **确实更高**（0.6369 vs 0.6312，**+0.0057**），与预测方向一致。

**⚠ 该"方向一致"在换底后不再稳健（2026-09-14 补记）**：在 `pos_enc` 底（0.6716）上，双线性为 **0.6643 = -0.0073 (-1.5σ)**，即**符号翻转**。两次测量分别是 +0.0057 (+1.14σ) 与 -0.0073 (-1.45σ)，**都落在噪声内且方向相反** ⇒ 正确结论是**"转置卷积 vs 双线性在本项目分辨力下不可分辨"**，**不能说"双线性更好"**。（伪影**存在**这一事实是实测的；但"换成双线性会提精度"不是。这两件事必须分开陈述。）



### 5.6.4 D3: Transformer 无位置编码

`TransformerEncoder.forward` 摊平为 token 后未插入任何位置信息，而 `nn.TransformerEncoderLayer` 不自带位置编码（不同于 ViT）。自注意力本身是 置换等变的：对置换矩阵  $P$ ， $A=\mathrm{softmax}(QK^{\top}/\sqrt{d})\rightarrow PAP^{\top}$ 。

**数值验证：**随机置换 64 个 token，把输出按逆置换还原，最大绝对差 **7.153e-07**（浮点噪声量级）→ 模块对 token 顺序完全等价。

三点如实限定：

1. **不等价于"完全无用"**：输入 token 来自卷积特征，其内容本身位置相关；且零填充/边界可充当隐式位置锚点（CPVT/PEG 一脉的论证）。
2. **但无法完成基于空间邻近的上下文建模**——而"长程空间上下文"正是分割网络中 全局注意力的标准用途。这是**机制性降级**。
3. **量级参照**：位置编码并非可有可无——移除 DeiT-tiny 的位置编码使 ImageNet 精度由 72.2% 降至 68.2%。

### 5.6.5 与消融结果的对应（机制解释）

| 变体              | 实测 $\Delta Kappa$              | 机制解释                     |
|-----------------|--------------------------------|--------------------------|
| w/o FPN         | +0.0002 (0.04 $\sigma$ , 不可分辨) | FPN 支路 0–2 是死计算 (§5.6.2) |
| w/o Transformer | -0.0010 (0.20 $\sigma$ , 不可分辨) | 置换等变集合算子 (§5.6.4)        |
| w/o ECSAM       | -0.0040 (0.80 $\sigma$ , 不可分辨) | 仅占 0.90% 参数              |

| 变体          | 实测 $\Delta Kappa$              | 机制解释                |
|-------------|--------------------------------|---------------------|
| w/o Adapter | +0.0030 ( $0.60\sigma$ , 不可分辨) | 仅 33K 参数 (0.54%)    |
| Bilinear-Up | +0.0057 ( $1.14\sigma$ , 弱)    | 消除转置卷积棋盘伪影 (§5.6.3) |

**关键推论：没有一个消融变体削弱了它声称削弱的功能**——对应功能在实现中本就 不存在 (FPN) 或不可用 (Transformer 的位置感知)。故这一组消融**不能**作为 "模块有效性"的证据，它衡量的是"移除无效计算的影响"。


### 5.6.6 基线为何领先？——从零对照推翻了本节的原始结论

| 设置        | 预训练主干  | 从零训练   | 预训练贡献          |
|-----------|--------|--------|----------------|
| 主数据集 60 轮 | —      | 0.6359 | —              |
| 阶梯 n250   | 0.2825 | 0.1762 | <b>+0.1063</b> |
| 阶梯 n500   | 0.4928 | 0.4393 | <b>+0.0535</b> |
| 阶梯 n1000  | 0.6310 | 0.4771 | <b>+0.1539</b> |

**主数据集 (60 轮, 双方均从零)：**自研 6.10M **0.6320** vs DeepLabV3+ 39.63M **0.6359**,  $\Delta = +0.0039$  ( $0.78\sigma \rightarrow$  不可分辨)。

**修正后的结论：**

1. 从零训练的公平对比下，自研 6.10M 与 DeepLabV3+ 39.63M 不可分辨 ( $\Delta = +0.0039$ ,  $0.78\sigma$ )，而后者参数是前者的 6.5 倍。原报告"DeepLabV3+ 显著优于自研 (+0.0720)"的表述**不成立**：那 0.0720 中约 95% 来自预训练主干。
2. 预训练主干是本任务上最大的单项杠杆：同一模型仅切换权重初始化，贡献 **+0.054 ~ +0.154** Kappa。作为对照，全部模块消融  $\leq 1.13\sigma$  ( $\approx 0.0057$ )，裁剪策略为 0.0199–0.0223。**杠杆排序：换主干权重  $\gg$  改训练策略  $>$  增删模块。**



**核验更正 (取证过程) :** `weights=None` 并不足以关闭主干预训练。torchvision 的 `deeplabv3_resnet50` 有两个互相独立的权重参数: `weights` (整体/分割头) 与 `weights_backbone` (主干), 后者默认即 `ResNet50_Weights.IMAGENET1K_V1`。

**权重级取证 (与该权重的官方文件逐张量比对) :**

| 构造方式                                   | 与官方权重相同的张量 | 相同参数量占比                                 |
|----------------------------------------|------------|-----------------------------------------|
| <code>pretrained_backbone=True</code>  | 264 / 265  | <b>23,551,744 / 23,561,152 = 100.0%</b> |
| <code>pretrained_backbone=False</code> | 0 / 265    | 0.0%                                    |

(唯一不同者是 `conv1`, 因输入改为 3 通道而被替换。) 该预训练覆盖了该模型 **58.1%** 的参数; 其来源是 PyTorch 官方在 **ImageNet-1K** (1000 个自然图像类) 上训练的 ResNet-50, 官方指标  $\text{acc}@1 = 76.13\%$ 。

**行为级取证:** 若该参数不生效, 两次运行应当统计一致; 而实测两者相差  $+0.054 \sim +0.154$  Kappa。参数确实在起作用。

### 5.6.7 通道-空间容量比

| 配置                        | 最深特征      | 元素数     | 输入元素数   | 比值           |
|---------------------------|-----------|---------|---------|--------------|
| light [32, 64, 128, 256]  | 256×32×32 | 262,144 | 196,608 | <b>1.33×</b> |
| large [64, 128, 256, 512] | 512×32×32 | 524,288 | 196,608 | <b>2.67×</b> |

即**最深特征图的标量数量超过输入图像本身** (large 达 2.67 倍), 而这些表征最终被压缩回  $256^2$  输出, 其中还有 29.98% 的参数不参与前向。此处**并非** transformer 的 秩亏问题 (token 数  $N=1024 > d_{\text{model}}$ ), 而是**空间侧信息量与通道侧容量的失衡**。

### 5.6.8 边界质量为何在聚合指标上不可见


| 距类边界       | 像素占比   | 共识 vs 标签 | 模型间分歧  |
|------------|--------|----------|--------|
| 0 (边界像素)   | 2.36%  | 0.4577   | 0.2881 |
| 1-2 px     | 5.34%  | 0.4891   | 0.2877 |
| 3-4 px     | 5.17%  | 0.5327   | 0.2847 |
| 5-8 px     | 8.75%  | 0.5882   | 0.2789 |
| >8 px (内部) | 78.39% | 0.7294   | 0.2294 |


**Kappa 归属上限** (oracle 作弊实验) :

| 模型         | 完美解决边界 | $\Delta$ 边界    | 完美解决内部 | $\Delta$ 内部    |
|------------|--------|----------------|--------|----------------|
| MSSACT-Net | 0.5936 | <b>+0.0161</b> | 0.8700 | <b>+0.2925</b> |
| DeepLabV3+ | 0.6654 | +0.0159        | 0.8800 | +0.2306        |

**完美预测全部边界像素 (2.36%) 最多换来 +0.016 Kappa; 内部像素 (78.39%) 值 +0.23 ~**

**+0.29**。因此任何**面向边界锐化**的模块在聚合 Kappa 上的可见空间被限制在  $\approx 0.016$  以内——与观测到的消融散布 0.008 同量级。





**勘误：**早期报告称"93.0% 像素在类边界上"，并据此得出"标签碎片化"与"越纯净区域模型越不同意标签"两条结论。经复核，原实现把标签批次按  $(N, H, W)$  三维数组沿  $axis=0$  求差分，跨图像的像素差被误判为类边界，故得出虚高比例。改为逐图 2D、且仅统计两个不同有效类别之间的相邻像素后，真实边界比例为 **2.4%**，结论方向亦反转（准确率随距边界距离单调上升）。

### 5.6.9 架构变体实测结果（两条管线互证）

| 管线         | 变体                            | 参数量     | Kappa         | 相对基线           |
|------------|-------------------------------|---------|---------------|----------------|
| P-MEM-ROLL | 完整模型                          | 6.099M  | 0.6320        | —              |
|            | D1 联合消融（-FPN -Trans -Adapter） | 2.002M  | 0.6293        | -0.0027        |
|            | D2 解码器坐标注意力                   | 6.112M  | <b>0.6375</b> | +0.0055        |
|            | D3 超轻量通道                      | 1.545M  | 0.6103        | <b>-0.0217</b> |
|            | D4 大容量通道                      | 24.237M | 0.6365        | +0.0045        |
| P-PNG      | 完整模型                          | 6.099M  | 0.6312        | —              |
|            | D1 联合消融                       | 2.002M  | 0.6277        | -0.0035        |
|            | D3 超轻量通道                      | 1.545M  | 0.6119        | -0.0193        |

**三条读表要点：**

1. 移除 **67.2%** 的参数只损失 **~0.003**（两条管线分别 -0.0027 / -0.0035，互证）。

2. 把坐标注意力移到解码器 (D2) 反而最好 (+0.0055 / +0.0029) , 与 "注意力在上采样路径上才有效"的文献结论一致。
3. 容量确有作用: D3 (通道减半) 显著下降 (-0.0217 / -0.0193, 约  $4\sigma$ ) , 而 D3 仍保留全部模块——所以"模块不重要"**不等于**"容量不重要"。精确表述是: **占参数 67.14% 的两个模块无可测量贡献, 而通道宽度才是性能来源。**

### 5.6.10 可验证的修复路径

| 优先级 | 修复                                     | 预期效果             | 状态                                                                                          |
|-----|----------------------------------------|------------------|---------------------------------------------------------------------------------------------|
| P0  | FPN 改为 <b>真正使用</b> 多尺度输出 (解码器接收全部 4 层) | 恢复多尺度融合语义; 死支路变活 | ✅ <b>已实现</b> ( <code>use_skip=True</code> , 29.99% 死参数 → 0.016%)                            |
| P0  | 解码器加入 <b>encoder→decoder 跳连</b>        | 修正 §5.6.3 的粒度瓶颈  | ⚠️ <b>已否决</b> : 单独 -0.0150 ( $3\sigma$ ) , 合并 -0.0325; 两个候选机制 (256 <sup>2</sup> 融合、学习率) 均证伪 |
| P1  | Transformer 加入 <b>位置编码</b> (2D sincos) | 恢复空间邻近建模能力       | <b>弱正向</b> : +0.0061 ( $1.2\sigma$ ) ; 置换等变性已被打破 (9.5e-07 → 1.9)                            |
| P1  | 重新定义消融语义: 先修实现, 再评估"模块是否有效"            | 使消融结论可解释         | 换底为 <code>lgR120_pos_abl_*</code> (底 = <code>pos_enc</code> ) ; 旧底因 <b>数值发散</b> 弃用          |
| P2  | 容量重新配比, 修正 2.67× 容量膨胀                  | 参数效率             | 🟡 未做                                                                                        |
| P3  | <code>ecsam_stage0</code> 是否默认启用       | 使死参数归零           | 🟡 优先级低 (仅 0.017% 死参数)                                                                       |

这张表的教训值得单独记下: P0 的两项 (跳连、FPN 多尺度) 当初排在最前, 部分依据是 "DeepLabV3+ 领先 +0.0720, 因为它有低层跳连而本模型没有"这一归因。该归因后被 **两次推翻** (预训练主干混淆; 从零对照 +0.0039 =  $0.78\sigma$  不可分辨) 。**一条被推翻的归因, 曾驱动出一项实测有害的改动。** 而 §5.6.3 自己的证据当时已指向 **双线性上采样** (棋盘伪影源自堆叠转置卷积, 且 `nd_abl_bilinear` 是全部消融中最好的 变体) 。**应当以本项目的直接证据为准, 而不是类比外部模型。**

### 5.6.11 本节局限

1.  $\sigma_{\text{seed}}$  的种子数仅 4 (文献建议  $\geq 10$ ) , 故适用于**量级判断**而非精确检验。
2. 等效性检验 (TOST) 已完成并落盘: `analysis/tost_equivalence.py` → `results/artifacts/tost_equivalence.json` , SESOI = 0.02 (预指定) 。实测配对 bootstrap 的 95% CI 半宽  $\delta \approx 0.010$  (如 `nd_unet` vs `full_all_v2` 为 [-0.0532, -0.0318]) , **小于** SESOI → 测试集层足以给出等效判定。关键是**配对设计**: 两个模型跑同一批图,  $\Delta$  的方差远小于各自 Kappa 的方差。尚须区分两套误差模型——**种子层** (换种子重训差异还在吗, 误差  $\sqrt{2} \cdot \sigma_{\text{seed}} \approx 0.010$ ) 与**测试集层** (取样了哪些图, 误差  $\approx 0.011$ ) ; 两者量级接近但回答不同问题, 不合并。

3. 缺陷检验在 **light** 配置上完成；大配置结构相同、结论可直接推广，但未复跑。

4. 分带与 Kappa 归属基于**已缓存的 6 个模型预测**。**原因已查明**：预测缓存

`results/consensus_analysis/pred_{tag}.npz` 存在两种不兼容布局（旧  $564 \times 256 \times 256$  / 新  $141 \times 1024 \times 1024$ ），`eval_rigor` 遇形状不符会**静默跳过**，导致 G1 的 8 个消融、`lg_D1..D4`、`lgR_D1..D4`、`nd_pspnet`、`nd_segformer` 等**从未进入测试集协议**——即报告此前关于消融的结论只有 val Kappa 单一来源，缺测试集侧独立证据。修复：`queues/run_post_fix.py` 对 44 个 tag 做全量重推理（覆盖前自动备份 consensus 目录），逐带分解与 TOST 随之覆盖全部结论。**该步在 IgR120 组训练结束后执行。**

5.6.12 缺陷修复：向后兼容实现与验证（2026-09-13）

**修复原则：只加开关，不改默认。** 三个新参数默认值 == 修复前行为，故既有 103 个实验的 checkpoint 仍能以 `strict=True` 加载、既有结论仍可复现。

| 开关                             | 作用                                                                        | 修复    | 参数变化                        |
|--------------------------------|---------------------------------------------------------------------------|-------|-----------------------------|
| <code>use_skip=True</code>     | 解码器逐级接入主干同分辨率特征；有 FPN 时接入 FPN <b>四级输出</b> （死支路变活，同时修好 D1），无 FPN 时接入编码器浅三层 | D1+D2 | 6.099M → 6.464M<br>(+5.99%) |
| <code>pos_enc=True</code>      | Transformer 注入 2D 正弦位置编码（dim 通道对半分为行/列，每半内再对半为 sin/cos）                   | D3    | 不变                          |
| <code>ecsam_stage0=True</code> | 第 0 阶段也应用 ECSAM                                                           | D5    | 不变（本轮未启用）                   |

**修复的验证证据（五项全部通过）：**

| 验证项              | 结果                                                                                         |
|------------------|--------------------------------------------------------------------------------------------|
| 默认路径 <b>逐位一致</b> | 默认配置加载旧权重成功；新旧输出最大逐元素差 <b>0.000e+00</b> （不是“很小”）                                           |
| <b>键集合一致</b>     | <code>mssact_light()</code> 与既有 checkpoint 键集合完全相同                                         |
| <b>置换等变性被打破</b>  | 残差 $9.537\text{e-}07 \rightarrow \mathbf{1.821\text{e+}00}$ （放大约 190 万倍）                   |
| <b>梯度可达性</b>     | 基线无梯度参数 <b>29.99%</b> → 打开 <code>use_skip</code> 后仅剩 <code>ecsam[0]</code> 的 <b>0.016%</b> |
| <b>组合路径</b>      | 10 种消融组合 × 跳连（含 bilinear / no_fpn / no_trans / trans4l / trans6l）输出与梯度完整性全部通过              |

**诚实限定：**以上验证的是**修复实现的正确性**（缺陷确已消除、既有行为未被破坏），**不是**修复的性能效果。

5.6.13 修复的性能效果是负面的（第一轮实测）

修复在当前协议下没有带来收益，全修反而明显更差。四个实验同为 120 轮 / pt20 / bs8 / lr2e-4,  $\sigma_{\text{seed}} = 0.0050$ :

| 实验             | 修复内容     | Kappa  | best@ | $\Delta$ vs 基线 | 判定                |
|----------------|----------|--------|-------|----------------|-------------------|
| lgR120_full    | 未修复 (基线) | 0.6655 | 91    | —              | 参照                |
| lgR120_fx_pos  | D3 位置编码  | 0.6716 | 96    | +0.0061        | 弱 ( $1.2\sigma$ ) |
| lgR120_fx_skip | D1+D2 跳连 | 0.6505 | 114   | -0.0150        | 可分辨 ( $3\sigma$ ) |
| lgR120_fx_all  | 三处全修     | 0.6330 | 62    | -0.0325        | 可分辨               |

三点必须同时陈述:

1. 两项修复合起来比任何单项都差得多 ( $-0.0325$  vs  $-0.0150$  /  $+0.0061$ )，即**非加性**——说明另有原因，不能简单读作"修复有害"。
2. **过拟合假设已被推翻**。fx\_all 的训练 loss 是四者中最高的 ( $0.7237$  vs 基线  $0.6269$ )，fx\_skip 次之 ( $0.6734$ )。训练集拟合更差、验证也更差  $\Rightarrow$  是欠拟合 / 优化困难，不是过拟合。训练 loss 偏高又叠加了容量，指向**优化/条件数问题**。
3. **两个假设都已检验，且都被证伪** (各为单变量实验)：

| 假设                                                                                   | 检验                                                       | 结果                                                                                                                      | 判定 |
|--------------------------------------------------------------------------------------|----------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|----|
| <b>H1</b> 256 <sup>2</sup> 全分辨率融合有害 (fuse 把主干最浅层直接接到输出，并让 FPN 三条全分辨率 3×3 支路首次进入梯度通路) | skip_stages=(1, 2)，只融合 128 <sup>2</sup> /64 <sup>2</sup> | 0.6466，与全融合的 0.6505 仅差 $-0.0039$ ( $<1\sigma$ )，距基线仍差 $-0.0189$ ( $3.8\sigma$ )                                         | 证伪 |
| <b>H2</b> 学习率不再匹配 (2e-4 是给未修复模型调的)                                                   | 同配置降到 lr=1e-4                                            | skip: 0.6505 $\rightarrow$ 0.6395 ( $-0.0110$ )；<br>全修: 0.6330 $\rightarrow$ 0.6170 ( $-0.0160$ )<br>—— <b>更低 LR 更差</b> | 证伪 |

$\Rightarrow$  **稳健事实**: 含跳连的配置全部低于基线 ( $0.6170$ – $0.6505$  vs  $0.6655$ )，不含跳连的 fx\_pos 反而高于基线 ( $0.6716$ )。有害的成分是跳连本身，与融合层级、学习率都无关。故 D1/D2 的"修复"在本项目中被**实测否决**——这不是"没修好"，而是"修了确实更差"，因而应当作为一项被拒绝的改动如实记录，而不是当作遗留缺陷。

5.6.14 修复后消融：换了底，以及一次数值发散

在 use\_skip+pos\_enc (fx\_all, 0.6330) 这个底上跑消融时，完成的三项显示**底本身不稳定**:

| 实验                | 结果                           | 性质                                    |
|-------------------|------------------------------|---------------------------------------|
| lgR120_abl_no_emr | 0.6600 (相对底 <b>+0.0271</b> ) | 移除 EMR 大幅 <b>改善</b> ——说明底病态，不是 EMR 有害 |

| 实验                               | 结果                      | 性质 |
|----------------------------------|-------------------------|----|
| <code>lgR120_abl_no_ecsam</code> | 0.4657@ep19 后 <b>发散</b> | 见下 |
| <code>lgR120_abl_no_fpn</code>   | 未跑完即停                   | —  |

`abl_no_ecsam` 的**发散已确证为数值失效，不是塌陷期**：epoch 20 起验证预测**冻结**（OA 精确恒定在 0.36989283961174824），训练 loss 变成精确的 0.0（连续 17 轮），`best.pt` 权重最大绝对值达 **1.26e4**（爆炸；tensor 无 NaN，但输出退化为常量）。**关键在于区分"塌陷"与"发散"**：发散后的指标会精确冻结，看起来像"收敛到一个较差的平台"，极易被误读为模块效应。故

`analysis/fix_attribution.py` 与 `queues/run_queue_fix3.py` 都加了显式检测（loss 连续为 0 / OA 长时间精确不变），并在表中标为**不可引用**，而不是把它当作读数。

**因此消融换了底**（选择理由在跑之前就写定，见 `queues/run_queue_fix3.py`）：底改用 `lgR120_fx_pos`（`pos_enc=True`，0.6716），因为它是修复族里**唯一稳定、且唯一 高于未修复基线**的配置，且不含已被实测否决的跳连。8 个消融变体以 `lgR120_pos_abl_*` 另存命名，**不覆盖旧结果**——旧底上的三项数据仍保留在案，作为"底的病态性"的证据。

**方法论提醒（本条比结论本身更重要）**：修复实验的价值不在于"修好了就该更好"的先验，而在于它把消融从"模块没接线"变成"模块接了线"。若 H1/H2 都不能解释这个负结果，那么**"缺陷导致无差异"这一诊断虽然成立，但"修好缺陷就能提升精度"的推论被实测否定**——这同样是一个可发表的结论，且比前者更有信息量。

数据来源：`results/artifacts/fix_attribution.json`（由 `analysis/fix_attribution.py` 生成，未跑完的实验不做任何判定）。H1/H2 由 `queues/run_queue_fix2.py` 执行，其后在**预先写定的规则**下选定消融基线——规则写在代码里，不是看到结果再挑。

**为什么必须重跑基线**：OneCycle 的收敛轮次由**退火终点**决定（best@49 对应 60 轮、best@109 对应 120 轮），故 60 轮与 120 轮是**两个不同的学习率调度**，其 Kappa 差值混合了"调度变化"与"训练量"两种效应。⇒ 修复归因必须有**同为 120 轮的基线**，并单独建立可比组 **G4-MEM-ROLL-120ep**；`experiments_index.json` 中已写明**禁止**把 G4 与 G2（60ep）相减 当作"预算效应"。

| 阶段 | 实验                                                                                                               | 目的                                                                |
|----|------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| 一  | <code>lgR120_full</code> / <code>lgR120_fx_skip</code> / <code>lgR120_fx_pos</code> / <code>lgR120_fx_all</code> | 修复归因：分别测 D1+D2、D3、以及 三处全修                                         |
| 二  | <code>lgR120_abl_{no_emr,no_ecsam,no_fpn,no_trans,no_adapter,bilinear,trans4l,trans6l}</code>                    | <b>首次可解释的消融</b> ：全部以 <code>use_skip+pos_enc</code> 为底，模块作用不再被缺陷掩盖 |

协议：120 轮 / pt20 / bs8 / lr2e-4，实测 43–59 s/轮（跳连使解码器计算量增加约 10%）。判别门限沿用  $\sigma_{\text{seed}} = 0.0050$ ： $|\Delta| \geq 2\sigma = 0.0100$  记为可分辨。

修复过程中新发现的两处元问题（已修，均影响报告可信度）：

1. 测试集协议此前只覆盖一半结论（详见 §5.6.11 第 4 条）。推论： `rigor.json` 里 "没有某个 tag" 不等于 "它不显著"，必须先确认缓存是否存在、布局是否正确。
2. TOST 此前只有打印、没有产物：判定无法引用、无法复现，新增 tag 也不会自动扩展。已成 `results/artifacts/tost_equivalence.json` 一等产物，并复用 `eval_rigor` 的度量函数（不重复实现，避免口径漂移）。

相关记录： `docs/缺陷修复_20260913.md` ； 队列 `queues/run_queue_fix.py` ； 评测后置链 `queues/run_post_fix.py` 。

5.6.15 修复后消融：首次给出方向可解释的消融表

底 = `lgR120_fx_pos` （ `pos_enc=True` ， 0.6716），同为 120 轮 / pt20 / bs8 / lr2e-4，判别门限  $|\Delta| \geq 2\sigma = 0.0100$ 。全部实现均取自实测，不是预期。

| 变体                         | Kappa         | best@ | $\Delta$ vs 底  | $\Delta/\sigma$ | 判定            |
|----------------------------|---------------|-------|----------------|-----------------|---------------|
| （底： <code>pos_enc</code> ） | <b>0.6716</b> | 96    | —              | —               | 参照            |
| 去掉 Adapter-Scale           | 0.6704        | 97    | −0.0012        | −0.23           | 不可分辨          |
| 去掉 FPN                     | 0.6679        | 90    | −0.0037        | −0.74           | 不可分辨          |
| 去掉 EMR                     | 0.6649        | 94    | −0.0067        | −1.34           | 弱             |
| 双线性替代转置卷积                  | 0.6643        | 110   | −0.0073        | −1.45           | 弱             |
| <b>去掉 Transformer</b>      | 0.6600        | 116   | <b>−0.0116</b> | <b>−2.33</b>    | <b>可分辨</b>    |
| 去掉 ECSAM                   | —             | —     | —              | —               | 训练发散，不可引用（见下） |
| Transformer 2→4 层 / 2→6 层  | 待完成           | —     | —              | —               | —             |

与未修复架构上的同一组消融对照（这是本节的核心）：

| 变体             | 未修复架构（60 轮，底 0.6312） | <code>pos_enc</code> 底（120 轮，底 0.6716） |
|----------------|----------------------|----------------------------------------|
| 去掉 Adapter     | +0.0030（移除反而更好）      | −0.0012                                |
| 去掉 FPN         | +0.0002（移除反而更好）      | −0.0037                                |
| 去掉 EMR         | +0.0043（移除反而更好）      | −0.0067                                |
| 双线性            | +0.0057（移除反而更好）      | −0.0073                                |
| 去掉 Transformer | −0.0010（几乎为零）        | <b>−0.0116（可分辨）</b>                    |

| 变体       | 未修复架构 (60 轮, 底 0.6312) | pos_enc 底 (120 轮, 底 0.6716) |
|----------|------------------------|-----------------------------|
| 去掉 ECSAM | -0.0040 (正常收敛)         | 发散                          |

### 三点结论：

1. 未修复架构上 6 项里有 4 项是"移除反而更好"；pos\_enc 底上全部为负 —— 这是"模块确在起作用"的signature。即：把位置编码这一处缺陷修好后，消融终于从"移不移除都一样"变成了"每个模块都有非负贡献"。
2. 位置编码修复的价值不在表头 Kappa，而在可解释性。它自己只带来 +0.0061 (1.2 $\sigma$ , 弱)，但移除 Transformer 的代价从 -0.0010 (无) 变成 -0.0116 (2.3 $\sigma$ , 可分辨)。机制上说得通：无位置编码时注意力是置换等变的集合算子 (§5.6.4)，本就做不了空间建模，移除它自然无所谓；注入 2D 正弦位置编码后它才能做邻近建模，于是开始承载性能。这正是"缺陷掩盖了模块作用"这一诊断的直接、正向的证据。
3. ECSAM 移除导致的训练发散在两个不同的底上各复现一次 (use\_skip+pos\_enc 底与 pos\_enc 底，均为 loss 连续为 0、验证指标精确冻结、权重最大绝对值爆炸)。而在未修复架构上移除 ECSAM 能正常收敛 (0.6272)。⇒ ECSAM 的作用是"条件性的训练稳定器"，而不是"没有贡献" —— 此前"移除 ECSAM 一致更好"的说法只在未修复架构上成立，不能外推。

### 两个必须同时说清的限定：

- 双线性 vs 转置卷积不可分辨：两次测量符号相反 (未修复底 +0.0057/+1.14 $\sigma$ 、pos\_enc 底 -0.0073/-1.45 $\sigma$ )，都落在噪声内。伪影存在是实测事实，但"换成双线性会提精度"不是。
- "每个模块都有非负贡献" ≠ "修好缺陷就提精度"：底本身 0.6716 相对未修复基线 0.6655 只有 +0.0061 (弱)。模块贡献变为非负，与整体精度是否提升，是两件事。

## 5.7 随机种子噪声底线 (多种子实测)

**方法学必要性：**本项目早期全部比较都基于**单次运行** (seed=42)。文献指出这不足以支持"无差异"结论：GEO-Bench (NeurIPS 2023 D&B) 建议 **≥10 个种子**，并指出 3-5 个种子不足以给出可靠置信区间。


**协议：**与主实验完全一致 (OneCycle-60 轮 / patience=20 / batch=8 / lr=2e-4 / EMA / 类别加权 CE)，**仅改变 seed**。seed 控制模型初始化、DataLoader 打乱顺序与几何增强抽样 (裁剪位置由 epoch\_seed 决定，与 seed 无关)。

| 配置                       | 种子数 | mean   | $\sigma_{\text{seed}}$ | 极差     | 区间               |
|--------------------------|-----|--------|------------------------|--------|------------------|
| 完整模型 MSSACT (P-MEM-ROLL) | 4   | 0.6362 | <b>0.0050</b>          | 0.0094 | [0.6318, 0.6412] |
| DeepLabV3+ (P-MEM-ROLL)  | 3   | 0.6931 | <b>0.0034</b>          | 0.0066 | [0.6895, 0.6961] |

**结论：**完整模型 4 次运行的  $\sigma_{\text{seed}} = 0.0050$ 、极差 0.0094。同管线模块消融的总散布 0.008 仅为种子极差的 0.87 倍——即 换一个随机种子带来的波动，比整套架构改动带来的差异还大。

两个副产品：**seed=42（原基线）**是四个种子中最差的；DeepLabV3+ 的  $\sigma$  更小（0.0034），与"预训练压低初始化方差"一致。

**保留的限定：** $n=4$  时  $\sigma$  本身有不确定性，该数值适用于**量级判断**（差异是  $1\sigma$  还是  $5\sigma$ ），不宜作精确检验。



## 5.8 训练策略对比：裁剪尺度与随机/固定裁剪


| 配置                 | crop | 位置   | 每样本像素 | Kappa  | $\Delta M$ vs 基准               | 秒/轮   | 总时长       |
|--------------------|------|------|-------|--------|--------------------------------|-------|-----------|
| lgR_bs8_full_lr2e4 | 256  | 随机   | 1.00× | 0.6320 | +0.0000 ( $0.00\sigma$ , 不可分辨) | 44 s  | 44.0 min  |
| lgR_c256_center    | 256  | 固定中心 | 1.00× | 0.6128 | -0.0192 ( $3.84\sigma$ , 可分辨)  | 44 s  | 44.0 min  |
| lgR_c384_rand      | 384  | 随机   | 2.25× | 0.6543 | +0.0223 ( $4.46\sigma$ , 可分辨)  | 100 s | 100.0 min |
| lgR_c512_rand      | 512  | 随机   | 4.00× | 0.6524 | +0.0204 ( $4.08\sigma$ , 可分辨)  | 192 s | 192.0 min |

| 对比                 | $\Delta Kappa$ | $\sigma$ 倍数  | 计算代价 | 判读  |
|--------------------|----------------|--------------|------|-----|
| 256 随机 vs 256 固定中心 | -0.0192        | 3.8 $\sigma$ | 同代价  | 可分辨 |
| 384 随机 vs 256 随机   | +0.0223        | 4.5 $\sigma$ | 2.3× | 可分辨 |

| 对比               | $\Delta Kappa$ | $\sigma$ 倍数                   | 计算代价 | 判读  |
|------------------|----------------|-------------------------------|------|-----|
| 512 随机 vs 256 随机 | +0.0199        | <b>4.0<math>\sigma</math></b> | 4.4× | 可分辨 |

#### 判读要点：

1. 本节三个对比的效应量，全部大于 §5.6 的所有模块消融。| $\Delta Kappa$ | 为 0.0199–0.0223 (3.8–4.5 $\sigma$ )；而模块消融全部  $\leq 1.13\sigma$ 。也就是说：在这套模型上，训练策略的收益是可分辨的，模块增删则不可分辨。这对后续工作更有指导意义——**先选对训练策略，再谈架构**。
2. **256 随机 vs 256 固定中心**：两者像素量与尺度完全相同，差异只能归因于“每轮随机位置”这一增强——随机裁剪本身值 **+0.0192**。
3. **256 → 384 → 512**：384 达 0.6543 (+0.0223)，512 为 0.6519 (+0.0199) —— **再放大到 512 无额外收益，代价却从 100 s/轮升到 192 s/轮 (4.4× 于基准)**。故 **384 是更优的工程取舍**：既印证了“过小的尺度没有意义”，也说明**过大的尺度不划算**。
4. 注意 batch 随面积下调 (256<sup>2</sup>:8 / 384<sup>2</sup>:4 / 512<sup>2</sup>:2) 以避免显存溢出，故每轮耗时与总时长必须一并报告——大裁剪的计算代价是**平方级增长**的。



## 5.9 数据量阶梯：容量与数据量的匹配

**协议**：30 轮 / patience=30 (固定预算、不早停) / bs8 / lr2e-4；子集为分层抽样的嵌套样本 (250  $\subset$  500  $\subset$  1000)；**验证集固定为 newsplit2 的 221 张** (与子集大小无关)，故各档 Kappa 可比。

**e50rel / e90rel**：首次达到该次运行自身 k\_max 的 50% / 90% 的轮次。使用相对阈值是因为低数据档的绝对 Kappa 很低 (n250 完整模型上限仅 0.03)，固定阈值 0.4/0.5/0.6 在这些档位**永远不可达**。

**n = 250 张**

| 模型                     | Kappa         | 末轮     | 达自身 50% 上限 | 达 90% |
|------------------------|---------------|--------|------------|-------|
| DeepLabV3+ 预训练 (旁证)    | <b>0.2825</b> | 0.2387 | 24         | 29    |
| U-Net (2.44M)          | <b>0.1915</b> | 0.1915 | 14         | 28    |
| DeepLabV3+ 从零 (39.63M) | <b>0.1762</b> | 0.1762 | 24         | 30    |
| MSSACT-Net w/o ECSAM   | <b>0.1164</b> | 0.1079 | 23         | 29    |
| MSSACT-Net 完整 (6.10M)  | <b>0.0322</b> | 0.0261 | 27         | 28    |

**n = 500 张**


| 模型                     | Kappa         | 末轮     | 达自身 50% 上限 | 达 90% |
|------------------------|---------------|--------|------------|-------|
| DeepLabV3+ 预训练 (旁证)    | <b>0.4928</b> | 0.4928 | 16         | 27    |
| DeepLabV3+ 从零 (39.63M) | <b>0.4393</b> | 0.4393 | 21         | 26    |
| U-Net (2.44M)          | <b>0.4050</b> | 0.4050 | 19         | 28    |
| MSSACT-Net w/o ECSAM   | <b>0.3954</b> | 0.3954 | 19         | 29    |
| MSSACT-Net 完整 (6.10M)  | <b>0.3312</b> | 0.3312 | 25         | 28    |

**n = 1000 张**

| 模型                     | Kappa         | 末轮     | 达自身 50% 上限 | 达 90% |
|------------------------|---------------|--------|------------|-------|
| DeepLabV3+ 预训练 (旁证)    | <b>0.6310</b> | 0.6303 | 13         | 21    |
| MSSACT-Net w/o ECSAM   | <b>0.5234</b> | 0.5234 | 15         | 24    |
| MSSACT-Net 完整 (6.10M)  | <b>0.5085</b> | 0.5085 | 17         | 25    |
| U-Net (2.44M)          | <b>0.4913</b> | 0.4913 | 12         | 20    |
| DeepLabV3+ 从零 (39.63M) | <b>0.4771</b> | 0.4771 | 13         | 21    |

**三点结论：**

- 小数据下"模块更多"反而更差。** n=250 时 U-Net (0.1915) 与 DeepLabV3+ 从零 (0.1762) 都远好于完整模型 (0.0322) 。这与 §5.6 的缺陷分析一致：被移除的 FPN/Transformer/ECSAM 在实现上并未执行其声明的功能，因此在样本稀少时只贡献了**优化难度**而非有效容量。
- w/o ECSAM 在全部三档上都不低于完整模型**，与 §5.6.1 的观察一致（坐标注意力仅占 0.90% 参数）。
- 学习曲线的形态随数据量变化：**n250 的完整模型直到第 27/30 轮才达到自身上限的一半，说明**小数据档在 30 轮预算内仍处于爬升期**。




**局限：**30 轮预算对小数据档偏紧 (e50rel 落在 23–27 轮)，故各档数值只宜用于 "同预算下的相对比较"，**不宜**解读为该模型在该数据量下的能力上限。

5.10 预算攻击：充足预算是否掩盖了模块差异？

**动机：**§5.6"模块无贡献"的结论是在 **60 轮充足预算**下得到的。自然的质疑是：**预算太足**，使各变体都有机会收敛到同一水平，从而掩盖了模块本身的差异。本实验把预算压到 **15 轮**，其余协议不变。

| 模型                     | 参数量     | Kappa (15 轮) | $\Delta$ vs 完整                 |
|------------------------|---------|--------------|--------------------------------|
| DeepLabV3+ 预训练 (旁证)    | 39.635M | 0.6358       | +0.1459 (29.17 $\sigma$ , 可分辨) |
| MSSACT-Net w/o ECSAM   | 6.044M  | 0.5092       | +0.0193 (3.86 $\sigma$ , 可分辨)  |
| MSSACT-Net 完整 (6.10M)  | 6.099M  | 0.4899       | +0.0000 (0.00 $\sigma$ , 不可分辨) |
| U-Net (2.44M)          | 2.443M  | 0.4884       | -0.0015 (0.31 $\sigma$ , 不可分辨) |
| MSSACT-Net w/o EMR     | 6.099M  | 0.4790       | -0.0109 (2.19 $\sigma$ , 可分辨)  |
| DeepLabV3+ 从零 (39.63M) | 39.635M | 0.4682       | -0.0217 (4.33 $\sigma$ , 可分辨)  |

**结论：**压到 15 轮后，模块之间的差异依然很小——完整模型 0.4899、w/o EMR 0.4790、U-Net 0.4884，散布仅 0.0109 (约 2 $\sigma$ )；"预算掩盖模块差异"这一质疑**不成立**。



但本实验揭示了一个跨四组实验一致的模式：在数据或预算受限的四种设置下，移除坐标注意力（ECSAM）都更好（4/4 一致）。这与 §5.6.1 的观察吻合——ECSAM 仅占 0.90% 参数，且被放在编码器深层（位置信息已被 8× 下采样稀释）。

### 5.11 全部效应量的可分辨性总表

把本项目全部"设计选择"的效应量统一折算到  $\sigma_{\text{seed}} = 0.0050$  这一尺度上，即可直接比较哪一类选择真正重要：

| 效应                        | $\Delta Kappa$ | $\sigma$ 倍数   | 判读               |
|---------------------------|----------------|---------------|------------------|
| 预训练主干贡献（阶梯 n1000）         | +0.1539        | $30.78\sigma$ | 可分辨              |
| 预训练主干贡献（阶梯 n250）          | +0.1063        | $21.26\sigma$ | 可分辨              |
| 预训练主干贡献（阶梯 n500）          | +0.0535        | $10.70\sigma$ | 可分辨              |
| 384 vs 256 随机裁剪           | +0.0223        | $4.46\sigma$  | 可分辨              |
| 模块/容量变体 lgR_D3_ch_tiny    | -0.0217        | $4.34\sigma$  | 可分辨              |
| 512 vs 256 随机裁剪           | +0.0204        | $4.08\sigma$  | 可分辨              |
| 随机裁剪 vs 固定中心（256）         | -0.0192        | $3.84\sigma$  | 可分辨              |
| 模块/容量变体 nd_abl_bilinear   | +0.0056        | $1.12\sigma$  | 弱（1–2 $\sigma$ ） |
| 模块/容量变体 lgR_D2_decoder_ca | +0.0055        | $1.10\sigma$  | 弱（1–2 $\sigma$ ） |

| 效应                                             | $\Delta Kappa$ | $\sigma$ 倍数   | 判读                |
|------------------------------------------------|----------------|---------------|-------------------|
| 模块/容量变体 <code>nd_abl_trans4l</code>            | +0.0050        | 1.00 $\sigma$ | 弱 (1-2 $\sigma$ ) |
| 模块/容量变体 <code>lgR_D4_ch_large</code>           | +0.0044        | 0.88 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_no_emr</code>             | +0.0043        | 0.86 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_no_ecsam</code>           | -0.0041        | 0.82 $\sigma$ | 不可分辨              |
| 从零 DeepLabV3+ 39.63M vs 自研 6.10M (主协议)         | +0.0039        | 0.78 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_no_adapter</code>         | +0.0030        | 0.60 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>lgR_D1_join_nofpn_notrans</code> | -0.0028        | 0.56 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_trans6l</code>            | +0.0023        | 0.46 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_no_trans</code>           | -0.0011        | 0.22 $\sigma$ | 不可分辨              |
| 模块/容量变体 <code>nd_abl_no_fpn</code>             | +0.0002        | 0.04 $\sigma$ | 不可分辨              |

这张表是全文最凝练的结论：在被测的全部设计维度中，只有三类效应超过 2 $\sigma$ ——预训练主干、训练策略（随机裁剪与裁剪尺度）、以及通道容量；而全部模块增删 都落在噪声内。

## 6. 关键结论

按"可分辨性"分级，并给出可执行的下一步。

### 6.1 已由实测确立 ( $|\Delta| > 2\sigma_{\text{seed}}$ )

- 预训练主干是本任务上最大的单项杠杆。同一模型仅切换权重初始化，Kappa 相差 +0.054 ~ +0.154 (§5.6.6)。这在实践中意味着：在有限标注预算下，把资源投向可获得预训练特征的骨干，收益远大于自研架构设计。
- 训练策略的收益是可分辨的。随机裁剪值 +0.0192 (3.8 $\sigma$ )；裁剪尺度 256→384 值 +0.0223 (4.5 $\sigma$ )，而 384→512 无额外收益、代价翻倍 (§5.8)。可执行的结论：采用 384<sup>2</sup> 随机裁剪。
- 通道容量确实重要。通道减半 (1.545M) 掉 0.0217 (4.3 $\sigma$ )，且该变体仍保留全部模块 (§5.9)。可执行结论：不要在容量上省钱。
- 数据规模在低数据区是主导因素。n=250 时完整模型几乎学不动 (Kappa 0.0322)，而 U-Net 达 0.1915 (§5.9)。可执行结论：自研模型需要  $\geq 1,000$  张才体现优势。
- 后训练有稳定的小幅收益 (+0.0101 Kappa, §4.3.1)。

### 6.2 已由实测否定或推翻的原有结论

1. **"DeepLabV3+ 显著优于自研模型 (+0.0720) "不成立。** 该比较中 DeepLabV3+ 带 ImageNet 预训练主干；从零对照下两者**不可分辨** ( $\Delta = +0.0039$ ,  $0.78\sigma$ )，而参数量相差 6.5 倍 (§5.6.6)。
2. **"DeepLabV3+ 架构的学习效率更高"被推翻。** 达 Kappa 0.5 所需累计学习量：从零 DeepLabV3+ **75.9%** vs 自研 **59.7%**——**从零条件下它更慢**；原先的 30.3% 完全来自预训练 (§5.2)。
3. **"五个设计模块均无可测量的独立贡献"需要修正表述。** 准确说法是：**这些模块在实现上并未执行其声明的功能** (FPN 的多尺度融合被丢弃、Transformer 无位置编码、解码器无跳连)，因此移除它们没有影响 (§5.6.2–5.6.5)。这是**实现缺陷**，不是"模块设计无效"的证据。
4. **"标签碎片化 (93% 像素在边界) "是错的**，真实边界像素占 **2.4%** (§5.6.8)；且原论证方向相反。

## 6.3 方法学结论 (对后续工作最有价值)

1. **先建立误差底线，再谈差异。**  $\sigma_{\text{seed}} = 0.0050$  使本项目能对每个结论给出 分级 (§5.11)，而不是罗列一堆无法比较的  $\Delta\text{Kappa}$ 。
2. **消融实验必须先验证"模块是否在工作"。** 如果直接做消融而跳过 §5.6 那样的 数值检验，本项目会把"移除无效计算无影响"误读为"模块冗余"——这正是早期 报告的错误来源。
3. **归因必须排除混淆变量。** 预训练混淆事件说明：**只验证自己假设的那个参数** 是不够的 (当时只看了 `weights=`，漏掉了 `weights_backbone=`)。可靠的做法是找**可证伪的观测量** (此处用"新初始化 BN 的 weight 必为 1.0"与"权重逐张量比对官方文件")。

---

## 7. 局限、疏漏与教训

### 7.1 研究区选择的疏漏

早期选用 GF-1 影像 + 内蒙古根河市 (2.4 m GSD)，其类别体系与分辨率不匹配：大量类别在 2.4 m 下光谱与空间不可分，且无公开可核验的逐像素标注。**教训**：数据集选择应由**分类体系的可分性与标注的可核验性**决定，而不是由手头有什么影像决定。

### 7.2 类别体系核对的疏漏

官方约定 0 为 no-data、1–7 为类别，早期实现误将 0 当作背景参与训练与评估，使指标虚高约 0.007–0.009 Kappa。**教训**：类别体系必须以**官方文档**为准逐条核对，不能凭直觉假设。

### 7.3 当前局限 (含 §5.6.11 的全部声明)

1.  $\sigma_{\text{seed}}$  的种子数仅 4 (文献建议  $\geq 10$ ) → 只支持量级判断。

- 2. 等效性检验 (TOST) 已完成: SESOI=0.02 下配对 bootstrap 的 95% CI 半宽  $\delta \approx 0.010 < \text{SESOI}$ , 故"无差异"已有统计等效支持 ( results/artifacts/tost\_equivalence.json ) 。
- 3. 数据集为 LoveDA 单一来源 (0.3 m 航空正射、城市/乡村两类场景) , 结论向其他传感器/分辨率/地域的外推性未验证。
- 4. 未使用预训练特征 (§8.1 列为后续方向) , 故不能回答"自研架构 + 预训练" 的上限。
- 5. 架构缺陷尚未修复: §5.6 的三处缺陷在结论中已如实标注, 但修复后的重评 尚未进行。
- 6. 标签质量上限只有提示性证据 (§5.3 的独立性限定) 。

7.4 质量控制措施 (本次新增)

| 措施                          | 作用                                                           |
|-----------------------------|--------------------------------------------------------------|
| 误差底线 $\sigma_{\text{seed}}$ | 给全部差异提供统一判据                                                  |
| 管线世代隔离                      | 不同数据投递后端的结果禁止跨世代比较                                           |
| 权重级取证                       | 用逐张量比对代替"读代码下结论"                                             |
| 推送前审核                       | 自动检查本机路径、内部语境词、大文件                                           |
| 索引与事实单一来源                   | experiments_index.json / FACTS.json 为唯一数据源, 报告与 README 均由其生成 |
| PDF 内容自检                    | 27 项关键词守卫, 防止报告回退为已否证的结论                                     |

8. 后续工作

8.1 预训练方向 (本次实验中收益最大的方向)

§5.6.6 已量化: 预训练主权重的贡献 (+0.054 ~ +0.154) 远大于任何架构改动。 因此这是后续最值得投入的方向, 具体两条路径:

- (1) 换用预训练主干 把自研 EMR 编码器替换为可获取预训练权重的骨干 (如 ImageNet 预训练的 ResNet / ConvNeXt / Swin) , 保留本项目的 FPN-Transformer-解码器结构。 可回答的问题: "自研架构 + 预训练特征"能否超过"标准架构 + 预训练特征"? (本项目已具备公平对照的全部条件: 同管线、同协议、 $\sigma_{\text{seed}}$  已知。)
- (2) 域内预训练 (自监督或跨区监督) 用 LoveDA 影像本身做预训练, 避免 ImageNet 与遥感影像的域差: - 自监督: MAE / SimCLR / DINO 等在无标注影像上预训练编码器; - 跨区监督: 官方数据集的另一分区 (官方 val 区 1,669 张带标注) 作为 预训练集, 本项目的 1,768 张作为微调集——两者天然不重叠, 无泄漏风险。

**注意：**这两条都需**重新设计数据预算的对照**（预训练用掉的数据不能同时用于 微调），否则会重演"数据量 vs 预训练无法分离"的混淆。

## 8.2 多光谱与高光谱适配（下一个阶段的核心方向）

本项目使用的是 3 波段 RGB。后续计划针对**多光谱（>4 波段）与高光谱**影像设计模型，三个具体方向：

1. **三方向池化：**现有 ECSAM 只做水平/垂直两个**空间**方向的池化。对多光谱数据，应扩展为**光谱维 / 空间维 / 通道维**的三方向池化，使注意力同时感知波段相关性。
2. **模块适配：**现有 FPN 的横向连接假设各层通道数相近，多光谱输入下需重新设计 光谱-空间特征的融合方式；Transformer 的 patch embedding 也需适配波段数。
3. **验证协议：**建立高光谱数据集上的**从零训练基准**与误差底线，以避免重演本项目早期的归因错误。

## 8.3 其他

- ~~补齐 TOST 等效性检验~~ → **已完成** ( $\delta \approx 0.010 < \text{SESOI} = 0.02$ )；下一步是**把测试集协议覆盖到全部消融变体**（见 §5.6.11 第 4 条）。
- **修复 §5.6 的三处缺陷后重评**，届时消融实验才具备可解释性。
- **扩大种子数至  $\geq 10$** ，使  $\sigma_{\text{seed}}$  可用于精确检验。
- **跨传感器/分辨率验证**（含 GF-1 同域微调），检验结论的外推性。

---

# 9. 个人工作与能力体现

## 9.1 数据工程

完成 LoveDA 官方训练区的全量获取与清洗：**MD5 去重**（2,821 张池）、**no-data  $\leq 10\%$  筛选**（剔除 312 张）、**8:1:1 分层划分**，并建立**泄漏防控校验**（三集两两互斥 + test\_clean 与历史训练集零重叠）。实现**预解码 memmap** 数据集，把每张图的训练成本由  $\approx 170$  ms 降到  $\approx 24$  ms。

## 9.2 模型训练与工程

搭建统一训练入口（OneCycle + EMA + 类别加权 CE + Kappa 早停），支持 12 类模型/变体的**同协议对比**。实现**断点续跑队列**（按 history 轮数判定完成）、**OOM 自动降 batch**、**队列互斥与无窗口后台执行**。把 GPU 利用率由 49.9% 提升到 84.3%，同时**零性能损失**（\$5.5）。

## 9.3 实验设计与分析

设计并执行 **7 基线对比 + 8 消融 + 4 架构变体 + 3 档数据阶梯 + 3 组裁剪策略 + 15 轮预算攻击 + 多种子重复**，共 40+ 次独立训练。建立**累计学习量**方法分离调度效应与架构效应（并据此推翻了一条原有结论）。建立**Kappa 归属 (oracle) 分析**量化指标的可见空间。

## 9.4 问题定位与修复

- 发现并证明三处架构实现缺陷（FPN 死支路 / 无跳连 / 无位置编码），全部给出**可复现的数值验证**（输出逐位不变、置换等变至  $7e-07$ ）。
- 发现并更正一处严重的公平性缺陷：`weights=None` 未关闭主干预训练，导致基线被误认为从零训练。用**权重级逐张量比对**取证，并重跑从零对照。
- 发现并更正一处统计错误：边界像素比例  $93\% \rightarrow 2.4\%$ （跨图求差分的缺陷），结论方向随之反转。
- 定位并修复训练基础设施瓶颈（PNG 解码、EMA 实现、进程同步）。

## 9.5 工具与产出

**可复现性基建**：`paths.py` 路径集中（脚本内零绝对路径）、`experiments_index.json` 实验索引（参数量直读张量）、`FACTS.json` 事实单一来源、`verify/pre_push_audit.py` 推送前审核、`report/make_pdf.py` 报告内容自检。**分析工具**：严格性评估（配对 bootstrap / TOST）、Kappa 归属分解、解码器伪影分析（FFT 周期检测）、随机种子噪声底线。**报告与图**：全部图表由 `viz/make_report_figures.py` 从权威数据源生成，**无手改数据**。

# 附录 A：复现指引

## A.1 环境与运行

```
cd loveda                                # 运行目录 = 仓库根
export LDA_DATA_ROOT=<数据根目录>        # 或写入 .env（不入库）
python prep/resplit_filtered.py           # 数据筛选 + 去重 + 划分
python prep/build_fast_dataset.py         # 预解码 memmap（强烈建议）
python prep/build_ladder_memmap.py        # 阶梯子集 memmap（跑阶梯前需停队列）
python queues/run_queue_new.py            # 对比(7) + 消融(8) + 主模型
python queues/run_queue_arch.py          # 架构变体 D1-D4 + 预算攻击 + 数据阶梯
python analysis/eval_rigor.py --infer    # 逐类 IoU / 配对 bootstrap / TOST
python analysis/convergence_amount.py     # 累计学习量（调度 vs 架构）
python analysis/seed_variance.py          #  $\sigma_{seed}$  与可分辨性
python viz/make_report_figures.py         # 全部报告图
python report/build_index.py              # 实验索引（参数量直读张量）
python report/build_facts.py              # 事实汇总  $\rightarrow$  FACTS.json
```

python report/make\_report\_v3.py

# 本报告 HTML

python report/make\_pdf.py

# HTML → PDF (含 27 项内容自检)

python verify/pre\_push\_audit.py

# 推送前审核 (必须通过)

A.2 训练管线世代 (禁止跨世代比较 Kappa)

| 世代         | 数据投递                          | num_workers | 实验前缀                         |
|------------|-------------------------------|-------------|------------------------------|
| P-PNG      | 每样本解码两张 1024 <sup>2</sup> PNG | 0           | nd_* lg_*                    |
| P-MEM-DET  | memmap + 确定性增强                | 8           | lgF_* (✖ 已否决, Kappa -0.0246) |
| P-MEM-ROLL | memmap + 原始增强                 | 0           | lgR_* sd*_*                  |

两代后端差异实测为 **+0.0008** (同配置 0.6320 vs 0.6312) , 故两组结论可**互相印证**, 但**不得混合求统计量**。

附录 B：文件与目录说明

**根目录只保留：** paths.py 与 4 个核心模块、文档、 figures/ (报告图)、 三项权威事实 ( FACTS.json / experiments\_index.json / seed\_variance.json )、 本报告 PDF。

**脚本按用途分 7 个子目录：** queues/ (实验队列)、 analysis/ (评估与分析)、 verify/ (核验与审核)、 prep/ (数据准备)、 viz/ (图表)、 report/ (汇总与报告)、 mapping/ (制图管线)。

**产物集中在 results/：** checkpoints/ (权重与训练历史)、 fast\_dataset/ (memmap)、 consensus\_analysis/ overfit\_diag/ ladder\_eval/ fulltile\_eval/ tta\_eval/ heldout\_test/ (各阶段评估)、 artifacts/ (中间分析产物)。

**本地归档 (不入库)：** \_local\_archive/ (历史数据集与旧图)、 backups/ (覆盖前备份)。

目录整理与路径适配的完整记录见 docs/整理记录\_20260913.md ； 本报告的问题审查与逐条修正见 docs/报告问题研究\_20260913.md 。