

MSSACT-Net 遥感土地覆盖分割

项目报告

数据集：LoveDA 公开基准（0.3 m 航空正射影像，7 类土地覆盖，官方人工标注） **模型：**MSSACT-Net（多尺度自注意力 ConvTransformer，light 配置 6.10M 参数） **代码：**
<https://github.com/eugenewang5425/mssact-loveda>

摘要

本项目在公开基准 **LoveDA** 上系统训练与评估自研的 **MSSACT-Net**，完成了 7 个主流分割模型的对比、8 个模块消融、架构缺陷的数值检验、数据量与裁剪策略的扫描、随机种子噪声底线的实测，以及标签质量上限的专项验证。

一、方法学层面最重要的产出是"误差底线"。 同配置换随机种子 ($n=4$) 得到 $\sigma_{\text{seed}} = 0.0042$ ($n=10$, $df=9$; 95% CI 约 [0.0029, 0.0077])、极差 0.0136。 **两个口径事实：**① 裁剪位置由 `epoch_seed` 决定、与训练 seed 无关，故该 σ 只含初始化与 shuffle 顺序方差、**不含增强路径方差**，是复制噪声的**下界**；② 读数取"各自 val 曲线上的 best"，属**极值统计量**。**适用范围：**val 协议 / 60 轮预算 / P-MEM-ROLL 世代 / 全量数据档。以此为尺度衡量**全部**实验差异后，可分辨的效应屈指可数——这为后续所有结论提供了 统一的判据（详见 §5.11）。

二、预训练主干是本任务上最大的单项杠杆，且它曾造成一处严重误判。 在从零对照下 ($n=10$ vs $n=6$ 复现)，自研 6.10M 优于 DeepLabV3+ 39.63M +0.0082 (组均值差, SE 0.0021) = $3.8\sigma_z$ (此前"不可分辨"仅为单次运行的结果，见 §5.7) ($\Delta = +0.0039$, 0.78σ)。而同一模型仅切换权重初始化，Kappa 即相差 +0.054 ~ +0.154 (§5.6.6)。项目早期因 `weights=None` 未关闭主干预训练，使 DeepLabV3+ 基线实际带着 ImageNet 预训练主干，导致"+0.0720 架构优势"的错误归因——该错误已定位、更正并记录取证过程。

三、消融实验"全部无差异"的真因是实现缺陷，不是模块设计无效。 数值检验证实四处**结构性缺陷**：FPN 的多尺度融合未被使用 (其 1,828,352 个参数 = 全模型 29.98% 不参与前向，实测归零后输出逐位不变)、解码器无跳连 (仅凭 $8\times$ 下采样特征上采样)、Transformer 无位置编码 (置换等变，实测差 $7.15e-07$)、以及 `ecsam[0]` 是死模块 (1,040 个参数，占 0.017%)。8 个消融变体的 Δ 极差 0.0097，小于种子极差 0.0136。四处缺陷已于 2026-09-13 修复并给出可复现证据 (§5.6.12)。

⚠️ 该"平坦"结论依评估协议而变 (§5.6.16)：上句是 **val 协议** (221 张 256² 裁剪) 下的结果。在**整图测试协议** (141 张 1024² 滑窗) 上，同样 8 个变体 **全部为负、4 个可分辨** (如去掉 Transformer $-0.0202 = 4.20\sigma_{\text{diff}}$ 、去掉 ECSAM $-0.0262 = 5.45\sigma_{\text{diff}}$)——即 **val 协议测不出这类差异、整图协议测得出** (§5.6.17 的解读；val 侧的 6 个正 Δ 全部 $\leq 1.2\sigma$ ，噪声没有符号，不宜表述为"两协议测出相反差异")。故"消融平坦"的成因是**架构缺陷 + val 协议不敏感**两项，任何"无差异"表述都必须注明协议。

四、训练策略的收益可分辨，架构模块增删不可分辨。 256 随机裁剪比固定中心裁剪高 **+0.0192** ($3.23\sigma_{\text{diff}}$)；384² 比 256² 高 **+0.0223** ($3.75\sigma_{\text{diff}}$)；而在 **val 协议** 下全部模块消融都 $\leq 1.0\sigma_{\text{diff}}$ (**整图协议** 下 4/8 可分辨，见第三、五条与此处的协议限定)。**杠杆排序：预训练主干 >> 训练策略 > 架构模块**——其中预训练一项的量级 (21–31 σ) 远高于其余，且该排序以满数据档为界有收窄 (§6.1)。

五、基线并非"领先"。 协议内从零对比下，自研 6.10M 与 DeepLabV3+ 39.63M 在主协议不可分辨；在预算受限 (15 轮) 与 1,000 张档位下自研更高；仅在 n=250/500 的极小数据档显著更低——说明自研模型**更依赖数据量**。

六、标签质量仍是评价上限的约束。 6 个模型 (2.4M–39.6M) 逐像素分析：模型间一致率 **0.7589** 显著高于模型与人工标签的 **0.6495**。但 2.4% 的边界像素仅值 +0.016 Kappa，而 78.4% 的内部像素值 +0.29——**聚合指标几乎看不见边界质量** (§5.6.8)。

关键词： 高分辨率遥感；土地覆盖分类；语义分割；自注意力；LoveDA；误差底线；标签质量；消融实验；可复现性

0. 项目状态

项	状态
数据集	LoveDA 官方训练区全量获取 (2,522 张)
数据筛选与划分	✅ no-data $\leq 10\%$ 筛选 → MD5 去重 → 8:1:1 (train 1768 / val 221 / test 221 / test_clean 141)
泄漏校验	✅ 三集两两互斥；test_clean 与历史训练集零重叠 (空间自相关边界 ：MD5 只排除精确重复；LoveDA 瓦片切自同一批正射影像，相邻瓦片像素不重叠但空间强自相关，故绝对 Kappa 乐观、相对比较不受影响——见 §7.3)
主模型训练	✅ full_all_v2 (60 轮) + post_all_v2 (后训练 30 轮)
对比实验 (7 基线)	✅ 完成 (含 协议内从零 DeepLabV3+ 对照)
消融实验 (8 变体)	✅ 完成 (val 协议 下 8 变体 Δ 极差 0.0097 < 种子极差 0.0136； 整图协议 下 4/8 可分辨，见 §5.6.16)

项	状态
架构缺陷数值检验	✅ 完成 (FPN 死支路 / 无跳连 / 无位置编码)
架构变体 D1–D4	✅ 完成 (同管线同协议, 两条管线互证)
随机种子噪声底线	✅ 完成 ($\sigma_{\text{seed}} = 0.0042$)
训练策略 (裁剪尺度/随机)	✅ 完成 (效应 $3.2\text{--}3.8\sigma_{\text{diff}}$, 见 §5.8)
数据量阶梯 (250/500/1000)	✅ 完成
预算攻击 (15 轮)	✅ 完成
DeepLabV3+ 从零对照	✅ 完成 (推翻原 +0.0720 的架构归因)
硬件效率优化	✅ 完成 (GPU 利用率均值 $49.9\% \rightarrow 84.3\%$, 零性能损失, 见 §5.5)
等效性检验 (TOST)	✅ 完成 (<code>results/artifacts/tost_equivalence.json</code>)
四处架构缺陷修复	✅ 已实现并验证 (§5.6.12) ; 性能效果由 lgR120 组测定中
预训练主干 / 域内预训练	📄 后续方向 (见 §8.1)
跨数据集与多光谱适配	📄 后续方向 (见 §8.2)

1. 项目背景

1.1 研究目标

在公开、可复现的遥感基准上，系统评估自研 MSSACT-Net 的：

- 土地覆盖分类精度**——以 Kappa 为主指标 (理由见 §3.3) , 并与主流分割模型横向对比;
- 各设计模块的实际贡献**——通过逐模块消融, 并先用数值手段检验模块是否 **真的在工作** (这一步发现了四处实现缺陷, 见 §5.6; 编号 D1/D2/D3/D5, 其中 **D4 缺号**——原方案里 D4 是一个「容量放大」对照组, 与前三者性质不同, 后被拆到 §5.6.9 的容量变体单独讨论; 编号保留空缺以免与既有记录错位) ;
- 训练策略与数据规模的影响**——裁剪尺度、随机/固定裁剪、数据量阶梯;
- 评价本身的可靠性**——实测随机种子噪声底线 σ_{seed} , 并用它给所有差异定级。

1.2 为什么改用公开数据集

早期工作选用的研究区（内蒙古根河市，GF-1 影像）存在两个不可避免的问题：**类别体系与影像分辨率不匹配**（2.4 m GSD 下大量类别在光谱与空间上不可分），以及**缺少可公开核验的逐像素标注**。

因此改用 **LoveDA**：0.3 m 航空正射影像、7 类、官方人工逐像素标注、有公开基准 与论文可对照。这一更换使全部结论建立在**他人可复现**的数据之上，是本项目最重要 的一次方法论更正。

2. 数据

2.1 官方类别体系（依据官方文档核对）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**; and the **no-data regions were assigned 0 which should be ignored**.

标签值	类别	本项目索引
0	no-data	必须忽略（→255）
1–7	背景/建筑/道路/水域/裸地/森林/农田	0–6

⚠ 早期实现曾把 0（no-data）错误映射为"背景"参与训练与评估，使指标虚高 约 0.007–0.009 Kappa。该缺陷已修复（\$3.4）。

2.2 数据演进三阶段

阶段	数据	标签处理	结论地位
A	957 张（镜像子集）	⚠ 含 no-data 映射缺陷	历史参考
B	2,257 张（官方全量去重）	⚠ 仍含缺陷	中间结果
C	1,768 张（筛选后）	✅ 已修复	结论依据

必须诚实说明的一点：A→B→C 的对比**不是纯粹的数据量效应**。阶段 C 的 1,768 张比阶段 B 的 2,257 张**更少**，却取得更高 Kappa，说明该对比同时 包含了"数据量、标签修复、低质量样本剔除"三项变化，三者**无法分离**。真正的数据量效应由 \$5.9 的阶梯实验（同协议、同管线的 250/500/1000 张）给出。

2.3 筛选与划分（阶段 C）

流程：**no-data 占比 ≤10% 筛选**（剔除 312 张）→ **MD5 去重** → **8:1:1 划分**。


集合	图像数	用途
train	1768	训练
val	221	早停 / 选优（不参与梯度）
test	221	评估
test_clean	141	结论用途（与历史训练集零重叠）

2.4 类别分布（已按实测更正）

划分	图像数	背景占比（最大类）	ignore 占比
训练集	1768	36.09%	0.17%
验证集	221	37.15%	0.13%
干净测试集	141	41.54%	0.40%

验证集逐类占比：背景 37.1%、建筑 9.3%、道路 5.2%、水域 6.4%、裸地 6.4%、森林 17.5%、农田 18.0%


勘误：早期报告称"验证集最大类（背景）占 **45.6%**"，并据此论证 "全预测背景的 OA=45.6%"。实测该值为 **37.15%**（train 36.1%、test_clean 41.5%）。论证方向不变（OA 会被单类支配、故采用 Kappa 选优），但**数值已更正**。



3. 方法与协议

3.1 模型架构

3.1.1 整体数据流



输入为 $256 \times 256 \times 3$ 的 RGB patch，逐级变换如下（括号内为分辨率与通道）：

阶段	输出	说明
Stem	$256^2 \times 32$	3×3 卷积 + BN + ReLU
EMR 编码器 $\times 4$	$256^2 \times 32 \rightarrow 128^2 \times 64 \rightarrow 64^2 \times 128 \rightarrow 32^2 \times 256$	每阶段后 max-pool 下采样（最后一级不下采样）
ECSAM 坐标注意力	同上（仅第 2-4 阶段）	见 §3.1.3
FPN 多尺度融合	$32^2 \times 256$ （仅最深层进入前向）	见 §5.6.2 的缺陷说明
Transformer 编码器	$32^2 \rightarrow 1024 \text{ token} \rightarrow 32^2$	见 §5.6.4 的缺陷说明
解码器（转置卷积 $\times 3$ ）	$64^2 \rightarrow 128^2 \rightarrow 256^2 \times 64$	无跳连，见 §5.6.3
分类头（ 1×1 卷积）	$256^2 \times 7$	逐像素类别 logits

3.1.2 各模块职责

- **EMR (Enhanced Multi-scale Residual)**：两个 3×3 卷积 + 短路连接，构成 残差基本块。作用是逐阶段扩大感受野、提取多尺度空间特征。
- **ECSAM (Enhanced Coordinate Spatial Attention Module)**：坐标注意力（Hou et al., CVPR 2021）。沿水平与垂直方向分别做 1D 池化，得到方向感知的特征向量，经共享 1×1 变换后重加权。其设计意图是编码长程空间位置信息。
- **FPN (Feature Pyramid Network)**：自顶向下把深层语义与浅层细节融合，输出 4 个尺度的特征图。
- **Transformer 编码器 + Adapter-Scale**：对最深层特征做全局自注意力，以捕捉长程上下文；Adapter 是一个低秩 ($d/4$) 残差分支，配合可学习的 `scale_factor` 控制其贡献强度。
- **解码器**：3 次 stride=2 的转置卷积，把 32^2 恢复到 256^2 。

3.1.3 配置与参数量账目

配置	embed_dims	Transformer	参数量
light (本报告主模型)	[32, 64, 128, 256]	2 层 4 头	6.10M
large (D4 实验)	[64, 128, 256, 512]	2 层 4 头	24.237M


本报告主模型 light 配置的**模块参数账目**（直读 checkpoint 张量求和，非估算）：

模块	参数量	占比
FPN	2,484,224	40.73%
Transformer	1,612,609	26.44%
EMR 编码器	1,224,576	20.08%
解码器	721,863	11.84%
ECSAM (坐标注意力)	54,912	0.90%
Stem	960	0.02%

口径说明：以上为 `nn.Parameter` 计数，不含 BatchNorm 的 `running_mean / running_var / num_batches_tracked`。早前版本引用的 6,101,784 是 `state_dict` 总元素数，含 16 层 BN 的 2,640 个 buffer，高估 **0.0433%**，已更正。FPN 与 Transformer 无 BN，其计数不受影响。| 合计 | **6,099,144** | 100% |

两点直接推论：

- 1. **FPN + Transformer 合计占 67.17% 的参数**，但 §5.6 将证明二者在实现上**未执行其声明的功能**。
- 2. **ECSAM (坐标注意力) 仅占 0.90%**——对占比不足 1% 的模块 期待显著增益，在容量意义上本就不合理。



3.2 训练协议 (所有实验一致)

项	设置
优化器	AdamW, lr = 2e-4, weight_decay = 0.02
调度	OneCycleLR, 最大学习率 2e-4, warmup 占 6%, 余弦退火, 总 60 轮
批大小	8 (裁剪 384 ² 时为 4, 512 ² 时为 2, 按面积下调以避免显存溢出)
精度	混合精度 (AMP) + 梯度裁剪 (max-norm = 1.0)
权重平滑	EMA, decay = 0.999, 评估用 EMA 权重
损失	类别加权交叉熵, 权重 $\propto 1/\sqrt{\text{频率}}$ (见下)
早停	验证集 Kappa 连续 20 轮不升则停
数据增强	每轮每图随机裁剪 1 个 patch (位置固定为 epoch_seed 决定); 随机 90° 旋转 $\times 4$ 、水平/垂直翻转

类别权重公式: 设第 c 类像素数为 n_c , 则

$$w_c = \left(\frac{n_c}{N} \right)^{-1/2} / \text{mean}_k \left(\frac{n_k}{N} \right)^{-1/2}$$

即取频率的**负平方根**并归一化到均值为 1。用负平方根而非倒数, 是为了避免 极稀有类 (如道路) 获得过大的权重而使训练不稳定。

EMA 更新公式: 设模型参数为 θ , 影子参数为 θ' , decay 为 λ :

$$\theta' \leftarrow \lambda * \theta' + (1 - \lambda) * \theta \quad (\lambda = 0.999)$$

即影子参数是历史参数的指数滑动平均; 用其评估可显著降低验证指标的抖动。

3.3 评价指标

全部指标在 **255 (no-data)** 像素上屏蔽后计算。

设混淆矩阵 CM ， CM_{ij} = 真值为 i 、预测为 j 的像素数， $N = \sum_{ij} CM_{ij}$ 。

OA (总体精度)

```
OA = sum_i CM_ii / N
```

Kappa (本报告的主指标与选优/早停依据)

```
po = sum_i CM_ii / N                # 观测一致率
pe = sum_i ( row_i * col_i ) / N^2  # 随机一致率
Kappa = (po - pe) / (1 - pe)
```

为什么用 Kappa 而非 OA：LoveDA 背景类占比约 37%，一个"全部预测背景"的 平凡模型即可取得 $OA \approx 0.37$ ，但其 $Kappa = 0$ 。Kappa 扣除了随机一致率，在不平衡数据上不会被单类支配。

F1 / mF1 (按类)

```
precision_i = CM_ii / col_i          # 亦称 UA (用户精度)
recall_i    = CM_ii / row_i          # 亦称 PA (生产者精度)
F1_i        = 2 * precision_i * recall_i / (precision_i + recall_i)
mF1         = mean_i F1_i
```

IoU / mIoU

```
IoU_i = CM_ii / ( row_i + col_i - CM_ii )
mIoU  = mean_i IoU_i
```

数据使用协议：val 仅用于早停与选优（在 `torch.no_grad()` 内评估，不参与 梯度更新）；**全部结论以 test / test_clean 为准。**

误差底线 σ_{seed} （本项目新增）：同配置、同数据、仅换随机种子重复训练，Kappa 的标准差。它给出"差异是否可分辨"的尺度： $|\Delta| < 1\sigma$ 视为不可分辨， $1-2\sigma$ 为弱证据， $> 2\sigma$ 才认为可分辨（详见 §5.7 与 §5.11）。

3.4 no-data 处理与缺陷修复

问题	表现	修复
标签映射缺陷	官方 0 = no-data 被当作"背景"参与训练与评估	REMAP : 0 及一切非 1-7 值 → 255 (ignore) , 评估时屏蔽
低质量样本	部分图像 no-data 占比过高	训练集剔除 no-data > 10% 的图像 (312 张)
评估数据泄漏	早期 val/test 可能与训练集重叠	MD5 去重 + 三集两两互斥校验 + test_clean 隔离

3.5 可复现性设计

- **路径集中**: 全部路径由 `paths.py` 提供, 脚本内**零绝对路径**; 本地数据路径只写在 `.env` (不入库)。
- **管线世代隔离**: 不同数据投递后端 (PNG / memmap) 的训练结果**分别标记**、**禁止跨世代比较 Kappa** (详见附录 A.2)。
- **产物登记**: `experiments_index.json` 登记全部实验 (参数量直读 checkpoint 张量、架构由形状反推、出处指向启动它的队列脚本)。
- **推送前审核**: `verify/pre_push_audit.py` 检查本机路径、内部语境词、大文件与误提交。

4. 实验结果

4.1 阶段 A: 早期实验 (957 张, 含缺陷) — 历史结果

主模型 Kappa **0.4065**, 基线中 DeepLabV3+ 最高 (0.3806)、SegFormer-Lite 最低 (0.1775)。120 轮消融中 w/o Adapter 反而最好 (0.4621)。

本阶段结果不作为结论依据, 原因有三: 数据量不足 (957 张)、标签映射含 no-data 缺陷、且当时的 DeepLabV3+ 基线带预训练主干 (见 §5.6.6)。**该阶段的图已全部撤出本报告** (原图基于上述缺陷数据), 仅保留文字记录。

4.2 阶段 B: 扩大数据 (2,257 张) — 中间结果


主模型 Kappa **0.6155**, 后训练 **0.6239**。相比阶段 A 有大幅提升, 但 **REMAP 缺陷仍未修复**, 故同样不作为结论依据。

4.3 阶段 C: 最终实验 (1,768 张筛选 + 修复) — 结论依据

4.3.1 主模型与后训练

模型	Kappa	OA	说明
full_all_v2 (60 轮)	0.6312	0.7030	主模型
post_all_v2 (+30 轮微调, lr=5e-5)	0.6413	0.7112	在已收敛模型上继续训练

后训练带来 **+0.0101 Kappa** (2.40σ , 属可分辨的小幅提升)。



图中可见两点：① DeepLabV3+ 的**从零版本收敛晚于自研模型**（起势更慢），与 §5.2 的累计学习量分析一致；② 带预训练主干的那条曲线早在第 11 轮即越过 Kappa 0.5——这正是早期报告误判"架构学习效率更高"的来源。


4.3.2 对比实验 (7 个基线)

模型	参数量	Kappa	OA	最优轮/总轮
MSSACT-Net light (自研)	6.10M	0.6312	0.7030	54/60
DeepLabV3+ (从零, 协议内)	39.63M	0.6281	0.7018	60/60
DeepLabV3+ (预训练主干, 旁证 ⚠️ 非协议内)	39.63M	0.6876	0.7497	60/60
FPN-Seg	27.15M	0.6151	0.6912	60/60
FCN	23.72M	0.6144	0.6903	60/60
U-Net	2.44M	0.6054	0.6833	60/60

模型	参数量	Kappa	OA	最优轮/总轮
Swin-Unet-Lite	32.67M	0.5859	0.6693	60/60
PSPNet	13.59M	0.5175	0.6160	60/60
SegFormer-Lite	1.23M	0.3043	0.4441	60/60


分析：



- 协议内（全部从零训练）的公平对比下，DeepLabV3+（39.63M）与自研 6.10M 不可分辨（ $\Delta = +0.0039$, 0.78σ ），而后者参数仅为其 1/6.5。
- 表中 DeepLabV3+ 的预训练版本已明确标注为"旁证 ⚠️ 非协议内"，**不作为基线**。它比从零版高出的 0.06，正是预训练的贡献（\$5.6.6\$）。
- 自研模型以 6.10M 参数达到与 23–27M 级别模型相当的水平。



4.3.3 混淆矩阵与逐类 IoU

MSSACT-Net light (自研)






读图要点：自研模型与 DeepLabV3+（预训练）的混淆**结构相似**——两者的主要 混淆都发生在 **裸地 ↔ 农田/森林** 与 **背景 ↔ 建筑** 之间，说明困难来自 **类间光谱相似性与标注边界模糊**，而非某个模型特有的缺陷。逐类看，DeepLabV3+（预训练）在 7 个类上均更高——但如 §5.6.6 所示，该优势主要来自预训练主干。

4.3.4 消融实验（8 个变体）

变体	Kappa	Δ Kappa vs 完整 (0.6312)	可分辨性
Bilinear-Up（可学习上采样 → 双线性）	0.6369	+0.0057 (0.96 σ _diff, 不可分辨)	
Transformer 2 层 → 4 层	0.6362	+0.0050 (0.84 σ _diff, 不可分辨)	
w/o EMR（改用标准 ResBlock）	0.6355	+0.0043 (0.72 σ _diff, 不可分辨)	
w/o Adapter-Scale	0.6342	+0.0030 (0.51 σ _diff, 不可分辨)	
Transformer 2 层 → 6 层	0.6335	+0.0023 (0.39 σ _diff, 不可分辨)	
w/o FPN（直接用最深层特征）	0.6314	+0.0002 (0.03 σ _diff, 不可分辨)	
w/o Transformer（含 Adapter）	0.6302	-0.0010 (0.17 σ _diff, 不可分辨)	
w/o ECSAM（去掉坐标注意力）	0.6272	-0.0040 (0.67 σ _diff, 不可分辨)	

关键发现：8 个变体的 Δ 极差 0.0097，全部落在 $\pm 1.7\sigma$ _diff 内（val 协议；整图测试协议下同一组变体全部为负、5 个可分辨，见 §5.6.16）——即在统计上 **不可分辨**。其中 5 个变体（含把可学习上采样换成双线性的 Bilinear-Up）**反而略优于完整模型**。



重要限定：这不等于"这些模块没有设计价值"。§5.6 的数值检验证明，其中若干模块**在实现上并未执行其声明的功能**（FPN 的多尺度融合被丢弃、未加位置编码的 Transformer 是置换等变集合算子）。因此本节**的正确解读是 "在 val 协议下移除它们看不出影响"**。

⚠ 该解读必须加两重限定（2026-09-15 审核补）：① **不适用于 ECSAM**——移除它在整图协议下 $-0.0262 = 5.45\sigma_{\text{diff}}$ 可分辨，且在修复后架构上导致训练发散（§5.6.15–5.6.16）；② **不适用于整图协议下的 Transformer**—— $-0.0202 = 4.20\sigma_{\text{diff}}$ 。即"移除无影响"只在 **val 协议 + FPN** 这个交集上成立，不能推广。

4.3.5 模块移除的架构适配说明

消融并非简单删除调用，部分变体需要架构层面的适配：

变体	适配方式
w/o EMR	EMR 残差块 → 标准 ResBlock 替换
w/o ECSAM	前向直接跳过坐标注意力（参数量 -0.055M ）
w/o FPN	跳过 FPN，最深层特征直送 Transformer/解码器
w/o Transformer	移除全局自注意力与 Adapter（参数量 -1.6M ）
w/o Adapter	仅移除 Adapter-Scale（低秩残差 + <code>scale_factor</code> ）
Bilinear-Up	转置卷积 → 双线性插值 + 1×1 卷积

5. 深入分析

5.1 数据规模与标签质量：三项同时变化的混合效应

数据量	主模型 Kappa	同时发生的变化
957 张（阶段 A）	0.4065	原始状态
2,257 张（阶段 B）	0.6155	仅扩数据
1,768 张筛选（阶段 C）	0.6312	扩数据 + 标签修复 + 剔除低质量样本

这三项在阶段 C 是同时发生的，无法分离。特别是阶段 C 的图像数比阶段 B 更少 却更好，直接说明"数据量"不是唯一变量。

若要单独度量数据量效应，必须固定其他一切——这正是 §5.9 阶梯实验的设计：同一管线、同一协议、同一验证集，只改训练集规模（250/500/1000 张）。

少数类是否获益更多？ 阶段 B 的逐类 F1 显示道路 +0.390、水域 +0.385、裸地 +0.324、建筑 +0.255，但**阶段 B 的标签映射仍有缺陷**，其逐类数值只宜 作为趋势参考。阶段 C 的逐类 IoU 见 §4.3.3。

5.2 收敛速度的归因：调度 vs 架构

方法（以及它为什么能分离两者）： OneCycleLR 的学习率轨迹是**解析已知**的——给定 max_lr、总步数 T、warmup 比例，任一时刻的 η 可由公式算出，**与模型无关**。定义**累计学习量**：

$$S(t) = \sum_{\tau \leq t} \eta_{\tau}$$

若两个模型在同一水平上所需的 S 相同，则差异来自架构；若几乎所有模型都在相近的 S 比例处达到同一水平，则说明“第几轮收敛”只是**调度曲线形状的映射**。

⚠ 方法学更正（审核 Q-17）： 在单一共享调度下，上式无法分离任何东西。同一次 60 轮 OneCycle 中 $S(t)/S(T)$ 是 t/T 的**确定单调函数、与模型无关**，故“达 K0.5 累计学习量 59.7%”只是“第 21/60 轮过阈”的**重新参数化**——把轮次乘以一个固定单调函数，不产生新信息，更谈不上把调度效应从架构效应中分离。要分离二者至少需要**不同调度**下的对照（§5.6.14 的 best@49/best@109 恰由退火 终点决定，反而印证了“收敛轮次是调度的函数”这一平凡性）。⇒ **本节降级为描述性对照**：“各模型过阈轮次”，不主张“分离”。

结果（达 Kappa 0.5 所需累计学习量占比；全部为 P-PNG 管线同协议）：

模型	达 K0.5 轮次	累计学习量
DeepLabV3+（预训练主干）	11	30.3%
Swin-Unet	14	39.7%
w/o ECSAM	16	45.7%
MSSACT-light / Trans-4L	21	59.7%
w/o EMR	22	62.2%
DeepLabV3+（从零）	28	75.9%
PSPNet	47	98.2%
SegFormer-Lite	未达到	—


结果解读（描述性；不外推为“学习效率”的架构比较）：

早期报告称“唯一例外是 DeepLabV3+（31.8%），其多尺度空洞卷积结构确实学习效率更高”。**该结论是错的**——31.8% 来自带 **ImageNet 预训练主干**的那一次运行。换成本

项目自己训练的从零版本后，DeepLabV3+ 需要 **75.9%** 的累计学习量，比自研模型的 **59.7%** 还慢。

因此：预训练带来的是早期收敛加速，而非该架构的学习效率优势；在公平的 从零条件下，DeepLabV3+ 的收敛速度**不优于**自研模型。


绝大多数模型（11/16）集中在 40%–76% 区间，支持"第几轮收敛主要由调度曲线决定" 这一判断。



5.3 标签质量上限的专项验证

6 个架构/容量差异极大的模型（2.4M–39.6M）在 test_clean（141 张）上逐像素分析：


判据	数值
平均模型间一致率	0.7589
平均模型-人工标签一致率	0.6495
多数投票共识 vs 人工标签	0.6815



解读：模型之间的互相认同（0.7589）显著高于它们与人工标签的认同（0.6495），说明模型在彼此一致地 偏离人工标注。

必须声明的限定：共识法（Warfield et al., 2004 的 STAPLE 一脉）要求 **各模型的误差相互独立**（Bouix et al., 2007）。本项目 6 个模型**共享训练集、损失函数与训练协议**，误差必然相关，因此共识评估会**偏向同族约定**。故本节结论应视为**提示性证据**，不能单独作为“标签上限已被证实”的依据。更强的证据来自 §5.6.8 的 Kappa 归属分析（与参考标准无关的纯数学量）。

5.4 过拟合诊断



以训练/验证 logits 的预测熵差 $\Delta H = H_{\text{train}} - H_{\text{val}}$ 衡量： ΔH 为负说明模型在训练集上更“自信”（预测更集中）。阶段 A 的主模型 $\Delta H = -0.241$ ，是所测模型中偏离最大的；而 SegFormer-Lite 接近 0（ -0.0003 ）——但那是因为它**几乎没学到东西**（Kappa 0.3043）。

判读要点： ΔH 单独看会误读。它必须与**绝对性能**联合解读： ΔH 大且性能高 = 记忆了训练集； $\Delta H \approx 0$ 且性能低 = 欠拟合。本项目主模型属于前者，与 §5.9 的结论（自研模型更依赖数据量）互相印证。

5.5 训练基础设施与硬件效率优化

5.5.1 问题诊断

训练时 GPU 利用率仅 49.9%，**34.6% 的时间 GPU 完全空闲**。

5.5.2 瓶颈定位

关键判据是**参数量与每轮耗时的无关性**：1.55M 参数（144 s/轮）与 24.237M 参数（121–176 s/轮）耗时接近——说明瓶颈**不在计算**，而在数据侧。

根因：每样本解码**两张 1024² PNG**，却只裁出 256²，**94% 的解码结果被丢弃**；且 `num_workers=0` 时代码在主进程串行解码，GPU 全程等数据。


5.5.3 优化措施（四项）


措施	做法
预解码 memmap	一次性把 1024 ² PNG 解码为 <code>uint8</code> memmap，训练时随机切片

措施	做法
多进程加载	<code>num_workers > 0</code> + <code>persistent_workers</code> + <code>prefetch_factor</code>
EMA 实现优化	改为直接遍历 <code>parameters()</code> ，避免每步构造 <code>state_dict()</code>
损失累积	用张量累加损失，去掉每步 <code>.item()</code> 造成的 GPU-CPU 同步

5.5.4 优化效果

指标	优化前	优化后
GPU 利用率 (均值)	49.9%	84.3%
每轮耗时	144 s	12–15 s
数据阶梯每张图成本	≈170 ms/张	≈24 ms/张





上图右为**后来补测**的数据：切到 memmap 后每轮耗时随参数量单调增长， 正面确认瓶颈已从"数据受限"转为"计算受限"。

5.5.5 零性能损失验证

优化过程中逐项验证，**仅保留不改变训练语义的措施**：

#	措施	结论
1	memmap 预解码	✅ 数据内容与 PNG 路径 逐位一致 (verify/bench_parity.py)
2	EMA 实现重写	✅ 数学等价 (同一滑动平均公式)
3	损失张量累积	✅ 仅去掉同步，数值不变
4	多进程加载	✅ 不影响增强语义
5	~~增强改确定性 generator~~	❌ 已回退 ：导致 Kappa 0.6277 → 0.6031 (-0.0246)
6	~~batch 8 → 16/32~~	❌ 主动放弃 (需重调学习率，破坏可比性；且 batch=32 需 9.16 GB 显存会 OOM)
7	~~学习率/调度再调优~~	❌ 主动放弃 (会破坏与已完成实验的可比性)

回退验证（同配置、同数据、同协议）：

配置	Kappa	每轮耗时
旧管线（原始增强）	0.6277	144 s
确定性增强版	0.6031	12 s
回退版（memmap + 原始增强 + workers=0）	0.6293	14.7 s

结论：回退后性能完全恢复（+0.0016，在噪声内），同时保留约 10 倍加速——加速的真实来源是 memmap 预解码，而非增强或并发改动。

5.6 架构有效性分析：为什么消融实验全部"无差异"

本节是对自研架构的否定性发现，也是本项目最重要的技术结论之一。

四处结构性缺陷（均由可复现的数值实验证实）：

#	缺陷	验证方式	结果
D1	FPN 的多尺度融合是死计算	归零 <code>lateral_convs[0..2]</code> ；把整个 FPN 换成"仅第 4 支路"的等价算子	两次输出差恰好 0.0（逐位相同）
D2	解码器无跳连	前向路径 + 分辨率链追踪 + 边缘密度/FFT 实测	高分辨率特征从未到达输出；预测边缘密度达标签 4.56×，且周期 k=8 功率超额 1.66×
D3	Transformer 无位置编码	置换 token 后按逆置换还原	差 7.15e-07 → 置换等变，无空间感知
D5	<code>ecsam[0]</code> 是死模块	构造时 4 个阶段全建，前向条件是 <code>i > 0</code> ；查各张量 <code>.grad</code>	第 0 个恒不执行，其 7 个张量的 <code>.grad</code> is None；1,040 个参数（0.017%）

5.6.1 参数账目

见表 §3.1.3。关键结论：FPN 的 1,828,352 个参数（真实参数的 29.98%）不参与前向，实际参与前向的有效参数仅 4,270,792（70.02%）；另有 `ecsam[0]` 的 1,040 个参数（0.017%）同样不参与前向。（更正说明：此前记 29.96% / 4,273,432 / 70.04%，分母误用了含 BN buffer 的 `state_dict` 总数 6,101,784；以真实参数 6,099,144 为分母的正确值为上述数字。）

5.6.2 D1：FPN 的多尺度融合未被使用

`MSSACTNet.forward` 只取 `fpn_features[-1]`；而 `FPN.forward` 的自顶向下融合循环写入索引 `i-1`（即 2/1/0），最深层 `laterals[3]` 从未被融合增强。两者叠加的结果：`laterals[0..2]` 及其对应的 `fpn_convs[0..2]` 算完就被丢弃。

因此"w/o FPN"消融的真实含义是：移除"最深尺度上的一个 1×1 卷积 + 一个 3×3 卷积，外加 3 条被丢弃的支路"。

这不是"FPN 冗余"的证据，而是"这个 FPN 没有在工作"的证据。前者是多尺度融合的一般性结论，后者是本实现的缺陷结论——科学含义完全不同。

5.6.3 D2：解码器无跳连 → 细节为"合成"而非"测量"，并伴生棋盘伪影

必须精确表述：三次转置卷积上采样**能够**产生高频结构（转置卷积可学习上采样核），因此**不能说**"输出被限制在 8 像素粒度"。正确表述是：**没有任何通路让高频的输入 证据到达输出**——输出中的细节是解码器**合成的**，而非在高分辨率上**测量**到的。


实测（逐图 2D 计算，有效相邻像素对 2.94×10^8 ）：

模型	边缘密度	相对标签	周期超额比峰值
标签（参照）	0.00771	1.000	—
MSSACT-Net 6.10M	0.03516	4.563	k=8: 1.66×
DeepLabV3+ 39.63M	0.00884	1.147	无
U-Net 2.4M	0.02139	2.776	k=16: 1.17×

所有模型都过度碎裂（1.15×–4.56×），而 **MSSACT-Net 最严重（4.56×）**。且其伪影**具有周期性**：水平边缘图的 FFT 在周期 **k=8** 附近功率占比为标签的 **1.66 倍**，而 8 正是解码器（ $32^2 \rightarrow 256^2$ ，三次 stride-2 转置卷积）的总上采样倍数——这与堆叠转置卷积的**棋盘伪影**机制一致。

可证伪的预测：若伪影确由转置卷积造成，则 `nd_abl_bilinear`（双线性替代 转置卷积）应同时具备更低的边缘密度与更小的 k=8 超额。该变体的实测 Kappa **确实更高**（0.6369 vs 0.6312，**+0.0057**），与预测方向一致。

⚠ 该"方向一致"在换底后不再稳健（2026-09-14 补记）：在 `pos_enc` 底（0.6716）上，双线性为 **0.6643 = -0.0073 (-1.5σ)**，即**符号翻转**。两次测量分别是 +0.0057 (+1.14σ) 与 -0.0073 (-1.45σ)，**都落在噪声内且方向相反** ⇒ 正确结论是**"转置卷积 vs 双线性在本项目分辨力下不可分辨"**，**不能说"双线性更好"**。（伪影**存在**这一事实是实测的；但"换成双线性会提精度"不是。这两件事必须分开陈述。）



5.6.4 D3: Transformer 无位置编码

`TransformerEncoder.forward` 摊平为 token 后未插入任何位置信息，而 `nn.TransformerEncoderLayer` 不自带位置编码（不同于 ViT）。自注意力本身是 置换等变的：对置换矩阵 P ， $A = \text{softmax}(QK^{\top} / \sqrt{d}) \rightarrow PA^{\top} P^{\top}$ 。

数值验证：随机置换 64 个 token，把输出按逆置换还原，最大绝对差 **7.153e-07**（浮点噪声量级）→ 模块对 token 顺序完全等价。

三点如实限定：

1. **不等价于"完全无用"**：输入 token 来自卷积特征，其内容本身位置相关；且零填充/边界可充当隐式位置锚点（CPVT/PEG 一脉的论证）。
2. **但无法完成基于空间邻近的上下文建模**——而"长程空间上下文"正是分割网络中 全局注意力的标准用途。这是**机制性降级**。
3. **量级参照**：位置编码并非可有可无——移除 DeiT-tiny 的位置编码使 ImageNet 精度由 72.2% 降至 68.2%。

5.6.5 与消融结果的对应（机制解释）

变体	实测 $\Delta Kappa$	机制解释
w/o FPN	+0.0002 (0.03 σ_{diff} , 不可分辨)	FPN 支路 0-2 是死计算 (§5.6.2)
w/o Transformer	-0.0010 (0.17 σ_{diff} , 不可分辨)	置换等变集合算子 (§5.6.4)
w/o ECSAM	-0.0040 (0.67 σ_{diff} , 不可分辨)	仅占 0.90% 参数

变体	实测 Δ Kappa	机制解释
w/o Adapter	+0.0030 ($0.51\sigma_{\text{diff}}$, 不可分辨)	仅 33K 参数 (0.54%)
Bilinear-Up	+0.0057 ($0.96\sigma_{\text{diff}}$, 不可分辨)	消除转置卷积棋盘伪影 (§5.6.3)

关键推论：没有一个消融变体削弱了它声称削弱的功能——对应功能在实现中本就 不存在 (FPN) 或不可用 (Transformer 的位置感知)。故这一组消融**不能**作为 "模块有效性"的证据，它衡量的是"移除无效计算的影响"。


5.6.6 基线为何领先？——从零对照推翻了本节的原始结论

设置	预训练主干	从零训练	预训练贡献
主数据集 60 轮	—	0.6359	—
阶梯 n250	0.2825	0.1762	+0.1063
阶梯 n500	0.4928	0.4393	+0.0535
阶梯 n1000	0.6310	0.4771	+0.1539

主数据集 (60 轮, 双方均从零)：自研 6.10M **0.6320** vs DeepLabV3+ 39.63M **0.6359**, $\Delta = +0.0039$ ($0.78\sigma \rightarrow$ 不可分辨)。

修正后的结论：

1. **从零训练的公平对比下，自研 6.10M 与 DeepLabV3+ 39.63M 不可分辨** ($\Delta = +0.0039$, 0.78σ)，而后者参数是前者的 **6.5 倍**。原报告"DeepLabV3+ 显著优于自研 (+0.0720)"的表述**不成立**：那 0.0720 中**约九成以上来自预训练主干**（按可加性点算术为 $(0.0720 - 0.0039)/0.0720 \approx 95\%$ ，但两项各自都带 $\sqrt{2}\sigma \approx 0.007$ 的不确定性，故不给精确百分数——审核 Q-04）。
2. **预训练主干是本任务上最大的单项杠杆**：同一模型仅切换权重初始化，贡献 **+0.054 ~ +0.154** Kappa（阶梯档；满数据档收窄至约 +0.05~+0.06，见 §6.1）。作为对照，val 协议下全部模块消融 $\leq 1.00\sigma_{\text{diff}}$ (≈ 0.0059)，裁剪策略为 0.0199–0.0223。**杠杆排序：换主干权重 $\gg$ 改训练策略 $>$ 增删模块。**



核验更正 (取证过程) : `weights=None` 并不足以关闭主干预训练。torchvision 的 `deeplabv3_resnet50` 有两个互相独立的权重参数: `weights` (整体/分割头) 与 `weights_backbone` (主干), 后者默认即 `ResNet50_Weights.IMAGENET1K_V1`。

权重级取证 (与该权重的官方文件逐张量比对) :

构造方式	与官方权重相同的张量	相同参数量占比
<code>pretrained_backbone=True</code>	264 / 265	23,551,744 / 23,561,152 = 100.0%
<code>pretrained_backbone=False</code>	0 / 265	0.0%

(唯一不同者是 `conv1`, 因输入改为 3 通道而被替换。) 该预训练覆盖了该模型 **59.4%** 的参数; 其来源是 PyTorch 官方在 **ImageNet-1K** (1000 个自然图像类) 上训练的 ResNet-50, 官方指标 $\text{acc}@1 = 76.13\%$ 。

行为级取证: 若该参数不生效, 两次运行应当统计一致; 而实测两者相差 $+0.054 \sim +0.154$ Kappa。参数确实在起作用。

5.6.7 通道-空间容量比

配置	最深特征	元素数	输入元素数	比值
light [32, 64, 128, 256]	$256 \times 32 \times 32$	262,144	196,608	1.33×
large [64, 128, 256, 512]	$512 \times 32 \times 32$	524,288	196,608	2.67×

即**最深特征图的标量数量超过输入图像本身** (large 达 2.67 倍), 而这些表征最终被压缩回 256^2 输出, 其中还有 29.98% 的参数不参与前向。此处**并非** transformer 的 秩亏问题 (token 数 $N=1024 > d_{\text{model}}$), 而是**空间侧信息量与通道侧容量的失衡**。


5.6.8 边界质量为何在聚合指标上不可见


距类边界	像素占比	共识 vs 标签	模型间分歧
0 (边界像素)	2.36%	0.4577	0.2881
1-2 px	5.34%	0.4891	0.2877
3-4 px	5.17%	0.5327	0.2847
5-8 px	8.75%	0.5882	0.2789
>8 px (内部)	78.39%	0.7294	0.2294

Kappa 归属上限 (oracle 作弊实验) :

模型	完美解决边界	Δ 边界	完美解决内部	Δ 内部
MSSACT-Net	0.5936	+0.0161	0.8700	+0.2925
DeepLabV3+	0.6654	+0.0159	0.8800	+0.2306

完美预测全部边界像素 (2.36%) 最多换来 +0.016 Kappa; 内部像素 (78.39%) 值 +0.23 ~ +0.29。 因此任何**面向边界锐化**的模块在聚合 Kappa 上的可见空间被限制在 ≈ 0.016 以内——与观测到的消融散布 0.008 同量级。





勘误：早期报告称"93.0% 像素在类边界上"，并据此得出"标签碎片化"与"越纯净区域模型越不同意标签"两条结论。经复核，原实现把标签批次按 (N, H, W) 三维数组沿 axis=0 求差分，跨图像的像素差被误判为类边界，故得出虚高比例。改为逐图 2D、且仅统计两个不同有效类别之间的相邻像素后，真实边界比例为 **2.4%**，结论方向亦反转（准确率随距边界距离单调上升）。

5.6.9 架构变体实测结果（两条管线互证）

管线	变体	参数量	Kappa	相对基线
P-MEM-ROLL	完整模型	6.099M	0.6320	—
	D1 联合消融（-FPN -Trans -Adapter）	2.002M	0.6293	-0.0027
	D2 解码器坐标注意力	6.112M	0.6375	+0.0055
	D3 超轻量通道	1.545M	0.6103	-0.0217
	D4 大容量通道	24.237M	0.6365	+0.0045
P-PNG	完整模型	6.099M	0.6312	—
	D1 联合消融	2.002M	0.6277	-0.0035
	D3 超轻量通道	1.545M	0.6119	-0.0193

三条读表要点：

1. 移除 **67.2%** 的参数只损失 **~0.003**（两条管线分别 -0.0027 / -0.0035，互证）。

2. 把坐标注意力移到解码器 (D2) 反而最好 (+0.0055 / +0.0029) , 与 "注意力在上采样路径上才有效"的文献结论一致。
3. 容量确有作用: D3 (通道减半) 显著下降 (−0.0217 / −0.0193, 约 4σ) , 而 D3 仍保留全部模块——所以"模块不重要"**不等于**"容量不重要"。精确表述是: 在 val 协议下, 占参数 67.14% 的两个模块无可测量贡献, 而通道宽度才是性能来源。(收窄: 在 test_clean 图像上 (整图或 4 角裁剪均可) Transformer 的贡献为 −0.0202 = $4.20\sigma_{\text{diff}}$; FPN 不可分辨 (−0.0064 = $1.33\sigma_{\text{diff}}$) ; 见 §5.6.16–5.6.17。)

5.6.10 可验证的修复路径

优先级	修复	预期效果	状态
P0	FPN 改为真正使用多尺度输出 (解码器接收全部 4 层)	恢复多尺度融合语义; 死支路变活	✅ 已实现 (use_skip=True , 29.99% 死参数 → 0.016%)
P0	解码器加入 encoder→decoder 跳连	修正 §5.6.3 的粒度瓶颈	⚠️ 已否决: 单独 −0.0150 (3σ) , 合并 −0.0325; 两个候选机制 (256 ² 融合、学习率) 均证伪
P1	Transformer 加入位置编码 (2D sincos)	恢复空间邻近建模能力	弱正向: +0.0061 ($1.03\sigma_{\text{diff}}$) ; 置换等变性已被打破 (9.5e-07 → 1.9)
P1	重新定义消融语义: 先修实现, 再评估"模块是否有效"	使消融结论可解释	换底为 lgR120_pos_abl_* (底 = pos_enc) ; 旧底因数值发散弃用
P2	容量重新配比, 修正 2.67× 容量膨胀	参数效率	🟡 未做
P3	ecsam_stage0 是否默认启用	使死参数归零	🟡 优先级低 (仅 0.017% 死参数)

这张表的教训值得单独记下: P0 的两项 (跳连、FPN 多尺度) 当初排在最前, 部分依据是 "DeepLabV3+ 领先 +0.0720, 因为它有低层跳连而本模型没有"这一归因。该归因后被 两次推翻 (预训练主干混淆; 从零对照 +0.0039 = $0.66\sigma_{\text{diff}}$) 。一条被推翻的归因, 曾驱动出一项实测有害的改动。而 §5.6.3 自己的证据当时已指向 双线性上采样 (棋盘伪影源自堆叠转置卷积, 且 nd_abl_bilinear 是全部消融中最好的 变体) 。应当以本项目的直接证据为准, 而不是类比外部模型。

5.6.11 本节局限

1. σ_{seed} 的种子数仅 4 (文献建议 ≥ 10) , 故适用于量级判断而非精确检验。
2. 等效性检验 (TOST) 已完成并落盘: analysis/tost_equivalence.py → results/artifacts/tost_equivalence.json , SESOI = 0.02 (预指定) 。实测配对 bootstrap 的 95% CI 半宽 $\delta \approx 0.010$ (如 nd_unet vs full_all_v2 为 [−0.0532, −0.0318]) , 小于 SESOI。
- ⚠️ 表述限定 (审核 Q-27) : SESOI = 0.02 意味着 TOST 只能排除 ≥ 0.02 的差异, 而全文讨论

的是 0.005–0.01 量级的差异——等效界限宽于感兴趣的效应量 2–4 倍时，TOST 通过**不能为**"这些小差异不存在"背书，只能说明"没有 0.02 级以上的差异"。若需支持 0.01 级的等效声明，须把 SESOI 预指定为 0.01 并重算。关键是**配对设计**：两个模型跑同一批图， Δ 的方差远小于各自 Kappa 的方差。尚须区分两套误差模型——**种子层**（换种子重训差异还在吗，误差 $\sqrt{2 \cdot \sigma_{\text{seed}}} \approx 0.010$ ）与**测试集层**（取样了哪些图，误差 ≈ 0.011 ）；两者量级接近但回答不同问题，不合并。

3. 缺陷检验在 **light** 配置上完成；大配置结构相同、结论可直接推广，但未复跑。

4. 分带与 Kappa 归属基于**已缓存的 6 个模型预测**。**原因已查明**：预测缓存

`results/consensus_analysis/pred_{tag}.npz` 存在两种不兼容布局（旧 $564 \times 256 \times 256$ / 新 $141 \times 1024 \times 1024$ ），`eval_rigor` 遇形状不符会**静默跳过**，导致 G1 的 8 个消融、`lg_D1..D4`、`lgR_D1..D4`、`nd_pspnet`、`nd_segformer` 等**从未进入测试集协议**——即报告此前关于消融的结论只有 val Kappa 单一来源，缺测试集侧独立证据。修复：`queues/run_post_fix.py` 对 44 个 tag 做全量重推理（覆盖前自动备份 consensus 目录），逐带分解与 TOST 随之覆盖全部结论。**该步在 lgR120 组训练结束后执行。**

5.6.12 缺陷修复：向后兼容实现与验证 (2026-09-13)

修复原则：只加开关，不改默认。 三个新参数默认值 == 修复前行为，故既有 103 个实验的 checkpoint 仍能以 `strict=True` 加载、既有结论仍可复现。

开关	作用	修复	参数变化
<code>use_skip=True</code>	解码器逐级接入主干同分辨率特征；有 FPN 时接入 FPN 四级输出 （死支路变活，同时修好 D1），无 FPN 时接入编码器浅三层	D1+D2	6.099M $\rightarrow$ 6.464M (+5.99%)
<code>pos_enc=True</code>	Transformer 注入 2D 正弦位置编码（dim 通道对半分为行/列，每半内再对半为 sin/cos）	D3	不变
<code>ecsam_stage0=True</code>	第 0 阶段也应用 ECSAM	D5	不变（本轮未启用）

修复的验证证据（五项全部通过）：

验证项	结果
默认路径 逐位一致	默认配置加载旧权重成功；新旧输出最大逐元素差 0.000e+00 （不是"很小"）
键集合一致	<code>mssact_light()</code> 与既有 checkpoint 键集合完全相同
置换等变性被打破	残差 $9.537\text{e-}07 \rightarrow$ 1.821e+00 （放大约 190 万倍）
梯度可达性	基线无梯度参数 29.99% $\rightarrow$ 打开 <code>use_skip</code> 后仅剩 <code>ecsam[0]</code> 的 0.016%
组合路径	10 种消融组合 $\times$ 跳连（含 bilinear / no_fpn / no_trans / trans4l / trans6l）输出与梯度完整性全部通过

诚实限定：以上验证的是**修复实现的正确性**（缺陷确已消除、既有行为未被破坏），**不是**修复的性能效果。

5.6.13 修复的性能效果是负面的（第一轮实测）

修复在当前协议下没有带来收益，全修反而明显更差。四个实验同为 120 轮 / pt20 / bs8 / lr2e-4, $\sigma_{\text{seed}} = 0.0050$:

实验	修复内容	Kappa	best@	Δ vs 基线	判定
lgR120_full	未修复（基线）	0.6655	91	—	参照
lgR120_fx_pos	D3 位置编码	0.6716	96	+0.0061	弱 ($1.03\sigma_{\text{diff}}$)
lgR120_fx_skip	D1+D2 跳连	0.6505	114	-0.0150	可分辨 (3σ)
lgR120_fx_all	三处全修	0.6330	62	-0.0325	可分辨

三点必须同时陈述：

1. **两项修复合起来比任何单项都差得多** (-0.0325 vs -0.0150 / $+0.0061$)，即**非加性**——说明另有原因，不能简单读作"修复有害"。
2. **过拟合假设已被推翻**。fx_all 的训练 loss 是四者中最高的 (0.7237 vs 基线 0.6269)，fx_skip 次之 (0.6734)。训练集拟合更差、验证也更差 $\Rightarrow$ 是欠拟合 / 优化困难，不是过拟合。训练 loss 偏高又叠加了容量，指向**优化/条件数问题**。
3. **两个假设都已检验，且都被证伪**（各为单变量实验）：

假设	检验	结果	判定
H1 256 ² 全分辨率融合有害（_fuse 把主干最浅层直接接到输出，并让 FPN 三条全分辨率 3×3 支路首次进入梯度通路）	skip_stages=(1,2)，只融合 128 ² /64 ²	0.6466，与全融合的 0.6505 仅差 -0.0039 ($<1\sigma$)，距基线仍差 -0.0189 (3.8σ)	证伪
H2 学习率不再匹配（2e-4 是给未修复模型调的）	同配置降到 lr=1e-4	skip: 0.6505 $\rightarrow$ 0.6395 (-0.0110)； 全修: 0.6330 $\rightarrow$ 0.6170 (-0.0160) —— 更低 LR 更差	证伪

$\Rightarrow$ **稳健事实：**含跳连的配置全部低于基线 (0.6170 – 0.6505 vs 0.6655)，不含跳连的 fx_pos 反而高于基线 (0.6716)。**有害的成分是跳连本身，与融合层级、学习率都无关。**故 D1/D2 的"修复"在本项目中被**实测否决**——这不是"没修好"，而是"修了确实更差"，因而应当作为一项被拒绝的改动如实记录，而不是当作遗留缺陷。

5.6.14 修复后消融：换了底，以及一次数值发散

在 `use_skip+pos_enc` (`fx_all`, 0.6330) 这个底上跑消融时, 完成的三项显示**底本身不稳定**:

实验	结果	性质
<code>lgR120_abl_no_emr</code>	0.6600 (相对底 +0.0271)	移除 EMR 大幅 改善 ——说明底病态, 不是 EMR 有害
<code>lgR120_abl_no_ecsam</code>	0.4657@ep19 后 发散	见下
<code>lgR120_abl_no_fpn</code>	未跑完即停	—

`abl_no_ecsam` 的**发散已确证为数值失效, 不是塌陷期**: epoch 20 起验证预测**冻结** (OA 精确恒定在 0.36989283961174824), 训练 loss 变成精确的 0.0 (连续 17 轮), `best.pt` 权重最大绝对值达 **1.26e4** (爆炸; tensor 无 NaN, 但输出退化为常量)。 **关键在于区分"塌陷"与"发散"**: 发散后的指标会精确冻结, 看起来像"收敛到一个较差的平台", 极易被误读为模块效应。故 `analysis/fix_attribution.py` 与 `queues/run_queue_fix3.py` 都加了显式检测 (loss 连续为 0 / OA 长时间精确不变), 并在表中标为**不可引用**, 而不是把它当作读数。

因此消融换了底 (选择理由在跑之前就写定, 见 `queues/run_queue_fix3.py`): 底改用 `lgR120_fx_pos` (`pos_enc=True`, 0.6716), 因为它是修复族里**唯一稳定、且唯一 高于未修复基线**的配置, 且不含已被实测否决的跳连。8 个消融变体以 `lgR120_pos_abl_*` 另存命名, **不覆盖旧结果**——旧底上的三项数据仍保留在案, 作为"底的病态性"的证据。

方法论提醒 (本条比结论本身更重要): 修复实验的价值不在于"修好了就该更好"的先验, 而在于它把消融从"模块没接线"变成"模块接了线"。若 H1/H2 都不能解释这个负结果, 那么**"缺陷导致无差异"这一诊断虽然成立, 但"修好缺陷就能提升精度"的推论被实测否定**——这同样是一个可发表的结论, 且比前者更有信息量。

数据来源: `results/artifacts/fix_attribution.json` (由 `analysis/fix_attribution.py` 生成, 未跑完的实验不做任何判定)。H1/H2 由 `queues/run_queue_fix2.py` 执行, 其后在**预先写定的规则**下选定消融基线——规则写在代码里, 不是看到结果再挑。

为什么必须重跑基线: OneCycle 的收敛轮次由**退火终点**决定 (`best@49` 对应 60 轮、`best@109` 对应 120 轮), 故 60 轮与 120 轮是**两个不同的学习率调度**, 其 Kappa 差值混合了 "调度变化"与"训练量"两种效应。⇒ 修复归因必须有**同为 120 轮的基线**, 并单独建立可比组 **G4-MEM-ROLL-120ep**; `experiments_index.json` 中已写明**禁止**把 G4 与 G2 (60ep) 相减 当作"预算效应"。

阶段	实验	目的
一	<code>lgR120_full</code> / <code>lgR120_fx_skip</code> / <code>lgR120_fx_pos</code> / <code>lgR120_fx_all</code>	修复归因: 分别测 D1+D2、D3、以及三处全修
二	<code>lgR120_abl_{no_emr,no_ecsam,no_fpn,no_trans,no_adapter,bilinear,trans4l,trans6l}</code>	首次可解释的消融 : 全部以

阶段	实验	目的
		<code>use_skip+pos_enc</code> 为底，模块作用不再被缺陷掩盖

协议：120 轮 / pt20 / bs8 / lr2e-4，实测 43–59 s/轮（跳连使解码器计算量增加约 10%）。**判别门限（2026-09-15 审核修正）**：本书的比较均为**两单次运行之差**，其标准差为 $\sqrt{2} \cdot \sigma_{\text{seed}} = \mathbf{0.0059}$ （val 协议， σ 已扩到 $n=10$ ），故 $|\Delta| \geq 2\sqrt{2} \cdot \sigma = \mathbf{0.0119}$ 才记为可分辨。此前误用 $2\sigma_{\text{seed}} = 0.0100$ （相当于差值分布的 1.41σ ，偏松 41%）。

修复过程中新发现的两处元问题（已修，均影响报告可信度）：

- 测试集协议此前只覆盖一半结论**（详见 §5.6.11 第 4 条）。**推论**：`rigor.json` 里 "没有某个 tag" 不等于 "它不显著"，必须先确认缓存是否存在、布局是否正确。
- TOST 此前只有打印、没有产物**：判定无法引用、无法复现，新增 tag 也不会自动扩展。已成 `results/artifacts/tost_equivalence.json` 一等产物，并复用 `eval_rigor` 的度量函数（不重复实现，避免口径漂移）。

相关记录：`docs/缺陷修复_20260913.md`；队列 `queues/run_queue_fix.py`；评测后置链 `queues/run_post_fix.py`。

5.6.15 修复后消融：首次给出方向可解释的消融表

底 = `lgR120_fx_pos`（`pos_enc=True`，0.6716），同为 120 轮 / pt20 / bs8 / lr2e-4，判别门限 $|\Delta| \geq 2\sigma = 0.0100$ 。**全部实现均取自实测，不是预期。**

全部 8 个变体已完成（底 = `lgR120_fx_pos`，0.6716）：

变体	Kappa	best@	Δ vs 底	Δ/σ	判定
（底： <code>pos_enc</code> ）	0.6716	96	—	—	参照
Transformer 2→4 层	0.6728	113	+0.0012	+0.23	不可分辨
去掉 Adapter-Scale	0.6704	97	−0.0012	−0.23	不可分辨
Transformer 2→6 层	0.6704	113	−0.0012	−0.23	不可分辨
去掉 FPN	0.6679	90	−0.0037	−0.74	不可分辨
去掉 EMR	0.6649	94	−0.0067	−1.34	弱
双线性替代转置卷积	0.6643	110	−0.0073	−1.45	弱
去掉 Transformer	0.6600	116	−0.0116	−2.33	可分辨

变体	Kappa	best@	Δ vs 底	Δ/σ	判定
去掉 ECSAM	—	—	—	—	训练发散，不可引用（见下）

即：修复后架构上，7 个可读变体无一为正、1 项为弱负（去 Transformer $-0.0116 = 1.95\sigma_{\text{diff}}$ ，按本报告自己的 $\sqrt{2}\sigma$ 口径未达 2σ 可分辨）；其余全部落在 $\pm 1.0\sigma_{\text{diff}}$ 内。加深 Transformer 到 4/6 层没有收益 ($\pm 0.0012 = 0.20\sigma_{\text{diff}}$) $\Rightarrow$ 它的贡献在 2 层就已饱和，回到 §5.6.6 的结论：性能来源是密集卷积的通道宽度，而不是注意力深度。

与未修复架构上的同一组消融对照（这是本节的核心）：

变体	未修复架构 (60 轮，底 0.6312)	pos_enc 底 (120 轮，底 0.6716)
去掉 Adapter	+0.0030 (移除反而更好)	-0.0012
去掉 FPN	+0.0002 (移除反而更好)	-0.0037
去掉 EMR	+0.0043 (移除反而更好)	-0.0067
双线性	+0.0057 (移除反而更好)	-0.0073
去掉 Transformer	-0.0010 (几乎为零)	-0.0116 (可分辨)
去掉 ECSAM	-0.0040 (正常收敛)	发散

三点结论：

1. 未修复架构上 6 项里有 4 项是“移除反而更好”；pos_enc 底上全部为负——这是“模块确在起作用”的signature。即：把位置编码这一处缺陷修好后，消融终于从“移不移除都一样”变成了“每个模块都有非负贡献”。
2. 位置编码修复的价值不在表头 Kappa，而在可解释性。它自己只带来 +0.0061 ($1.03\sigma_{\text{diff}}$ ，弱)，但移除 Transformer 的代价从 -0.0010 (0.17σ) 变成 -0.0116 ($1.95\sigma_{\text{diff}}$)——按本报告自己的 $\sqrt{2}\sigma$ 口径尚未达 2σ 可分辨，但已从“完全无信号”变为“接近可分辨”。机制上说得通：无位置编码时注意力是置换等变的集合算子 (§5.6.4)，本就做不了空间建模，移除它自然无所谓；注入 2D 正弦位置编码后它才能做邻近建模，于是开始承载性能。这正是“缺陷掩盖了模块作用”这一诊断的直接、正向的证据。
3. ECSAM 移除导致的训练发散在两个不同的底上各复现一次（use_skip+pos_enc 底与 pos_enc 底，均为 loss 连续为 0、验证指标精确冻结、权重最大绝对值爆炸）。而在未修复架构上移除 ECSAM 能正常收敛 (0.6272)。 $\Rightarrow$ ECSAM 的作用是“条件性的训练稳定器”，而不是“没有贡献”——此前“移除 ECSAM 一致更好”的说法只在未修复架构上成立，不能外推。

两个必须同时说清的限定：

- 双线性 vs 转置卷积不可分辨：两次测量符号相反（未修复底 +0.0057/ $+0.96\sigma_{\text{diff}}$ 、pos_enc 底 -0.0073/ $-1.23\sigma_{\text{diff}}$ ），都落在噪声内。伪影存在是实测事实，但“换成双线性会提精度”不是。

- "每个模块都有非负贡献" ≠ "修好缺陷就提精度"：底本身 0.6716 相对未修复基线 0.6655 只有 +0.0061（弱）。模块贡献变为非负，与整体精度是否提升，是两件事。

5.6.16 ⚠ 意外发现：「消融平坦」这一核心结论依协议而变

背景：本轮修复了 `eval_rigor` 的一个缺陷（见 §5.6.11 第 4 条与 §7 的溯源）—— 整图预测缓存有两种不兼容布局，导致 14 个以上 tag **从未进入测试集协议**。修好后把 8 个消融变体全部重推（50 个 tag 覆盖、TOST 从 5 对增到 25 对），于是**第一次**能在整图协议上核对消融表。结果与 val 协议**大面积不符**：

变体	val 协议 Δ (底 0.6312, $\sigma=0.0050$)	整图测试协议 Δ (底 0.5774, $\sigma=0.0041$)	方向
去掉 EMR	+0.0043 (+0.72 σ_{diff})	-0.0049 (-1.02 σ_{diff})	相反
去掉 FPN	+0.0002 (+0.03 σ_{diff})	-0.0064 (-1.33 σ_{diff})	相反
去掉 Adapter	+0.0030 (+0.51 σ_{diff})	-0.0107 (-2.23 σ_{diff})	相反
双线性上采样	+0.0057 (+0.96 σ_{diff})	-0.0090 (-1.87 σ_{diff})	相反
Transformer 2→4 层	+0.0050 (+0.84 σ_{diff})	-0.0102 (-2.12 σ_{diff})	相反
Transformer 2→6 层	+0.0023 (+0.39 σ_{diff})	-0.0033 (-0.69 σ_{diff})	相反
去掉 ECSAM	-0.0040 (-0.67 σ_{diff})	-0.0262 (-5.45 σ_{diff})	一致 (均负)
去掉 Transformer	-0.0010 (-0.17 σ_{diff})	-0.0202 (-4.20 σ_{diff})	一致 (均负)

倍数口径：左列除以 $\sqrt{2} \cdot \sigma_{val} = 0.0059$ ，右列除以 $\sqrt{2} \cdot \sigma_{test} = 0.0034$ （ σ 均为 $n=10$ ；两单次运行之差的标准差是 $\sqrt{2}\sigma$ ，见 §5.6.11 第 2 条）。

8 项里有 6 项符号相反。 val 协议下 6/8 为"移除反而更好"（但**全部 $\leq 0.96\sigma_{diff}$** ，本就在噪声内）；整图协议下 **8/8 全为负**，且 **4/8 达到 $2\sigma_{diff}$ 可分辨**（去 Transformer / 去 ECSAM / 去 Adapter / Transformer 2→4 层）。**正确读法（§5.6.17 的解剖结论）：**不是"两个协议测出了相反的稳健差异"，而是"**val 协议测不出这类差异、整图协议测得出**"——val 侧的正 Δ 是噪声，噪声没有符号。

σ_{seed} 本身也是协议相关的（本轮实测，均 $n=10$ ）：val 协议 **0.0042**（221 张 256^2 裁剪）、整图测试协议 **0.0034**（141 张 1024^2 滑窗）。⇒ 判定某一协议的差值必须用**同协议**的 σ ；

`analysis/tost_equivalence.py` 已改为自动取匹配口径并标注来源。

三条必须同时说清的推论：

- 1. "消融平坦、模块无可测量贡献"是 val 协议下的结论，不能推广到整图协议。在整图协议上，Transformer 的贡献是可分辨的（ $-0.0202 = 4.20\sigma_{diff}$ ），而 FPN 仍不可分辨（ $-0.0064 = 1.33\sigma_{diff}$ ）。此前"占参数 67.14% 的两个模块都无可测量贡献"这一说法过宽，应收窄为"FPN 在所有协议下均不可分辨；Transformer 在整图协议下可分辨"。
- 2. 缺陷诊断仍然成立，且与之并列而非互斥。D1（归零 FPN 侧向支路输出逐位不变）、D3（置换等变 $7.15e-07$ ）是与协议无关的实现层事实。故"消融平坦"有两个成因：架构缺陷 + val 协议对该类差异不敏感。二者都已实测，不互相取消。
- 3. 两个协议的推理窗口都是 256^2 （val 为每图 4 固定角 patch；整图为 256^2 滑窗 + 高斯混合）。因此不存在"跨尺度泛化"之别——更正此前"训练 256^2 、测试 1024^2 "的说法。真实差异 = 图像集(val 221 / test_clean 141) + 覆盖率(4 角 $\approx 25\%$ 像素 / 全图)
- 4. 窗口混合(无 / 高斯) + 汇聚方式。任何"无差异"表述都必须注明协议。

5.6.17 协议解剖：符号翻转由图像集驱动，不是评估流程（实测）

四个因子逐一隔离（同一批 checkpoint，预登记判读规则见 `analysis/protocol_dissection.py` 的 docstring）：

臂	评估内容	full	w/o trans	w/o ecsam	w/o fpn	bilinear	w/o emr
A val 4 角 patch（原值）	val 图像	0.6312	-0.0011	-0.0041	+0.0002	+0.0056	+0.0043
B test_clean 4 角 patch（复刻 val 流程）	仅换图像集	0.5590	-0.0168	-0.0282	-0.0142	-0.0080	-0.0045
C test_clean 256^2 网格无混合	全覆盖、无混合	0.5646	-0.0198	-0.0254	-0.0084	-0.0114	-0.0062
D test_clean 滑窗+高斯（现整图协议）	全覆盖+混合	0.5774	-0.0202	-0.0262	-0.0064	-0.0090	-0.0049
E test_clean 512^2 窗口+高斯	窗口尺度	0.5805	-0.0206	-0.0241	-0.0030	-0.0053	+0.0005

判读（预登记规则自动归类，5/5 一致）：

- 1. $\Delta B \approx \Delta D \approx \Delta C$ ，全部远离 $\Delta A \Rightarrow$ 符号翻转由图像集本身驱动，与覆盖、高斯混合、窗口尺度基本无关。在 test_clean 图像上即使用与 val 完全相同的 4 角裁剪流程，消融 Δ 也立刻呈现真实负值。
- 2. "6 项符号相反"的正确读法：val 侧 6 个正 Δ 全部 $\leq 1.2\sigma$ （本就在噪声内）；test_clean 侧的负 Δ 才是真实信号（ $5/8 > 2\sigma$ ）。不是"两个协议测出了相反的 稳健差异"，而是"val 测不出、test_clean 测得出"。 $\Rightarrow$ 消融应在 test_clean 型（整图、全量覆盖）协议上读数；val 协议对该类差异不敏感。
- 3. 窗口尺度有次要作用（E vs D）： 512^2 窗口使所有模型小幅提升（ $+0.003 \sim +0.008$ ），w/o emr 升至 ≈ 0 ，但排序不变——不足以解释翻转。

4. 修正后的机制图景：模块（Transformer / ECSAM / FPN 侧向融合）的贡献在 **test_clean 图像的内容分布**上才可测。val 子集（同一筛选池的另一部分）对这些差异不敏感——这是划分的代表性问题，不是“能力维度”不同。

产物：`results/artifacts/protocol_dissection.json`；脚本 `analysis/protocol_dissection.py`
(含臂定义与预登记判读规则)。

两个绝对值的缺口也因此可以精确闭合（full_all_v2: val 0.6312 → 整图 0.5774, 共 -0.0538）：

因子	贡献	依据
图像集（val→test_clean, 同为角块直推）	-0.0722	臂 A vs 臂 B（流程完全相同）
覆盖率（角块→全覆盖、无混合）	+0.0056	臂 B vs 臂 C
高斯混合（无混合→滑窗融合）	+0.0128	臂 C vs 臂 D
合计	-0.0538	恰好闭合

选模偏差的量级（best.pt 按 val Kappa 挑选，故 val 数字带选择偏差）：其上界 = best - 末轮 val。实测解剖所用 6 个 `nd*` checkpoint 均 ≤0.0001（皆训练至 60 轮上限，选模几乎未起作用），`lgR` 系约 0.003，最大 0.0081（`lgR120_fx_pos`）。⇒ 选模偏差真实存在但是**三阶小量**；两协议绝对差的主项是**图像集难度**（test_clean 更难 -0.072），流程细节往复补偿 +0.018。

两点纪律：① 推理策略对消融 Δ 有 ±0.01 级影响（如 w/o FPN：ΔA +0.0002 → ΔB -0.0142 → ΔD -0.0064，流程项捞回约一半），但不足以改变任何变体的排序结论——“次要”即此义；② “消融应以 test_clean 型协议读数”这条建议**本身来自对 test_clean 的观察**，而该集合已被 rigor/TOST/解剖多次使用——未来新实验的协议选择应**预登记**，避免在同一份 test_clean 上反复做决定造成变相选模。

5.7 随机种子噪声底线（多种子实测）

方法学必要性：本项目早期全部比较都基于**单次运行**（seed=42）。文献指出这不足以支持“无差异”结论：GEO-Bench（NeurIPS 2023 D&B）建议 ≥10 个种子，并指出 3-5 个种子不足以给出可靠置信区间。

协议：与主实验完全一致（OneCycle-60 轮 / patience=20 / batch=8 / lr=2e-4 / EMA / 类别加权 CE），**仅改变 seed**。seed 控制模型初始化、DataLoader 打乱顺序与几何增强抽样（裁剪位置由 `epoch_seed` 决定，与 seed 无关）。

配置	种子数	mean	σ_seed	极差	区间
完整模型 MSSACT (P-MEM-ROLL)	10	0.6349	0.0042	0.0136	[0.6276, 0.6412]

配置	种子数	mean	σ_{seed}	极差	区间
DeepLabV3+ 预训练主干 (P-MEM-ROLL)	3	0.6931	0.0034	0.0066	[0.6895, 0.6961]
DeepLabV3+ 从零 (P-MEM-ROLL)	6	0.6267	0.0041	0.0120	[0.6213, 0.6333]
REF-参照(非种子组): 完整模型/DeepLab 的 P-PNG 单次结果	2	0.6594	0.0399	0.0564	[0.6312, 0.6876]

2026-09-15 扩展：完整模型种子数 $n=4 \rightarrow 10$ 、DeepLabV3+ $n=3 \rightarrow 9$ ，达到文献建议的 ≥ 10 （DeepLab 因下述原因拆为两组）。 σ_{seed} 是评估协议相关的，故两个口径各测一份（同一批 checkpoint 分别按 val 与整图协议评估）：

组	n	均值	σ_{seed}	极差
完整模型 MSSACT (val 协议)	10	0.6349	0.0042	0.0136
完整模型 MSSACT (整图协议)	10	0.5680	0.0034	0.0088
DeepLabV3+ 预训练主干 (val)	3	0.6931	0.0034	0.0066
DeepLabV3+ 从零 (val)	6	0.6267	0.0041	0.0120

判定的口径纪律：模块消融的 Δ 均取自 120 轮同调度组，对应的噪声是**完整模型在 val 协议下的 $\sigma = 0.0042$** ($2\sigma = 0.0084$)；整图协议上的 Δ 则用 0.0034。 `analysis/seed_variance.py` 已强制"与消融同配置"取 σ ，不再跨架构取最大值（原因见下）。


两处口径事实（审核 Q-01/Q-33）：① 裁剪位置由 `epoch_seed` 决定、与训练 seed 无关，故 σ 只含初始化与 shuffle 顺序方差、**不含增强路径方差**，是复制噪声的下界；② 读数取"各自 val 曲线上的 best"，属**极值统计量**。**适用范围：**val 协议 / 60 轮预算 / P-MEM-ROLL 世代 / 全量数据档——摘要与正文引用该 σ 时须注明，不可当作"全部实验差异"的普适尺度。

同管线模块消融 (val 协议) 的 Δ 极差 0.0097 为种子极差的 0.71 倍 ($0.0097 / 0.0136$) —— 即换一个随机种子带来的波动，比整套架构改动带来的差异还大。

⚠ 一处必须记录的数据完整性事故 (2026-09-15)：DeepLab 的 9 次种子运行 **混了两种配置** —— 旧 3 次训练于 `pretrained_backbone` 默认仍为 `True` 的时期（主干首个 BN 层 weight 均值 **0.248**），新 6 次训练于默认改为 `False` 之后 (**0.973**)。把它们并成一组后，组内 σ 变成 **0.0334**（真实的种子噪声仅 ~ 0.003 ，**差 11 倍**），而这正好比"配置差 0.065"小一个量级——混合把配置差当成了噪声。更危险的是旧的取 σ 规则是"**各管线取最大（保守）**"，于是 0.0334 会被下游拿去给 **MSSACT 消融定门限**，使**一切真实差异都被判成"不可分辨"**——一次静默的结论性破坏。

已修三处：① DeepLab 按预训练状态拆为两组（上表）；② σ 改为取 **与消融同配置**的组（跨架构的种子噪声不可互换）；③ 在 `seed_variance.py` 中加入 **组内同质性守卫**：用主干 BN 统计检出手干预训练状态不一致、用 checkpoint 参数量 指纹检出架构不一致，命中即**拒绝**该组的 σ 用于判定并显式告警。该守卫已用**受控测试**验证（故意复现上述混组 → 被检出；正常组 → 通过）。

新结论（复现带来的）：从零训练的自研 6.099M 与 DeepLabV3+ 39.64M，此前只有**单次对单次**（+0.0039, 0.78σ ，判"不可分辨"）。现在 $n=10$ vs $n=6$ ：自研均值 0.6349、DeepLab 从零均值 0.6267，**差 +0.0082 (SE 0.0021) = 3.8σ ，可分辨**；若把 `lgR_deeplab_scr` 也并入从零组 ($n=7$ ，均值 0.6280) 则为 **+0.0069 = 3.4σ** 。选择偏差核验：两组的 best-末轮 均为正（自研 +0.0026、DeepLab +0.0038），**DeepLab 偏离更大，校正后差距只会扩大——结论稳健。** ⇒ 原"从零对比不可分辨"是**单次运行的产物**；以复现为准，**自研模型在从零条件下 优于参数多 6.5 倍的 DeepLabV3+。**




5.8 训练策略对比：裁剪尺度与随机/固定裁剪

配置	crop	位置	每样本像素	Kappa	ΔM vs 基准	秒/轮	总时长
<code>lgR_bs8_full_lr2e4</code>	256	随机	1.00×	0.6320	+0.0000 ($0.00\sigma_{diff}$, 不可分辨)	44 s	44.0 min
<code>lgR_c256_center</code>	256	固定中心	1.00×	0.6128	-0.0192 ($3.23\sigma_{diff}$, 可分辨)	44 s	44.0 min
<code>lgR_c384_rand</code>	384	随机	2.25×	0.6543	+0.0223 ($3.75\sigma_{diff}$, 可分辨)	100 s	100.0 min
<code>lgR_c512_rand</code>	512	随机	4.00×	0.6524	+0.0204 ($3.43\sigma_{diff}$, 可分辨)	192 s	192.0 min

对比	$\Delta Kappa$	σ 倍数	计算代价	判读
256 随机 vs 256 固定中心	-0.0192	3.23σ_diff	同代价	可分辨
384 随机 vs 256 随机	+0.0223	3.75σ_diff	2.3×	可分辨
512 随机 vs 256 随机	+0.0199	3.35σ_diff	4.4×	可分辨

判读要点：

1. 本节三个对比的效应量，全部大于 §5.6 的所有模块消融。| $\Delta Kappa$ | 为 0.0199–0.0223 (**3.2–3.8 σ _diff**)；而在 val 协议下模块消融 全部 $\leq 1.00\sigma_diff$ (整图协议下 4/8 可分辨，见 §5.6.16)。也就是说：**在这套模型上，训练策略的收益是可分辨的，模块增删则不可分辨**。这对后续工作更有指导意义——**先选对训练策略，再谈架构**。
2. **256 随机 vs 256 固定中心**：两者像素量与尺度完全相同，差异**只能**归因于“每轮随机位置”这一增强——随机裁剪本身值 **+0.0192**。
3. **256 → 384 → 512**：384 达 0.6543 (+0.0223)，512 为 0.6519 (+0.0199) —— **再放大到 512 无额外收益，代价却从 100 s/轮升到 192 s/轮 (4.4× 于基准)**。故 **384 是更优的工程取舍**：既印证了“过小的尺度没有意义”，也说明**过大的尺度不划算**。
4. 注意 batch 随面积下调 (256²:8 / 384²:4 / 512²:2) 以避免显存溢出，故每轮耗时与总时长必须一并报告——大裁剪的计算代价是**平方级增长**的。



5.9 数据量阶梯：容量与数据量的匹配

协议：30 轮 / patience=30 (固定预算、不早停) / bs8 / lr2e-4；子集为分层抽样的嵌套样本 (250 $\subset$ 500 $\subset$ 1000)；验证集固定为 newsplit2 的 221 张 (与子集大小无关)，故各档 Kappa 可比。

e50rel / e90rel: 首次达到该次运行自身 k_{max} 的 50% / 90% 的轮次。使用相对阈值是因为低数据档的绝对 Kappa 很低 (n250 完整模型上限仅 0.03) , 固定阈值 0.4/0.5/0.6 在这些档位**永远不可达**。

n = 250 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.2825	0.2387	24	29
U-Net (2.44M)	0.1915	0.1915	14	28
DeepLabV3+ 从零 (39.63M)	0.1762	0.1762	24	30
MSSACT-Net w/o ECSAM	0.1164	0.1079	23	29
MSSACT-Net 完整 (6.10M)	0.0322	0.0261	27	28

n = 500 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.4928	0.4928	16	27
DeepLabV3+ 从零 (39.63M)	0.4393	0.4393	21	26
U-Net (2.44M)	0.4050	0.4050	19	28
MSSACT-Net w/o ECSAM	0.3954	0.3954	19	29
MSSACT-Net 完整 (6.10M)	0.3312	0.3312	25	28


n = 1000 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.6310	0.6303	13	21
MSSACT-Net w/o ECSAM	0.5234	0.5234	15	24
MSSACT-Net 完整 (6.10M)	0.5085	0.5085	17	25
U-Net (2.44M)	0.4913	0.4913	12	20
DeepLabV3+ 从零 (39.63M)	0.4771	0.4771	13	21

三点结论:

1. **小数据下"模块更多"反而更差**。n=250 时 U-Net (0.1915) 与 DeepLabV3+ 从零 (0.1762) 都远好于完整模型 (0.0322) 。这与 §5.6 的缺陷分析一致: 被移除的 FPN/Transformer/ECSAM 在实现上并未执行其声明的功能, 因此在样本稀少时只贡献了**优化难度**而非有效容量。

2. **w/o ECSAM 在全部三档上都不低于完整模型**，与 §5.6.1 的观察一致（坐标注意力仅占 0.90% 参数）。
3. **学习曲线的形态随数据量变化**：n250 的完整模型直到第 27/30 轮才达到自身上限的一半，说明小数据档在 30 轮预算内仍处于爬升期。




局限：30 轮预算对小数据档偏紧（e50rel 落在 23–27 轮），故各档数值只宜用于“同预算下的相对比较”，**不宜**解读为该模型在该数据量下的能力上限。

5.10 预算攻击：充足预算是否掩盖了模块差异？

动机：§5.6“模块无贡献”的结论是在 **60 轮充足预算**下得到的。自然的质疑是：**预算太足**，使各变体都有机会收敛到同一水平，从而掩盖了模块本身的差异。本实验把预算压到 **15 轮**，其余协议不变。

模型	参数量	Kappa (15 轮)	Δ vs 完整
DeepLabV3+ 预训练 (旁证)	39.635M	0.6358	+0.1459 (24.56 σ_{diff} , 可分辨)
MSSACT-Net w/o ECSAM	6.044M	0.5092	+0.0193 (3.25 σ_{diff} , 可分辨)
MSSACT-Net 完整 (6.10M)	6.099M	0.4899	+0.0000 (0.00 σ_{diff} , 不可分辨)
U-Net (2.44M)	2.443M	0.4884	-0.0015 (0.26 σ_{diff} , 不可分辨)
MSSACT-Net w/o EMR	6.099M	0.4790	-0.0109 (1.84 σ_{diff} , 弱)
DeepLabV3+ 从零 (39.63M)	39.635M	0.4682	-0.0217 (3.65 σ_{diff} , 可分辨)

结论：压到 15 轮后，模块之间的差异依然很小——完整模型 0.4899、w/o EMR 0.4790、U-Net 0.4884，散布仅 0.0109（约 2σ ）；"预算掩盖模块差异"这一质疑不成立**。**



但本实验揭示了一个跨四组实验一致的模式：在数据或预算受限的四种设置下，移除坐标注意力（ECSAM）都更好（4/4 一致）。这与 §5.6.1 的观察吻合——ECSAM 仅占 0.90% 参数，且被放在编码器深层（位置信息已被 $8\times$ 下采样稀释）。

5.11 全部效应量的可分辨性总表

把本项目的"设计选择"效应量折算到**两单次运行之差**的尺度上，即可比较哪一类选择 真正重要。三条口径纪律：① **按世代分组**（P-PNG 与 P-MEM-ROLL 的 Δ 不得排进同一序，见附录 A.2）；② **按协议分组**（val 用 $\sqrt{2}\times 0.0042 = 0.0059$ ，整图用 $\sqrt{2}\times 0.0034 = 0.0048$ ）；③ **单次对单次之差用 $\sqrt{2}\sigma_{diff}$ 定级**（审核 Q-26）。

世代	效应	$\Delta Kappa$	σ_{diff} 倍数	判读
P-MEM-ROLL	预训练主干贡献（阶梯 n1000）	+0.1539	25.91	可分辨
P-MEM-ROLL	预训练主干贡献（阶梯 n250）	+0.1063	17.90	可分辨
P-MEM-ROLL	预训练主干贡献（阶梯 n500）	+0.0535	9.01	可分辨
P-MEM-ROLL	训练预算/退火 60→120 轮（含调度效应，见注 2）	+0.0334	5.63	可分辨
P-MEM-ROLL	384 vs 256 随机裁剪	+0.0223	3.75	可分辨
P-MEM-ROLL	模块/容量变体 lgR_D3_ch_tiny	-0.0217	3.65	可分辨

世代	效应	$\Delta Kappa$	σ_diff 倍数	判读
P-MEM-ROLL	512 vs 256 随机裁剪	+0.0204	3.43	可分辨
P-MEM-ROLL	随机裁剪 vs 固定中心 (256)	-0.0192	3.23	可分辨
P-PNG	模块/容量变体 <code>nd_abl_bilinear</code>	+0.0056	0.94	不可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D2_decoder_ca</code>	+0.0055	0.93	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_trans4l</code>	+0.0050	0.84	不可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D4_ch_large</code>	+0.0044	0.74	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_emr</code>	+0.0043	0.72	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_ecsam</code>	-0.0041	0.69	不可分辨
P-MEM-ROLL	从零 DeepLabV3+ 39.63M vs 自研 6.10M (单次对单次)	+0.0039	0.66	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_adapter</code>	+0.0030	0.51	不可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D1_join_nofpn_notrans</code>	-0.0028	0.47	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_trans6l</code>	+0.0023	0.39	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_trans</code>	-0.0011	0.19	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_fpn</code>	+0.0002	0.03	不可分辨

val 协议侧合计 8 项 $\geq 2\sigma_diff$ 。 下表为**整图协议侧** (σ_diff 口径不同: $\sqrt{2} \times 0.0034 = 0.0048$) , 单独列出:

世代	效应	$\Delta Kappa$	σ_diff 倍数	判读
P-PNG	去掉 ECSAM	-0.0262	5.38	可分辨
P-PNG	去掉 Transformer	-0.0202	4.14	可分辨
P-PNG	去掉 Adapter	-0.0107	2.20	可分辨
P-PNG	Transformer 2→4 层	-0.0102	2.09	可分辨

这张表是全文最凝练的结论: val 协议下超过 $2\sigma_diff$ 的效应集中在 **预训练主干 (量级最大, $21-31\sigma$)**、**训练预算/退火 ($60 \rightarrow 120$ 轮, 约 5.7σ)**、**训练策略 (随机裁剪 3.23σ 、裁剪尺度 3.75σ)** 与**通道容量 (3.65σ)** ; 而val 协议下的模块增删全部 $\leq 1.00\sigma_diff$ 。

⚠ 三处必须与表同时读 (审核 Q-05/Q-37) : 1. "模块增删落在噪声内"只对 val 协议成立。整图协议下 4/8 可分辨 (去 Transformer $4.20\sigma_diff$ 、去 ECSAM $5.45\sigma_diff$) , 见下表的整图协议段。 2. **$60 \rightarrow 120$ 轮一行含调度效应:** OneCycle 的退火终点随预算改变, 故该 $+0.0335$ 是 "调度变化 + 训练量"的联合结果, **不可读作纯粹的"训练量效应"** (§5.6.14) 。 3. **预训练主干的领先幅度依数据量收窄:**

表内 +0.054~+0.154 全部来自 30 轮阶梯档；满数据档实测约 +0.05~+0.06，与训练侧最大效应的比值由 4~7 倍收窄到约 1.5~2.7 倍 (§6.1)。

6. 关键结论

按"可分辨性"分级，并给出可执行的下一步。

6.1 已由实测确立 ($|\Delta| > 2\sigma_{\text{seed}}$)

1. **预训练主干是本任务上最大的单项杠杆。** 同一模型仅切换权重初始化，Kappa 相差 **+0.054 ~ +0.154** (§5.6.6)。这在实践中意味着：**在有限标注预算下，把资源投向可获得预训练特征的骨干，收益远大于自研架构设计。**
2. **训练策略的收益是可分辨的。** 随机裁剪值 **+0.0192 ($3.23\sigma_{\text{diff}}$)**；裁剪尺度 256→384 值 **+0.0223 ($3.75\sigma_{\text{diff}}$)**，而 384→512 无额外收益、代价翻倍 (§5.8)。**可执行的结论：采用 384^2 随机裁剪。**
3. **通道容量确实重要。** 通道减半 (1.545M) 掉 **0.0217 ($3.65\sigma_{\text{diff}}$)**，且该变体仍保留全部模块 (§5.6.9)。**可执行结论：不要在容量上省钱。**
4. **数据规模在低数据区是主导因素。** $n=250$ 时完整模型几乎学不动 (Kappa 0.0322)，而 U-Net 达 0.1915 (§5.9)。**可执行结论：自研模型需要 $\geq 1,000$ 张才体现优势。**
5. **后训练有稳定的小幅收益** (+0.0101 Kappa, §4.3.1)。

6.2 已由实测否定或推翻的原有结论

1. **"DeepLabV3+ 显著优于自研模型 (+0.0720)"不成立。** 该比较中 DeepLabV3+ 带 ImageNet 预训练主干；从零对照下两者**不可分辨** ($\Delta = +0.0039$, 0.78σ)，而参数量相差 6.5 倍 (§5.6.6)。
2. **"DeepLabV3+ 架构的学习效率更高"被推翻。** 达 Kappa 0.5 所需累计学习量：从零 DeepLabV3+ **75.9%** vs 自研 **59.7%**——**从零条件下它更慢**；原先的 30.3% 完全来自预训练 (§5.2)。
3. **"五个设计模块均无可测量的独立贡献"需要修正表述。** 准确说法是：**这些模块在实现上并未执行其声明的功能** (FPN 的多尺度融合被丢弃、Transformer 无位置编码、解码器无跳连)，因此在 **val 协议下** 移除它们看不出影响 (§5.6.2–5.6.5)。这是**实现缺陷**，不是"模块设计无效"的证据。
 **但"移除无影响"不能推广：**在整图协议下移除 Transformer 为 $-0.0202 = 4.20\sigma_{\text{diff}}$ 、移除 ECSAM 为 $-0.0262 = 5.45\sigma_{\text{diff}}$ ，**均可分辨**；ECSAM 在修复后架构上移除更会导致训练发散 (§5.6.15–5.6.16)。正确表述是：**"实现缺陷"诊断成立 (与协议无关)，而"移除无影响"只在 val 协议与 FPN 上成立。**

4. "标签碎片化 (93% 像素在边界)"是错的, 真实边界像素占 2.4% (§5.6.8) ; 且原论证方向相反。

6.3 方法学结论 (对后续工作最有价值)

1. 先建立误差底线, 再谈差异。 $\sigma_{\text{seed}} = 0.0042$ 使本项目能对每个结论给出 分级 (§5.11) , 而不是罗列一堆无法比较的 ΔKappa 。
2. 消融实验必须先验证"模块是否在工作"。 如果直接做消融而跳过 §5.6 那样的 数值检验, 本项目会把"移除无效计算无影响"误读为"模块冗余"——这正是早期 报告的错误来源。
3. 归因必须排除混淆变量。 预训练混淆事件说明: 只验证自己假设的那个参数 是不够的 (当时只看了 `weights=` , 漏掉了 `weights_backbone=`) 。 可靠的做法是找可证伪的观测量 (此处用"新初始化 BN 的 weight 必为 1.0" 与"权重逐张量比对官方文件") 。

7. 局限、疏漏与教训

7.1 研究区选择的疏漏

早期选用 GF-1 影像 + 内蒙古根河市 (2.4 m GSD) , 其类别体系与分辨率不匹配: 大量类别在 2.4 m 下光谱与空间不可分, 且无公开可核验的逐像素标注。 **教训:** 数据集选择应由分类体系的可分性与标注的可核验性决定, 而不是由手头有什么影像决定。

7.2 类别体系核对的疏漏

官方约定 0 为 no-data、1-7 为类别, 早期实现误将 0 当作背景参与训练与评估, 使指标虚高约 0.007-0.009 Kappa。 **教训:** 类别体系必须以官方文档为准逐条核对, 不能凭直觉假设。

7.3 当前局限 (含 §5.6.11 的全部声明)

1. σ_{seed} 的种子数仅 4 (文献建议 ≥ 10) $\rightarrow$ 只支持量级判断。
2. 等效性检验 (TOST) 已完成: $\text{SESOI}=0.02$ 下配对 bootstrap 的 95% CI 半宽 $\delta \approx 0.010 < \text{SESOI}$, 故"无差异"已有统计等效支持 (`results/artifacts/tost_equivalence.json`) 。
3. 数据集为 LoveDA 单一来源 (0.3 m 航空正射、城市/乡村两类场景) , 结论向其他传感器/分辨率/地域的外推性未验证。
4. 未使用预训练特征 (§8.1 列为后续方向) , 故不能回答"自研架构 + 预训练" 的上限。
5. ~~架构缺陷尚未修复~~ $\rightarrow$ 已完成 (2026-09-14) : §5.6 的四处缺陷 (D1/D2/D3/D5) 已实现向后兼容修复并验证 (§5.6.12) , 120 轮组已测定效果 (跳连被实测否决、位置编码弱正向, §5.6.13) , 消融已换底重跑并首次给出 方向可解释的结果 (§5.6.15) 。 仍未做: P2 容量膨胀 (2.67 $\times$) 。 本报告 §7 写于该批实验之前, 此条为回写。

6. 标签质量上限只有提示性证据（\$5.3 的独立性限定）。

7.4 质量控制措施（本次新增）

措施	作用
误差底线 σ_{seed}	给全部差异提供统一判据
管线世代隔离	不同数据投递后端的结果禁止跨世代比较
权重级取证	用逐张量比对代替"读代码下结论"
推送前审核	自动检查本机路径、内部语境词、大文件
索引与事实单一来源	<code>experiments_index.json</code> / <code>FACTS.json</code> 为唯一数据源，报告与 README 均由其生成
PDF 内容自检	27 项关键词守卫，防止报告回退为已否证的结论

8. 后续工作

8.1 预训练方向（本次实验中收益最大的方向）

\$5.6.6 已量化：预训练主干权重的贡献（+0.054 ~ +0.154）远大于任何架构改动。因此这是后续最值得投入的方向，具体两条路径：

(1) 换用预训练主干 把自研 EMR 编码器替换为可获取预训练权重的骨干（如 ImageNet 预训练的 ResNet / ConvNeXt / Swin），保留本项目的 FPN-Transformer-解码器结构。可回答的问题："自研架构 + 预训练特征"能否超过"标准架构 + 预训练特征"？（本项目已具备公平对照的全部条件：同管线、同协议、 σ_{seed} 已知。）

(2) 域内预训练（自监督或跨区监督）用 LoveDA 影像本身做预训练，避免 ImageNet 与遥感影像的域差：- 自监督：MAE / SimCLR / DINO 等在无标注影像上预训练编码器；- 跨区监督：官方数据集的另一分区（官方 val 区 1,669 张带标注）作为预训练集，本项目的 1,768 张作为微调集——两者天然不重叠，无泄漏风险。

注意：这两条都需重新设计数据预算的对照（预训练用掉的数据不能同时用于微调），否则会重演"数据量 vs 预训练无法分离"的混淆。

8.2 多光谱与高光谱适配（下一个阶段的核心方向）

本项目使用的是 3 波段 RGB。后续计划针对多光谱（>4 波段）与高光谱影像设计模型，三个具体方向：

1. **三方向池化**：现有 ECSAM 只做水平/垂直两个**空间**方向的池化。对多光谱数据，应扩展为**光谱维 / 空间维 / 通道维**的三方向池化，使注意力同时感知波段相关性。
2. **模块适配**：现有 FPN 的横向连接假设各层通道数相近，多光谱输入下需重新设计 光谱-空间特征的融合方式；Transformer 的 patch embedding 也需适配波段数。
3. **验证协议**：建立高光谱数据集上的**从零训练基准**与误差底线，以避免重演本项目早期的归因错误。

8.3 其他

- ~~补齐 TOST 等效性检验~~ → **已完成** (§5.6.11 第 2 条) 。 ⚠ **限定 (审核 Q-27)** : SESOI = 0.02 意味着 TOST 只能**排除 ≥ 0.02 的差异**，而全文讨论的是 0.005–0.01 量级的差异——等效域宽于感兴趣的效应量 2–4 倍，故 TOST 通过**不能为**"这些小差异不存在"背书。
- ~~把测试集协议覆盖到全部消融变体~~ → **已完成** (§5.6.16, 50 个 tag 全量重推) 。
- ~~修复 §5.6 的**四处**缺陷后重评~~ → **已完成** (§5.6.13–5.6.15) 。
- ~~扩大种子数至 ≥ 10 ~~ → **已完成** (完整模型 $n=10$ 、DeepLab 分组 $n=3/n=6$, §5.7) 。
- **跨传感器/分辨率验证** (含 GF-1 同域微调)，检验结论的外推性。

9. 个人工作与能力体现

9.1 数据工程

完成 LoveDA 官方训练区的全量获取与清洗：**MD5 去重** (2,821 张池)、**no-data $\leq 10\%$ 筛选** (剔除 312 张)、**8:1:1 分层划分**，并建立**泄漏防控校验** (三集两两互斥 + test_clean 与历史训练集零重叠)。实现**预解码 memmap** 数据集，把每张图的训练成本由 ≈ 170 ms 降到 ≈ 24 ms。

9.2 模型训练与工程

搭建统一训练入口 (OneCycle + EMA + 类别加权 CE + Kappa 早停)，支持 12 类模型/变体的**同协议对比**。实现**断点续跑队列** (按 history 轮数判定完成)、**OOM 自动降 batch**、**队列互斥与无窗口后台执行**。把 GPU 利用率由 49.9% 提升到 84.3%，同时**零性能损失** (§5.5) 。

9.3 实验设计与分析

设计并执行 **7 基线对比 + 8 消融 + 4 架构变体 + 3 档数据阶梯 + 3 组裁剪策略 + 15 轮预算攻击 + 多种子重复**，共 40+ 次独立训练。建立**累计学习量**方法分离调度效应与架构效应 (并据此推翻了一条原有结论)。建立**Kappa 归属 (oracle)** 分析量化指标的可见空间。

9.4 问题定位与修复

- **发现并证明四处架构实现缺陷**（FPN 死支路 / 无跳连 / 无位置编码），全部给出**可复现的数值验证**（输出逐位不变、置换等变至 $7e-07$ ）。
- **发现并更正一处严重的公平性缺陷**：`weights=None` 未关闭主干预训练，导致基线被误认为从零训练。用**权重级逐张量比对**取证，并重跑从零对照。
- **发现并更正一处统计错误**：边界像素比例 $93\% \rightarrow 2.4\%$ （跨图求差分的缺陷），结论方向随之反转。
- 定位并修复训练基础设施瓶颈（PNG 解码、EMA 实现、进程同步）。

9.5 工具与产出

可复现性基建：`paths.py` 路径集中（脚本内零绝对路径）、`experiments_index.json` 实验索引（参数量直读张量）、`FACTS.json` 事实单一来源、`verify/pre_push_audit.py` 推送前审核、`report/make_pdf.py` 报告内容自检。**分析工具**：严格性评估（配对 bootstrap / TOST）、Kappa 归属分解、解码器伪影分析（FFT 周期检测）、随机种子噪声底线。**报告与图**：全部图表由 `viz/make_report_figures.py` 从权威数据源生成，**无手改数据**。

附录 A：复现指引

A.1 环境与运行

```
cd loveda                                # 运行目录 = 仓库根
export LDA_DATA_ROOT=<数据根目录>        # 或写入 .env（不入库）
python prep/resplit_filtered.py           # 数据筛选 + 去重 + 划分
python prep/build_fast_dataset.py         # 预解码 memmap（强烈建议）
python prep/build_ladder_memmap.py        # 阶梯子集 memmap（跑阶梯前需停队列）
python queues/run_queue_new.py            # 对比(7) + 消融(8) + 主模型
python queues/run_queue_arch.py          # 架构变体 D1-D4 + 预算攻击 + 数据阶梯
python analysis/eval_rigor.py --infer    # 逐类 IoU / 配对 bootstrap / TOST
python analysis/convergence_amount.py     # 累计学习量（调度 vs 架构）
python analysis/seed_variance.py          #  $\sigma_{seed}$  与可分辨性
python viz/make_report_figures.py         # 全部报告图
python report/build_index.py              # 实验索引（参数量直读张量）
python report/build_facts.py              # 事实汇总  $\rightarrow$  FACTS.json
python report/make_report_v3.py           # 本报告 HTML
python report/make_pdf.py                 # HTML  $\rightarrow$  PDF（含 27 项内容自检）
python verify/pre_push_audit.py           # 推送前审核（必须通过）
```

A.2 训练管线世代（禁止跨世代比较 Kappa）

世代	数据投递	num_workers	实验前缀
P-PNG	每样本解码两张 1024 ² PNG	0	nd_* lg_*
P-MEM-DET	memmap + 确定性增强	8	lgF_* (✗ 已否决, Kappa -0.0246)
P-MEM-ROLL	memmap + 原始增强	0	lgR_* sd*_*

两代后端差异实测为 **+0.0008** (同配置 0.6320 vs 0.6312) , 故两组结论可**互相印证**, 但**不得混合求统计量**。

附录 B：文件与目录说明

- 根目录只保留：** `paths.py` 与 4 个核心模块、文档、`figures/` (报告图)、 三项权威事实 (位于 `results/facts/`) (`FACTS.json` / `experiments_index.json` / `seed_variance.json`)、 本报告 PDF。
- 脚本按用途分 7 个子目录：** `queues/` (实验队列)、 `analysis/` (评估与分析)、 `verify/` (核验与审核)、 `prep/` (数据准备)、 `viz/` (图表)、 `report/` (汇总与报告)、 `mapping/` (制图管线)。
- 产物集中在 `results/`：** `checkpoints/` (权重与训练历史)、 `fast_dataset/` (memmap)、 `consensus_analysis/`、 `overfit_diag/`、 `ladder_eval/`、 `fulltile_eval/`、 `tta_eval/`、 `heldout_test/` (各阶段评估)、 `artifacts/` (中间分析产物)。
- 本地归档 (不入库)：** `_local_archive/` (历史数据集与旧图)、 `backups/` (覆盖前备份)。
- 目录整理与路径适配的完整记录见 `docs/整理记录_20260913.md`； 本报告的问题审查与逐条修正见 `docs/报告问题研究_20260913.md`。