

MSSACT-Net 遥感土地覆盖分割

项目报告

数据集: LoveDA 公开基准 (0.3 m 航空正射影像, 7 类土地覆盖, 官方人工标注) **模型:** MSSACT-Net (多尺度自注意力 ConvTransformer, light 配置 6.10M 参数) **代码:** <https://github.com/eugenewang5425/mssact-loveda>

摘要

本项目在公开基准 **LoveDA** 上系统训练与评估自研的 **MSSACT-Net**, 完成了 7 个主流分割模型的对比、8 个模块消融、架构缺陷的数值检验、数据量与裁剪策略的扫描、随机种子噪声底线的实测, 以及标签质量上限的专项验证。

一、方法学层面最重要的产出是"误差底线"。 同配置换随机种子 ($n=4$) 得到 $\sigma_{\text{seed}} = 0.0042$ ($n=10$, $df=9$; 95% CI 约 [0.0029, 0.0077])、极差 0.0136。 **两个口径事实:** ① 裁剪位置由 `epoch_seed` 决定、与训练 `seed` 无关, 故该 σ 只含初始化与 `shuffle` 顺序方差、**不含增强路径方差**, 是复制噪声的**下界**; ② 读数取"各自 val 曲线上的 best", 属**极值统计量**。 **适用范围:** val 协议 / 60 轮预算 / P-MEM-ROLL 世代 / 全量数据档。 以此为尺度衡量**全部**实验差异后, 可分辨的效应屈指可数——这为后续所有结论提供了统一的判据 (详见 §5.11)。

二、预训练主干是本任务上最大的单项杠杆, 且它曾造成一处严重误判。 在从零对照下 ($n=10$ vs $n=6$ 复现), 自研 6.10M 优于 DeepLabV3+ 39.63M **+0.0082 (组均值差, SE 0.0021) = $3.8\sigma_z$** (此前"不可分辨"仅为单次运行的结果, 见 §5.7) ($\Delta = +0.0039$, 0.78σ)。 而同一模型仅切换权重初始化, Kappa 即相差 **+0.054 ~ +0.154** (§5.6.6)。 项目早期因 `weights=None` 未关闭主干预训练, 使 DeepLabV3+ 基线实际带着 ImageNet 预训练主干, 导致"+0.0720 架构优势"的错误归因——该错误已定位、更正并记录取证过程。

三、消融实验"全部无差异"的真因是实现缺陷, 不是模块设计无效。数值检验证实四处结构性缺陷: FPN 的多尺度融合未被使用 (其 **1,828,352 个参数 = 全模型 29.98% 不参与前向, 实测归零后输出逐位不变**)、解码器无跳连 (仅凭 $8\times$ 下采样特征上采样)、Transformer **无位置编码** (置换等变, 实测差 $7.15e-07$)、以及 `ecsam[0]` 是死模块 (1,040 个参数, 占 0.017%)。 8 个消融变体的 Δ 极差 0.0097, 小于种子极差 0.0136。 **四处缺陷已于 2026-09-13 修复并给出可复现证据 (§5.6.12)。**

⚠ 该"平坦"结论依评估协议而变 (§5.6.16): 上句是 **val 协议** (221 张 256^2 裁剪) 下的结果。在**整图测试协议** (141 张 1024^2 滑窗) 上, 同样 8 个变体 **全部为负、4 个可分辨** (如去掉 Transformer $-0.0202 = 4.20\sigma_{\text{diff}}$ 、去掉 ECSAM $-0.0262 = 5.45\sigma_{\text{diff}}$)——即 **val 协议测不出这类差异、整图协议测得出** (§5.6.17 的解读; val 侧的 6 个正 Δ)

全部 $\leq 1.2\sigma$ ，噪声没有符号，不宜表述为"两协议测出相反差异")。故"消融平坦"的成因是**架构缺陷 + val 协议不敏感**两项，任何"无差异"表述都必须注明协议。

四、训练策略的收益可分辨，架构模块增删不可分辨。 256 随机裁剪比固定中心裁剪高 **+0.0192** ($3.23\sigma_{\text{diff}}$)；384² 比 256² 高 **+0.0223** ($3.75\sigma_{\text{diff}}$)；而在 **val 协议**下全部模块消融都 $\leq 1.0\sigma_{\text{diff}}$ (**整图协议**下 4/8 可分辨，见第三、五条与此处的协议限定)。**杠杆排序：预训练主干 >> 训练策略 > 架构模块**——其中预训练一项的量级 ($21\text{--}31\sigma$) 远高于其余，且该排序以满数据档为界有收窄 (\$6.1)。

五、基线并非"领先"。 协议内从零对比下，自研 6.10M 与 DeepLabV3+ 39.63M 在主协议不可分辨；在预算受限 (15 轮) 与 1,000 张档位下自研更高；仅在 $n=250/500$ 的极小数据档显著更低——说明自研模型**更依赖数据量**。

六、标签质量仍是评价上限的约束。 6 个模型 (2.4M–39.6M) 逐像素分析：模型间一致率 **0.7589** 显著高于模型与人工标签的 **0.6495**。但 2.4% 的边界像素仅值 +0.016 Kappa，而 78.4% 的内部像素值 +0.29——**聚合指标几乎看不见边界质量** (\$5.6.8)。

关键词：高分辨率遥感；土地覆盖分类；语义分割；自注意力；LoveDA；误差底线；标签质量；消融实验；可复现性

0. 项目状态

项	状态
数据集	LoveDA 官方训练区全量获取 (2,522 张)
数据筛选与划分	✅ no-data $\leq 10\%$ 筛选 → MD5 去重 → 8:1:1 (train 1768 / val 221 / test 221 / test_clean 141)
泄漏校验	✅ 三集两两互斥；test_clean 与历史训练集零重叠 (空间自相关边界 ：MD5 只排除精确重复；LoveDA 瓦片切自同一批正射影像，相邻瓦片像素不重叠但空间强自相关，故绝对 Kappa 偏乐观、相对比较不受影响——见 §7.3)
主模型训练	✅ full_all_v2 (60 轮) + post_all_v2 (后训练 30 轮)
对比实验 (7 基线)	✅ 完成 (含 协议内从零 DeepLabV3+ 对照)
消融实验 (8 变体)	✅ 完成 (val 协议 下 8 变体 Δ 极差 0.0097 < 种子极差 0.0136； 整图协议 下 4/8 可分辨，见 §5.6.16)
架构缺陷数值检验	✅ 完成 (FPN 死支路 / 无跳连 / 无位置编码)
架构变体 D1–D4	✅ 完成 (同管线同协议，两条管线互证)
随机种子噪声底线	✅ 完成 ($\sigma_{\text{seed}} = 0.0042$)
训练策略 (裁剪尺度/随机)	✅ 完成 (效应 $3.2\text{--}3.8\sigma_{\text{diff}}$ ，见 §5.8)
数据量阶梯 (250/500/1000)	✅ 完成

项	状态
预算攻击（15 轮）	✅ 完成
DeepLabV3+ 从零对照	✅ 完成（推翻原 +0.0720 的架构归因）
硬件效率优化	✅ 完成（GPU 利用率均值 49.9% → 84.3%，零性能损失，见 §5.5）
等效性检验（TOST）	✅ 完成（ results/artifacts/tost_equivalence.json ）
四处架构缺陷修复	✅ 已实现并验证（§5.6.12）；性能效果由 lgR120 组测定中
预训练主干 / 域内预训练	📄 后续方向（见 §8.1）
跨数据集与多光谱适配	📄 后续方向（见 §8.2）

1. 项目背景

1.1 研究目标

在公开、可复现的遥感基准上，系统评估自研 MSSACT-Net 的：

1. **土地覆盖分类精度**——以 Kappa 为主指标（理由见 §3.3），并与主流分割模型横向对比；
2. **各设计模块的实际贡献**——通过逐模块消融，并先用数值手段检验模块是否 **真的在工作**（这一步发现了四处实现缺陷，见 §5.6；编号 D1/D2/D3/D5，其中 **D4 缺号**——原方案里 D4 是一个「容量放大」对照组，与前三者性质不同，后被拆到 §5.6.9 的容量变体单独讨论；编号保留空缺以免与既有记录错位）；
3. **训练策略与数据规模的影响**——裁剪尺度、随机/固定裁剪、数据量阶梯；
4. **评价本身的可靠性**——实测随机种子噪声底线 σ_{seed} ，并用它给所有差异定级。

1.2 为什么改用公开数据集

早期工作选用的研究区（内蒙古根河市，GF-1 影像）存在两个不可回避的问题：**类别体系与影像分辨率不匹配**（2.4 m GSD 下大量类别在光谱与空间上不可分），以及**缺少可公开核验的逐像素标注**。

因此改用 **LoveDA**：0.3 m 航空正射影像、7 类、官方人工逐像素标注、有公开基准 与论文可对照。这一更换使全部结论建立在**他人可复现**的数据之上，是本项目最重要 的一次方法论更正。

2. 数据

2.1 官方类别体系（依据官方文档核对）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**; and the **no-data regions were assigned 0 which should be ignored.**

标签值	类别	本项目索引
0	no-data	必须忽略 (→255)
1–7	背景/建筑/道路/水域/裸地/森林/农田	0–6

⚠️ 早期实现曾把 0 (no-data) 错误映射为"背景"参与训练与评估, 使指标虚高 约 0.007–0.009 Kappa。该缺陷已修复 (§3.4) 。

2.2 数据演进三阶段

阶段	数据	标签处理	结论地位
A	957 张 (镜像子集)	⚠️ 含 no-data 映射缺陷	历史参考
B	2,257 张 (官方全量去重)	⚠️ 仍含缺陷	中间结果
C	1,768 张 (筛选后)	✅ 已修复	结论依据

必须诚实说明的一点：A→B→C 的对比**不是纯粹的数据量效应**。阶段 C 的 1,768 张比阶段 B 的 2,257 张**更少**, 却取得更高 Kappa, 说明该对比同时 包含了"数据量、标签修复、低质量样本剔除"三项变化, 三者**无法分离**。 真正的数据量效应由 §5.9 的阶梯实验 (同协议、同管线的 250/500/1000 张) 给出。

2.3 筛选与划分 (阶段 C)

流程: **no-data 占比 ≤10% 筛选** (剔除 312 张) → **MD5 去重** → **8:1:1 划分**。


集合	图像数	用途
train	1768	训练
val	221	早停 / 选优 (不参与梯度)
test	221	评估
test_clean	141	结论用途 (与历史训练集零重叠)

2.4 类别分布 (已按实测更正)

划分	图像数	背景占比 (最大类)	ignore 占比
训练集	1768	36.09%	0.17%
验证集	221	37.15%	0.13%
干净测试集	141	41.54%	0.40%

验证集逐类占比：背景 37.1%、建筑 9.3%、道路 5.2%、水域 6.4%、裸地 6.4%、森林 17.5%、农田 18.0%


勘误：早期报告称"验证集最大类（背景）占 **45.6%**"，并据此论证 "全预测背景
OA=45.6%"。实测该值为 **37.15%** (train 36.1%、test_clean 41.5%) 。 论证方向不变
(OA 会被单类支配、故采用 Kappa 选优) ， 但**数值已更正**。



3. 方法与协议

3.1 模型架构

3.1.1 整体数据流



输入为 256×256×3 的 RGB patch，逐级变换如下（括号内为分辨率与通道）：

阶段	输出	说明
Stem	256 ² ×32	3×3 卷积 + BN + ReLU
EMR 编码器 ×4	256 ² ×32 → 128 ² ×64 → 64 ² ×128 → 32 ² ×256	每阶段后 max-pool 下采样（最后一级不下采样）

阶段	输出	说明
ECSAM 坐标注意力	同上（仅第 2–4 阶段）	见 §3.1.3
FPN 多尺度融合	$32^2 \times 256$ （仅最深层进入前向）	见 §5.6.2 的缺陷说明
Transformer 编码器	$32^2 \rightarrow 1024 \text{ token} \rightarrow 32^2$	见 §5.6.4 的缺陷说明
解码器（转置卷积 $\times 3$ ）	$64^2 \rightarrow 128^2 \rightarrow 256^2 \times 64$	无跳连，见 §5.6.3
分类头（ 1×1 卷积）	$256^2 \times 7$	逐像素类别 logits

3.1.2 各模块职责

- **EMR (Enhanced Multi-scale Residual)**：两个 3×3 卷积 + 短路连接，构成 残差基本块。作用是逐阶段扩大感受野、提取多尺度空间特征。
- **ECSAM (Enhanced Coordinate Spatial Attention Module)**：坐标注意力（Hou et al., CVPR 2021）。沿水平与垂直方向分别做 1D 池化，得到方向感知的 特征向量，经共享 1×1 变换后重加权。其设计意图是编码长程空间位置信息。
- **FPN (Feature Pyramid Network)**：自顶向下把深层语义与浅层细节融合，输出 4 个尺度的特征图。
- **Transformer 编码器 + Adapter-Scale**：对最深层特征做全局自注意力，以捕捉长程上下文；Adapter 是一个低秩 ($d/4$) 残差分支，配合可学习的 `scale_factor` 控制其贡献强度。
- **解码器**：3 次 $\text{stride}=2$ 的转置卷积，把 32^2 恢复到 256^2 。

3.1.3 配置与参数量账目

配置	embed_dims	Transformer	参数量
light（本报告主模型）	[32, 64, 128, 256]	2 层 4 头	6.10M
large（D4 实验）	[64, 128, 256, 512]	2 层 4 头	24.237M

本报告主模型 light 配置的**模块参数账目**（直读 checkpoint 张量求和，非估算）：


模块	参数量	占比
FPN	2,484,224	40.73%
Transformer	1,612,609	26.44%
EMR 编码器	1,224,576	20.08%
解码器	721,863	11.84%
ECSAM（坐标注意力）	54,912	0.90%
Stem	960	0.02%

口径说明：以上为 `nn.Parameter` 计数，不含 BatchNorm 的 `running_mean / running_var / num_batches_tracked`。早前版本引用的 6,101,784 是

state_dict 总元素数, 含 16 层 BN 的 2,640 个 buffer, 高估 **0.0433%**, 已更正。FPN 与 Transformer 无 BN, 其计数不受影响。| 合计 | **6,099,144** | 100% |

两点直接推论:

1. FPN + Transformer 合计占 **67.17%** 的参数, 但 §5.6 将证明二者在实现上**未执行其声明的功能**。
2. ECSAM (坐标注意力) 仅占 **0.90%**——对占比不足 1% 的模块 期待显著增益, 在容量意义上本就不合理。



3.2 训练协议 (所有实验一致)

项	设置
优化器	AdamW, lr = 2e-4, weight_decay = 0.02
调度	OneCycleLR, 最大学习率 2e-4, warmup 占 6%, 余弦退火, 总 60 轮
批大小	8 (裁剪 384 ² 时为 4, 512 ² 时为 2, 按面积下调以避免显存溢出)
精度	混合精度 (AMP) + 梯度裁剪 (max-norm = 1.0)
权重平滑	EMA, decay = 0.999, 评估用 EMA 权重
损失	类别加权交叉熵, 权重 $\propto 1/\sqrt{\text{频率}}$ (见下)
早停	验证集 Kappa 连续 20 轮不升则停
数据增强	每轮每图随机裁剪 1 个 patch (位置固定为 epoch_seed 决定); 随机 90° 旋转 $\times 4$ 、水平/垂直翻转

类别权重公式: 设第 c 类在训练集中的像素数为 n_c , 有效像素总数为 N , 则第 c 类的损失权重为

$$w_c = \frac{(n_c/N)^{-1/2}}{\text{mean}_k[(n_k/N)^{-1/2}]}$$

符号	含义	取值域
c	类别索引 (本报告重映射后为 0...6, 0 为背景)	0-6

符号	含义	取值域
n_c	训练集中第 c 类的像素数 (不含 ignore 像素)	正整数
N	训练集有效像素总数, $N = \sum_c n_c$	正整数
n_c/N	第 c 类的像素频率	$(0, 1)$
mean_k	对 $k = 0 \dots 6$ 取算术平均	—
w_c	第 c 类的损失权重	归一化后 $\text{mean}_c w_c = 1$

即取频率的**负平方根**并归一化到均值为 1。用负平方根而非倒数，是为了避免 极稀有类（如道路）获得过大的权重而使训练不稳定。

EMA 更新公式： 设在线模型参数为 θ , 影子 (EMA) 参数为 θ' , 衰减系数为 λ :

$$\theta' \leftarrow \lambda \theta' + (1 - \lambda) \theta, \quad \lambda = 0.999$$

符号	含义	取值域
θ	梯度更新后的 在线 权重	张量
θ'	影子 权重, 只做指数滑动平均、不接收梯度	张量
λ	衰减系数 (每个优化步更新一次)	0.999
θ' 的有效平均窗口	$\approx 1/(1 - \lambda)$ 步	≈ 1000 步

评估与选优全部使用 θ' ： 影子权重是历史权重的指数滑动平均，可显著降低验证指标的抖动。

即影子参数是历史参数的指数滑动平均；用其评估可显著降低验证指标的抖动。

3.3 评价指标

全部指标在 **255 (no-data) 像素上屏蔽**后计算。

设混淆矩阵 CM , CM_{ij} = 真值为 i 、预测为 j 的像素数, $N = \sum_{ij} CM_{ij}$ 。

OA (总体精度)

$$\text{OA} = \frac{1}{N} \sum_{i=0}^6 CM_{ii}$$

符号	含义
CM	7×7 混淆矩阵, CM_{ij} = 真值为 i 、模型预测为 j 的像素数
CM_{ii}	对角线元素, 即第 i 类被正确识别的像素数
N	全部有效像素数 (已屏蔽 ignore 像素)

Kappa (本报告的主指标与选优/早停依据)

$$p_o = \frac{1}{N} \sum_{i=0}^6 CM_{ii}, \quad p_e = \frac{1}{N^2} \sum_{i=0}^6 \text{row}_i \cdot \text{col}_i, \quad \kappa = \frac{p_o - p_e}{1 - p_e}$$

符号	含义	备注
p_o	观测一致率	与上式的 OA 数值相同
$\text{row}_i = \sum_j CM_{ij}$	真值为 i 的像素总数	即该类的 支持度 （分母）
$\text{col}_i = \sum_j CM_{ji}$	被预测为 i 的像素总数	即该类的 预测总量
p_e	随机一致率：两个独立随机标注者按各类边缘分布标注时的期望一致率	由 row, col 决定
κ	Kappa 系数	1 = 完全一致，0 = 与随机相当，可为负

为什么用 Kappa 而非 OA：LoveDA 背景类占比约 37%，一个"全部预测背景"的 平凡模型即可取得 $OA \approx 0.37$ ，但其 $Kappa = 0$ 。Kappa 扣除了随机一致率，在不平衡数据上不会被单类支配。

F1 / mF1（按类）

$$\text{precision}_i = \frac{CM_{ii}}{\text{col}_i}, \quad \text{recall}_i = \frac{CM_{ii}}{\text{row}_i}, \quad F1_i = \frac{2 \text{precision}_i \text{recall}_i}{\text{precision}_i + \text{recall}_i}$$
$$\text{mF1} = \frac{1}{7} \sum_{i=0}^6 F1_i$$

符号	含义	亦称
precision_i	预测为 i 的像素中真正属于 i 的比例	UA （用户精度）
recall_i	真值为 i 的像素中被正确识别的比例	PA （生产者精度）
$F1_i$	二者的调和平均	—
mF1	对 7 类取算术平均； 按类等权 ，故不受大类支配	—

IoU / mIoU

$$\text{IoU}_i = \frac{CM_{ii}}{\text{row}_i + \text{col}_i - CM_{ii}}, \quad \text{mIoU} = \frac{1}{7} \sum_{i=0}^6 \text{IoU}_i$$

符号	含义
分母	并集大小：真值或预测命中第 i 类的像素数（交集被计两次，故减去 CM_{ii} ）
mIoU	对 7 类取算术平均（ 按类等权 ）

口径纪律：mIoU 必须先在全数据集上**汇总**出唯一的 CM ，再逐类算 IoU、最后对类平均。若改成像元级逐图计算再对图平均，类别像素少时极不稳定、会系统性偏低（实测差 0.20，见下方勘误）。

 **勘误（2026-09-15）：**本报告此前的 mIoU 数值被系统性低估约 21 个点。上面这个定义是**标准口径**——先在全数据集上汇总混淆矩阵 CM ，再逐类算 IoU、最后对类取平

均 (LoveDA 排行榜与 FCN/DeepLab 系论文一致)。但 `analysis/eval_rigor.py` 的实现当时写成逐图算每类 IoU 再对图平均，字段名却叫 `miou_pooled` (名实不符)。逐图 IoU 在类别像素数很少时极不稳定 (一个错像素即可把该类 IoU 压到 0)，对图平均后被系统性拉低。

实测同一批预测的差额 (test_clean, 六模型)：

模型	标准 pooled (更正后)	逐图平均 (旧, 错)	差
MSSACT-Net 6.10M	0.5383	0.3327	+0.2057
DeepLabV3+ 39.63M (预训练)	0.6021	0.4109	+0.1911
U-Net 2.44M	0.4935	0.2718	+0.2216
FCN 23.72M	0.4971	0.3074	+0.1897
FPN-Seg 27.15M	0.5010	0.3212	+0.1798

两条完全独立的实现 (`bincount` 汇总 vs 逐像素累加) 给出同一值 0.538349，排除实现误差。本报告此前所有 `mIoU` 数值均按此更正；为便于与历史记录对照，旧口径保留为 `miou_img_mean` 字段，但不应再被引用。注意：`per_class_iou` 字段也同步更正为 pooled 口径。

本案与本项目其他几处勘误同型：报告正文的定义写对了，而代码没有按定义实现 (另见 §5.6.11 的 $\sqrt{2}\sigma$ 判据、§5.6.14 的塌陷/发散判别)。教训：任何印刷的指标都必须有一条“定义↔实现”的核对，否则定义正确也不能保证数值正确。

数据使用协议：val 仅用于早停与选优 (在 `torch.no_grad()` 内评估，不参与梯度更新)；结论以 test / test_clean 为准。⚠ 实际执行与本条的偏差 (2026-09-15 审核 Q-12 后补写)：早停与选优确用 val；但模块消融的 Δ 主要以 val 协议报告，整图协议作为并列口径——因为 §5.6.15–5.6.17 证明两协议对这类差异的分辨力不同 (val 测不出、整图测得出)，故两个都报并注明协议，而非只报其一。此处如实写出偏差，以免读者误以为所有结论都基于 test_clean。

误差底线 σ_{seed} (本项目新增)：同配置、同数据、仅换随机种子重复训练，Kappa 的标准差。它给出“差异是否可分辨”的尺度： $|\Delta| < 1\sigma$ 视为不可分辨， $1-2\sigma$ 为弱证据， $> 2\sigma$ 才认为可分辨 (详见 §5.7 与 §5.11)。

3.4 no-data 处理与缺陷修复

问题	表现	修复
标签映射缺陷	官方 0 = no-data 被当作“背景”参与训练与评估	REMAP：0 及一切非 1-7 值 → 255 (ignore)，评估时屏蔽
低质量样本	部分图像 no-data 占比过高	训练集剔除 no-data > 10% 的图像 (312 张)
评估数据泄漏	早期 val/test 可能与训练集重叠	MD5 去重 + 三集两两互斥校验 + test_clean 隔离

3.5 可复现性设计

- **路径集中**：全部路由由 `paths.py` 提供，脚本内**零绝对路径**；本地数据路径只写在 `.env`（不入库）。
- **管线世代隔离**：不同数据投递后端（PNG / memmap）的训练结果**分别标记、禁止跨世代比较 Kappa**（详见附录 A.2）。
- **产物登记**：`experiments_index.json` 登记全部实验（参数量直读 checkpoint 张量、架构由形状反推、出处指向启动它的队列脚本）。
- **推送前审核**：`verify/pre_push_audit.py` 检查本机路径、内部语境词、大文件与误提交。

4. 实验结果

4.1 阶段 A：早期实验（957 张，含缺陷） — 历史结果

主模型 Kappa **0.4065**，基线中 DeepLabV3+ 最高（0.3806）、SegFormer-Lite 最低（0.1775）。120 轮消融中 w/o Adapter 反而最好（0.4621）。

本阶段结果不作为结论依据，原因有三：数据量不足（957 张）、标签映射含 no-data 缺陷、且当时的 DeepLabV3+ 基线带预训练主干（见 §5.6.6）。该阶段的图已全部撤出本报告（原图基于上述缺陷数据），仅保留文字记录。

4.2 阶段 B：扩大数据（2,257 张） — 中间结果


主模型 Kappa **0.6155**，后训练 **0.6239**。相比阶段 A 有大幅提升，但 **REMAP 缺陷仍未修复**，故同样不作为结论依据。

4.3 阶段 C：最终实验（1,768 张筛选 + 修复） — 结论依据

4.3.1 主模型与后训练

模型	Kappa	OA	说明
full_all_v2 (60 轮)	0.6312	0.7030	主模型
post_all_v2 (+30 轮微调, lr=5e-5)	0.6413	0.7112	在已收敛模型上继续训练

后训练带来 **+0.0101 Kappa**（ 2.40σ ，属可分辨的小幅提升）。




图中可见两点：① DeepLabV3+ 的**从零版本收敛晚于**自研模型（起势更慢），与 §5.2 的累计学习量分析一致；② 带预训练主干的那条曲线早在第 11 轮即越过 Kappa 0.5——这正是早期报告误判“架构学习效率更高”的来源。

4.3.2 对比实验 (7 个基线)


模型	参数量	Kappa	OA	最优轮/总轮
MSSACT-Net light (自研)	6.10M	0.6312	0.7030	54/60
DeepLabV3+ (从零, 协议内)	39.63M	0.6281	0.7018	60/60
DeepLabV3+ (预训练主干, 旁证 ⚠️ 非协议内)	39.63M	0.6876	0.7497	60/60
FPN-Seg	27.15M	0.6151	0.6912	60/60
FCN	23.72M	0.6144	0.6903	60/60
U-Net	2.44M	0.6054	0.6833	60/60
Swin-Unet-Lite	32.67M	0.5859	0.6693	60/60
PSPNet	13.59M	0.5175	0.6160	60/60
SegFormer-Lite	1.23M	0.3043	0.4441	60/60



分析：

- 协议内（全部从零训练）的公平对比下，DeepLabV3+ (39.63M) 与自研 6.10M 不可分辨 ($\Delta = +0.0039$, 0.78σ)，而后者参数仅为其 1/6.5。
- 表中 DeepLabV3+ 的**预训练版本**已明确标注为“旁证 ⚠️ 非协议内”，**不作为基线**。它比从零版高出的 0.06，正是预训练的贡献 (§5.6.6)。
- 自研模型以 6.10M 参数达到与 23–27M 级别模型相当的水平。



4.3.3 混淆矩阵与逐类 IoU






读图要点：自研模型与 DeepLabV3+ (预训练) 的混淆结构相似——两者的主要混淆都发生在 **裸地** ↔ **农田/森林** 与 **背景** ↔ **建筑** 之间，说明困难来自 **类间光谱相似性**与**标注边界模糊**，而非某个模型特有的缺陷。逐类看，DeepLabV3+ (预训练) 在 7 个类上均更高——但如 §5.6.6 所示，该优势主要来自预训练主干。

4.3.4 消融实验（8 个变体）

变体	Kappa	Δ Kappa vs 完整 (0.6312)	可分辨性
Bilinear-Up (可学习上采样 $\rightarrow$ 双线性)	0.6369	+0.0057 (0.96 σ_{diff} , 不可分辨)	
Transformer 2 层 $\rightarrow$ 4 层	0.6362	+0.0050 (0.84 σ_{diff} , 不可分辨)	
w/o EMR (改用标准 ResBlock)	0.6355	+0.0043 (0.72 σ_{diff} , 不可分辨)	
w/o Adapter-Scale	0.6342	+0.0030 (0.51 σ_{diff} , 不可分辨)	
Transformer 2 层 $\rightarrow$ 6 层	0.6335	+0.0023 (0.39 σ_{diff} , 不可分辨)	
w/o FPN (直接用最深层特征)	0.6314	+0.0002 (0.03 σ_{diff} , 不可分辨)	
w/o Transformer (含 Adapter)	0.6302	-0.0010 (0.17 σ_{diff} , 不可分辨)	
w/o ECSAM (去掉坐标注意力)	0.6272	-0.0040 (0.67 σ_{diff} , 不可分辨)	

关键发现：8 个变体的 Δ 极差 0.0097，全部落在 $\pm 1.7\sigma_{diff}$ 内（val 协议；整图测试协议下同一组变体全部为负、5 个可分辨，见 §5.6.16）——即在统计上 **不可分辨。其中 5 个变体（含把可学习上采样换成双线性的 Bilinear-Up）**反而略优于完整模型**。**



重要限定：这不等于“这些模块没有设计价值”。§5.6 的数值检验证明，其中若干模块**在实现上并未执行其声明的功能**（FPN 的多尺度融合被丢弃、未加位置编码的 Transformer 是置换等变集合算子）。因此本节**的正确解读是“在 val 协议下移除它们看不出影响”**。

⚠ 该解读必须加两重限定（2026-09-15 审核补）：① **不适用于 ECSAM**——移除它在整图协议下 $-0.0262 = 5.45\sigma_{diff}$ 可分辨，且在修复后架构上导致训练发散 (§5.6.15–5.6.16)；② **不适用于整图协议下的 Transformer**—— $-0.0202 = 4.20\sigma_{diff}$ 。即“移除无影响”只在 **val 协议 + FPN** 这个交集上成立，不能推广。

4.3.5 模块移除的架构适配说明

消融并非简单删除调用，部分变体需要架构层面的适配：

变体	适配方式
w/o EMR	EMR 残差块 → 标准 ResBlock 替换
w/o ECSAM	前向直接跳过坐标注意力（参数量 -0.055M）
w/o FPN	跳过 FPN，最深层特征直送 Transformer/解码器
w/o Transformer	移除全局自注意力与 Adapter（参数量 -1.6M）
w/o Adapter	仅移除 Adapter-Scale（低秩残差 + scale_factor）
Bilinear-Up	转置卷积 → 双线性插值 + 1×1 卷积

5. 深入分析

5.1 数据规模与标签质量：三项同时变化的混合效应

数据量	主模型 Kappa	同时发生的变化
957 张（阶段 A）	0.4065	原始状态
2,257 张（阶段 B）	0.6155	仅扩数据
1,768 张筛选（阶段 C）	0.6312	扩数据 + 标签修复 + 剔除低质量样本

这三项在阶段 C 是同时发生的，无法分离。特别是阶段 C 的图像数比阶段 B 更少 却更好，直接说明"数据量"不是唯一变量。

若要单独度量数据量效应，必须固定其他一切——这正是 §5.9 阶梯实验的设计：同一管线、同一协议、同一验证集，只改训练集规模（250/500/1000 张）。

少数类是否获益更多？ 阶段 B 的逐类 F1 显示道路 +0.390、水域 +0.385、裸地 +0.324、建筑 +0.255，但阶段 B 的标签映射仍有缺陷，其逐类数值只宜 作为趋势参考。阶段 C 的逐类 IoU 见 §4.3.3。

5.2 收敛速度的归因：调度 vs 架构

方法（以及它为什么能分离两者）：OneCycleLR 的学习率轨迹是解析已知的——给定 max_lr、总步数 T、warmup 比例，任一时刻的 η 可由公式算出，与模型无关。定义累计学习量：

$$S(t) = \sum_{\tau \leq t} \eta_{\tau}$$

若两个模型在同一水平上所需的 S 相同，则差异来自架构；若几乎所有模型都在相近的 S 比例处达到同一水平，则说明"第几轮收敛"只是调度曲线形状的映射。

⚠️ **方法学更正（审核 Q-17）**：在单一共享调度下，上式无法分离任何东西。同一次 60 轮 OneCycle 中 $S(t)/S(T)$ 是 t/T 的**确定单调函数、与模型无关**，故"达 K0.5 累计学习量 59.7%"只是"第 21/60 轮过阈"的**重新参数化**——把轮次乘以一个固定单调函数，不产生新信息，更谈不上把调度效应从架构效应中分离。要分离二者至少需要**不同调度**下的对照（\$5.6.14 的 best@49/best@109 恰由退火 终点决定，反而印证了"收敛轮次是调度的函数"这一平凡性）。⇒ **本节降级为描述性对照**："各模型过阈轮次"，不主张"分离"。

结果（达 Kappa 0.5 所需累计学习量占比；全部为 P-PNG 管线同协议）：


模型	达 K0.5 轮次	累计学习量
DeepLabV3+（预训练主干）	11	30.3%
Swin-Unet	14	39.7%
w/o ECSAM	16	45.7%
MSSACT-light / Trans-4L	21	59.7%
w/o EMR	22	62.2%
DeepLabV3+（从零）	28	75.9%
PSPNet	47	98.2%
SegFormer-Lite	未达到	—

结果解读（描述性；不外推为"学习效率"的架构比较）：

早期报告称"唯一例外是 DeepLabV3+（31.8%），其多尺度空洞卷积结构确实学习效率更高"。**该结论是错的**——31.8% 来自带 ImageNet 预训练主干的那一次运行。换成本项目自己训练的**从零版本**后，DeepLabV3+ 需要 **75.9%** 的累计学习量，**比自研模型的 59.7% 还慢**。

因此：**预训练带来的是早期收敛加速，而非该架构的学习效率优势**；在公平的 从零条件下，DeepLabV3+ 的收敛速度**不优于**自研模型。


绝大多数模型（11/16）集中在 40%–76% 区间，支持"第几轮收敛主要由调度曲线决定"这一判断。



5.3 标签质量上限的专项验证

6 个架构/容量差异极大的模型 (2.4M-39.6M) 在 test_clean (141 张) 上逐像素分析：

判据	数值
平均模型间一致率	0.7589
平均模型-人工标签一致率	0.6495
多数投票共识 vs 人工标签	0.6815




解读：模型之间的互相认同（0.7589）显著高于它们与人工标签的认同（0.6495），说明模型在彼此一致地 偏离人工标注。

必须声明的限定：共识法（Warfield et al., 2004 的 STAPLE 一脉）要求 **各模型的误差相互独立**

（Bouix et al., 2007）。本项目 6 个模型**共享训练集、损失函数与训练协议**，误差必然相关，因此共识评估会**偏向同族约定**。故本节结论应视为**提示性证据**，不能单独作为“标签上限已被证实”的依据。更强的证据来自 §5.6.8 的 Kappa 归属分析（与参考标准无关的纯数学量）。

5.4 过拟合诊断



以训练/验证 logits 的预测熵差 $\Delta H = H_{\text{train}} - H_{\text{val}}$ 衡量： ΔH 为负说明模型在训练集上更“自信”（预测更集中）。阶段 A 的主模型 $\Delta H = -0.241$ ，是所测模型中偏离最大的；而 SegFormer-Lite 接近 0（-0.0003）——但那是因为它**几乎没学到东西**（Kappa 0.3043）。

判读要点： ΔH 单独看会误读。它必须与**绝对性能**联合解读： ΔH 大且性能高 = 记忆了训练集； $\Delta H \approx 0$ 且性能低 = 欠拟合。本项目主模型属于前者，与 §5.9 的结论（自研模型更依赖数据量）互相印证。

5.5 训练基础设施与硬件效率优化

5.5.1 问题诊断

训练时 GPU 利用率仅 49.9%，**34.6% 的时间 GPU 完全空闲**。

5.5.2 瓶颈定位

关键判据是**参数量与每轮耗时的无关性**：1.55M 参数（144 s/轮）与 24.237M 参数（121–176 s/轮）耗时接近——说明瓶颈**不在计算**，而在数据侧。


根因：每样本解码**两张 1024² PNG**，却只裁出 256²，**94% 的解码结果被丢弃**；且 `num_workers=0` 时代码在主进程串行解码，GPU 全程等数据。


5.5.3 优化措施（四项）

措施	做法
预解码 memmap	一次性把 1024 ² PNG 解码为 uint8 memmap, 训练时随机切片
多进程加载	<code>num_workers > 0 + persistent_workers + prefetch_factor</code>
EMA 实现优化	改为直接遍历 <code>parameters()</code> , 避免每步构造 <code>state_dict()</code>
损失累积	用张量累加损失, 去掉每步 <code>.item()</code> 造成的 GPU-CPU 同步

5.5.4 优化效果

指标	优化前	优化后
GPU 利用率 (均值)	49.9%	84.3%
每轮耗时	144 s	12~15 s
数据阶梯每张图成本	≈170 ms/张	≈24 ms/张





上图右为**后来补测**的数据：切到 memmap 后每轮耗时随参数量单调增长， 正面确认瓶颈已从"数据受限"转为"计算受限"。

5.5.5 零性能损失验证

优化过程中逐项验证，**仅保留不改变训练语义的措施**：

#	措施	结论
1	memmap 预解码	✅ 数据内容与 PNG 路径 逐位一致 (verify/bench_parity.py)
2	EMA 实现重写	✅ 数学等价 (同一滑动平均公式)
3	损失张量累积	✅ 仅去掉同步，数值不变
4	多进程加载	✅ 不影响增强语义
5	~~增强改确定性 generator~~	❌ 已回退 ：导致 Kappa 0.6277 → 0.6031 (-0.0246)
6	~~batch 8 → 16/32~~	❌ 主动放弃 (需重调学习率，破坏可比性；且 batch=32 需 9.16 GB 显存会 OOM)
7	~~学习率/调度再调优~~	❌ 主动放弃 (会破坏与已完成实验的可比性)

回退验证（同配置、同数据、同协议）：

配置	Kappa	每轮耗时
旧管线（原始增强）	0.6277	144 s
确定性增强版	0.6031	12 s

配置	Kappa	每轮耗时
回退版 (memmap + 原始增强 + workers=0)	0.6293	14.7 s

结论：回退后性能完全恢复 (+0.0016, 在噪声内)，同时保留约 10 倍加速——加速的真实来源是 memmap 预解码，而非增强或并发改动。

5.6 架构有效性分析：为什么消融实验全部"无差异"

本节是对自研架构的否定性发现，也是本项目最重要的技术结论之一。

四处结构性缺陷（均由可复现的数值实验证实）：

#	缺陷	验证方式	结果
D1	FPN 的多尺度融合是死计算	归零 lateral_convs[0..2]；把整个 FPN 换成"仅第 4 支路"的等价算子	两次输出差恰好 0.0（逐位相同）
D2	解码器无跳连	前向路径 + 分辨率链追踪 + 边缘密度/FFT 实测	高分辨率特征从未到达输出；预测边缘密度达标签 4.56×，且周期 k=8 功率超额 1.66×
D3	Transformer 无位置编码	置换 token 后按逆置换还原	差 7.15e-07 → 置换等变，无空间感知
D5	ecsam[0] 是死模块	构造时 4 个阶段全建，前向条件是 i > 0；查各张量 .grad	第 0 个恒不执行，其 7 个张量的 .grad is None；1,040 个参数 (0.017%)

5.6.1 参数账目

见表 §3.1.3。关键结论：FPN 的 1,828,352 个参数（真实参数的 29.98%）不参与前向，实际参与前向的有效参数仅 4,270,792 (70.02%)；另有 ecsam[0] 的 1,040 个参数 (0.017%) 同样不参与前向。（更正说明：此前记 29.96% / 4,273,432 / 70.04%，分母误用了含 BN buffer 的 state_dict 总数 6,101,784；以真实参数 6,099,144 为分母的正确值为上述数字。）

5.6.2 D1：FPN 的多尺度融合未被使用

MSSACTNet.forward 只取 fpn_features[-1]；而 FPN.forward 的自顶向下融合循环 写入索引 i-1（即 2/1/0），最深层 laterals[3] 从未被融合增强。两者叠加的结果：laterals[0..2] 及其对应的 fpn_convs[0..2] 算完就被丢弃。

因此"w/o FPN"消融的真实含义是：移除"最深尺度上的一个 1×1 卷积 + 一个 3×3 卷积，外加 3 条被丢弃的支路"。

这不是"FPN 冗余"的证据，而是"这个 FPN 没有在工作"的证据。前者是多尺度融合的一般性结论，后者是本实现的缺陷结论——科学含义完全不同。

5.6.3 D2：解码器无跳连 → 细节为"合成"而非"测量"，并伴生棋盘伪影

必须精确表述：三次转置卷积上采样能够产生高频结构（转置卷积可学习上采样核），因此**不能说**"输出被限制在 8 像素粒度"。正确表述是：**没有任何通路让高频的输入 证据到达输出**——输出中的细节是解码器合成的，而非在高分辨率上测量到的。


实测（逐图 2D 计算，有效相邻像素对 2.94×10^8 ）：

模型	边缘密度	相对标签	周期超额比峰值
标签（参照）	0.00771	1.000	—
MSSACT-Net 6.10M	0.03516	4.563	k=8: 1.66×
DeepLabV3+ 39.63M	0.00884	1.147	无
U-Net 2.4M	0.02139	2.776	k=16: 1.17×

所有模型都过度碎裂（1.15×–4.56×），而 **MSSACT-Net 最严重（4.56×）**。且其伪影**具有周期性**：水平边缘图的 FFT 在周期 **k=8** 附近功率占比为标签的 **1.66 倍**，而 8 正是解码器（ $32^2 \rightarrow 256^2$ ，三次 stride-2 转置卷积）的总上采样倍数——这与堆叠转置卷积的**棋盘伪影**机制一致。

可证伪的预测：若伪影确由转置卷积造成，则 `nd_abl_bilinear`（双线性替代 转置卷积）应同时具备更低的边缘密度与更小的 k=8 超额。该变体的实测 Kappa **确实更高**（0.6369 vs 0.6312，**+0.0057**），与预测方向一致。

⚠ 该"方向一致"在换底后不再稳健（2026-09-14 补记）：在 `pos_enc` 底（0.6716）上，双线性为 **0.6643 = -0.0073 (-1.5 σ)**，即**符号翻转**。两次测量分别是 +0.0057 (+1.14 σ) 与 -0.0073 (-1.45 σ)，**都落在噪声内且方向相反** $\Rightarrow$ 正确结论是"**转置卷积 vs 双线性在本项目分辨力下不可分辨**"，**不能说"双线性更好"**。（伪影**存在**这一事实是实测的；但"换成双线性会提精度"不是。这两件事必须分开陈述。）



5.6.4 D3: Transformer 无位置编码

`TransformerEncoder.forward` 摊平为 token 后未插入任何位置信息，而 `nn.TransformerEncoderLayer` 不自带位置编码（不同于 ViT）。自注意力本身是 置换等变的：对置换矩阵 P , $A = \text{softmax}(QK^\top/\sqrt{d}) \rightarrow PAP^\top$ 。

数值验证： 随机置换 64 个 token，把输出按逆置换还原，最大绝对差 **7.153e-07**（浮点噪声量级）→ 模块对 token 顺序完全等价。

三点如实限定：

1. 不等价于"完全无用"：输入 token 来自卷积特征，其内容本身位置相关；且零填充/边界可充当 **隐式位置锚点**（CPVT/PEG 一脉的论证）。
2. 但无法完成基于空间邻近的上下文建模——而"长程空间上下文"正是分割网络中 全局注意力的标准用途。这是 **机制性降级**。
3. **量级参照（语境不同，仅作量级提示，审核 Q-25）**：DeiT-tiny 是纯 ViT（图像块 序列）语境，与本项目"卷积特征 + 零填充隐式位置锚"的情形强度不同，故该数字只作 **跨语境量级参照**，不作为本项目效应的预期。移除 DeiT-tiny 的位置编码使 ImageNet 精度由 72.2% 降至 68.2%。

5.6.5 与消融结果的对应（机制解释）

变体	实测 $\Delta Kappa$	机制解释
w/o FPN	+0.0002 (0.03 σ _diff, 不可分辨)	FPN 支路 0-2 是死计算 (§5.6.2)
w/o Transformer	-0.0010 (0.17 σ _diff, 不可分辨)	置换等变集合算子 (§5.6.4)
w/o ECSAM	-0.0040 (0.67 σ _diff, 不可分辨)	仅占 0.90% 参数
w/o Adapter	+0.0030 (0.51 σ _diff, 不可分辨)	仅 33K 参数 (0.54%)
Bilinear-Up	+0.0057 (0.96 σ _diff, 不可分辨)	消除转置卷积棋盘伪影 (§5.6.3)

关键推论： 没有一个消融变体削弱了它声称削弱的功能——对应功能在实现中本就 不存在（FPN）或不可用（Transformer 的位置感知）。故这一组消融**不能作为** "模块有效性"的证据，它衡量的是"移除无效计算的影响"。


5.6.6 基线为何领先？——从零对照推翻了本节的原始结论

设置	预训练主干	从零训练	预训练贡献
主数据集 60 轮	—	0.6359	—
阶梯 n250	0.2825	0.1762	+0.1063
阶梯 n500	0.4928	0.4393	+0.0535
阶梯 n1000	0.6310	0.4771	+0.1539

主数据集（60 轮，双方均从零）： 自研 6.10M **0.6320** vs DeepLabV3+ 39.63M **0.6359**, $\Delta = +0.0039$ (0.78 $\sigma \rightarrow$ 不可分辨)。

修正后的结论：

1. 从零训练的公平对比下，自研 6.10M 与 DeepLabV3+ 39.63M 不可分辨 ($\Delta = +0.0039$, 0.78σ)，而后者参数是前者的 6.5 倍。原报告"DeepLabV3+ 显著优于自研 (+0.0720)" 的表述不成立：那 0.0720 中约九成以上来自预训练主干（按可加性点算术为 $(0.0720-0.0039)/0.0720 \approx 95\%$ ，但两项各自都带 $\sqrt{2}\sigma \approx 0.007$ 的不确定性，故不给精确百分数——审核 Q-04）。
2. 预训练主干是本任务上最大的单项杠杆：同一模型仅切换权重初始化，贡献 $+0.054 \sim +0.154$ Kappa（阶梯档；满数据档收窄至约 $+0.05 \sim +0.06$ ，见 §6.1）。作为对照，val 协议下全部模块消融 $\leq 1.00\sigma_{\text{diff}}$ (≈ 0.0059)，裁剪策略为 0.0199–0.0223。杠杆排序：换主干权重 $\gg$ 改训练策略 $>$ 增删模块。



核验更正 (取证过程)： `weights=None` 并不足以关闭主干预训练。torchvision 的 `deeplabv3_resnet50` 有两个互相独立的权重参数：`weights`（整体/分割头）与 `weights_backbone`（主干），后者默认即 `ResNet50_Weights.IMAGENET1K_V1`。

权重级取证（与该权重的官方文件逐张量比对）：

构造方式	与官方权重相同的张量	相同参数量占比
<code>pretrained_backbone=True</code>	264 / 265	$23,551,744 / 23,561,152 = 100.0\%$
<code>pretrained_backbone=False</code>	0 / 265	0.0%

（唯一不同者是 `conv1`，因输入改为 3 通道而被替换。）该预训练覆盖了该模型 59.4% 的参数；其来源是 PyTorch 官方在 **ImageNet-1K**（1000 个自然图像类）上训练的 ResNet-50，官方指标 $\text{acc}@1 = 76.13\%$ 。

行为级取证：若该参数不生效，两次运行应当统计一致；而实测两者相差 $+0.054 \sim +0.154$ Kappa。参数确实在起作用。

5.6.7 通道-空间容量比

配置	最深特征	元素数	输入元素数	比值
light [32, 64, 128, 256]	256×32×32	262,144	196,608	1.33×
large [64, 128, 256, 512]	512×32×32	524,288	196,608	2.67×

即**最深特征图的标量数量超过输入图像本身**（large 达 2.67 倍），而这些表征最终被 压缩回 256^2 输出，其中还有 29.98% 的参数不参与前向。此处**并非** transformer 的 秩亏问题（token 数 $N = 1024 > d_{model}$ ），而是**空间侧信息量与通道侧容量的失衡**。


5.6.8 边界质量为何在聚合指标上不可见


距类边界	像素占比	共识 vs 标签	模型间分歧
0（边界像素）	2.36%	0.4577	0.2881
1-2 px	5.34%	0.4891	0.2877
3-4 px	5.17%	0.5327	0.2847
5-8 px	8.75%	0.5882	0.2789
>8 px（内部）	78.39%	0.7294	0.2294

Kappa 归属上限（oracle 作弊实验）：

模型	完美解决边界	Δ 边界	完美解决内部	Δ 内部
MSSACT-Net	0.5936	+0.0161	0.8700	+0.2925
DeepLabV3+	0.6654	+0.0159	0.8800	+0.2306

完美预测全部边界像素（2.36%）最多换来 +0.016 Kappa；内部像素（78.39%）值 +0.23 ~ +0.29。 因此任何**面向边界锐化**的模块在聚合 Kappa 上的可见空间被限制在 ≈ 0.016 以内——与观测到的消融散布 0.008 同量级。





勘误：早期报告称"**93.0%** 像素在类边界上"，并据此得出"标签碎片化"与"越纯净区域模型越不同意标签"两条结论。经复核，原实现把标签批次按 (N, H, W) 三维数组沿 $axis=0$ 求差分，**跨图像的像素差被误判为类边界**，故得出虚高比例。改为逐图 2D、且仅统计两个**不同有效类别**之间的相邻像素后，真实边界比例为 **2.4%**，结论方向亦反转（准确率随距边界距离**单调上升**）。

5.6.9 架构变体实测结果（两条管线互证）

管线	变体	参数量	Kappa	相对基线
P-MEM-ROLL	完整模型	6.099M	0.6320	—
	D1 联合消融（-FPN -Trans -Adapter）	2.002M	0.6293	-0.0027
	D2 解码器坐标注意力	6.112M	0.6375	+0.0055
	D3 超轻量通道	1.545M	0.6103	-0.0217
	D4 大容量通道	24.237M	0.6365	+0.0045
P-PNG	完整模型	6.099M	0.6312	—
	D1 联合消融	2.002M	0.6277	-0.0035
	D3 超轻量通道	1.545M	0.6119	-0.0193

三条读表要点：

1. 移除 **67.2%** 的参数只损失 **~0.003**（两条管线分别 -0.0027 / -0.0035，互证）。
2. 把坐标注意力移到解码器（D2）反而最好（+0.0055 / +0.0029），与"注意力在上采样路径上才有效"的文献结论一致。
3. 容量确有作用：D3（通道减半）显著下降（-0.0217 / -0.0193，约 4σ ），而 D3 仍保留全部模块——所以"模块不重要"**不等于**"容量不重要"。精确表述是：**在 val 协议下，占参数 67.14% 的两个模块无可测量贡献，而通道宽度才是性能来源。**（收窄：在 test_clean 图像上（整图或 4 角

裁剪均可) Transformer 的贡献为 $-0.0202 = 4.20\sigma_{\text{diff}}$; FPN 不可分辨 ($-0.0064 = 1.33\sigma_{\text{diff}}$) ; 见 §5.6.16–5.6.17。)

5.6.10 可验证的修复路径

优先级	修复	预期效果	状态
P0	FPN 改为 真正使用 多尺度输出 (解码器接收全部 4 层)	恢复多尺度融合语义; 死支路变活	✅ 已实现 (<code>use_skip=True</code> , 29.99% 死参数 $\rightarrow$ 0.016%)
P0	解码器加入 encoder$\rightarrow$decoder 跳连	修正 §5.6.3 的粒度瓶颈	⚠️ 已否决 : 单独 -0.0150 (3σ) , 合并 -0.0325 ; 两个候选机制 (256^2 融合、学习率) 均证伪
P1	Transformer 加入 位置编码 (2D sincos)	恢复空间邻近建模能力	弱正向 : $+0.0061$ ($1.03\sigma_{\text{diff}}$) ; 置换等变性已被打破 ($9.5e-07 \rightarrow 1.9$)
P1	重新定义消融语义: 先修实现, 再评估"模块是否有效"	使消融结论可解释	换底为 <code>lgR120_pos_abl_*</code> (底 = <code>pos_enc</code>) ; 旧底因 数值发散 弃用
P2	容量重新配比, 修正 $2.67\times$ 容量膨胀	参数效率	🟡 未做
P3	<code>ecsam_stage0</code> 是否默认启用	使死参数归零	🟡 优先级低 (仅 0.017% 死参数)

这张表的教训值得单独记下: P0 的两项 (跳连、FPN 多尺度) 当初排在最前, 部分依据是 "DeepLabV3+ 领先 $+0.0720$, 因为它有低层跳连而本模型没有" 这一归因。该归因后被 **两次推翻** (预训练主干混淆; 从零对照 $+0.0039 = 0.66\sigma_{\text{diff}}$) 。 **一条被推翻的归因, 曾驱动出一项实测有害的改动**。而 §5.6.3 自己的证据当时已指向 **双线性上采样** (棋盘伪影源自堆叠转置卷积, 且 `nd_abl_bilinear` 是全部消融中最好的 变体) 。**应当以本项目的直接证据为准, 而不是类比外部模型**。

5.6.11 本节局限

- 1. σ_{seed} 的种子数仅 4 (文献建议 ≥ 10) , 故适用于**量级判断**而非精确检验。
- 2. **等效性检验 (TOST) 已完成并落盘**: `analysis/tost_equivalence.py` $\rightarrow$ `results/artifacts/tost_equivalence.json` , SESOI = 0.02 (预指定) 。实测配对 bootstrap 的 95% CI 半宽 $\delta \approx 0.010$ (如 `nd_unet` vs `full_all_v2` 为 $[-0.0532, -0.0318]$) , **小于** SESOI。
⚠️ **表述限定 (审核 Q-27)** : SESOI = 0.02 意味着 TOST 只能**排除 ≥ 0.02 的差异**, 而全文讨论的是 0.005–0.01 量级的差异——等效界限宽于感兴趣的效应量 2–4 倍时, TOST 通过**不能为**"这些小差异不存在"背书, 只能说明"没有 0.02 级以上的差异"。若需支持 0.01 级的等效声明, 须把 SESOI 预指定为 0.01 并重算。关键是**配对设计**: 两个模型跑同一批图, Δ 的方差远小于各自 Kappa 的方差。尚须区分两套误差模型——**种子层** (换种子重训差异还在吗, 误差 $\sqrt{2}\cdot\sigma_{\text{seed}} \approx 0.010$) 与**测试集层** (取样了哪些图, 误差 ≈ 0.011) ; 两者量级接近但回答不同问题, 不合并。
- 3. 缺陷检验在 **light** 配置上完成; 大配置结构相同、结论可直接推广, 但未复跑。
- 4. 分带与 Kappa 归属基于**已缓存的 6 个模型预测**。原因已查明: 预测缓存 `results/consensus_analysis/pred_{tag}.npz` 存在两种不兼容布局 (旧 $564\times 256\times 256$ / 新

141×1024×1024) , eval_rigor 遇形状不符合会**静默跳过**，导致 G1 的 8 个消融、lg_D1..D4、lgR_D1..D4、nd_pspnet、nd_segformer 等**从未进入测试集协议**——即报告此前关于消融的结论只有 val Kappa 单一来源，缺测试集侧独立证据。修复：queues/run_post_fix.py 对 44 个 tag 做全量重推理（覆盖前自动备份 consensus 目录），逐带分解与 TOST 随之覆盖全部结论。**该步在 IgR120 组训练结束后执行。**

5.6.12 缺陷修复：向后兼容实现与验证 (2026-09-13)

修复原则：只加开关，不改默认。 三个新参数默认值 == 修复前行为，故既有 103 个实验的 checkpoint 仍能以 strict=True 加载、既有结论仍可复现。

开关	作用	修复	参数变化
use_skip=True	解码器逐级接入主干同分辨率特征；有 FPN 时接入 FPN 四级输出 （死支路变活，同时修好 D1），无 FPN 时接入编码器浅三层	D1+D2	6.099M → 6.464M (+5.99%)
pos_enc=True	Transformer 注入 2D 正弦位置编码（dim 通道对半分为行/列，每半内再对半为 sin/cos）	D3	不变
ecsam_stage0=True	第 0 阶段也应用 ECSAM	D5	不变（本轮未启用）

修复的验证证据（五项全部通过）：

验证项	结果
默认路径 逐位一致	默认配置加载旧权重成功；新旧输出最大逐元素差 0.000e+00 （不是"很小"）
键集合一致	mssact_light() 与既有 checkpoint 键集合完全相同
置换等变性被打破	残差 9.537e-07 → 1.821e+00 （放大约 190 万倍）
梯度可达性	基线无梯度参数 29.99% → 打开 use_skip 后仅剩 ecsam[0] 的 0.016%
组合路径	10 种消融组合 × 跳连（含 bilinear / no_fpn / no_trans / trans4l / trans6l）输出与梯度完整性全部通过

诚实限定：以上验证的是**修复实现的正确性**（缺陷确已消除、既有行为未被破坏），**不是**修复的性能效果。

5.6.13 修复的性能效果是负面的（第一轮实测）

修复在**当前协议下没有带来收益，全修反而明显更差**。四个实验同为 120 轮 / pt20 / bs8 / lr2e-4, σ_seed = 0.0050:

实验	修复内容	Kappa	best@	Δ vs 基线	判定
lgR120_full	未修复（基线）	0.6655	91	—	参照
lgR120_fx_pos	D3 位置编码	0.6716	96	+0.0061	弱 (1.03σ_diff)

实验	修复内容	Kappa	best@	Δ vs 基线	判定
lgR120_fx_skip	D1+D2 跳连	0.6505	114	-0.0150	可分辨 (3 σ)
lgR120_fx_all	三处全修	0.6330	62	-0.0325	可分辨

三点必须同时陈述：

1. **两项修复合起来比任何单项都差得多** (-0.0325 vs -0.0150 / +0.0061) ， 即**非加性** —— 说明另有原因，不能简单读作"修复有害"。
2. **过拟合假设已被推翻**。 `fx_all` 的训练 loss 是四者中最高的 (0.7237 vs 基线 0.6269) ， `fx_skip` 次之 (0.6734) 。 **训练集拟合更差、验证也更差 $\Rightarrow$ 是欠拟合 / 优化困难，不是过拟合**。 训练 loss 偏高又叠加了容量，指向**优化/条件数问题**。
3. **两个假设都已检验，且都被证伪** (各为单变量实验) ：

假设	检验	结果	判定
H1 256 ² 全分辨率融合有害 (<code>_fuse</code> 把主干最浅层直接接到输出，并让 FPN 三条全分辨率 3 $\times$ 3 支路首次进入梯度通路)	<code>skip_stages=(1,2)</code> ，只融合 128 ² /64 ²	0.6466，与全融合的 0.6505 仅差 -0.0039 (<1 σ)，距基线仍差 -0.0189 (3.8 σ)	证伪
H2 学习率不再匹配 (2e-4 是给未修复模型调的)	同配置降到 lr=1e-4	skip: 0.6505 $\rightarrow$ 0.6395 (-0.0110) ； 全修: 0.6330 $\rightarrow$ 0.6170 (-0.0160) —— 更低 LR 更差	证伪

$\Rightarrow$ **稳健事实：含跳连的配置全部低于基线** (0.6170–0.6505 vs 0.6655) ， 不含跳连的 `fx_pos` 反而高于基线 (0.6716) 。 **有害的成分是跳连本身，与融合层级、学习率都无关**。 故 D1/D2 的"修复"在本项目中被**实测否决**——这不是"没修好"，而是"修了确实更差"，因而应当作为一项被拒绝的改动如实记录，而不是当作遗留缺陷。

5.6.14 修复后消融：换了底，以及一次数值发散

在 `use_skip+pos_enc` (`fx_all`, 0.6330) 这个底上跑消融时，完成的三项显示**底本身不稳定**：

实验	结果	性质
lgR120_abl_no_emr	0.6600 (相对底 +0.0271)	移除 EMR 大幅 改善 ——说明底病态，不是 EMR 有害
lgR120_abl_no_ecsam	0.4657@ep19 后 发散	见下
lgR120_abl_no_fpn	未跑完即停	—

`abl_no_ecsam` 的**发散已确证为数值失效，不是塌陷期**：epoch 20 起验证预测**冻结** (OA 精确恒定在 0.36989283961174824) ， 训练 loss 变成精确的 0.0 (连续 17 轮) ， `best.pt` 权重最大绝对值达 **1.26e4** (爆炸；tensor 无 NaN，但输出退化为常量) 。 **关键在于区分"塌陷"与"发散"**：发散后的指标会精确冻结，看起来像"收敛到一个较差的平台"，极易被误读为模块效应。故 `analysis/fix_attribution.py` 与 `queues/run_queue_fix3.py` 都加了显式检测 (loss 连续为 0 / OA 长时间精确不变) ， 并在表中标为**不可引用**，而不是把它当作读数。

因此消融换了底（选择理由在跑之前就写定，见 `queues/run_queue_fix3.py`）：底改用 `lgR120_fx_pos`（`pos_enc=True`，0.6716），因为它是修复族里**唯一稳定、且唯一高于未修复基线**的配置，且不含已被实测否决的跳连。8 个消融变体以 `lgR120_pos_abl_*` 另存命名，**不覆盖旧结果**——旧底上的三项数据仍保留在案，作为“底的病态性”的证据。

方法论提醒（本条比结论本身更重要）：修复实验的价值不在于“修好了就该更好”的先验，而在于它把消融从“模块没接线”变成“模块接了线”。若 H1/H2 都不能解释这个负结果，那么**“缺陷导致无差异”这一诊断虽然成立，但“修好缺陷就能提升精度”的推论被实测否定**——这同样是一个可发表的结论，且比前者更有信息量。

数据来源：`results/artifacts/fix_attribution.json`（由 `analysis/fix_attribution.py` 生成，未跑完的实验不做任何判定）。H1/H2 由 `queues/run_queue_fix2.py` 执行，其后在**预先写定的规则下**选定消融基线——规则写在代码里，不是看到结果再挑。

为什么必须重跑基线：OneCycle 的收敛轮次由**退火终点**决定（best@49 对应 60 轮、best@109 对应 120 轮），故 60 轮与 120 轮是**两个不同的学习率调度**，其 Kappa 差值混合了“调度变化”与“训练量”两种效应。⇒ 修复归因必须有**同为 120 轮的基线**，并单独建立可比组 **G4-MEM-ROLL-120ep**；`experiments_index.json` 中已写明**禁止把 G4 与 G2（60ep）相减**当作“预算效应”。

阶段	实验	目的
一	<code>lgR120_full</code> / <code>lgR120_fx_skip</code> / <code>lgR120_fx_pos</code> / <code>lgR120_fx_all</code>	修复归因：分别测 D1+D2、D3、以及 三处全修
二	<code>lgR120_abl_{no_emr,no_ecsam,no_fpn,no_trans,no_adapter,bilinear,trans4l,trans6l}</code>	首次可解释的消融 ：全部以 <code>use_skip+pos_enc</code> 为底，模块作用不再被缺陷掩盖

协议：120 轮 / pt20 / bs8 / lr2e-4，实测 43–59 s/轮（跳连使解码器计算量增加约 10%）。**判别门限（2026-09-15 审核修正）**：本书的比较均为**两单次运行之差**，其标准差为 $\sqrt{2} \cdot \sigma_{\text{seed}} = \mathbf{0.0059}$ （val 协议， σ 已扩到 $n=10$ ），故 $|\Delta| \geq 2\sqrt{2} \cdot \sigma = \mathbf{0.0119}$ 才记为可分辨。此前误用 $2\sigma_{\text{seed}} = 0.0100$ （相当于差值分布的 1.41σ ，偏松 41%）。

修复过程中新发现的两处元问题（已修，均影响报告可信度）：

1. **测试集协议此前只覆盖一半结论**（详见 §5.6.11 第 4 条）。**推论**：`rigor.json` 里“没有某个 tag”不等于“它不显著”，必须先确认缓存是否存在、布局是否正确。
2. **TOST 此前只有打印、没有产物**：判定无法引用、无法复现，新增 tag 也不会自动扩展。已成 `results/artifacts/tost_equivalence.json` 一等产物，并复用 `eval_rigor` 的**度量函数**（不重复实现，避免口径漂移）。

相关记录：`docs/缺陷修复_20260913.md`；队列 `queues/run_queue_fix.py`；评测后置链 `queues/run_post_fix.py`。

5.6.15 修复后消融：首次给出方向可解释的消融表

底 = lgR120_fx_pos (pos_enc=True , 0.6716) , 同为 120 轮 / pt20 / bs8 / lr2e-4, 判别门限 $|\Delta| \geq 2\sigma = 0.0100$ 。全部实现均取自实测，不是预期。

全部 8 个变体已完成 (底 = lgR120_fx_pos , 0.6716) :

变体	Kappa	best@	Δ vs 底	Δ/σ	判定
(底: pos_enc)	0.6716	96	—	—	参照
Transformer 2→4 层	0.6728	113	+0.0012	+0.23	不可分辨
去掉 Adapter-Scale	0.6704	97	-0.0012	-0.23	不可分辨
Transformer 2→6 层	0.6704	113	-0.0012	-0.23	不可分辨
去掉 FPN	0.6679	90	-0.0037	-0.74	不可分辨
去掉 EMR	0.6649	94	-0.0067	-1.34	弱
双线性替代转置卷积	0.6643	110	-0.0073	-1.45	弱
去掉 Transformer	0.6600	116	-0.0116	-2.33	可分辨
去掉 ECSAM	—	—	—	—	训练发散，不可引用 (见下)

即：修复后架构上，7 个可读变体无一项为正、1 项为弱负 (去 Transformer -0.0116 = 1.95 σ _diff, 按本报告自己的 $\sqrt{2}\sigma$ 口径未达 2 σ 可分辨)；其余全部落在 $\pm 1.0\sigma$ _diff 内。加深 Transformer 到 4/6 层没有收益 ($\pm 0.0012 = 0.20\sigma$ _diff) $\Rightarrow$ 它的贡献在 2 层就已饱和，回到 §5.6.6 的结论：性能来源是密集卷积的通道宽度，而不是注意力深度。

与未修复架构上的同一组消融对照 (这是本节的核心) :

变体	未修复架构 (60 轮, 底 0.6312)	pos_enc 底 (120 轮, 底 0.6716)
去掉 Adapter	+0.0030 (移除反而更好)	-0.0012
去掉 FPN	+0.0002 (移除反而更好)	-0.0037
去掉 EMR	+0.0043 (移除反而更好)	-0.0067
双线性	+0.0057 (移除反而更好)	-0.0073
去掉 Transformer	-0.0010 (几乎为零)	-0.0116 (可分辨)
去掉 ECSAM	-0.0040 (正常收敛)	发散

三点结论：

1. 未修复架构上 6 项里有 4 项是"移除反而更好"； pos_enc 底上全部为负 —— 这是"模块确在起作用"的signature。即：把位置编码这一处缺陷修好后，消融终于从"移不移除都一样"变成了"每个模块都有非负贡献"。
2. 位置编码修复的价值不在表头 Kappa，而在可解释性。它自己只带来 +0.0061 (1.03 σ _diff, 弱)，但移除 Transformer 的代价从 -0.0010 (0.17 σ) 变成 -0.0116 (1.95 σ _diff) —— 按

本报告自己的 $\sqrt{2}\sigma$ 口径尚未达 2σ 可分辨，但已从"完全无信号"变为"接近可分辨"。机制上说得通：无位置编码时注意力是置换等变的集合算子 (§5.6.4)，本就做不了空间建模，移除它自然无所谓；注入 2D 正弦位置编码后它才能做邻近建模，于是开始承载性能。这正是"缺陷掩盖了模块作用"这一诊断的直接、正向的证据。

3. ECSAM 移除导致的训练发散在两个不同的底上各复现一次（`use_skip+pos_enc` 底与 `pos_enc` 底，均为 `loss` 连续为 0、验证指标精确冻结、权重最大绝对值爆炸）。而在未修复架构上移除 ECSAM 能正常收敛 (0.6272)。⇒ ECSAM 的作用是"条件性的训练稳定器"，而不是"没有贡献"——此前"移除 ECSAM 一致更好"的说法只在未修复架构上成立，不能外推。

两个必须同时说清的限定：

- 双线性 vs 转置卷积不可分辨：两次测量符号相反（未修复底 $+0.0057/+0.96\sigma_{\text{diff}}$ 、`pos_enc` 底 $-0.0073/-1.23\sigma_{\text{diff}}$ ），都落在噪声内。伪影存在是实测事实，但"换成双线性会提精度"不是。
- "每个模块都有非负贡献" ≠ "修好缺陷就提精度"：底本身 0.6716 相对未修复基线 0.6655 只有 $+0.0061$ （弱）。模块贡献变为非负，与整体精度是否提升，是两件事。

5.6.16 ⚠ 意外发现：「消融平坦」这一核心结论依协议而变

背景：本轮修复了 `eval_rigor` 的一个缺陷（见 §5.6.11 第 4 条与 §7 的溯源）——整图预测缓存有两种不兼容布局，导致 14 个以上 tag 从未进入测试集协议。修好后把 8 个消融变体全部重推（50 个 tag 覆盖、TOST 从 5 对增到 25 对），于是第一次能在整图协议上核对消融表。结果与 val 协议大面积不符：

变体	val 协议 Δ (底 0.6312, $\sigma=0.0050$)	整图测试协议 Δ (底 0.5774, $\sigma=0.0041$)	方向
去掉 EMR	$+0.0043 (+0.72\sigma_{\text{diff}})$	$-0.0049 (-1.02\sigma_{\text{diff}})$	相反
去掉 FPN	$+0.0002 (+0.03\sigma_{\text{diff}})$	$-0.0064 (-1.33\sigma_{\text{diff}})$	相反
去掉 Adapter	$+0.0030 (+0.51\sigma_{\text{diff}})$	$-0.0107 (-2.23\sigma_{\text{diff}})$	相反
双线性上采样	$+0.0057 (+0.96\sigma_{\text{diff}})$	$-0.0090 (-1.87\sigma_{\text{diff}})$	相反
Transformer 2→4 层	$+0.0050 (+0.84\sigma_{\text{diff}})$	$-0.0102 (-2.12\sigma_{\text{diff}})$	相反
Transformer 2→6 层	$+0.0023 (+0.39\sigma_{\text{diff}})$	$-0.0033 (-0.69\sigma_{\text{diff}})$	相反
去掉 ECSAM	$-0.0040 (-0.67\sigma_{\text{diff}})$	$-0.0262 (-5.45\sigma_{\text{diff}})$	一致 (均负)
去掉 Transformer	$-0.0010 (-0.17\sigma_{\text{diff}})$	$-0.0202 (-4.20\sigma_{\text{diff}})$	一致 (均负)

倍数口径：左列除以 $\sqrt{2}\cdot\sigma_{\text{val}} = 0.0059$ ，右列除以 $\sqrt{2}\cdot\sigma_{\text{test}} = 0.0034$ （ σ 均为 $n=10$ ；两单次运行之差的标准差是 $\sqrt{2}\sigma$ ，见 §5.6.11 第 2 条）。

8 项里有 6 项符号相反。val 协议下 6/8 为"移除反而更好"（但全部 $\leq 0.96\sigma_{\text{diff}}$ ，本就在噪声内）；整图协议下 8/8 全为负，且 4/8 达到 $2\sigma_{\text{diff}}$ 可分辨（去 Transformer / 去 ECSAM / 去 Adapter /

Transformer 2→4 层)。**正确读法 (§5.6.17 的解剖结论)**：不是"两个协议测出了相反的稳健差异"，而是"**val 协议测不出这类差异、整图协议测得出**"——val 侧的正 Δ 是噪声，噪声没有符号。

σ_{seed} 本身也是协议相关的 (本轮实测，均 $n=10$)：val 协议 **0.0042** (221 张 256^2 裁剪)、整图测试协议 **0.0034** (141 张 1024^2 滑窗)。⇒ 判定某一协议的差值必须用**同协议**的 σ ；

`analysis/tost_equivalence.py` 已改为自动取匹配口径并标注来源。

三条必须同时说清的推论：

1. **"消融平坦、模块无可测量贡献"是 val 协议下的结论，不能推广到整图协议。** 在整图协议上，**Transformer 的贡献是可分辨的** ($-0.0202 = 4.20\sigma_{\text{diff}}$)，而 FPN 仍不可分辨 ($-0.0064 = 1.33\sigma_{\text{diff}}$)。此前"占参数 67.14% 的两个模块都无可测量贡献"这一说法**过宽**，应收窄为"FPN 在所有协议下均不可分辨；Transformer 在整图协议下可分辨"。
2. **缺陷诊断仍然成立，且与之并列而非互斥。** D1 (归零 FPN 侧向支路输出逐位不变)、D3 (置换等变 $7.15e-07$) 是**与协议无关**的实现层事实。故"消融平坦"有**两个**成因：架构缺陷 + val 协议对该类差异不敏感。二者都已实测，不互相取消。
3. **两个协议的推理窗口都是 256^2** (val 为每图 4 固定角 patch；整图为 256^2 滑窗 + 高斯混合)。**因此不存在"跨尺度泛化"之别**——更正此前"训练 256^2 、测试 1024^2 "的说法。真实差异 = 图像集(val 221 / test_clean 141) + 覆盖率(4 角 $\approx 25\%$ 像素 / 全图)
4. 窗口混合(无 / 高斯) + 汇聚方式。任何"无差异"表述都必须**注明协议**。

5.6.17 协议解剖：符号翻转由图像集驱动，不是评估流程 (实测)

四个因子逐一隔离 (同一批 checkpoint，预登记判读规则见 `analysis/protocol_dissection.py` 的 docstring)：

臂	评估内容	full	w/o trans	w/o ecsam	w/o fpn	bilinear	w/o emr
A val 4 角 patch (原值)	val 图像	0.6312	-0.0011	-0.0041	+0.0002	+0.0056	+0.0043
B test_clean 4 角 patch (复刻 val 流程)	仅换图像集	0.5590	-0.0168	-0.0282	-0.0142	-0.0080	-0.0045
C test_clean 256^2 网格无混合	全覆盖、无混合	0.5646	-0.0198	-0.0254	-0.0084	-0.0114	-0.0062
D test_clean 滑窗+高斯 (现整图协议)	全覆盖+混合	0.5774	-0.0202	-0.0262	-0.0064	-0.0090	-0.0049
E test_clean 512^2 窗口+高斯	窗口尺度	0.5805	-0.0206	-0.0241	-0.0030	-0.0053	+0.0005

判读 (预登记规则自动归类，5/5 一致)：

1. **$\Delta B \approx \Delta D \approx \Delta C$ ，全部远离 $\Delta A \Rightarrow$ 符号翻转由图像集本身驱动**，与覆盖、高斯混合、窗口尺度基本无关。在 test_clean 图像上**即使用与 val 完全相同的 4 角裁剪流程**，消融 Δ 也立刻呈现真实负值。
2. **"6 项符号相反"的正确读法**：val 侧 6 个正 Δ 全部 $\leq 1.2\sigma$ (本就在噪声内)；test_clean 侧的负 Δ 才是真实信号 ($5/8 > 2\sigma$)。**不是"两个协议测出了相反的 稳健差异"，而是"val 测不出、**

test_clean 测得出”。 ⇒ 消融应在 test_clean 型（整图、全量覆盖）协议上读数；val 协议对该类差异不敏感。

3. **窗口尺度有次要作用**（E vs D）：512² 窗口使所有模型小幅提升（+0.003~+0.008），w/o emr 升至 ≈0，但排序不变——不足以解释翻转。

4. **修正后的机制图景**：模块（Transformer / ECSAM / FPN 侧向融合）的贡献在 **test_clean 图像的内容分布**上才可测。val 子集（同一筛选池的另一部分）对这些差异不敏感——这是划分的**代表性问题**，不是“能力维度”不同。

产物：results/artifacts/protocol_dissection.json；脚本 analysis/protocol_dissection.py
（含臂定义与预登记判读规则）。

两个绝对值的缺口也因此可以精确闭合（full_all_v2: val 0.6312 → 整图 0.5774，共 -0.0538）：

因子	贡献	依据
图像集（val→test_clean，同为角块直推）	-0.0722	臂 A vs 臂 B（流程完全相同）
覆盖率（角块→全覆盖、无混合）	+0.0056	臂 B vs 臂 C
高斯混合（无混合→滑窗融合）	+0.0128	臂 C vs 臂 D
合计	-0.0538	恰好闭合

选模偏差的量级（best.pt 按 val Kappa 挑选，故 val 数字带选择偏差）：其上界 = best - 末轮 val。

实测解剖所用 6 个 nd_* checkpoint 均 ≤0.0001（皆训练至 60 轮上限，选模几乎未起作用），lgR 系约 0.003，最大 0.0081（lgR120_fx_pos）。⇒ 选模偏差真实存在但是**三阶小量**；两协议绝对差的主项是**图像集难度**（test_clean 更难 -0.072），流程细节往复补偿 +0.018。

两点纪律：① 推理策略对消融 Δ 有 ±0.01 级影响（如 w/o FPN：ΔA +0.0002 → ΔB -0.0142 → ΔD -0.0064，流程项捞回约一半），但不足以改变任何变体的排序结论——“次要”即此义；② “消融应以 test_clean 型协议读数”这条建议**本身来自对 test_clean 的观察**，而该集合已被 rigor/TOST/解剖多次使用——未来新实验的协议选择应**预登记**，避免在同一份 test_clean 上反复做决定造成变相选模。

5.7 随机种子噪声底线（多种子实测）

方法学必要性：本项目早期全部比较都基于**单次运行**（seed=42）。文献指出这不足以支持“无差异”结论：GEO-Bench（NeurIPS 2023 D&B）建议 ≥10 个种子，并指出 3–5 个种子不足以给出可靠置信区间。

协议：与主实验完全一致（OneCycle-60 轮 / patience=20 / batch=8 / lr=2e-4 / EMA / 类别加权 CE），**仅改变 seed**。seed 控制模型初始化、DataLoader 打乱顺序与几何增强抽样（裁剪位置由 epoch_seed 决定，与 seed 无关）。

配置	种子数	mean	σ_seed	极差	区间
完整模型 MSSACT (P-MEM-ROLL)	10	0.6349	0.0042	0.0136	[0.6276, 0.6412]

配置	种子数	mean	σ_{seed}	极差	区间
DeepLabV3+ 预训练主干 (P-MEM-ROLL)	3	0.6931	0.0034	0.0066	[0.6895, 0.6961]
DeepLabV3+ 从零 (P-MEM-ROLL)	6	0.6267	0.0041	0.0120	[0.6213, 0.6333]
REF-参照(非种子组): 完整模型/DeepLab 的 P-PNG 单次结果	2	0.6594	0.0399	0.0564	[0.6312, 0.6876]

2026-09-15 扩展：完整模型种子数 $n=4 \rightarrow 10$ 、DeepLabV3+ $n=3 \rightarrow 9$ ，达到文献建议的 ≥ 10 （DeepLab 因下述原因拆为两组）。 σ_{seed} 是评估协议相关的，故两个口径各测一份（同一批 checkpoint 分别按 val 与整图协议评估）：

组	n	均值	σ_{seed}	极差
完整模型 MSSACT (val 协议)	10	0.6349	0.0042	0.0136
完整模型 MSSACT (整图协议)	10	0.5680	0.0034	0.0088
DeepLabV3+ 预训练主干 (val)	3	0.6931	0.0034	0.0066
DeepLabV3+ 从零 (val)	6	0.6267	0.0041	0.0120

判定的口径纪律：模块消融的 Δ 均取自 120 轮同调度组，对应的噪声是完整模型在 val 协议下的 $\sigma = 0.0042$ ($2\sigma = 0.0084$)；整图协议上的 Δ 则用 0.0034。`analysis/seed_variance.py` 已强制"与消融同配置"取 σ ，不再跨架构取最大值（原因见下）。

判据的保守性（本报告自行论证）：本项目全部消融都用 `seed=42` 训练，而 `seed` 控制 "模型初始化 / DataLoader 打乱顺序 / 几何增强抽样"。同 `seed` 下数据侧随机性完全相同（同一打乱序列、同一增强抽样、同一 `epoch_seed` 裁剪位置），故它在配对差值中共模抵消，真正独立的只有初始化 $\Rightarrow$ 严格地 $SD(\Delta) \leq \sqrt{2} \cdot \sigma_{\text{seed}}$ 。即用 $\sqrt{2}\sigma$ 定级偏保守——对"可分辨"这类肯定性判定而言方向正确（反之，用它去断言"不可分辨"则偏宽松，故本报告的"不可分辨"一律同时给出 Δ 与 σ 倍数）。


两处口径事实（审核 Q-01/Q-33）：① 裁剪位置由 `epoch_seed` 决定、与训练 `seed` 无关，故 σ 只含初始化与 `shuffle` 顺序方差、不含增强路径方差，是复制噪声的下界；② 读数取"各自 val 曲线上的 best"，属极值统计量。适用范围：val 协议 / 60 轮预算 / P-MEM-ROLL 世代 / 全量数据档——摘要与正文引用该 σ 时须注明，不可当作"全部实验差异"的普适尺度。

同管线模块消融 (val 协议) 的 Δ 极差 0.0097 为种子极差的 0.71 倍 ($0.0097 / 0.0136$) ——即换一个随机种子带来的波动，比整套架构改动带来的差异还大。

⚠ 一处必须记录的数据完整性事故 (2026-09-15)：DeepLab 的 9 次种子运行混了两种配置——旧 3 次训练于 `pretrained_backbone` 默认仍为 `True` 的时期（主干首个 BN 层 weight 均值 **0.248**），新 6 次训练于默认改为 `False` 之后 (**0.973**)。把它们并成一组后，组内 σ 变成 **0.0334**（真实的种子噪声仅 ~ 0.003 ，差 **11 倍**），而这正好比"配置差 0.065"小一个量级——混合把配置差当成了噪声。更危险的是旧的取 σ 规则是"各管线取最大（保守）"，于是 0.0334 会被下游拿去给 MSSACT 消融定门限，使一切真实差异都被判成"不可分辨"——一次静默的结论性破坏。

已修三处：① DeepLab 按预训练状态拆为两组（上表）；② σ 改为取 与消融同配置 的组（跨架构的种子噪声不可互换）；③ 在 `seed_variance.py` 中加入 组内同质性守卫：用主干 BN 统计检出手干预训练状态不一致、用 checkpoint 参数量 指纹检出架构不一致，命中即拒绝该组的 σ 用于判定并显式告警。该守卫已用受控测试验证（故意复现上述混组 → 被检出；正常组 → 通过）。

新结论（复现带来的）：从零训练的自研 6.099M 与 DeepLabV3+ 39.64M，此前只有单次对单次（+0.0039, 0.78σ ，判"不可分辨"）。现在 $n=10$ vs $n=6$ ：自研均值 0.6349、DeepLab 从零均值 0.6267，差 +0.0082 (SE 0.0021) = 3.8σ ，可分辨；若把 `lgR_deeplab_scr` 也并入从零组（ $n=7$ ，均值 0.6280）则为 +0.0069 = 3.4σ 。选择偏差核验：两组的 best-末轮 均为正（自研 +0.0026、DeepLab +0.0038），DeepLab 偏离更大，校正后差距只会扩大——结论稳健。⇒ 原"从零对比不可分辨"是单次运行的产物；以复现为准，自研模型在从零条件下 优于参数多 6.5 倍的 DeepLabV3+。



5.8 训练策略对比：裁剪尺度与随机/固定裁剪


配置	crop	位置	每样本像素	Kappa	ΔM vs 基准	秒/轮	总时长
lgR_bs8_full_lr2e4	256	随机	1.00×	0.6320	+0.0000 (0.00 σ_{diff} , 不可分辨)	44 s	44.0 min
lgR_c256_center	256	固定中心	1.00×	0.6128	-0.0192 (3.23 σ_{diff} , 可分辨)	44 s	44.0 min
lgR_c384_rand	384	随机	2.25×	0.6543	+0.0223 (3.75 σ_{diff} , 可分辨)	100 s	100.0 min
lgR_c512_rand	512	随机	4.00×	0.6524	+0.0204 (3.43 σ_{diff} , 可分辨)	192 s	192.0 min

对比	ΔKappa	σ 倍数	计算代价	判读
256 随机 vs 256 固定中心	-0.0192	3.23 σ_{diff}	同代价	可分辨
384 随机 vs 256 随机	+0.0223	3.75 σ_{diff}	2.3×	可分辨

对比	$\Delta Kappa$	σ 倍数	计算代价	判读
512 随机 vs 256 随机	+0.0199	3.35 σ_{diff}	4.4×	可分辨

判读要点：

1. 本节三个对比的效应量，全部大于 §5.6 的所有模块消融。 $|\Delta Kappa|$ 为 0.0199–0.0223 (3.2–3.8 σ_{diff})；而在 val 协议下模块消融全部 $\leq 1.00\sigma_{diff}$ (整图协议下 4/8 可分辨，见 §5.6.16)。也就是说：**在这套模型上，训练策略的收益是可分辨的，模块增删则不可分辨**。这对后续工作更有指导意义——**先选对训练策略，再谈架构**。
2. **256 随机 vs 256 固定中心**：两者像素量与尺度完全相同，差异只能归因于“每轮随机位置”这一增强——随机裁剪本身值 +0.0192。
3. **256 → 384 → 512**：384 达 0.6543 (+0.0223)，512 为 0.6519 (+0.0199) —— **再放大到 512 无额外收益，代价却从 100 s/轮升到 192 s/轮 (4.4× 于基准)**。⚠ **归因混杂 (审核 Q-34)**：batch 随裁剪面积同步下调 (8/4/2)，而 OneCycle 的总步数 T 随 batch 改变 $\Rightarrow$ **学习率调度形状与裁剪尺度共变**。故 “+0.0223” 是 (裁剪尺度 $\times$ batch $\times$ 调度) 的**复合效应**，不能单独归因于裁剪尺度。本报告**未做**梯度累积等价对照 (384²+等效 bs8)，理由：该结论的用途是**工程决策** (选 384²/bs4) 而非机制归因，而对照需新增 3–4 次长训练才能拆开三者，拆开后也不改变这个可执行结论。**读者应以“384²/bs4 最优”读之**。相比之下 **256 随机 vs 固定中心的 +0.0192 不受此影响** (同尺度、同 batch)，依然干净。故 **384 是更优的工程取舍**：既印证了“过小的尺度没有意义”，也说明**过大的尺度不划算**。
4. 注意 batch 随面积下调 (256²:8 / 384²:4 / 512²:2) 以避免显存溢出，故每轮耗时与总时长必须一并报告——大裁剪的计算代价是**平方级增长**的。



5.9 数据量阶梯：容量与数据量的匹配

协议：30 轮 / patience=30 (固定预算、不早停) / bs8 / lr2e-4；子集为分层抽样的嵌套样本 (250 $\subset$ 500 $\subset$ 1000)；验证集固定为 newsplit2 的 221 张 (与子集大小无关)，故各档 Kappa 可比。

e50rel / e90rel: 首次达到**该次运行自身 k_max** 的 50% / 90% 的轮次。使用相对阈值是因为低数据档的绝对 Kappa 很低 (n250 完整模型上限仅 0.03) , 固定阈值 0.4/0.5/0.6 在这些档位**永远不可达**。

n = 250 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.2825	0.2387	24	29
U-Net (2.44M)	0.1915	0.1915	14	28
DeepLabV3+ 从零 (39.63M)	0.1762	0.1762	24	30
MSSACT-Net w/o ECSAM	0.1164	0.1079	23	29
MSSACT-Net 完整 (6.10M)	0.0322	0.0261	27	28

n = 500 张


模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.4928	0.4928	16	27
DeepLabV3+ 从零 (39.63M)	0.4393	0.4393	21	26
U-Net (2.44M)	0.4050	0.4050	19	28
MSSACT-Net w/o ECSAM	0.3954	0.3954	19	29
MSSACT-Net 完整 (6.10M)	0.3312	0.3312	25	28

n = 1000 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.6310	0.6303	13	21
MSSACT-Net w/o ECSAM	0.5234	0.5234	15	24
MSSACT-Net 完整 (6.10M)	0.5085	0.5085	17	25
U-Net (2.44M)	0.4913	0.4913	12	20
DeepLabV3+ 从零 (39.63M)	0.4771	0.4771	13	21

三点结论:

- 1. **小数据下"模块更多"反而更差。** n=250 时 U-Net (0.1915) 与 DeepLabV3+ 从零 (0.1762) 都远好于完整模型 (0.0322) 。这与 §5.6 的缺陷分析 一致：被移除的 FPN/Transformer/ECSAM 在实现上并未执行其声明的功能，因此在样本稀少时只贡献了**优化难度**而非有效容量。
- 2. **w/o ECSAM 在全部三档上都不低于完整模型**，与 §5.6.1 的观察一致（坐标注意力仅占 0.90% 参数）。
- 3. **学习曲线的形态随数据量变化:** n250 的完整模型直到第 27/30 轮才达到自身上限的一半，说明**小数据档在 30 轮预算内仍处于爬升期**。




局限：30 轮预算对小数据档偏紧 (e50rel 落在 23–27 轮)，故各档数值只宜用于 "同预算下的相对比较"，**不宜**解读为该模型在该数据量下的能力上限。

5.10 预算攻击：充足预算是否掩盖了模块差异？

动机：§5.6 "模块无贡献" 的结论是在 **60 轮充足预算**下得到的。自然的质疑是：**预算太足**，使各变体都有机会收敛到同一水平，从而掩盖了模块本身的差异。本实验把预算压到 **15 轮**，其余协议不变。

模型	参数量	Kappa (15 轮)	Δ vs 完整
DeepLabV3+ 预训练 (旁证)	39.635M	0.6358	+0.1459 (24.56 σ _diff, 可分辨)
MSSACT-Net w/o ECSAM	6.044M	0.5092	+0.0193 (3.25 σ _diff, 可分辨)
MSSACT-Net 完整 (6.10M)	6.099M	0.4899	+0.0000 (0.00 σ _diff, 不可分辨)
U-Net (2.44M)	2.443M	0.4884	-0.0015 (0.26 σ _diff, 不可分辨)
MSSACT-Net w/o EMR	6.099M	0.4790	-0.0109 (1.84 σ _diff, 弱)
DeepLabV3+ 从零 (39.63M)	39.635M	0.4682	-0.0217 (3.65 σ _diff, 可分辨)

结论：压到 15 轮后，模块之间的差异依然很小——完整模型 0.4899、w/o EMR 0.4790、U-Net 0.4884，散布仅 0.0109 (约 2σ)；"**预算掩盖模块差异**"这一质疑**不成立**。



但本实验揭示了一个跨四组实验一致的模式：在数据或预算受限的四种设置下，移除坐标注意力（ECSAM）都更好（4/4 一致）。这与 §5.6.1 的观察吻合——ECSAM 仅占 0.90% 参数，且被放在编码器深层（位置信息已被 $8\times$ 下采样稀释）。

5.11 全部效应量的可分辨性总表

把本项目的"设计选择"效应量折算到**两单次运行之差**的尺度上，即可比较哪一类选择 真正重要。三条口径纪律：① **按世代分组**（P-PNG 与 P-MEM-ROLL 的 Δ 不得排进同一序，见附录 A.2）；② **按协议分组**（val 用 $\sqrt{2\times 0.0042} = 0.0059$ ，整图用 $\sqrt{2\times 0.0034} = 0.0048$ ）；③ **单次对单次之差用 $\sqrt{2}\sigma_{\text{diff}}$ 定级**（审核 Q-26）。

世代	效应	$\Delta Kappa$	σ_{diff} 倍数	判读
P-MEM-ROLL	预训练主干贡献（阶梯 n1000）	+0.1539	25.91	可分辨
P-MEM-ROLL	预训练主干贡献（阶梯 n250）	+0.1063	17.90	可分辨
P-MEM-ROLL	预训练主干贡献（阶梯 n500）	+0.0535	9.01	可分辨
P-MEM-ROLL	训练预算/退火 60→120 轮（含调度效应，见注 2）	+0.0334	5.63	可分辨
P-MEM-ROLL	384 vs 256 随机裁剪	+0.0223	3.75	可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D3_ch_tiny</code>	-0.0217	3.65	可分辨
P-MEM-ROLL	512 vs 256 随机裁剪	+0.0204	3.43	可分辨
P-MEM-ROLL	随机裁剪 vs 固定中心（256）	-0.0192	3.23	可分辨
P-PNG	模块/容量变体 <code>nd_abl_bilinear</code>	+0.0056	0.94	不可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D2_decoder_ca</code>	+0.0055	0.93	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_trans41</code>	+0.0050	0.84	不可分辨

世代	效应	$\Delta Kappa$	σ_diff 倍数	判读
P-MEM-ROLL	模块/容量变体 <code>lgR_D4_ch_large</code>	+0.0044	0.74	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_emr</code>	+0.0043	0.72	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_ecsam</code>	-0.0041	0.69	不可分辨
P-MEM-ROLL	从零 DeepLabV3+ 39.63M vs 自研 6.10M (单次对单次)	+0.0039	0.66	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_adapter</code>	+0.0030	0.51	不可分辨
P-MEM-ROLL	模块/容量变体 <code>lgR_D1_join_nofpn_notrans</code>	-0.0028	0.47	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_trans6l</code>	+0.0023	0.39	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_trans</code>	-0.0011	0.19	不可分辨
P-PNG	模块/容量变体 <code>nd_abl_no_fpn</code>	+0.0002	0.03	不可分辨

val 协议侧合计 8 项 $\geq 2\sigma_diff$ 。下表为**整图协议侧** (σ_diff 口径不同: $\sqrt{2}\times 0.0034 = 0.0048$) , 单独列出:

世代	效应	$\Delta Kappa$	σ_diff 倍数	判读
P-PNG	去掉 ECSAM	-0.0262	5.38	可分辨
P-PNG	去掉 Transformer	-0.0202	4.14	可分辨
P-PNG	去掉 Adapter	-0.0107	2.20	可分辨
P-PNG	Transformer 2→4 层	-0.0102	2.09	可分辨

这张表是全文最凝练的结论: val 协议下超过 $2\sigma_diff$ 的效应集中在 **预训练主干 (量级最大, 21-31 σ)**、**训练预算/退火 (60→120 轮, 约 5.7 σ)**、**训练策略 (随机裁剪 3.23 σ 、裁剪尺度 3.75 σ)** 与**通道容量 (3.65 σ)** ; 而val 协议下的模块增删全部 $\leq 1.00\sigma_diff$ 。

⚠ 三处必须与表同时读 (审核 Q-05/Q-37) : 1. "模块增删落在噪声内"只对 **val 协议成立**。整图协议下 4/8 可分辨 (去 Transformer 4.20 σ_diff 、去 ECSAM 5.45 σ_diff) , 见下表的整图协议段。2. **60→120 轮一行含调度效应**: OneCycle 的退火终点随预算改变, 故该 +0.0335 是 "调度变化 + 训练量"的联合结果, **不可读作纯粹的"训练量效应"** (§5.6.14) 。 3. **预训练主干的领先幅度依数据量收窄**: 表内 +0.054~+0.154 全部来自 30 轮阶梯档; 满数据档实测约 +0.05~+0.06, 与训练侧最大效应的比值由 4-7 倍收窄到约 1.5-2.7 倍 (§6.1) 。

6. 关键结论

按"可分辨性"分级, 并给出可执行的下一步。

6.1 已由实测确立 ($|\Delta| > 2\sigma_diff$)

1. 预训练主干是本任务上最大的单项杠杆。同一模型仅切换权重初始化，Kappa 相差 $+0.054 \sim +0.154$ (§5.6.6)。这在实践中意味着：**在有限标注预算下，把资源投向可获得预训练特征的骨干，收益远大于自研架构设计。**
2. 训练策略的收益是可分辨的。随机裁剪值 $+0.0192$ ($3.23\sigma_{\text{diff}}$)；裁剪尺度 256→384 值 $+0.0223$ ($3.75\sigma_{\text{diff}}$)，而 384→512 无额外收益、代价翻倍 (§5.8)。**可执行的结论：采用 384² 随机裁剪。**
3. 通道容量确实重要。通道减半 (1.545M) 掉 0.0217 ($3.65\sigma_{\text{diff}}$)，且该变体仍保留全部模块 (§5.6.9)。**可执行结论：不要在容量上省钱。**
4. 数据规模在低数据区是主导因素。n=250 时完整模型几乎学不动 (Kappa 0.0322)，而 U-Net 达 0.1915 (§5.9)。**可执行结论：自研模型需要 $\geq 1,000$ 张才体现优势。**
5. 后训练有稳定的小幅收益 ($+0.0101$ Kappa, §4.3.1)。

6.2 已由实测否定或推翻的原有结论

1. "DeepLabV3+ 显著优于自研模型 ($+0.0720$)" **不成立**。该比较中 DeepLabV3+ 带 ImageNet 预训练主干；从零对照下两者**不可分辨** ($\Delta = +0.0039$, 0.78σ)，而参数量相差 6.5 倍 (§5.6.6)。
2. "DeepLabV3+ 架构的学习效率更高" **被推翻**。达 Kappa 0.5 所需累计学习量：从零 DeepLabV3+ **75.9%** vs 自研 **59.7%**——**从零条件下它更慢**；原先的 30.3% 完全来自预训练 (§5.2)。
3. "五个设计模块均无可测量的独立贡献" **需要修正表述**。准确说法是：**这些模块在实现上并未执行其声明的功能** (FPN 的多尺度融合被丢弃、Transformer 无位置编码、解码器无跳连)，因此在 **val** 协议下移除它们看不出影响 (§5.6.2–5.6.5)。这是**实现缺陷**，不是"模块设计无效"的证据。
⚠️ 但"移除无影响" **不能推广**：在整图协议下移除 Transformer 为 $-0.0202 = 4.20\sigma_{\text{diff}}$ 、移除 ECSAM 为 $-0.0262 = 5.45\sigma_{\text{diff}}$ ，**均可分辨**；ECSAM 在修复后架构上移除更会导致训练发散 (§5.6.15–5.6.16)。正确表述是："实现缺陷" **诊断成立 (与协议无关)**，而"移除无影响" **只在 val 协议与 FPN 上成立**。
4. "标签碎片化 (93% 像素在边界)" **是错的**，真实边界像素占 **2.4%** (§5.6.8)；且原论证方向相反。

6.3 方法学结论 (对后续工作最有价值)

1. **先建立误差底线，再谈差异**。 $\sigma_{\text{seed}} = 0.0042$ 使本项目能对每个结论给出 分级 (§5.11)，而不是罗列一堆无法比较的 ΔKappa 。
2. **消融实验必须先验证"模块是否在工作"**。如果直接做消融而跳过 §5.6 那样的数值检验，本项目会把"移除无效计算无影响"误读为"模块冗余"——这正是早期 报告的错误来源。
3. **归因必须排除混淆变量**。预训练混淆事件说明：**只验证自己假设的那个参数** 是不够的 (当时只看了 `weights=`，漏掉了 `weights_backbone=`)。可靠的做法是找**可证伪的观测量** (此处用"新初始化 BN 的 weight 必为 1.0"与"权重逐张量比对官方文件")。

7. 局限、疏漏与教训

7.1 研究区选择的疏漏

早期选用 GF-1 影像 + 内蒙古根河市 (2.4 m GSD) , 其类别体系与分辨率不匹配: 大量类别在 2.4 m 下光谱与空间不可分, 且无公开可核验的逐像素标注。 **教训:** 数据集选择应由**分类体系的可分性与标注的可核验性**决定, 而不是由手头有什么影像决定。

7.2 类别体系核对的疏漏

官方约定 0 为 no-data、1-7 为类别, 早期实现误将 0 当作背景参与训练与评估, 使指标虚高约 0.007-0.009 Kappa。 **教训:** 类别体系必须以**官方文档**为准逐条核对, 不能凭直觉假设。

7.3 当前局限 (含 §5.6.11 的全部声明)

- 1. $\sim\sim\sigma_{seed}$ 的种子数仅 4 $\sim\sim$ $\rightarrow$ **已扩到 $n=10$** (完整模型) / $n=3$ 与 $n=6$ (DeepLab 分组) , 并按**两单次运行之差 = $\sqrt{2}\sigma$** 的正确口径重算全部判定 (审核 Q-26) 。 仍未做的: σ 只覆盖 60 轮 / 全量数据档 / P-MEM-ROLL 世代, **其他档位未测**。
- 2. **等效性检验 (TOST) 已完成:** SESOI=0.02 下配对 bootstrap 的 95% CI 半宽 $\delta \approx 0.010 < \text{SESOI}$, 故"无差异"已有统计等效支持 (`results/artifacts/tost_equivalence.json`) 。
- 3. **数据集为 LoveDA 单一来源** (0.3 m 航空正射、城市/乡村两类场景) , 结论向其他传感器/分辨率/地域的外推性未验证。
- 4. **未使用预训练特征** (§8.1 列为后续方向) , 故不能回答"自研架构 + 预训练" 的上限。
- 5. $\sim\sim$ 架构缺陷尚未修复 $\sim\sim \rightarrow$ **已完成 (2026-09-14)** : §5.6 的**四处缺陷** (D1/D2/D3/D5) 已实现向后兼容修复并验证 (§5.6.12) , 120 轮组已测定效果 (跳连**被实测否决**、位置编码弱正向, §5.6.13) , 消融已换底重跑并首次给出 方向可解释的结果 (§5.6.15) 。 **仍未做:** P2 容量膨胀 (2.67 $\times$) 。 本报告 §7 写于该批实验之前, 此条为回写。
- 6. **标签质量上限只有提示性证据** (§5.3 的独立性限定) 。

7.4 质量控制措施 (本次新增)

措施	作用
误差底线 σ_{seed}	为 val 协议下的差异提供判据 (协议/配置相关, 非普适)
管线世代隔离	不同数据投递后端的结果禁止跨世代比较
权重级取证	用逐张量比对代替"读代码下结论"
推送前审核	自动检查本机路径、内部语境词、大文件
索引与事实单一来源	<code>experiments_index.json</code> / <code>FACTS.json</code> 为唯一数据源, 报告与 README 均由其生成
PDF 内容自检	27 项关键词守卫, 防止报告回退为已否证的结论

8. 后续工作

8.1 预训练方向（本次实验中收益最大的方向）

§5.6.6 已量化：**预训练主干权重的贡献 (+0.054 ~ +0.154) 远大于任何架构改动**。因此这是后续最值得投入的方向，具体两条路径：

(1) 换用预训练主干 把自研 EMR 编码器替换为可获取预训练权重的骨干（如 ImageNet 预训练的 ResNet / ConvNeXt / Swin），保留本项目的 FPN-Transformer-解码器结构。可回答的问题：“**自研架构 + 预训练特征**”能否超过“**标准架构 + 预训练特征**”？（本项目已具备公平对照的全部条件：同管线、同协议、 σ_{seed} 已知。）

(2) 域内预训练（自监督或跨区监督） 用 LoveDA 影像本身做预训练，避免 ImageNet 与遥感影像的域差：- **自监督**：MAE / SimCLR / DINO 等在无标注影像上预训练编码器；- **跨区监督**：官方数据集的另一分区（官方 val 区 1,669 张**带标注**）作为预训练集，本项目的 1,768 张作为微调集——两者天然不重叠，无泄漏风险。

注意：这两条都需**重新设计数据预算的对照**（预训练用掉的数据不能同时用于微调），否则会重演“数据量 vs 预训练无法分离”的混淆。

8.2 多光谱与高光谱适配（下一个阶段的核心方向）

本项目使用的是 3 波段 RGB。后续计划针对**多光谱（>4 波段）与高光谱**影像设计模型，三个具体方向：

1. **三方向池化**：现有 ECSAM 只做水平/垂直两个**空间**方向的池化。对多光谱数据，应扩展为**光谱维 / 空间维 / 通道维**的三方向池化，使注意力同时感知波段相关性。
2. **模块适配**：现有 FPN 的横向连接假设各层通道数相近，多光谱输入下需重新设计 光谱-空间特征的融合方式；Transformer 的 patch embedding 也需适配波段数。
3. **验证协议**：建立高光谱数据集上的**从零训练基准**与误差底线，以避免重演本项目早期的归因错误。

8.3 其他

- ~~补齐 TOST 等效性检验~~ → **已完成** (§5.6.11 第 2 条)。⚠ **限定（审核 Q-27）**：SESOI = 0.02 意味着 TOST 只能**排除 ≥ 0.02 的差异**，而全文讨论的是 0.005–0.01 量级的差异——等效域宽于感兴趣的效应量 2–4 倍，故 TOST 通过**不能为**“这些小差异不存在”背书。
- ~~把测试集协议覆盖到全部消融变体~~ → **已完成** (§5.6.16, 50 个 tag 全量重推)。
- ~~修复 §5.6 的四处缺陷后重评~~ → **已完成** (§5.6.13–5.6.15)。
- ~~扩大种子数至 ≥ 10 ~~ → **已完成**（完整模型 $n=10$ 、DeepLab 分组 $n=3/n=6$ ，§5.7）。
- **跨传感器/分辨率验证**（含 GF-1 同域微调），检验结论的外推性。

9. 个人工作与能力体现

9.1 数据工程

完成 LoveDA 官方训练区的全量获取与清洗：**MD5 去重** (2,821 张池)、**no-data ≤10% 筛选** (剔除 312 张)、**8:1:1 分层划分**，并建立**泄漏防控校验** (三集两两互斥 + test_clean 与历史训练集零重叠)。实现**预解码 memmap** 数据集，把每张图的训练成本由 ≈ 170 ms 降到 ≈ 24 ms。

9.2 模型训练与工程

搭建统一训练入口 (OneCycle + EMA + 类别加权 CE + Kappa 早停)，支持 12 类模型/变体的**同协议对比**。实现**断点续跑队列** (按 history 轮数判定完成)、**OOM 自动降 batch**、**队列互斥与无窗口后台执行**。把 GPU 利用率由 49.9% 提升到 84.3%，同时**零性能损失** (\$5.5)。

9.3 实验设计与分析

设计并执行 **7 基线对比 + 8 消融 + 4 架构变体 + 3 档数据阶梯 + 3 组裁剪策略 + 15 轮预算攻击 + 多种子重复**，共 40+ 次独立训练。建立**累计学习量**方法分离调度效应与架构效应 (并据此推翻了一条原有结论)。建立**Kappa 归属 (oracle) 分析**量化指标的可见空间。

9.4 问题定位与修复

- **发现并证明四处架构实现缺陷** (FPN 死支路 / 无跳连 / 无位置编码)，全部给出**可复现的数值验证** (输出逐位不变、置换等变至 $7e-07$)。
- **发现并更正一处严重的公平性缺陷**：weights=None 未关闭主干预训练，导致基线被误认为从零训练。用**权重级逐张量比对**取证，并重跑从零对照。
- **发现并更正一处统计错误**：边界像素比例 93% $\rightarrow$ 2.4% (跨图求差分的缺陷)，结论方向随之反转。
- 定位并修复训练基础设施瓶颈 (PNG 解码、EMA 实现、进程同步)。

9.5 工具与产出

可复现性基建：paths.py 路径集中 (脚本内零绝对路径)、experiments_index.json 实验索引 (参数量直读张量)、FACTS.json 事实单一来源、verify/pre_push_audit.py 推送前审核、report/make_pdf.py 报告内容自检。**分析工具**：严格性评估 (配对 bootstrap / TOST)、Kappa 归属分解、解码器伪影分析 (FFT 周期检测)、随机种子噪声底线。**报告与图**：全部图表由 viz/make_report_figures.py 从权威数据源生成，**无手改数据**。

附录 A：复现指引

A.1 环境与运行

```
cd loveda                                # 运行目录 = 仓库根
export LDA_DATA_ROOT=<数据根目录>        # 或写入 .env (不入库)
python prep/resplit_filtered.py           # 数据筛选 + 去重 + 划分
python prep/build_fast_dataset.py         # 预解码 memmap (强烈建议)
```

```
python prep/build_ladder_memmap.py # 阶梯子集 memmap (跑阶梯前需停队列)
python queues/run_queue_new.py      # 对比(7) + 消融(8) + 主模型
python queues/run_queue_arch.py     # 架构变体 D1-D4 + 预算攻击 + 数据阶梯
python analysis/eval_rigor.py --infer # 逐类 IoU / 配对 bootstrap / TOST
python analysis/convergence_amount.py # 累计学习量 (调度 vs 架构)
python analysis/seed_variance.py     #  $\sigma$ _seed 与可分辨性
python viz/make_report_figures.py    # 全部报告图
python report/build_index.py         # 实验索引 (参数量直读张量)
python report/build_facts.py         # 事实汇总 → FACTS.json
python report/make_report_v3.py      # 本报告 HTML
python report/make_pdf.py            # HTML → PDF (含 27 项内容自检)
python verify/pre_push_audit.py      # 推送前审核 (必须通过)
```

A.2 训练管线世代 (禁止跨世代比较 Kappa)

世代	数据投递	num_workers	实验前缀
P-PNG	每样本解码两张 1024 ² PNG	0	nd_* lg_*
P-MEM-DET	memmap + 确定性增强	8	lgF_* (✗ 已否决, Kappa -0.0246)
P-MEM-ROLL	memmap + 原始增强	0	lgR_* sd*_*

两代后端差异实测为 **+0.0008** (同配置 0.6320 vs 0.6312) ——**注意分辨力 (审核 Q-45)** : n=1 配对时该差值的种子层噪声约 $\sqrt{2}\sigma = 0.007$, 故 0.0008 与 0 **在现有分辨力下不可区分** (既支持"可互相印证", 也同样允许"世代差大到 0.007 而未被察觉"; §5.5.5 的确定性增强 事件 -0.0246 证明管线级改动足以产生远超 σ 的漂移)。正确表述是 **"未见差异 (分辨力 ± 0.007)"**, 而非断言两代等价。据此两组结论可**互相印证**, 但**不得混合求统计量**。

附录 B：文件与目录说明

根目录只保留：paths.py 与 4 个核心模块、文档、figures/ (报告图)、三项权威事实 (位于 results/facts/) (FACTS.json / experiments_index.json / seed_variance.json)、本报告 PDF。

脚本按用途分 7 个子目录：queues/ (实验队列)、analysis/ (评估与分析)、verify/ (核验与审核)、prep/ (数据准备)、viz/ (图表)、report/ (汇总与报告)、mapping/ (制图管线)。

产物集中在 results/：checkpoints/ (权重与训练历史)、fast_dataset/ (memmap)、consensus_analysis/ overfit_diag/ ladder_eval/ fulltile_eval/ tta_eval/ heldout_test/ (各阶段评估)、artifacts/ (中间分析产物)。

本地归档 (不入库)：_local_archive/ (历史数据集与旧图)、backups/ (覆盖前备份)。

目录整理与路径适配的完整记录见 docs/整理记录_20260913.md ; 本报告的问题审查与逐条修正见 docs/报告问题研究_20260913.md 。