

MSSACT-Net 遥感土地覆盖分割

项目报告

数据集: LoveDA 公开基准 (0.3m 航空正射, 7 类土地覆盖, 官方人工标注) **模型:** MSSACT-Net (多尺度自注意力 ConvTransformer, light 6.10M) **报告日期:** 2026-09-10

本文档为个人项目材料，记录基于毕业设计方向的完整实验工作，供指导教师参考。

摘要

本项目基于公开遥感基准 **LoveDA** (0.3m 航空正射, 7 类土地覆盖, 官方人工逐像素 标注)，对自研 **MSSACT-Net** (多尺度自注意力 ConvTransformer, 6.1M 参数) 开展系统性实验，覆盖数据量效应、后训练、推理增强、对比实验、消融实验与 公平性验证。主要结果：

1. 数据量是精度主导因素。 训练数据由 957 张增至 2,257 张 (2.4×)，干净测试集 Kappa 由 **0.3921** 提升至 **0.6114 (+0.219)**，OA 由 0.5255 提升至 0.6862。少数类获益最大：道路 F1 **+0.390**、水域 **+0.385**、裸地 **+0.324**、建筑 **+0.255**，证明早期精度偏低的主因是训练样本不足，而非模型能力缺陷。

2. 后训练与推理增强提供边际增益。 在已收敛模型上继续低学习率训练 (lr=5e-5) 获得 **+0.012 Kappa**；8× 几何变换 TTA 再获得 **+0.005**。四阶段递进后最终达到 **Kappa 0.6278 / OA 0.7009 / mF1 0.7089 / mIoU 0.5583** (192 张干净测试集)。

3. 模块贡献需按收敛协议重评。 在统一 120 轮收敛协议下，仅 **ECSAM 注意力** 为正贡献 (-0.028)，Adapter/Transformer/FPN 为负 (+0.055 ~ +0.076)；而 **EMR 的「训练坍缩」** 系早停误杀——延长至 120 轮后恢复至 0.4055。这说明 模块价值与训练预算强相关，单预算消融会得出误导性结论。

4. 训练策略对稳定性至关重要。 策略探索表明 **SGDR 热重启最优** (Kappa 0.4183)；**30.5M 原版架构** 在调优策略下同样可收敛 (0.4186)，证明此前的训练不稳定属于策略问题

而非架构缺陷。

5. 参数效率优势显著。 在基线对比中，MSSACT-Net 以 **6.1M 参数**取得 最高 Kappa (0.4065) ， 优于 DeepLabV3+ (39.6M, 0.3806) 、 FCN (23.7M, 0.2837) 等模型， 占据精度-参数量帕累托前沿。

方法学工作： 完成数据泄漏核查 (MD5 去重 + 三集互斥校验 + test_clean 隔离)、 类别体系核对 (依据官方文档确认「背景≠未分类」， 修复 no-data 标签处理 bug)、 以及收敛协议设计 (Kappa 早停 + EMA + OneCycle) 。

关键词： 高分辨率遥感；土地覆盖分类；语义分割；Transformer；自注意力；LoveDA；数据量效应；消融实验

0. 项目当前状态

项	状态
数据准备	✅ 官方全量 2,522 张下载完成, 筛选+去重+重划分完成 (newsplit2)
数据筛选	✅ no-data ≤10% 筛选, 剔除 312 张低质量图
泄漏校验	✅ train/val/test 两两无交集; test_clean 与旧训练集零重叠
主模型	✅ full_all (2,257张) 训练完成; v2 (筛选数据) 待重训
对比实验	🔄 7 个基线在新数据上待重跑
消融实验	🔄 8 个变体在新数据上待重跑
关键修复	✅ no-data 标签处理 bug 已定位并修复

1. 研究背景与目标

高分辨率遥感土地覆盖分类是遥感智能解译的核心任务。本项目基于自研 **MSSACT-Net** (多尺度自注意力 ConvTransformer) ， 在公开基准 LoveDA 上 完成系统性实验：数据量效应、后训练、推理增强、对比实验、消融实验。

1.1 为什么改用公开数据集

早期研究采用自选研究区（根河市 GF-1 影像）配合 CLCD 公开标签。该方法存在 两个根本问题：

- 1. **标签与影像不匹配**：CLCD 为 30m 分辨率产品，与 2m 高分影像存在尺度鸿沟， 标签错位导致监督信号不可靠
- 2. **类别分布极端**：该区域森林占比超过 80%，模型倾向单类预测即可获得高 OA， 结论不具备代表性与可比性

改用 LoveDA（0.3m 航空正射 + 官方人工逐像素标注 + 社区公认基准）后， 类别分布均衡（最大类 45.6%）、标签精度可靠、结果可与文献直接对比。

2. 数据集与划分

2.1 官方类别体系（已核实官方 README）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**. And the **no-data regions** were assigned 0 which should be ignored.

值	类别	说明
0	no-data（未标注）	官方要求忽略，不参与训练与评估
1	背景	官方正式类别（不属其他6类的区域），最大类
2	建筑	—
3	道路	—
4	水域	—
5	裸地	—
6	森林	—
7	农田	—

重要澄清：「背景」不是「未分类」；真正的未分类是值 0（no-data）。

2.2 数据筛选与重划分（newsplit2）

步骤	结果
官方训练区原图	2,522 张
no-data 占比分析	75% 的图无 no-data; 312 张有 10–53% 的 no-data
筛选 (no-data ≤10%)	剔除 312 张, 保留 2,210 张
MD5 去重	去除与历史镜像的重复
8:1:1 划分 (seed=42)	train 1,768 / val 221 / test 221
test_clean	141 张 (额外排除旧模型训练集, 用于新旧公平对比)

2.3 泄漏校验 (已通过)

- $\text{train} \cap \text{val} = \emptyset, \text{train} \cap \text{test} = \emptyset, \text{val} \cap \text{test} = \emptyset$
- $\text{test_clean} \subseteq \text{test}$
- $\text{test_clean} \cap \text{旧模型训练集} = \emptyset$
- 筛选后 train 的 no-data 均值 **0.13%**、最大 8.27% (阈值内)

3. 评价体系

3.1 指标选择: Kappa 而非 OA

$\kappa = (p_o - p_e)/(1 - p_e)$, 校正随机一致性。LoveDA 最大类 (背景) 占 45.6%, **全预测背景的 OA=45.6% 但 Kappa=0**——OA 在不平衡数据上会被单类支配。全部早停与选优均以验证 Kappa 为准。

3.2 数据使用协议

集合	梯度更新	参与选优	角色
train	✅ 是	—	学习
val	❌ 否 (<code>torch.no_grad()</code>)	✅ 是 (早停/选优)	监控
test / test_clean	❌ 否	❌ 否	最终无偏评估

3.3 no-data 处理 (含修复记录)

官方协议：no-data（值 0）必须忽略。

已修复的 bug：早期 `REMAP` 实现将值 0 映射为 0（背景类），导致约 3% 的 no-data 像素被错误当作背景参与训练与评估。修复后（0 → 255 ignore）同一模型 指标变化：

	OA	Kappa
修复前（0→背景）	0.6862	0.6114
修复后（0→ignore）	0.6770	0.6040
差异	-0.0092	-0.0074

即此前指标虚高约 **0.007–0.009**。修复已生效，后续实验全部使用正确协议。

4. 训练协议

统一协议（所有实验一致）：

- 优化器：AdamW(lr=2e-4, weight_decay=0.02)
- 调度：OneCycle（6% warmup + 余弦退火，60 轮）
- 权重平滑：EMA(decay=0.999)
- 损失：类别加权交叉熵（频率逆平方根）
- 采样：训练每图随机裁剪 256×256；验证每图 4 角固定 patch
- 早停：验证 Kappa patience=20


5. 已完成实验结果

5.1 数据量效应（核心结果）


阶段	训练数据	干净测试 Kappa	OA	mF1	mIoU
基线	957 张	0.3921	0.5255	0.4532	0.3061
+数据量	2,257 张	0.6114*	0.6862*	0.6946*	0.5420*
+后训练	继续训练 lr=5e-5	0.6233*	0.6968*	0.7048*	0.5536*

阶段	训练数据	干净测试 Kappa	OA	mF1	mIoU
+TTA	8× 几何变换平均	0.6278*	0.7009*	0.7089*	0.5583*

*注：标星数值使用修复前的 REMAP（含 no-data 计入背景，约虚高 0.007–0.009）。修复版重训结果 (v2) 待补。



5.2 学习曲线




全量模型（红）第 8 轮起飞、第 35 轮达 0.61；旧模型（灰）缓慢爬至 0.40 后平台化。

5.3 每类 F1 提升


类别	957张	最终	提升
道路	0.284	0.674	+0.390
水域	0.431	0.817	+0.385
裸地	0.203	0.527	+0.324
建筑	0.437	0.692	+0.255
农田	0.552	0.806	+0.254
森林	0.679	0.809	+0.130
背景	0.587	0.637	+0.051

少数类获益最大，印证小类样本稀缺是此前精度低的主因。


5.4 混淆矩阵与统计诊断



关键错误流向（新模型）：各类召回 0.72–0.84，仅背景类召回 0.53——其像素 主要流向建筑（0.18）与裸地（0.10）。原因是背景类定义宽泛（含道路边缘、建筑阴影、田间小路等异质内容），是模型的主要剩余难点。





5.5 参数效率



MSSACT-Net 以 **6.1M 参数** 占据帕累托前沿——DeepLabV3+ 需 39.6M 参数才达到 0.38 Kappa。

5.6 测试集预测对比



三条曲线（旧模型 / 全量 / 后训练）对比：旧模型大面积误判水域、建筑丢失；全量模型清晰还原建筑群、道路网、水域边界。

5.7 对比实验（957 数据，历史结果）

模型	参数量	Kappa	OA
MSSACT-Net (light)	6.10M	0.4065	0.5630
DeepLabV3+ (R50)	39.6M	0.3806	0.5092
FCN-32s (R50)	23.7M	0.2837	0.4245
PSPNet (R18+PPM)	13.6M	0.2513	0.3834
SegFormer-Lite	1.01M	0.1775	0.3550
U-Net (base=32)	2.44M	0.0939	0.4055
FPN (R50)	27.2M	0.2982	0.4328
Swin-Unet (lite)	32.6M	0.2682	0.3878


5.8 消融实验（957 数据，历史结果）

A) 60 轮预算

配置	Kappa	Δ Kappa
Full	0.4065	—
w/o Adapter	0.3452	−0.061
w/o Transformer	0.3636	−0.043
w/o FPN	0.3760	−0.031
w/o ECSAM	0.3134	−0.093
w/o EMR	0.0004	坍塌

B) 120 轮预算 (收敛后重评)

配置	Kappa	Δ Kappa vs full120
full (120ep)	0.3862	—
w/o Adapter	0.4621	+0.076
w/o Transformer	0.4580	+0.072
w/o FPN	0.4416	+0.055
w/o EMR	0.4055	+0.019
w/o ECSAM	0.3587	−0.028




关键发现：收敛协议下仅 **ECSAM** 正贡献；**EMR** 的「坍塌」系早停误杀（120 轮恢复至 0.4055）。

5.9 模块移除的架构适配与训练响应

变体	架构适配	训练响应
w/o EMR	EMR → 标准 ResBlock	60轮/pt15 坍塌；120轮/pt20 恢复
w/o ECSAM	跳过 3 阶段坐标注意力	稳定，上限降低
w/o FPN	解码器只收最深特征	收敛更快，长期最优
w/o Transformer	移除全局自注意力	稳定，上限略低
w/o Adapter	仅移除 Adapter-Scale	小数据上是负担
Trans-4L/6L	层数 2→4/6	4L=0.3907, 6L=0.4026
Bilinear-Up	转置卷积 → 双线性	60轮坍塌；lr=1e-4 可救援

5.10 策略探索

策略	Kappa	说明
SGDR 热重启 120轮	0.4183	最优
30.5M 原版 OneCycle-60	0.4186	原版架构可收敛
快退火 30轮	0.10–0.16	不足
DeepLab 快退火	0.3331	基线亦有上限



5.11 过拟合诊断

训练集 vs 验证集 logits 熵差 ($\Delta H < 0$ 表示过拟合) :

模型	ΔH
MSSACT (957张)	-0.241
DeepLabV3+	-0.194
Swin-Unet	-0.144
U-Net	-0.0003 (欠拟合)
SegFormer-Lite	+0.032 (校准良好)

数据量提升后泛化差距显著缩小（测试集与验证集 Kappa 接近）。

6. 关键结论

- 1. **数据量是精度主导因素**：2.4× 数据带来 +0.219 Kappa，远超架构/策略调整
 - 2. **少数类可修复**：道路/水域/裸地/建筑 F1 提升 0.25–0.39
 - 3. **MSSACT-Net 参数效率优**：6.1M 参数达到/超过 13–40M 基线
 - 4. **训练策略决定稳定性**：多组「坍缩」实为协议敏感，非架构缺陷
 - 5. **后训练与 TTA 提供边际增益**（合计 +0.017）
-

7. 疏忽与教训

7.1 研究区选择的疏忽

早期直接采用自选研究区（根河市）+ 公开标签产品（CLCD），未事先核对 **标签分辨率与影像分辨率的匹配性**（30m vs 2m），也未检查**类别分布是否具代表性**（森林 >80%）。结果：标签错位 + 单类支配，模型指标看似可用（OA 76.8%）但实际不具备科学意义，结论无法与文献对比。

教训：实验设计阶段必须先完成「数据可用性三查」——①标签精度与影像 分辨率匹配；②类别分布是否均衡；③是否有公认基准与可对比结果。

7.2 类别体系核对的疏忽

在改用 LoveDA 后，未第一时间逐项核对官方类别定义，将「背景（值1）」与「未分类（值0）」混淆，导致 REMAP 将 no-data 错误并入背景类，使全部实验 指标虚高约 0.007–0.009。

教训：使用任何公开数据集前，必须以**官方文档原文**为准核对：类别编号、每类语义、无效值定义与评估协议。此项疏漏由提问发现并修复，后续所有实验 均按官方协议执行。

7.3 已建立的质量控制

控制项	措施
数据泄漏	MD5 去重 + 三集两两校验 + test_clean 隔离旧训练集
指标可信	全部以 Kappa 选优；训练/验证/测试协议明确；train 不用于报告
标签正确	以官方 README 原文为准；no-data 显式 ignore
结果可复现	全部实验保留 history.json + 权重 + 固定 seed
架构一致性	checkpoint 架构自动核验 (verify_experiments.py)

8. 接下来的项目安排

阶段一：筛选数据上的完整重跑（进行中，约 50 小时）

序号	任务	说明
1	主模型重训	full_all_v2（筛选数据 1,768 张, 60 轮）
2	后训练	post_all_v2（从 v2 权重继续训练）
3	对比实验 ×7	U-Net / PSPNet / FCN / DeepLabV3+ / SegFormer / FPN / Swin-Unet
4	消融实验 ×8	no_emr / no_ecsam / no_fpn / no_trans / no_adapter / Trans-4L / Trans-6L / Bilinear
5	统一评估	全部模型在 test / test_clean 上评估（含 TTA）

阶段二：结果汇总与图表更新（约 1 天）

- 生成新版对比表、消融表、混淆矩阵、学习曲线
- 更新项目报告与 README
- 修正历史数字（标注 REMAP 修复前后差异）

阶段三：成果整理与学术输出（约 1 周）

- 整理完整实验记录与技术文档（方法、协议、全部结果）
- 总结方法学经验：数据泄漏防控、类别体系核对、收敛协议设计

- 梳理可延伸的学术问题（见阶段四），为后续研究选题做准备

阶段四：后续研究展望

- 跨域验证（GF-1 2.4m 影像 + 同域微调）
 - 少数类增强（重采样 / 损失函数调优）
 - 更大规模预训练与自监督学习
 - 推理加速与部署
-

9. 个人工作与能力体现

本项目从数据获取到结果验证全流程独立完成，主要工作与能力体现如下：

9.1 数据工程

- **数据获取与整合**：从 HuggingFace 镜像定位并获取 LoveDA 官方全量训练集（2,522 张, 4GB），完成解压、格式核对与目录组织
- **数据质量控制**：编写筛选脚本按 no-data 占比过滤低质量图（剔除 312 张 10–53% 无标注的样本）；MD5 去重避免重复样本；8:1:1 重划分并做泄漏校验（三集两两互斥 + test_clean 隔离历史训练集）

9.2 模型训练与工程

- **训练管线**：PyTorch + AMP 混合精度 + EMA 权重平滑 + OneCycle 调度 + 类别加权损失；单卡 8GB 显存下完成 6.1M ~ 39.6M 参数模型训练
- **自动化队列**：实现断点续跑的串行实验队列（42+ 组实验），含任务状态判定、失败重试、显存不足自动降 batch、历史完整性校验
- **实时监控**：开发动态刷新监控面板（阶段/任务/epoch/指标/剩余时间估算）

9.3 实验设计与分析

- **公平性设计**：统一训练协议（同数据划分、同步数、同调度）、以 Kappa 为选优标准（避免 OA 在不平衡数据上被单类支配）、val 仅用于选优不参与训练
- **消融与对比**：完成 7 个基线模型对比、8 个消融变体、11 组训练策略探索，并按收敛协议重评模块贡献（发现单预算消融的误导性）

- **统计诊断**：混淆矩阵、每类精度/召回/F1、参数效率、logits 熵过拟合诊断

9.4 问题定位与修复

- **标签协议 bug**：通过核对官方文档发现「背景」与「未分类」混淆，定位 REMAP 实现缺陷，量化影响（指标虚高 0.007–0.009）并修复
- **数据泄漏**：发现历史数据与新测试集 90 张重叠，构建干净测试子集保证 对比公平
- **训练稳定性**：定位多组「坍缩」现象为调度-模型不匹配而非架构缺陷，通过策略调整（SGDR / 低 LR 长退火）使全部变体可收敛

9.5 工具与产出

- 自动化脚本：`resplit_filtered.py`（筛选+划分+校验）、`run_queue_new.py`（实验队列）、`eval_complete.py`（统一评估）、`make_figures.py`（图表）、`make_project_report.py`（Markdown→HTML→PDF 报告管线）
- 全部代码与方法学文档已开源至 GitHub
(<https://github.com/eugenewang5425/mssact-loveda>)

附录：复现命令

```
python resplit_filtered.py      # no-data筛选 + 去重 + 8:1:1 重划分
python verify_split2.py        # 泄漏校验
python run_queue_new.py        # 主模型重训 + 对比(7) + 消融(8)
python eval_complete.py        # val/test × TTA 评估
python make_figures.py         # 图表生成
python make_report_pdf.py      # 报告生成
```

代码仓库: <https://github.com/eugenewang5425/mssact-loveda>