

MSSACT-Net 遥感土地覆盖分割

项目报告

报告编号: 项目报告_20260912 **数据集:** LoveDA 公开基准 (0.3m 航空正射, 7 类土地覆盖, 官方人工标注) **模型:** MSSACT-Net (多尺度自注意力 ConvTransformer, light 6.10M / full 30.54M) **报告日期:** 2026-09-12

数据来源声明: 本报告全部数字由项目仓库的实验记录自动汇总生成
(`FACTS.json` $\leftarrow$ `checkpoints/*_history.json` + 评估结果 JSON), 可逐项追溯, 不包含手工填写或估算值。

摘要

本项目在公开遥感基准 **LoveDA** 上系统训练与评估 **MSSACT-Net** (多尺度自注意力 ConvTransformer), 并完成与 7 个主流分割模型的对比、8 个模块消融、多组训练策略探索、以及针对**标签质量上限**的专项验证。主要结论:

- 数据量与质量共同决定性能上限。** 训练数据由 957 张扩至 1,768 张 (并剔除前 10% 高 no-data 的低质量图、修复标签映射缺陷) 后, 主模型 Kappa 由 **0.4065** 提升至 **0.6312**, OA 提升至 **0.7030**。
- 全部五个设计模块在数据充足时均无可测量的独立贡献。** 8 个消融变体的 Kappa 落在 0.627–0.637, 与完整模型 (0.6312) 的最大差异仅 **0.006**; 其中 **5 个变体 (含替换可学习解码器的 Bilinear-Up)** 反而略优于完整模型。FPN 与 Transformer 合计占 67% 的参数, 其移除对性能无显著影响。
- 收敛速度主要由学习率调度决定, 而非架构。** 通过累计学习量 (LR 积分) 分析: 12 个模型中 9 个达到 Kappa 0.5 所需的累计学习量集中在 47%–64%, 说明"第几轮收敛"是调度曲线的映射, 不是架构优势。**唯一例外是 DeepLabV3+ (31.8%)**, 其空洞卷积 + ASPP 多尺度结构确实具备更高的学习效率。

4. 标签质量已成为模型能力评价的瓶颈。 6 个架构/容量差异极大的模型（2.4M–39.6M）逐像素分析显示：模型间一致率 **0.7589** 显著高于模型与人工标签的一致率 **0.6495**；多模型共识与人工标签仅 **0.6815** 一致；且**容量-性能相关性 发生反转**（人工标签下 $r=+0.311$ ，共识参考下 $r=-0.444$ ）。表明标注精度已成为 评价模型能力上限的约束。

5. 方法学工作。 建立数据泄漏防控（MD5 去重 + 三集互斥校验 + 干净测试子集）、类别体系核对（依据官方文档确认「背景」与「未分类」的区别并修复标签映射缺陷）、收敛协议设计（Kappa 早停 + EMA + OneCycle）与模型间一致性分析框架。

关键词： 高分辨率遥感；土地覆盖分类；语义分割；Transformer；自注意力；LoveDA；数据量效应；标签噪声；消融实验

0. 项目状态

项	状态
数据集	LoveDA 官方训练区全量获取（2,522 张）
数据筛选与划分	✅ no-data $\leq 10\%$ 筛选 → MD5 去重 → 8:1:1（train 1768 / val 221 / test 221 / test_clean 141）
泄漏校验	✅ 三集两两互斥；test_clean 与历史训练集零重叠
主模型训练	✅ full_all_v2（60 轮）+ post_all_v2（后训练 30 轮）
对比实验（7 个基线）	✅ 完成
消融实验（8 个变体）	✅ 完成（最大差异 0.006 Kappa）
标签质量专项验证	✅ 完成（一致性分析 + 边界分层）
训练策略探索	✅ 完成（11 组，含 SGDR）
架构改进实验（4 个）	🔄 运行中（联合消融 / 解码器CA / 通道扫描）
数据阶梯 / 预算攻击	⌚ 已挂载，排队
跨数据集验证、多光谱适配	📅 后续计划（见第 8 节）

1. 项目背景

1.1 研究目标

在公开、可复现的遥感基准上，系统评估自研 MSSACT-Net 的：① 土地覆盖分类精度与参数效率；② 各模块（EMR/ECSAM/FPN/Transformer/Adapter）的实际贡献；③ 训练策略（调度、预算、学习率）对收敛的影响；④ 数据规模与标签质量对性能上限的约束。

1.2 为什么改用公开数据集（早期疏漏说明）

早期研究采用自选研究区（国产高分卫星影像, 2m 分辨率）配合公开标签产品（CLCD, 30m 分辨率）。该方案存在两个根本缺陷：

- 标签与影像尺度不匹配**：30m 标签重采样到 2m 影像造成标注与地物错位，监督信号不可靠
- 类别分布极端**：该区域森林占比超过 80%，模型倾向单类预测即可获得较高 OA，结论不具备代表性与可比性

改用 LoveDA（0.3m 航空正射 + 官方人工逐像素标注 + 社区公认基准）后，类别分布均衡（最大类背景 45.6%）、标签精度可靠、结果可与文献直接对比。

2. 数据

2.1 官方类别体系（依据官方文档核对）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**. And the **no-data regions** were assigned 0 which should be ignored.

标签值	类别	说明
0	no-data（未标注）	官方要求忽略，不参与训练与评估
1	背景（Background）	官方正式类别，占比最大（约 33–38%）
2	建筑	
3	道路	
4	水域	

标签值	类别	说明
5	裸地	
6	森林	
7	农田	

要点：「背景」是官方正式类别，**不是**「未分类」；真正的未分类是值 0。

2.2 数据演进三阶段

阶段	数据	划分	标签处理	用途
A	957 张（镜像子集）	单划分	⚠ 含 no-data 映射缺陷	历史结果（第 4.1 节），仅供参考
B	2,257 张（官方全量去重）	8:1:1	⚠ 仍含缺陷	中间结果（第 4.2 节）
C	1,768 张（筛选后）	8:1:1 + test_clean	✅ 已修复	最终结果（第 4.3 节起）

阶段 A/B 的标签映射缺陷：`no-data(值0)` 被错误并入「背景」类，导致约 3% 的无标注像素参与训练与评估，指标虚高约 **0.007–0.009 Kappa**（已量化，见 3.4 节）。阶段 C 已修复为官方协议（值 0 → ignore）。

2.3 数据筛选与划分（阶段 C）

步骤	结果
官方训练区原图	2,522 张
no-data 占比分布	75% 的图无 no-data；312 张含 10%–53% 的 no-data
筛选 (no-data ≤10%)	剔除 312 张，保留 2,210 张
MD5 去重	剔除与历史镜像重复的样本
8:1:1 划分 (seed=42)	train 1768 / val 221 / test 221
test_clean	141 张 （额外排除历史模型训练集，用于跨阶段公平对比）

2.4 泄漏防控（已校验）

- $\text{train} \cap \text{val} = \emptyset, \text{train} \cap \text{test} = \emptyset, \text{val} \cap \text{test} = \emptyset$
- $\text{test_clean} \subseteq \text{test}$
- $\text{test_clean} \cap \text{历史训练集} = \emptyset$
- 筛选后训练集 no-data 均值 0.13%、最大 8.27% (阈值内)

3. 方法与协议

3.1 模型架构

MSSACT-Net: Stem 卷积 → 4 阶段 EMR 残差编码器 (逐阶段 ECSAM 坐标注意力) → FPN 特征金字塔 → Transformer 编码器 (含 Adapter-Scale) → 转置卷积解码器。

配置	embed_dims	Transformer	参数量
light (本报告主模型)	[32, 64, 128, 256]	2 层 4 头	6.10M
full (原版)	[64, 128, 256, 512]	4 层 8 头	30.54M

3.2 训练协议 (所有实验一致)

项	设置
优化器	AdamW (lr=2e-4, weight_decay=0.02)
调度	OneCycle (6% warmup + 余弦退火, 60 轮)
权重平滑	EMA (decay=0.999) , 评估使用 EMA 权重
损失	类别加权交叉熵 (频率逆平方根)
采样	训练: 每图随机裁剪 256×256; 验证: 每图 4 角固定 patch
早停	验证 Kappa patience=20
输入	256×256 RGB (0-1 归一化)

3.3 评价指标

- **Kappa 作为选优与早停标准:** 校正随机一致性。验证集最大类 (背景) 占 45.6%, 全预测背景的 OA=45.6% 但 Kappa=0——OA 在不平衡数据上会被单类支配。

- 辅助指标：OA、mF1、mIoU、混淆矩阵、每类 PA(召回)/UA(精度)。
- **数据使用协议**：val 仅用于早停/选优（`torch.no_grad()` 内评估，不参与梯度更新）；最终结论以 test / test_clean 为准。

3.4 no-data 处理与缺陷修复（重要）

官方协议：no-data（值 0）必须忽略。

已修复缺陷：早期 `REMAP` 实现将值 0 映射为 0（背景类），导致约 3% 的 no-data 像素被错误参与训练与评估。修复后同一模型指标变化：

	OA	Kappa
修复前（0→背景）	0.6862	0.6114
修复后（0→ignore）	0.6770	0.6040
差异	-0.0092	-0.0074

即此前指标**虚高约 0.007–0.009**。阶段 C 的全部实验使用修复后协议。

4. 实验结果

4.1 阶段 A：早期实验（957 张，含缺陷） — 历史结果

 本节数据含 no-data 映射缺陷，且训练集仅 957 张，**仅作历史记录**，不作为结论依据。

对比实验（60 轮预算）


模型	Kappa	OA	最优轮/总轮
mssact_full60	0.4065	0.5630	49/60
deeplab	0.3806	0.5092	42/57
fcn	0.2837	0.4245	35/50
pspnet	0.2513	0.3834	37/52
segformer	0.1775	0.3550	44/59


模型	Kappa	OA	最优轮/总轮
fpn_seg	0.2982	0.4364	60/60
swin_unet	0.2682	0.3991	40/55

多尺度 patch 对照


模型	Kappa	OA	最优轮/总轮
v3_s256	0.3862	0.5416	109/120
v3_s512	0.2187	0.3339	16/36
v3_s1024	0.2203	0.3452	30/31
v3_s128gf	0.0098	0.3038	22/38

消融实验曲线（60 轮 / 120 轮预算对比）：






训练策略探索 (SGDR / 不同预算 / 不同学习率) :



参数效率 (阶段 A 数据) :



阶段 A 的主要发现（供后续阶段验证）：



- 256px 在本数据量下为最优尺度 - 0.3m → 2.4m 跨分辨率直接迁移失效 (Kappa≈0.01)
- 训练策略探索：SGDR 热重启最优；30.5M 原版架构在调优策略下可收敛

4.2 阶段 B：扩大数据（2,257 张）— 中间结果



⚠️ 仍含 no-data 映射缺陷。

配置	Kappa	OA
full_all (主模型)	0.6155	0.6924
post_all (后训练)	0.6239	0.7003


核心发现：数据量由 957 → 2,257 张，Kappa 提升约 **+0.2**，少数类（道路/水域/裸地/建筑）F1 提升最大（+0.24 ~ +0.39）——直接证明**此前的精度瓶颈是数据量不足**。




混淆矩阵 (阶段 B 主模型 vs 阶段 A 基线, 192 张干净测试集) :



每类 精度(UA)/召回(PA)/F1:



测试集预测对比 (影像 | 真值 | 阶段 A 模型 | 阶段 B 模型) :



4.3 阶段 C: 最终实验 (1,768 张筛选 + 修复) — 结论依据

4.3.1 主模型与后训练

主模型 (完整 MSSACT-Net light)

模型	Kappa	OA	最优轮/总轮
full_all_v2	0.6312	0.7030	54/60
post_all_v2	0.6413	0.7112	27/30

后训练: 在已收敛模型上以 $lr=5e-5$ 继续训练 30 轮, 获得小幅稳定提升 (+0.0101 Kappa)。

4.3.2 对比实验 (7 个基线)

基线模型（同协议）

模型	Kappa	OA	最优轮/总轮
nd_deeplab	0.6876	0.7497	60/60
nd_fpn_seg	0.6151	0.6912	60/60
nd_fcn	0.6144	0.6903	60/60
nd_unet	0.6054	0.6833	60/60
nd_swin_unet	0.5859	0.6693	60/60
nd_pspnet	0.5175	0.6160	60/60
nd_segformer	0.3043	0.4441	60/60

分析： - DeepLabV3+ (39.6M, Kappa 0.6876) 领先， 但其参数量为 MSSACT-light 的 6.5 倍 - MSSACT-light (6.10M, 0.6312) 位列第二梯队， 与 FPN (27.2M) 、 FCN (23.7M) 相当， 但参数量仅为它们的 1/4 ~ 1/3 - 参数量-性能关系： U-Net (2.4M, 0.6054) 用 极简结构即达到接近 MSSACT 的水平， 说明在该任务与数据规模下， 架构复杂度带来的收益有限

4.3.3 消融实验（8 个变体）

消融变体（同协议）

模型	Kappa	OA	最优轮/总轮
nd_abl_no_emr	0.6355	0.7066	60/60
nd_abl_no_adapter	0.6342	0.7052	60/60
nd_abl_trans4l	0.6362	0.7064	60/60
nd_abl_trans6l	0.6335	0.7046	60/60
nd_abl_no_fpn	0.6314	0.7025	60/60
nd_abl_no_trans	0.6302	0.7023	54/60
nd_abl_no_ecsam	0.6272	0.6996	60/60
nd_abl_bilinear	0.6369	0.7082	59/60

关键发现：

变体	Δ Kappa vs 完整 (0.6312)	结论
w/o EMR	+0.0043	无显著影响
w/o Adapter	+0.0030	无显著影响
Trans-4L	+0.0050	无显著影响
Trans-6L	+0.0023	无显著影响
w/o FPN	+0.0002	无显著影响
w/o Transformer	-0.0010	无显著影响
w/o ECSAM	-0.0040	轻微负贡献
Bilinear-Up	+0.0057	无退化（略优）

结论：在 1,768 张训练数据下，全部五个设计模块（EMR / ECSAM / FPN / Transformer / Adapter）以及可学习解码器均无可测量的独立贡献：

- 8 个变体的 $|\Delta$ Kappa| 全部 ≤ 0.006
- 5 个变体略优于完整模型（Bilinear-Up +0.0057、Trans-4L +0.0050、w/o EMR +0.0043、w/o Adapter +0.0030、Trans-6L +0.0023）
- 仅两个变体略低：w/o ECSAM（-0.0040）、w/o Transformer（-0.0010）

这与阶段 A（957 张）的结论（"EMR 关键、ECSAM 有用"）**方向相反**——说明 模块的边际价值随数据量增加而被压缩至噪声水平。

参数效率含义：FPN（40.7% 参数）+ Transformer（26.4% 参数）合计 **67% 的模型容量对性能无显著贡献**，移除两者后参数量降至 2.00M（-67%），该验证实验（lg_D1_join_nofpn_notrans）正在进行中。

4.3.4 模块移除的架构适配说明

消融变体并非简单"删除模块"，而需架构层面适配：

变体	架构适配	训练表现
w/o EMR	EMR $\rightarrow$ 标准 ResBlock 替换	正常收敛，性能持平
w/o ECSAM	跳过 3 阶段坐标注意力（-0.06M）	正常收敛，略低
w/o FPN	解码器只接收最深特征（多尺度融合丢失）	正常收敛，持平


变体	架构适配	训练表现
w/o Transformer	移除全局自注意力 (-1.6M)	正常收敛, 持平
w/o Adapter	仅移除 Adapter-Scale 缩放	正常收敛, 持平
Trans-4L/6L	层数 2→4/6 (+1.6M / +3.2M)	正常收敛, 持平
Bilinear-Up	转置卷积 → 双线性 + 1×1 (-0.7M)	显著退化

5. 深入分析

5.1 数据量效应

数据量	主模型 Kappa	说明
957 张 (阶段 A)	0.4065	含缺陷
2,257 张 (阶段 B)	0.6155	含缺陷
1,768 张筛选 (阶段 C)	0.6312	修复+筛选

少数类获益最大 (阶段 B 测量)：道路 F1 +0.390、水域 +0.385、裸地 +0.324、建筑 +0.255——印证小类样本稀缺是此前的核心限制。




5.2 收敛速度的归因：调度 vs 架构

方法：计算各模型达到同一 Kappa 所需的**累计学习量**（LR 积分 $S=\sum \eta_i$ ）。OneCycle 的 LR 轨迹解析已知，可直接从历史重建。

结果（达 Kappa 0.5 所需累计学习量占比）：

模型	轮次	累计学习量	判读
DeepLabV3+ (39.6M)	11	31.8%	⚡ 真实学习效率优势
Swin-Unet (32.6M)	14	41.2%	较快
w/o ECSAM	16	47.1%	去掉注意力后更快
FPN / w/o Transformer	19	55.6%	中等
U-Net / FCN / w/o FPN / w/o Adapter	20	58.3%	中等
MSSACT-light (6.1M)	21	60.9%	中等（无优势）
w/o EMR	22	63.5%	中等
PSPNet (13.6M)	47	98.4%	最慢


结论：12 个模型中 9 个的累计学习量集中在 **47%–64%**——说明"第几轮收敛" 主要由调度曲线形状决定，**MSSACT 在收敛速度上无架构优势**。唯一明确例外是 DeepLabV3+（31.8%），其多尺度空洞卷积结构确实学习效率更高。



5.3 标签质量上限的专项验证

动机：当多个架构/容量差异极大的模型表现接近（0.61–0.69）时，需判断性能 上限由模型能力还是标签质量决定。

方法：在 test_clean (141 张) 上用 6 个模型 (U-Net 2.4M / MSSACT 6.1M / FCN 23.7M / FPN 27.2M / Swin-Unet 32.6M / DeepLabV3+ 39.6M) 逐像素推理，比较一致性与共识。



五项证据：

#	证据	数值	含义
1	模型间一致率 vs 模型-标签一致率	0.7589 vs 0.6495	模型互相认同远高于认同人工标签
2	共识标签 vs 人工标签	0.6815	约 31.9% 像素上多数模型与人工标注不符
3	容量-性能相关性反转	人工 $r = +0.311$ → 共识 $r = -0.444$	大模型更贴合人工标签模式而非更接近共识
4	标签碎片化	93.0% 像素在类边界上	0.3m 分辨率下边界"真值"难以定义
5	准确率随距边界距离	边界 0.61–0.73 → 中距离 0.47–0.57	越"纯净"区域模型越不同意标签

结论：6 个模型的能力差异（跨度约 0.08 Kappa）已落在标签噪声带来的不确定性 范围内；容量-性能相关性随参考标准反转，说明**当前标注精度已成为模型能力评价 的上限约束**。进一步区分架构优劣需要更高精度的人工标注数据（多标注者一致性 标注、更严格的边界规范）。

理论支撑： - 标签噪声下的贝叶斯上限： $\epsilon_{\min} \approx \epsilon_{\text{Bayes}} + \eta \cdot L / (L - 1)$ - 学习曲线幂律： $\epsilon(n) = a \cdot n^{(-\alpha)} + \epsilon_{\infty}$, ϵ_{∞} 由标签噪声决定 (Hestness et al. 2017) - 谱结构解释：大模型有更大"谱覆盖范围"，但噪声主导的谱尾无有效信号 (Bahri et al. PNAS 2024)

文献佐证：NSegment+ (arXiv:2508.10383) 指出真实数据集存在"隐式标签噪声"（模糊边界、标注者差异），仅在**标签端**做弹性形变即可在 LoveDA 上获得 **+2.38 mIoU**——若标签

质量不是瓶颈，此类"仅改标签"的增益不可能出现。

5.4 过拟合诊断

训练集 vs 验证集预测熵差 ($\Delta H < 0$ 表示训练集更自信 = 过拟合)：

模型	H_train	H_val	ΔH
mssact_full60	0.667	0.908	-0.241
v3_s256	0.535	0.734	-0.199
deeplab	0.577	0.771	-0.194
swin_unet	0.777	0.921	-0.144
pspnet	1.173	1.305	-0.132
fpn_seg	0.721	0.852	-0.131
fcn	0.880	0.994	-0.114
unet_matrix	1.941	1.941	-0.0003
segformer	1.252	1.220	+0.032

结论：除 SegFormer 外普遍存在中度过拟合；数据量提升后泛化差距缩小（test 与 val 的 Kappa 接近）。

5.5 训练基础设施与硬件效率优化

5.5.1 问题诊断：GPU 半时间空闲

在训练进行中连续采样（480 样本 / 274 秒），发现 **GPU 利用率仅 49.9%**，且 **34.6% 的时间处于基本空闲 (<10%)**：

指标	优化前
GPU 利用率均值 / 中位	49.9% / 43%
低于 10%（基本空闲）	34.6% 的时间
低于 30%	42.9% 的时间

指标	优化前
高于 90%	31.7% 的时间
功耗均值	88.5 W（上限 180 W）

时序采样呈现规律的「空闲簇 → 满载簇」周期（每 5–10 秒循环），是典型的 **等待数据** 特征：

```
_____=+=____-+=-____-+=____=#____-##=-###=-_-####=____+##+____=##=-_-+#+-____=##+____
（_ <10%，- <30%，= <60%，+ <90%，# ≥90%）
```

5.5.2 瓶颈定位：参数量-耗时无关性检验

最有力的证据来自**不同容量实验的每轮耗时**：

实验	参数量	每轮耗时
D3 通道[16,32,64,128]	1.55M	144 s
D2 解码器CA	6.11M	159 s
D4 通道[64,128,256,512]	24.24M	121–176 s

参数量相差 **15.6 倍**，每轮耗时几乎不变。若 GPU 是瓶颈，D4 应显著慢于 D3—— **结论：每轮时间被数据管线钉住，且该成本对所有模型是同一常数。**

数据侧实测：每张训练图需解码两个 1024×1024 PNG（图像 1.96 MB + 掩膜），解码后仅裁出 256×256——**94% 的解码结果被丢弃**。单样本约 31–37 ms，一个 batch 约 310 ms。而数据加载配置为 `num_workers=0`，即解码与增强全部在 训练主进程中**串行执行**，与 GPU 计算争用同一关键路径。

5.5.3 四项优化措施

#	措施	原理
1	预解码为 <code>npz memmap</code> (9.86 GB / 2351 张)	一次性解码后以 <code>np.memmap</code> 随机裁剪，彻底消除 PNG 解码（保留“每轮每图随机位置”增强语义）
2	<code>num_workers=8 + persistent_workers</code> <code>+ prefetch_factor=4</code>	解码/增强移出主进程，与 GPU 计算并行

#	措施	原理
3	EMA 改为遍历 <code>parameters()</code> / <code>buffers()</code>	替代每步 <code>state_dict()</code> （省去字典构建开销）
4	损失张量累积，去掉每步 <code>.item()</code>	消除每步 GPU→CPU 同步往返

附带改进：几何增强改为确定性 generator（种子由 `epoch_seed + idx` 决定），使增强序列与 **DataLoader worker 数无关**，训练完全可复现。

5.5.4 优化效果

指标	优化前	优化后	改善
GPU 利用率均值	49.9%	84.3%	1.69×
中位数	43%	87%	—
低于 10%（空闲）	34.6%	0.0%	完全消除
低于 30%	42.9%	0.0%	完全消除
高于 90%	31.7%	91.0%	2.87×
功耗均值	88.5 W	117.5 W	1.33×
数据等待	59.3 s/轮（268 ms/batch）	0.9 s/轮（4 ms/batch）	66×
每轮耗时（6.10M 模型）	88.0 s	29.5 s	3.0×
每轮耗时（2.00M 模型, 含验证/EMA/保存）	~150 s	14.7 s （回退版, 性能已验证）	~10×

优化后的时序采样**无任何空闲帧**：

++++++#####+=++++++######+#####+. . .
(+ 60 - 90%, # ≥90%)

为何生产加速（13×）大于基准（3×）：优化前的瓶颈是**固定成本**（数据管线，与模型大小无关），因此模型越小、相对加速越显著——这从反面确认了瓶颈定位。

5.5.5 方法论价值

- 1. **瓶颈定位的判据**：以"参数量-耗时无关性"区分"计算受限"与"数据受限"，比单看 GPU 利用率更可靠
- 2. **时序采样的必要性**：均值会掩盖周期性等待；时序图能直接区分"随机波动"与"规律的等待周期"
- 3. **工程收益**：实验队列总时长由约 **24 小时压缩至约 3 小时**，使更多 对照实验（架构验证、数据阶梯）在同等时间预算内成为可能

5.5.5 零性能损失验证

优化过程中**仅采用不改变训练语义的措施**，并逐项验证：

#	措施	语义影响	验证方式	结论
1	预解码 memmap	无（数据相同）	逐像素对比：随机 30 张全部一致（最大差 0）	✅ 零损失
2	<code>num_workers=8</code>	无（增强分布相同）	同一 <code>(epoch_seed, idx)</code> 决定增强序列	✅ 零损失
3	EMA 遍历 <code>parameters()</code>	无（数学等价）	与 <code>state_dict</code> 版本逐张量等价	✅ 零损失
4	损失张量累积	无（数值等价）	float32 累积，每轮一次同步	✅ 零损失
5	~~增强改确定性 <code>generator~~</code>	序列改变	实测回退验证	❌ 已回退 ：导致 Kappa 由 0.6277 降至 0.6031 (-0.0246)

第 5 项的关键发现（已回退）：将几何增强改为确定性 generator（种子由 `epoch_seed + idx` 决定）后，D1 配置（2.00M）的 Kappa 从 **0.6277 降至 0.6031**。轨迹分析显示原因是**训练前期的"验证坍缩期"长度改变**——旧管线（全局 RNG）前 10 轮验证 OA 恒为 0.1778（模型预测单一类别），第 11 轮后才开始正常学习；确定性增强版则从第 1 轮即开始上升。该改动虽不改变增强的**分布**，却显著影响 **随机性来源**，进而改变优化轨迹与最终收敛值。

回退验证（同配置、同数据、同协议）：

配置	Kappa	每轮耗时
旧管线（原始增强）	0.6277	144 s

配置	Kappa	每轮耗时
确定性增强版	0.6031	12 s
回退版 (memmap + 原始增强 + workers=0)	0.6293	14.7 s

结论：回退后性能完全恢复 (+0.0016, 在噪声内)，同时保留约 10 倍加速——加速的真实来源是 memmap 预解码（消除 PNG 解码），而非增强或并发改动。

主动放弃的改动（均为会改变训练语义、损失可比性的措施）：

措施	预期速度收益	放弃原因
batch 8 → 16/32	约 10–15%	改变 batch 需按线性缩放规则重调学习率；且显存实测：batch=16 峰值 4.61 GB（安全）、batch=32 需 9.16 GB（超 8 GB 会 OOM）
EMA 改为每 N 步更新	小	降低更新频率会改变权重平滑效果，影响精度
学习率/调度再调优	不确定	会破坏与已完成 15 个阶段 C 实验的可比性

结论：优化后 GPU 利用率由 49.9% 提升至 84.3%、每轮耗时降低 3–13 倍，且训练语义与数据完全不变——所有收益来自消除数据管线瓶颈与主进程同步开销，而非牺牲精度。

6. 关键结论

1. 数据量与数据质量共同决定上限：两者提升使主模型 Kappa 达到 **0.6312**（后训练 **0.6413**）
2. 全部设计模块均无显著贡献：8 个消融变体的最大差异仅 0.006 Kappa，5 个变体反而略优；FPN+Transformer 占 67% 参数但移除无影响
3. 收敛速度由调度主导：累计学习量分析显示 MSSACT 无收敛速度优势；DeepLabV3+ 是唯一的学习效率优势案例
4. 标签质量是当前评价瓶颈：模型间一致率 >> 模型-标签一致率，容量-性能相关性 随参考标准反转
5. 参数效率：MSSACT-light (6.1M) 达到与 23–27M 基线相当的性能，但落后于 39.6M 的 DeepLabV3+

7. 局限、疏漏与教训

7.1 研究区选择的疏漏

早期直接用自选研究区 + 公开标签产品，未核对**标签分辨率与影像分辨率的匹配性**（30m vs 2m），也未检查**类别分布代表性**（森林 >80%）。结果：标签错位 + 单类支配，指标看似可用但无科学意义、无法与文献对比。

教训：实验设计阶段先做"数据可用性三查"——①标签精度与影像分辨率匹配；②类别分布是否均衡；③是否有公认基准与可对比结果。

7.2 类别体系核对的疏漏

改用 LoveDA 后未第一时间核对官方类别定义，将「背景（值 1）」与「未分类（值 0）」混淆，导致标签映射缺陷、全部指标虚高约 0.007–0.009。

教训：使用公开数据集前，必须以**官方文档原文**核对：类别编号、每类语义、无效值定义与评估协议。

7.3 当前局限

- 训练数据仅用官方 train 区（2,522 张筛选后 2,210 张），未纳入验证区
- 标签质量不足以支撑细粒度架构比较（5.3 节实证）
- 跨分辨率迁移（GF-1 2.4m）仍受域差限制，需同域微调
- 少数类（道路占比约 2.4%）仍是最弱环节

7.4 质量控制措施

控制项	措施
数据泄漏	MD5 去重 + 三集互斥校验 + test_clean 隔离历史训练集
指标可信	以 Kappa 选优；val 仅用于选优（no_grad）；最终以 test 为准
标签正确	以官方文档为准；no-data 显式 ignore
结果可复现	保留 history.json + 权重 + 固定 seed；FACTS.json 自动汇总
架构一致性	checkpoint 架构自动核验（verify_experiments.py）

8. 后续工作

1. **标签质量与评价体系**：引入多标注者一致性标注，估计真实标签噪声率；在更高精度标注数据上重新评价各架构能力
 2. **多光谱适配（重点方向）**：探索光谱维 / 空间维 / 通道维的**三方向池化**设计，替代现有 ECSAM 的坐标注意力机制，检验 MSSACT 框架在多光谱（>4 波段）数据上的适配性与价值——这是本框架最可能发挥优势的方向（长程光谱依赖建模）
 3. **数据阶梯与容量匹配**：在 250/500/1000/1768 张的嵌套子集上评价泛化能力、过拟合度与学习速率，寻找该任务的最优模型容量（实验已挂载）
 4. **跨域验证**：GF-1 2.4m 影像 + 同域微调，检验分辨率-域差异下的迁移能力
 5. **少数类与部署**：重采样/损失调优；推理加速与 TTA 部署
-

9. 个人工作与能力体现

本项目从数据获取到结果验证全流程独立完成：

9.1 数据工程

- 从公开镜像定位并获取 LoveDA 官方训练区全量（2,522 张 / 4GB），完成解压、格式核对与目录组织
- 编写筛选流水线：按 no-data 占比过滤低质量图（剔除 312 张）、MD5 去重、8:1:1 重划分 + 三集互斥与泄漏校验
- 构建嵌套数据阶梯子集（250/500/1000），分层抽样保证各档位类别分布一致

9.2 模型训练与工程

- 训练管线：PyTorch + AMP + EMA + OneCycle + 类别加权损失；单卡 8GB 显存完成 6.1M ~ 39.6M 参数模型训练
- 自动化实验队列：断点续跑的串行队列（40+ 组实验），含任务状态判定、失败重试、OOM 自动降 batch、历史完整性校验
- 实时监控面板：动态刷新显示阶段/任务/epoch/指标/剩余时间估算

9.3 实验设计与分析

- 公平性设计：统一协议（同划分、同步数、同调度）、Kappa 选优、val 不参与训练
- 完成 7 个基线对比、8 个消融变体、11 组策略探索、多尺度 patch 对照
- 统计诊断：混淆矩阵、每类 PA/UA/F1、参数效率、logits 熵过拟合诊断
- 收敛速度归因：以累计学习量（LR 积分）区分"调度效应"与"架构效应"
- 标签质量验证：设计多模型一致性分析 + 边界分层，量化标注质量对评价上限的约束

9.4 问题定位与修复

- **标签协议缺陷**：核对官方文档发现「背景/未分类」混淆，定位 REMAP 实现缺陷，量化影响（虚高 0.007–0.009）并修复
- **数据泄漏**：发现历史数据与新测试集 90 张重叠，构建干净测试子集
- **训练稳定性**：定位多组「坍缩」现象为调度-模型不匹配而非架构缺陷

9.5 工具与产出

- 自动化脚本：筛选划分（resplit_filtered.py）、实验队列（run_queue.py）、统一评估（eval.py）、事实汇总（build_facts.py）、图表生成、报告生成管线
- 全部代码与方法学文档已开源：<https://github.com/eugenewang5425/mssact-loveda>

附录 A：复现指引

```
# 数据准备
python resplit_filtered.py      # no-data筛选 + MD5去重 + 8:1:1 划分
python verify_split2.py        # 泄漏校验
python build_data_ladder.py     # 嵌套数据阶梯子集

# 训练（实验队列，自动串行）
python run_queue_new.py         # 主模型重训 + 对比(7) + 消融(8)
python run_queue_30m.py        # 30.5M 原版架构 + 后训练 + TTA
python run_queue_interaction.py # 预算攻击 + 固定LR + 数据阶梯

# 评估与分析
python eval_complete.py        # val/test × TTA
python eval_tta_new.py         # 新数据 TTA 评估
python consensus_analysis.py    # 标签质量一致性分析
```

```
python eval_ladder.py          # 数据阶梯评价

# 汇总与报告
python build_facts.py          # 事实汇总 (FACTS.json)
python make_project_report.py   # 本报告生成
```

附录 B：文件与目录说明

目录/文件	说明	是否入库
models/	模型定义 (msscactnet.py)	✓
train_v3.py	数据集与训练循环核心	✓
experiment_matrix.py	通用训练入口 + 基线模型定义	✓
experiment_matrix_v2.py	扩展基线 (FPN/Swin-Unet) + 消融构造	✓
run_queue*.py	实验队列 (自动串行)	✓
eval_*.py	评估脚本	✓
build_facts.py	事实汇总 (FACTS.json 生成器)	✓
make_project_report.py	本报告生成器	✓
figures/	图表 (报告与 README 引用)	✓
docs/	文档与历史报告归档	✓
checkpoints/	权重与训练历史 (体积大)	✗
fulltile_eval/ tta_eval*/ 等	评估结果 (可复现生成)	✗
原始数据	LoveDA (需自行下载)	✗

代码仓库: <https://github.com/eugenewang5425/mssact-loveda>