

MSSACT-Net 遥感土地覆盖分割

项目报告

数据集： LoveDA 公开基准 (0.3 m 航空正射影像, 7 类土地覆盖, 官方人工标注) **模型：** MSSACT-Net (多尺度自注意力 ConvTransformer, light 配置 6.10M 参数) **代码：** <https://github.com/eugenewang5425/mssact-loveda>

摘要

本项目在公开基准 **LoveDA** 上系统训练与评估自研的 **MSSACT-Net**, 完成了 7 个主流分割模型的对比、8 个模块消融、架构缺陷的数值检验、数据量与裁剪策略的扫描、随机种子噪声底线的实测, 以及标签质量上限的专项验证。

一、方法学层面最重要的产出是"误差底线"。 同配置换随机种子 ($n=4$) 得到 $\sigma_{\text{seed}} = 0.0050$ 、极差 0.0094。以此为尺度衡量**全部**实验差异后, 可分辨的效应屈指可数——这为后续所有结论提供了 统一的判据 (详见 §5.11) 。

二、预训练主干是本任务上最大的单项杠杆, 且它曾造成一处严重误判。 在公平的从零对照下, 自研 6.10M 与 DeepLabV3+ 39.69M 不可分辨 ($\Delta = +0.0039$, 0.78σ)。而同一模型仅切换权重初始化, Kappa 即相差 $+0.054 \sim +0.154$ (§5.6.6)。项目早期因

`weights=None` 未关闭主干预训练, 使 DeepLabV3+ 基线实际带着 ImageNet 预训练主干, 导致 "+0.0720 架构优势"的错误归因——该错误已定位、更正并记录取证过程。

三、消融实验"全部无差异"的真因是实现缺陷, 不是模块设计无效。 数值检验证实三处结构性缺陷: FPN 的多尺度融合未被使用 (其 1,828,352 个参数 = 全模型 29.96% 不参与前向, 实测归零后输出逐位不变)、解码器无跳连 (仅凭 $8\times$ 下采样特征上采样)、Transformer 无位置编码 (置换等变, 实测差 $7.15e-07$)。8 个消融变体的散布仅 0.008, 落在 σ_{seed} 带内。

四、训练策略的收益可分辨, 架构模块增删不可分辨。 256 随机裁剪比固定中心裁剪高 $+0.0192$ (3.8σ) ; 384^2 比 256^2 高 $+0.0223$ (4.5σ) ; 而全部模块消融都 $\leq 1.13\sigma$ 。杠杆排序: 预训练主干 $\gg$ 训练策略 $>$ 架构模块。

五、基线并非"领先"。 协议内从零对比下，自研 6.10M 与 DeepLabV3+ 39.69M 在主协议不可分辨；在预算受限（15 轮）与 1,000 张档位下自研更高；仅在 n=250/500 的极小数据档显著更低——说明自研模型**更依赖数据量**。

六、标签质量仍是评价上限的约束。 6 个模型（2.4M–39.6M）逐像素分析：模型间一致率 **0.7589** 显著高于模型与人工标签的 **0.6495**。但 2.4% 的边界像素仅值 +0.016 Kappa，而 78.4% 的内部像素值 +0.29——**聚合指标几乎看不见边界质量**（\$5.6.8）。

关键词： 高分辨率遥感；土地覆盖分类；语义分割；自注意力；LoveDA；误差底线；标签质量；消融实验；可复现性

0. 项目状态

项	状态
数据集	LoveDA 官方训练区全量获取（2,522 张）
数据筛选与划分	✅ no-data ≤10% 筛选 → MD5 去重 → 8:1:1（train 1768 / val 221 / test 221 / test_clean 141）
泄漏校验	✅ 三集两两互斥；test_clean 与历史训练集零重叠
主模型训练	✅ full_all_v2（60 轮）+ post_all_v2（后训练 30 轮）
对比实验（7 基线）	✅ 完成（含 协议内从零 DeepLabV3+ 对照）
消融实验（8 变体）	✅ 完成（散布 0.008；实测 $\sigma_{\text{seed}}=0.0050 \rightarrow$ 不可分辨）
架构缺陷数值检验	✅ 完成（FPN 死支路 / 无跳连 / 无位置编码）
架构变体 D1–D4	✅ 完成（同管线同协议，两条管线互证）
随机种子噪声底线	✅ 完成（ $\sigma_{\text{seed}} = 0.0050$ ）
训练策略（裁剪尺度/随机）	✅ 完成（效应 3.8–4.5 σ ）
数据量阶梯 （250/500/1000）	✅ 完成
预算攻击（15 轮）	✅ 完成
DeepLabV3+ 从零对照	✅ 完成（推翻原 +0.0720 的架构归因）
硬件效率优化	✅ 完成（GPU 利用率中位 6% $\rightarrow$ 75%，零性能损失）

项	状态
等效性检验 (TOST)	 材料已就绪 (<code>analysis/eval_rigor.py</code>) , 待补齐
预训练主干 / 域内预训练	 后续方向 (见 §8.1)
跨数据集与多光谱适配	 后续方向 (见 §8.2)

1. 项目背景

1.1 研究目标

在公开、可复现的遥感基准上，系统评估自研 MSSACT-Net 的：

- 土地覆盖分类精度**——以 Kappa 为主指标（理由见 §3.3），并与主流分割模型横向对比；
- 各设计模块的实际贡献**——通过逐模块消融，并先用数值手段检验模块是否真的在工作（这一步发现了三处实现缺陷，见 §5.6）；
- 训练策略与数据规模的影响**——裁剪尺度、随机/固定裁剪、数据量阶梯；
- 评价本身的可靠性**——实测随机种子噪声底线 σ_{seed} ，并用它给所有差异定级。

1.2 为什么改用公开数据集

早期工作选用的研究区（内蒙古根河市，GF-1 影像）存在两个不可回避的问题：**类别体系与影像分辨率不匹配**（2.4 m GSD 下大量类别在光谱与空间上不可分），以及**缺少可公开核验的逐像素标注**。

因此改用 **LoveDA**：0.3 m 航空正射影像、7 类、官方人工逐像素标注、有公开基准 与论文可对照。这一更换使全部结论建立在**他人可复现**的数据之上，是本项目最重要 的一次方法论更正。

2. 数据

2.1 官方类别体系（依据官方文档核对）

Category labels: **background – 1, building – 2, road – 3, water – 4, barren – 5, forest – 6, agriculture – 7**; and the **no-data regions were assigned 0 which should be ignored.**

标签值	类别	本项目索引
0	no-data	必须忽略 (→255)
1–7	背景/建筑/道路/水域/裸地/森林/农田	0–6

⚠️ 早期实现曾把 0 (no-data) 错误映射为"背景"参与训练与评估，使指标虚高 约 0.007–0.009 Kappa。该缺陷已修复 (§3.4) 。

2.2 数据演进三阶段

阶段	数据	标签处理	结论地位
A	957 张 (镜像子集)	⚠️ 含 no-data 映射缺陷	历史参考
B	2,257 张 (官方全量去重)	⚠️ 仍含缺陷	中间结果
C	1,768 张 (筛选后)	✅ 已修复	结论依据

必须诚实说明的一点：A→B→C 的对比**不是纯粹的数据量效应**。阶段 C 的 1,768 张比阶段 B 的 2,257 张**更少**，却取得更高 Kappa，说明该对比同时 包含了"数据量、标签修复、低质量样本剔除"三项变化，三者**无法分离**。真正的数据量效应由 §5.9 的阶梯实验（同协议、同管线的 250/500/1000 张）给出。

2.3 筛选与划分 (阶段 C)

流程：**no-data 占比 ≤10% 筛选** (剔除 312 张) → **MD5 去重** → **8:1:1 划分**。


集合	图像数	用途
train	1768	训练
val	221	早停 / 选优 (不参与梯度)
test	221	评估
test_clean	141	结论用途 (与历史训练集零重叠)

2.4 类别分布 (已按实测更正)

划分	图像数	背景占比（最大类）	ignore 占比
训练集	1768	36.09%	0.17%
验证集	221	37.15%	0.13%
干净测试集	141	41.54%	0.40%

验证集逐类占比：背景 37.1%、建筑 9.3%、道路 5.2%、水域 6.4%、裸地 6.4%、森林 17.5%、农田 18.0%


勘误：早期报告称"验证集最大类（背景）占 **45.6%**"，并据此论证 "全预测背景 的 OA=45.6%"。实测该值为 **37.15%**（train 36.1%、test_clean 41.5%）。论证方向不变（OA 会被单类支配、故采用 Kappa 选优），但**数值已更正**。



3. 方法与协议

3.1 模型架构

3.1.1 整体数据流



红色 = 已数值证实的缺陷环节：FPN 的多尺度输出仅最深层进入前向（29.96% 参数不参与），解码器无跳连、由 32^2 特征上采样 8 倍；Transformer 无位置编码

输入为 $256 \times 256 \times 3$ 的 RGB patch，逐级变换如下（括号内为分辨率与通道）：

阶段	输出	说明
Stem	$256^2 \times 32$	3×3 卷积 + BN + ReLU
EMR 编码器 $\times 4$	$256^2 \times 32 \rightarrow 128^2 \times 64 \rightarrow 64^2 \times 128 \rightarrow 32^2 \times 256$	每阶段后 max-pool 下采样（最后一级不下采样）
ECSAM 坐标注意力	同上（仅第 2–4 阶段）	见 §3.1.3
FPN 多尺度融合	$32^2 \times 256$ （仅最深层进入前向）	见 §5.6.2 的缺陷说明
Transformer 编码器	$32^2 \rightarrow 1024 \text{ token} \rightarrow 32^2$	见 §5.6.4 的缺陷说明
解码器（转置卷积 $\times 3$ ）	$64^2 \rightarrow 128^2 \rightarrow 256^2 \times 64$	无跳连，见 §5.6.3
分类头（ 1×1 卷积）	$256^2 \times 7$	逐像素类别 logits

3.1.2 各模块职责

- **EMR (Enhanced Multi-scale Residual)**：两个 3×3 卷积 + 短路连接，构成 残差基本块。作用是逐阶段扩大感受野、提取多尺度空间特征。
- **ECSAM (Enhanced Coordinate Spatial Attention Module)**：坐标注意力（Hou et al., CVPR 2021）。沿水平与垂直方向分别做 1D 池化，得到方向感知的 特征向量，经共享 1×1 变换后重加权。**其设计意图是编码长程空间位置信息。**
- **FPN (Feature Pyramid Network)**：自顶向下把深层语义与浅层细节融合，输出 4 个尺度的特征图。
- **Transformer 编码器 + Adapter-Scale**：对最深层特征做全局自注意力，以捕捉长程上下文；Adapter 是一个低秩 ($d/4$) 残差分支，配合可学习的 `scale_factor` 控制其贡献强度。

- **解码器**：3 次 stride=2 的转置卷积，把 32^2 恢复到 256^2 。

3.1.3 配置与参数量账目


配置	embed_dims	Transformer	参数量
light (本报告主模型)	[32, 64, 128, 256]	2 层 4 头	6.10M
large (D4 实验)	[64, 128, 256, 512]	2 层 4 头	24.24M

本报告主模型 light 配置的**模块参数账目**（直读 checkpoint 张量求和，非估算）：

模块	参数量	占比
FPN	2,484,224	40.71%
Transformer	1,612,609	26.43%
EMR 编码器	1,226,504	20.10%
解码器	722,378	11.84%
ECSAM（坐标注意力）	55,044	0.90%
Stem	1,025	0.02%
合计	6,101,784	100%

两点直接推论：

1. **FPN + Transformer 合计占 67.14% 的参数**，但 §5.6 将证明二者在实现上**未执行其声明的功能**。
2. **ECSAM（坐标注意力）仅占 0.90%**——对占比不足 1% 的模块 期待显著增益，在容量意义上本就不合理。



3.2 训练协议 (所有实验一致)

项	设置
优化器	AdamW, lr = 2e-4, weight_decay = 0.02
调度	OneCycleLR, 最大学习率 2e-4, warmup 占 6%, 余弦退火, 总 60 轮
批大小	8 (裁剪 384 ² 时为 4, 512 ² 时为 2, 按面积下调以避免显存溢出)
精度	混合精度 (AMP) + 梯度裁剪 (max-norm = 1.0)
权重平滑	EMA, decay = 0.999, 评估用 EMA 权重
损失	类别加权交叉熵, 权重 $\propto 1/\sqrt{\text{频率}}$ (见下)
早停	验证集 Kappa 连续 20 轮不升则停
数据增强	每轮每图随机裁剪 1 个 patch (位置固定为 epoch_seed 决定); 随机 90° 旋转 ×4、水平/垂直翻转

类别权重公式: 设第 c 类像素数为 n_c , 则

$$w_c = \left(\frac{n_c}{N} \right)^{-1/2} / \text{mean}_k \left(\frac{n_k}{N} \right)^{-1/2}$$

即取频率的**负平方根**并归一化到均值为 1。用负平方根而非倒数, 是为了避免 极稀有类 (如道路) 获得过大的权重而使训练不稳定。

EMA 更新公式: 设模型参数为 θ , 影子参数为 θ' , decay 为 λ :

```
theta' <- lambda * theta' + (1 - lambda) * theta      (lambda = 0.999)
```

即影子参数是历史参数的指数滑动平均；用其评估可显著降低验证指标的抖动。

3.3 评价指标

全部指标在 **255 (no-data) 像素上屏蔽**后计算。

设混淆矩阵 CM ， CM_{ij} = 真值为 i 、预测为 j 的像素数， $N = \sum_{ij} CM_{ij}$ 。

OA (总体精度)

```
OA = sum_i CM_ii / N
```

Kappa (本报告的主指标与选优/早停依据)

```
po = sum_i CM_ii / N          # 观测一致率
pe = sum_i ( row_i * col_i ) / N^2    # 随机一致率
Kappa = (po - pe) / (1 - pe)
```

为什么用 Kappa 而非 OA：LoveDA 背景类占比约 37%，一个"全部预测背景"的 平凡模型即可取得 $OA \approx 0.37$ ，但其 $Kappa = 0$ 。Kappa 扣除了随机一致率，在不平衡数据上不会被单类支配。

F1 / mF1 (按类)

```
precision_i = CM_ii / col_i      # 亦称 UA (用户精度)
recall_i    = CM_ii / row_i      # 亦称 PA (生产者精度)
F1_i        = 2 * precision_i * recall_i / (precision_i + recall_i)
mF1         = mean_i F1_i
```

IoU / mIoU

```
IoU_i = CM_ii / ( row_i + col_i - CM_ii )
mIoU  = mean_i IoU_i
```

数据使用协议：val 仅用于早停与选优（在 `torch.no_grad()` 内评估，不参与 梯度更新）；**全部结论以 test / test_clean 为准。**

误差底线 σ_{seed} （本项目新增）：同配置、同数据、仅换随机种子重复训练，Kappa 的标准差。它给出"差异是否可分辨"的尺度： $|\Delta| < 1\sigma$ 视为不可分辨， $1-2\sigma$ 为弱证据， $> 2\sigma$ 才认为可分辨（详见 §5.7 与 §5.11）。

3.4 no-data 处理与缺陷修复

问题	表现	修复
标签映射缺陷	官方 0 = no-data 被当作"背景"参与训练与评估	REMAP：0 及一切非 1-7 值 → 255 (ignore)，评估时屏蔽
低质量样本	部分图像 no-data 占比过高	训练集剔除 no-data > 10% 的图像 (312 张)
评估数据泄漏	早期 val/test 可能与训练集重叠	MD5 去重 + 三集两两互斥校验 + test_clean 隔离

3.5 可复现性设计

- **路径集中：**全部路径由 `paths.py` 提供，脚本内**零绝对路径**；本地数据路径只写在 `.env`（不入库）。
- **管线世代隔离：**不同数据投递后端（PNG / memmap）的训练结果**分别标记、禁止跨世代比较 Kappa**（详见附录 A.2）。
- **产物登记：**`experiments_index.json` 登记全部实验（参数量直读 checkpoint 张量、架构由形状反推、出处指向启动它的队列脚本）。
- **推送前审核：**`verify/pre_push_audit.py` 检查本机路径、内部语境词、大文件与误提交。

4. 实验结果

4.1 阶段 A：早期实验（957 张，含缺陷） — 历史结果

主模型 Kappa **0.4065**，基线中 DeepLabV3+ 最高 (0.3806)、SegFormer-Lite 最低 (0.1775)。120 轮消融中 w/o Adapter 反而最好 (0.4621)。

本阶段结果不作为结论依据，原因有三：数据量不足（957 张）、标签映射含 no-data 缺陷、且当时的 DeepLabV3+ 基线带预训练主干（见 §5.6.6）。该阶段的图已全部撤出本报告（原图基于上述缺陷数据），仅保留文字记录。

4.2 阶段 B：扩大数据（2,257 张）— 中间结果


主模型 Kappa **0.6155**，后训练 **0.6239**。相比阶段 A 有大幅提升，但 **REMAP** 缺陷仍未修复，故同样不作为结论依据。

4.3 阶段 C：最终实验（1,768 张筛选 + 修复）— 结论依据

4.3.1 主模型与后训练

模型	Kappa	OA	说明
full_all_v2 (60 轮)	0.6312	0.7030	主模型
post_all_v2 (+30 轮微调, lr=5e-5)	0.6413	0.7112	在已收敛模型上继续训练

后训练带来 **+0.0101** Kappa（ 2.02σ ，属可分辨的小幅提升）。




图中可见两点：① DeepLabV3+ 的**从零版本收敛晚于**自研模型（起势更慢），与 §5.2 的累计学习量分析一致；② 带预训练主干的那条曲线早在第 11 轮即越过 Kappa 0.5——这正是早期报告误判"架构学习效率更高"的来源。

4.3.2 对比实验（7 个基线）

模型	参数量	Kappa	OA	最优轮/总轮
MSSACT-Net light（自研）	6.10M	0.6312	0.7030	54/60
DeepLabV3+（从零，协议内）	39.69M	0.6281	0.7018	60/60
DeepLabV3+（预训练主干，旁证 ⚠️ 非协议内）	39.69M	0.6876	0.7497	60/60
FPN-Seg	27.20M	0.6151	0.6912	60/60
FCN	23.78M	0.6144	0.6903	60/60
U-Net	2.45M	0.6054	0.6833	60/60
Swin-Unet-Lite	32.67M	0.5859	0.6693	60/60
PSPNet	13.60M	0.5175	0.6160	60/60
SegFormer-Lite	1.23M	0.3043	0.4441	60/60


分析：

- 协议内（全部从零训练）的公平对比下，DeepLabV3+（39.69M）与自研 6.10M 不可分辨 ($\Delta = +0.0039, 0.78\sigma$)，而后者参数仅为其 1/6.5。
- 表中 DeepLabV3+ 的**预训练版本**已明确标注为"旁证 ⚠️ 非协议内"，**不作为基线**。它比从零版高出的 0.06，正是预训练的贡献 (§5.6.6)。
- 自研模型以 6.10M 参数达到与 23–27M 级别模型相当的水平。





4.3.3 混淆矩阵与逐类 IoU

MSSACT-Net light (自研)



DeepLabV3+ (预训练主干, 旁证)






读图要点：自研模型与 DeepLabV3+（预训练）的混淆**结构相似**——两者的主要混淆都发生在 **裸地 ↔ 农田/森林** 与 **背景 ↔ 建筑** 之间，说明困难来自 **类间光谱相似性与标注边界模糊**，而非某个模型特有的缺陷。逐类看，DeepLabV3+（预训练）在 7 个类上均更高——但如 §5.6.6 所示，该优势主要来自预训练主干。

4.3.4 消融实验（8 个变体）

变体	Kappa	Δ Kappa vs 完整 (0.6312)	可分辨性
Bilinear-Up (可学习上采样 → 双线性)	0.6369	+0.0057 (1.14 σ , 弱)	
Transformer 2 层 → 4 层	0.6362	+0.0050 (1.00 σ , 弱)	
w/o EMR (改用标准 ResBlock)	0.6355	+0.0043 (0.86 σ , 不可分辨)	
w/o Adapter-Scale	0.6342	+0.0030 (0.60 σ , 不可分辨)	
Transformer 2 层 → 6 层	0.6335	+0.0023 (0.46 σ , 不可分辨)	
w/o FPN (直接用最深层特征)	0.6314	+0.0002 (0.04 σ , 不可分辨)	
w/o Transformer (含 Adapter)	0.6302	-0.0010 (0.20 σ , 不可分辨)	
w/o ECSAM (去掉坐标注意力)	0.6272	-0.0040 (0.80 σ , 不可分辨)	

关键发现：8 个变体的散布仅 0.008，全部落在 $\pm 1.6\sigma_{\text{seed}}$ 内——即在统计上 **不可分辨**。其中 5 个变体（含把可学习上采样换成双线性的 Bilinear-Up）**反而略优于完整模型**。



重要限定：这**不等于**"这五个模块没有设计价值"。§5.6 的数值检验证明，其中若干模块在实现上并未执行其声明的功能（FPN 的多尺度融合被丢弃、Transformer 无位置编码）。因此本节**的正确解读是 "移除它们没有影响，因为它们在数值上接近什么都不做"**。

4.3.5 模块移除的架构适配说明

消融并非简单删除调用，部分变体需要架构层面的适配：

变体	适配方式
w/o EMR	EMR 残差块 → 标准 ResBlock 替换
w/o ECSAM	前向直接跳过坐标注意力（参数量 -0.055M）
w/o FPN	跳过 FPN，最深层特征直送 Transformer/解码器
w/o Transformer	移除全局自注意力与 Adapter（参数量 -1.6M）
w/o Adapter	仅移除 Adapter-Scale（低秩残差 + scale_factor）
Bilinear-Up	转置卷积 → 双线性插值 + 1×1 卷积

5. 深入分析

5.1 数据规模与标签质量：三项同时变化的混合效应

数据量	主模型 Kappa	同时发生的变化
957 张 (阶段 A)	0.4065	原始状态
2,257 张 (阶段 B)	0.6155	仅扩数据
1,768 张筛选 (阶段 C)	0.6312	扩数据 + 标签修复 + 剔除低质量样本

这三项在阶段 C 是同时发生的，无法分离。特别是阶段 C 的图像数比阶段 B 更少 却更好，直接说明"数据量"不是唯一变量。

若要单独度量数据量效应，必须固定其他一切——这正是 §5.9 阶梯实验的设计：同一管线、同一协议、同一验证集，只改训练集规模（250/500/1000 张）。

少数类是否获益更多？阶段 B 的逐类 F1 显示道路 +0.390、水域 +0.385、裸地 +0.324、建筑 +0.255，但阶段 B 的标签映射仍有缺陷，其逐类数值只宜 作为趋势参考。阶段 C 的逐类 IoU 见 §4.3.3。

5.2 收敛速度的归因：调度 vs 架构

方法（以及它为什么能分离两者）：OneCycleLR 的学习率轨迹是解析已知的——给定 max_lr、总步数 T、warmup 比例，任一时刻的 η 可由公式算出，与模型无关。定义累计学习量：

$$S(t) = \sum_{\tau \leq t} \eta_{\tau}$$

若两个模型在同一水平上所需的 S 相同，则差异来自架构；若几乎所有模型都在相近的 S 比例处达到同一水平，则说明"第几轮收敛"只是调度曲线形状的映射。

结果（达 Kappa 0.5 所需累计学习量占比；全部为 P-PNG 管线同协议）：

模型	达 K0.5 轮次	累计学习量
DeepLabV3+（预训练主干）	11	30.3%
Swin-Unet	14	39.7%
w/o ECSAM	16	45.7%
MSSACT-light / Trans-4L	21	59.7%


模型	达 K0.5 轮次	累计学习量
w/o EMR	22	62.2%
DeepLabV3+ (从零)	28	75.9%
PSPNet	47	98.2%
SegFormer-Lite	未达到	—

结论（已更正）：

早期报告称"唯一例外是 DeepLabV3+ (31.8%)，其多尺度空洞卷积结构确实学习效率更高"。该结论是错的——31.8% 来自带 ImageNet 预训练主干的那一次运行。换成本项目自己训练的**从零**版本后，DeepLabV3+ 需要 **75.9%** 的累计学习量，比自研模型的 59.7% 还慢。

因此：预训练带来的是早期收敛加速，而非该架构的学习效率优势；在公平的 从零条件下，DeepLabV3+ 的收敛速度**不优于**自研模型。


绝大多数模型（11/16）集中在 40%–76% 区间，支持"第几轮收敛主要由调度曲线决定"这一判断。



5.3 标签质量上限的专项验证

6 个架构/容量差异极大的模型（2.4M–39.6M）在 test_clean（141 张）上逐像素分析：


判据	数值
平均 模型间 一致率	0.7589
平均 模型–人工标签 一致率	0.6495
多数投票共识 vs 人工标签	0.6815



解读：模型之间的互相认同（0.7589）显著高于它们与 人工标签的认同（0.6495），说明模型在**彼此一致地 偏离**人工标注。

必须声明的限定：共识法（Warfield et al., 2004 的 STAPLE 一脉）要求 **各模型的误差相互独立**（Bouix et al., 2007）。本项目 6 个模型**共享训练集、损失函数与训练协议**，误差必然相关，因此共识评估会**偏向同族约定**。故本节结论应视为**提示性证据**，不能单独作为“标签上限已被证实”的依据。更强的证据来自 §5.6.8 的 Kappa 归属分析（与参考标准无关的纯数学量）。

5.4 过拟合诊断



以训练/验证 logits 的预测熵差 $\Delta H = H_{\text{train}} - H_{\text{val}}$ 衡量： ΔH 为负说明模型在训练集上更“自信”（预测更集中）。阶段 A 的主模型 $\Delta H = -0.241$ ，是所测模型中偏离最大的；而 SegFormer-Lite 接近 0（ -0.0003 ）——但那是因为它**几乎没学到东西**（Kappa 0.3043）。

判读要点： ΔH 单独看会误读。它必须与**绝对性能**联合解读： ΔH 大且性能高 = 记忆了训练集； $\Delta H \approx 0$ 且性能低 = 欠拟合。本项目主模型属于前者，与 §5.9 的结论（自研模型更依赖数据量）互相印证。

5.5 训练基础设施与硬件效率优化

5.5.1 问题诊断

训练时 GPU 利用率仅 49.9%，**34.6% 的时间 GPU 完全空闲**。

5.5.2 瓶颈定位

关键判据是**参数量与每轮耗时的无关性**：1.55M 参数（144 s/轮）与 24.24M 参数（121–176 s/轮）耗时接近——说明瓶颈**不在计算**，而在数据侧。

根因：每样本解码**两张 1024^2 PNG**，却只裁出 256^2 ，**94% 的解码结果被丢弃**；且


`num_workers=0` 时代码在主进程串行解码，GPU 全程等数据。


5.5.3 优化措施（四项）

措施	做法
预解码 memmap	一次性把 1024 ² PNG 解码为 <code>uint8</code> memmap, 训练时随机切片
多进程加载	<code>num_workers > 0 + persistent_workers + prefetch_factor</code>
EMA 实现优化	改为直接遍历 <code>parameters()</code> , 避免每步构造 <code>state_dict()</code>
损失累积	用张量累加损失, 去掉每步 <code>.item()</code> 造成的 GPU-CPU 同步

5.5.4 优化效果

指标	优化前	优化后
GPU 利用率 (均值)	49.9%	84.3%
每轮耗时	144 s	12–15 s
数据阶梯每张图成本	≈170 ms/张	≈24 ms/张





上图右为**后来补测**的数据：切到 memmap 后每轮耗时随参数量单调增长，正面确认瓶颈已从"数据受限"转为"计算受限"。

5.5.5 零性能损失验证

优化过程中逐项验证，**仅保留不改变训练语义的措施**：

#	措施	结论
1	memmap 预解码	✅ 数据内容与 PNG 路径 逐位一致 (<code>verify/bench_parity.py</code>)
2	EMA 实现重写	✅ 数学等价 (同一滑动平均公式)
3	损失张量累积	✅ 仅去掉同步，数值不变
4	多进程加载	✅ 不影响增强语义
5	~~增强改确定性 generator~~	❌ 已回退 ：导致 Kappa $0.6277 \rightarrow 0.6031$ (-0.0246)
6	~~batch 8 $\rightarrow$ 16/32~~	❌ 主动放弃 (需重调学习率，破坏可比性；且 batch=32 需 9.16 GB 显存会 OOM)
7	~~学习率/调度再调优~~	❌ 主动放弃 (会破坏与已完成实验的可比性)

回退验证（同配置、同数据、同协议）：

配置	Kappa	每轮耗时
旧管线（原始增强）	0.6277	144 s
确定性增强版	0.6031	12 s
回退版（memmap + 原始增强 + workers=0）	0.6293	14.7 s

结论：回退后性能完全恢复（+0.0016，在噪声内），同时保留约 10 倍加速——加速的真实来源是 memmap 预解码，而非增强或并发改动。

5.6 架构有效性分析：为什么消融实验全部"无差异"

本节是对自研架构的否定性发现，也是本项目最重要的技术结论之一。

三处结构性缺陷（均由可复现的数值实验证实）：

#	缺陷	验证方式	结果
D1	FPN 的多尺度融合是死计算	归零 lateral_convs[0..2]；把整个 FPN 换成"仅第 4 支路"的等价算子	两次输出差恰好 0.0（逐位相同）
D2	解码器无跳连	前向路径 + 分辨率链追踪 + 边缘密度/FFT 实测	高分辨率特征从未到达输出；预测边缘密度达标签 4.56×，且周期 k=8 功率超额 1.66×
D3	Transformer 无位置编码	置换 token 后按逆置换还原	差 7.15e-07 → 置换等变，无空间感知

5.6.1 参数账目

见表 §3.1.3。关键结论：FPN 的 1,828,352 个参数（全模型 29.96%）不参与前向，实际参与前向的有效参数仅 4,273,432（70.04%）。

5.6.2 D1：FPN 的多尺度融合未被使用

MSSACTNet.forward 只取 fpn_features[-1]；而 FPN.forward 的自顶向下融合循环 写入索引 i-1（即 2/1/0），最深层 laterals[3] 从未被融合增强。两者叠加的结果：laterals[0..2] 及其对应的 fpn_convs[0..2] 算完就被丢弃。

因此"w/o FPN"消融的真实含义是：移除"最深尺度上的一个 1×1 卷积 + 一个 3×3 卷积，外加 3 条被丢弃的支路"。

这不是"FPN 冗余"的证据，而是"这个 FPN 没有在工作"的证据。前者是多尺度融合的一般性结论，后者是本实现的缺陷结论——科学含义完全不同。

5.6.3 D2：解码器无跳连 → 细节为"合成"而非"测量"，并伴生棋盘伪影


必须精确表述：三次转置卷积上采样能够产生高频结构（转置卷积可学习上采样核），因此不能说"输出被限制在 8 像素粒度"。正确表述是：没有任何通路让高频的输入证据到达输出——输出中的细节是解码器合成的，而非在高分辨率上测量到的。

实测（逐图 2D 计算，有效相邻像素对 2.94×10^8 ）：

模型	边缘密度	相对标签	周期超额比峰值
标签（参照）	0.00771	1.000	—
MSSACT-Net 6.10M	0.03516	4.563	k=8: 1.66×
DeepLabV3+ 39.7M	0.00884	1.147	无
U-Net 2.4M	0.02139	2.776	k=16: 1.17×

所有模型都过度碎裂（1.15×–4.56×），而 MSSACT-Net 最严重（4.56×）。且其伪影具有周期性：水平边缘图的 FFT 在周期 k=8 附近功率占比为标签的 1.66 倍，而 8 正是解码器（ $32^2 \rightarrow 256^2$ ，三次 stride-2 转置卷积）的总上采样倍数——这与堆叠转置卷积的棋盘伪影机制一致。

可证伪的预测：若伪影确由转置卷积造成，则 `nd_abl_bilinear`（双线性替代 转置卷积）应同时具备更低的边缘密度与更小的 k=8 超额。该变体的实测 Kappa 确实更高（0.6369 vs 0.6312， +0.0057），与预测方向一致。



5.6.4 D3: Transformer 无位置编码

`TransformerEncoder.forward` 摊平为 token 后未插入任何位置信息，而

`nn.TransformerEncoderLayer` 不自带位置编码（不同于 ViT）。自注意力本身是 置换等变的：对置换矩阵 P ， $A = \text{softmax}(QK^{\top}/\sqrt{d}) \rightarrow PAP^{\top}$ 。

数值验证： 随机置换 64 个 token，把输出按逆置换还原，最大绝对差 **7.153e-07**（浮点噪声量级）→ 模块对 token 顺序完全等价。

三点如实限定：

1. **不等价于"完全无用"**：输入 token 来自卷积特征，其内容本身位置相关；且零填充/边界可充当**隐式位置锚点**（CPVT/PEG 一脉的论证）。
2. **但无法完成基于空间邻近的上下文建模**——而"长程空间上下文"正是分割网络中 全局注意力的标准用途。这是**机制性降级**。
3. **量级参照**：位置编码并非可有可无——移除 DeiT-tiny 的位置编码使 ImageNet 精度由 72.2% 降至 68.2%。

5.6.5 与消融结果的对应（机制解释）

变体	实测 ΔKappa	机制解释
w/o FPN	+0.0002 (0.04 σ , 不可分辨)	FPN 支路 0-2 是死计算 (§5.6.2)

变体	实测 ΔKappa	机制解释
w/o Transformer	-0.0010 (0.20σ , 不可分辨)	置换等变集合算子 (§5.6.4)
w/o ECSAM	-0.0040 (0.80σ , 不可分辨)	仅占 0.90% 参数
w/o Adapter	+0.0030 (0.60σ , 不可分辨)	仅 33K 参数 (0.54%)
Bilinear-Up	+0.0057 (1.14σ , 弱)	消除转置卷积棋盘伪影 (§5.6.3)

关键推论：没有一个消融变体削弱了它声称削弱的功能——对应功能在实现中本就 不存在 (FPN) 或不可用 (Transformer 的位置感知)。故这一组消融**不能**作为 "模块有效性"的证据，它衡量的是"移除无效计算的影响"。


5.6.6 基线为何领先？——从零对照推翻了本节的原始结论

设置	预训练主干	从零训练	预训练贡献
主数据集 60 轮	—	0.6359	—
阶梯 n250	0.2825	0.1762	+0.1063
阶梯 n500	0.4928	0.4393	+0.0535
阶梯 n1000	0.6310	0.4771	+0.1539

主数据集 (60 轮, 双方均从零)：自研 6.10M **0.6320** vs DeepLabV3+ 39.69M **0.6359**, $\Delta = +0.0039$ ($0.78\sigma \rightarrow$ **不可分辨**)。

修正后的结论：

1. **从零训练的公平对比下，自研 6.10M 与 DeepLabV3+ 39.69M 不可分辨** ($\Delta = +0.0039$, 0.78σ)，而后者参数是前者的 **6.5 倍**。原报告"DeepLabV3+ 显著优于自研 (+0.0720)" 的表述**不成立**：那 0.0720 中约 **95% 来自预训练主干**。
2. **预训练主干是本任务上最大的单项杠杆**：同一模型仅切换权重初始化，贡献 **+0.054 ~ +0.154 Kappa**。作为对照，全部模块消融 $\leq 1.13\sigma$ (≈ 0.0057)，裁剪策略为 0.0199–0.0223。**杠杆排序：换主干权重 $\gg$ 改训练策略 > 增删模块**。



核验更正 (取证过程) : `weights=None` 并不足以关闭主干预训练。torchvision 的 `deeplabv3_resnet50` 有两个互相独立的权重参数: `weights` (整体/分割头) 与 `weights_backbone` (主干), 后者默认即 `ResNet50_Weights.IMAGENET1K_V1`。

权重级取证 (与该权重的官方文件逐张量比对) :

构造方式	与官方权重相同的张量	相同参数量占比
<code>pretrained_backbone=True</code>	264 / 265	23,551,744 / 23,561,152 = 100.0%
<code>pretrained_backbone=False</code>	0 / 265	0.0%

(唯一不同者是 `conv1`, 因输入改为 3 通道而被替换。) 该预训练覆盖了该模型 **58.1%** 的参数; 其来源是 PyTorch 官方在 **ImageNet-1K** (1000 个自然图像类) 上训练的 ResNet-50, 官方指标 $\text{acc@1} = 76.13\%$ 。

行为级取证: 若该参数不生效, 两次运行应当统计一致; 而实测两者相差 $+0.054 \sim +0.154$ Kappa。参数确实在起作用。

5.6.7 通道-空间容量比

配置	最深特征	元素数	输入元素数	比值
light <code>[32, 64, 128, 256]</code>	$256 \times 32 \times 32$	262,144	196,608	1.33×
large <code>[64, 128, 256, 512]</code>	$512 \times 32 \times 32$	524,288	196,608	2.67×

即**最深特征图**的标量数量超过输入图像本身（large 达 2.67 倍），而这些表征最终被 压缩回 256^2 输出，其中还有 29.96% 的参数不参与前向。此处**并非** transformer 的 秩亏问题（token 数 $N=1024 > d_{\{model\}}$ ），而是**空间侧信息量与通道侧容量的失衡**。


5.6.8 边界质量为何在聚合指标上不可见


距类边界	像素占比	共识 vs 标签	模型间分歧
0（边界像素）	2.36%	0.4577	0.2881
1-2 px	5.34%	0.4891	0.2877
3-4 px	5.17%	0.5327	0.2847
5-8 px	8.75%	0.5882	0.2789
>8 px（内部）	78.39%	0.7294	0.2294

Kappa 归属上限（oracle 作弊实验）：

模型	完美解决边界	Δ 边界	完美解决内部	Δ 内部
MSSACT-Net	0.5936	+0.0161	0.8700	+0.2925
DeepLabV3+	0.6654	+0.0159	0.8800	+0.2306

完美预测全部边界像素（2.36%）最多换来 +0.016 Kappa；内部像素（78.39%）值 +0.23 ~ +0.29。 因此任何**面向边界锐化**的模块在聚合 Kappa 上的可见空间被限制在 ≈ 0.016 以内——与观测到的消融散布 0.008 同量级。





勘误：早期报告称"**93.0%** 像素在类边界上"，并据此得出"标签碎片化"与 "越纯净区域模型越不同意标签"两条结论。经复核，原实现把标签批次按 (N, H, W) 三维数组沿 $axis=0$ 求差分，**跨图像的像素差被误判为类边界**，故得出虚高比例。改为逐图 2D、且仅统计两个**不同有效类别**之间的相邻像素后，真实边界比例为 **2.4%**，结论方向亦反转（准确率随距边界距离**单调上升**）。

5.6.9 架构变体实测结果（两条管线互证）

管线	变体	参数量	Kappa	相对基线
P-MEM-ROLL	完整模型	6.102M	0.6320	—
	D1 联合消融（-FPN -Trans -Adapter）	2.005M	0.6293	-0.0027
	D2 解码器坐标注意力	6.115M	0.6375	+0.0055
	D3 超轻量通道	1.547M	0.6103	-0.0217
	D4 大容量通道	24.242M	0.6365	+0.0045
P-PNG	完整模型	6.102M	0.6312	—
	D1 联合消融	2.005M	0.6277	-0.0035
	D3 超轻量通道	1.547M	0.6119	-0.0193

三条读表要点：

1. 移除 67.2% 的参数只损失 ~0.003 (两条管线分别 -0.0027 / -0.0035, 互证)。
2. 把坐标注意力移到解码器 (D2) 反而最好 (+0.0055 / +0.0029), 与 "注意力在上采样路径上才有效"的文献结论一致。
3. 容量确有作用: D3 (通道减半) 显著下降 (-0.0217 / -0.0193, 约 4σ), 而 D3 仍保留全部模块——所以"模块不重要"**不等于**"容量不重要"。精确表述是: **占参数 67.14% 的两个模块无可测量贡献, 而通道宽度才是性能来源。**

5.6.10 可验证的修复路径

优先级	修复	预期效果	验证方式
P0	FPN 改为 真正使用 多尺度输出 (解码器接收全部 4 层, 或至少做跳连)	恢复多尺度融合语义	消融应出现可测差异
P0	解码器加入 encoder→decoder 跳连 (U-Net 式或 DeepLabV3+ 单条低层跳连)	修正 §5.6.3 的粒度瓶颈	边界带 OA 应显著上升
P1	Transformer 加入 位置编码 (2D sincos / 可学习 / 相对位置偏置)	恢复空间邻近建模能力	置换等变性检验应被打破
P1	重新定义消融语义: 先修实现, 再评估"模块是否有效"	使消融结论可解释	—
P2	容量重新配比, 修正 $2.67\times$ 容量膨胀	参数效率	参数量-Kappa 曲线

5.6.11 本节局限

1. σ_{seed} 的种子数仅 4 (文献建议 ≥ 10), 故适用于**量级判断**而非精确检验。
2. 等效性检验 (TOST) 尚未完成: 严格区分"无证据有差异"与"有证据无差异"需要预指定 SESOI 的 TOST。本项目已实现配对 bootstrap CI (`analysis/eval_rigor.py`), TOST 待补齐。
3. 缺陷检验在 **light 配置**上完成; 大配置结构相同、结论可直接推广, 但未复跑。
4. 分带与 Kappa 归属基于**已缓存的 6 个模型预测**; 8 个消融变体的逐带分解待补齐。

5.7 随机种子噪声底线 (多种子实测)

方法学必要性: 本项目早期全部比较都基于**单次运行** (seed=42)。文献指出这不足以支持"无差异"结论: GEO-Bench (NeurIPS 2023 D&B) 建议 ≥ 10 个种子, 并指出 3-5 个种子不足以给出可靠置信区间。


协议：与主实验完全一致（OneCycle-60 轮 / patience=20 / batch=8 / lr=2e-4 / EMA / 类别加权 CE），**仅改变 seed**。seed 控制模型初始化、DataLoader 打乱顺序与 几何增强抽样（裁剪位置由 `epoch_seed` 决定，与 seed 无关）。

配置	种子数	mean	σ_{seed}	极差	区间
完整模型 MSSACT 6.10M (P-MEM-ROLL)	4	0.6362	0.0050	0.0094	[0.6318, 0.6412]
DeepLabV3+ 39.69M (P-MEM-ROLL)	3	0.6931	0.0034	0.0066	[0.6895, 0.6961]

结论：完整模型 4 次运行的 $\sigma_{\text{seed}} = 0.0050$ 、极差 0.0094。**同管线模块消融的总散布 0.008 仅为种子极差的 0.87 倍——即 换一个随机种子带来的波动，比整套架构改动带来的差异还大。**

两个副产品：**seed=42（原基线）是四个种子中最差的**；DeepLabV3+ 的 σ 更小（0.0034），与"预训练压低初始化方差"一致。

保留的限定：n=4 时 σ 本身有不确定性，该数值适用于**量级判断**（差异是 1σ 还是 5σ ），不宜作精确检验。



5.8 训练策略对比：裁剪尺度与随机/固定裁剪


配置	crop	位置	每样本像素	Kappa	ΔM vs 基准	秒/轮	总时长
lgR_bs8_full_lr2e4	256	随机	1.00×	0.6320	+0.0000 (0.00 σ , 不可分辨)	44 s	44.0 min

配置	crop	位置	每样本 像素	Kappa	ΔM vs 基准	秒/ 轮	总时长
lgR_c256_center	256	固定 中心	1.00×	0.6128	-0.0192 (3.84σ , 可分辨)	44 s	44.0 min
lgR_c384_rand	384	随机	2.25×	0.6543	+0.0223 (4.46σ , 可分辨)	100 s	100.0 min
lgR_c512_rand	512	随机	4.00×	0.6524	+0.0204 (4.08σ , 可分辨)	192 s	192.0 min

对比	$\Delta Kappa$	σ 倍数	计算代价	判读
256 随机 vs 256 固定中心	-0.0192	3.8σ	同代价	可分辨
384 随机 vs 256 随机	+0.0223	4.5σ	2.3×	可分辨
512 随机 vs 256 随机	+0.0199	4.0σ	4.4×	可分辨

判读要点：

1. 本节三个对比的效应量，全部大于 §5.6 的所有模块消融。 $|\Delta Kappa|$ 为 0.0199–0.0223 ($3.8\text{--}4.5\sigma$)；而模块消融全部 $\leq 1.13\sigma$ 。也就是说：**在这套模型上，训练策略的收益是可分辨的，模块增删则不可分辨。**这对后续工作更有指导意义——**先选对训练策略，再谈架构。**
2. **256 随机 vs 256 固定中心**：两者像素量与尺度完全相同，差异**只能**归因于“每轮随机位置”这一增强——随机裁剪本身值 **+0.0192**。
3. **256 $\rightarrow$ 384 $\rightarrow$ 512**：384 达 0.6543 (+0.0223)，512 为 0.6519 (+0.0199) ——再放大到 512 无额外收益，代价却从 100 s/轮升到 192 s/轮 ($4.4\times$ 于基准)。故 **384 是更优的工程取舍**：既印证了“过小的尺度没有意义”，也说明**过大的尺度不划算**。
4. 注意 batch 随面积下调 ($256^2:8$ / $384^2:4$ / $512^2:2$) 以避免显存溢出，故每轮耗时与总时长必须一并报告——大裁剪的计算代价是**平方级增长**的。



5.9 数据量阶梯：容量与数据量的匹配

协议： 30 轮 / patience=30 (固定预算、不早停) / bs8 / lr2e-4；子集为分层抽样的嵌套样本 ($250 < 500 < 1000$)；**验证集固定为 newsplit2 的 221 张** (与子集大小无关)，故各档 Kappa 可比。

e50rel / e90rel： 首次达到**该次运行自身 k_max** 的 50% / 90% 的轮次。使用相对阈值是因为低数据档的绝对 Kappa 很低 (n250 完整模型上限仅 0.03)，固定阈值 0.4/0.5/0.6 在这些档位**永远不可达**。

n = 250 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.2825	0.2387	24	29
U-Net (2.45M)	0.1915	0.1915	14	28
DeepLabV3+ 从零 (39.69M)	0.1762	0.1762	24	30
MSSACT-Net w/o ECSAM	0.1164	0.1079	23	29
MSSACT-Net 完整 (6.10M)	0.0322	0.0261	27	28

n = 500 张


模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.4928	0.4928	16	27
DeepLabV3+ 从零 (39.69M)	0.4393	0.4393	21	26
U-Net (2.45M)	0.4050	0.4050	19	28
MSSACT-Net w/o ECSAM	0.3954	0.3954	19	29
MSSACT-Net 完整 (6.10M)	0.3312	0.3312	25	28

n = 1000 张

模型	Kappa	末轮	达自身 50% 上限	达 90%
DeepLabV3+ 预训练 (旁证)	0.6310	0.6303	13	21
MSSACT-Net w/o ECSAM	0.5234	0.5234	15	24
MSSACT-Net 完整 (6.10M)	0.5085	0.5085	17	25
U-Net (2.45M)	0.4913	0.4913	12	20
DeepLabV3+ 从零 (39.69M)	0.4771	0.4771	13	21

三点结论：

1. **小数据下"模块更多"反而更差。** n=250 时 U-Net (0.1915) 与 DeepLabV3+ 从零 (0.1762) 都远好于完整模型 (0.0322) 。这与 §5.6 的缺陷分析 一致：被移除的 FPN/Transformer/ECSAM 在实现上并未执行其声明的功能，因此在样本稀少时只贡献了**优化难度**而非有效容量。
2. **w/o ECSAM 在全部三档上都不低于完整模型**，与 §5.6.1 的观察一致（坐标注意力仅占 0.90% 参数）。
3. **学习曲线的形态随数据量变化：** n250 的完整模型直到第 27/30 轮才达到自身上限的 一半，说明**小数据档在 30 轮预算内仍处于爬升期**。




局限：30 轮预算对小数据档偏紧 (e50rel 落在 23–27 轮)，故各档数值只宜用于 "同预算下的相对比较"，**不宜**解读为该模型在该数据量下的能力上限。

5.10 预算攻击：充足预算是否掩盖了模块差异？

动机：§5.6"模块无贡献"的结论是在 **60 轮充足预算**下得到的。自然的质疑是：**预算太足**，使各变体都有机会收敛到同一水平，从而掩盖了模块本身的差异。本实验把预算压到 **15 轮**，其余协议不变。

模型	参数量	Kappa (15 轮)	Δ vs 完整
DeepLabV3+ 预训练 (旁证)	39.692M	0.6358	+0.1459 (29.17 σ , 可分辨)
MSSACT-Net w/o ECSAM	6.047M	0.5092	+0.0193 (3.86 σ , 可分辨)
MSSACT-Net 完整 (6.10M)	6.102M	0.4899	+0.0000 (0.00 σ , 不可分辨)
U-Net (2.45M)	2.446M	0.4884	-0.0015 (0.31 σ , 不可分辨)
MSSACT-Net w/o EMR	6.102M	0.4790	-0.0109 (2.19 σ , 可分辨)
DeepLabV3+ 从零 (39.69M)	39.692M	0.4682	-0.0217 (4.33 σ , 可分辨)

结论：压到 **15 轮**后，模块之间的差异依然很小——完整模型 0.4899、w/o EMR 0.4790、U-Net 0.4884，散布仅 0.0109 (约 2 σ)；"**预算掩盖模块差异**"这一质疑**不成立**。



但本实验揭示了一个跨四组实验一致的模式：在数据或预算受限的四种设置下，移除坐标注意力 (ECSAM) 都更好 (4/4 一致)。这与 §5.6.1 的观察吻合——ECSAM 仅占 0.90% 参数，且被放在编码器深层（位置信息已被 8× 下采样稀释）。

5.11 全部效应量的可分辨性总表

把本项目全部"设计选择"的效应量统一折算到 $\sigma_{\text{seed}} = 0.0050$ 这一尺度上，即可直接比较哪一类选择真正重要：

效应	ΔKappa	σ 倍数	判读
预训练主干贡献 (阶梯 n1000)	+0.1539	30.78σ	可分辨
预训练主干贡献 (阶梯 n250)	+0.1063	21.26σ	可分辨
预训练主干贡献 (阶梯 n500)	+0.0535	10.70σ	可分辨
384 vs 256 随机裁剪	+0.0223	4.46σ	可分辨
模块/容量变体 lgR_D3_ch_tiny	-0.0217	4.34σ	可分辨
512 vs 256 随机裁剪	+0.0204	4.08σ	可分辨
随机裁剪 vs 固定中心 (256)	-0.0192	3.84σ	可分辨
模块/容量变体 nd_abl_bilinear	+0.0056	1.12σ	弱 (1–2 σ)

效应	$\Delta Kappa$	σ 倍数	判读
模块/容量变体 lgR_D2_decoder_ca	+0.0055	1.10 σ	弱 (1-2 σ)
模块/容量变体 nd_abl_trans4l	+0.0050	1.00 σ	弱 (1-2 σ)
模块/容量变体 lgR_D4_ch_large	+0.0044	0.88 σ	不可分辨
模块/容量变体 nd_abl_no_emr	+0.0043	0.86 σ	不可分辨
模块/容量变体 nd_abl_no_ecsam	-0.0041	0.82 σ	不可分辨
从零 DeepLabV3+ 39.69M vs 自研 6.10M (主协议)	+0.0039	0.78 σ	不可分辨
模块/容量变体 nd_abl_no_adapter	+0.0030	0.60 σ	不可分辨
模块/容量变体 lgR_D1_join_nofpn_notrans	-0.0028	0.56 σ	不可分辨
模块/容量变体 nd_abl_trans6l	+0.0023	0.46 σ	不可分辨
模块/容量变体 nd_abl_no_trans	-0.0011	0.22 σ	不可分辨
模块/容量变体 nd_abl_no_fpn	+0.0002	0.04 σ	不可分辨

这张表是全文最凝练的结论：在被测的全部设计维度中，只有三类效应超过 2 σ ——预训练主干、训练策略（随机裁剪与裁剪尺度）、以及通道容量；而全部模块增删 都落在噪声内。

6. 关键结论

按"可分辨性"分级，并给出可执行的下一步。

6.1 已由实测确立 ($|\Delta| > 2\sigma_{seed}$)

1. 预训练主干是本任务上最大的单项杠杆。同一模型仅切换权重初始化，Kappa 相差 +0.054 ~ +0.154 (§5.6.6)。这在实践中意味着：在有限标注预算下，把资源投向可获得预训练特征的骨干，收益远大于自研架构设计。
2. 训练策略的收益是可分辨的。随机裁剪值 +0.0192 (3.8 σ)；裁剪尺度 256→384 值 +0.0223 (4.5 σ)，而 384→512 无额外收益、代价翻倍 (§5.8)。可执行的结论：采用 384² 随机裁剪。
3. 通道容量确实重要。通道减半 (1.547M) 掉 0.0217 (4.3 σ)，且该变体仍保留全部模块 (§5.9)。可执行结论：不要在容量上省钱。

4. **数据规模在低数据区是主导因素。** $n=250$ 时完整模型几乎学不动 (Kappa 0.0322) , 而 U-Net 达 0.1915 (§5.9) 。**可执行结论: 自研模型需要 $\geq 1,000$ 张才体现优势。**
5. **后训练有稳定的小幅收益** (+0.0101 Kappa, §4.3.1) 。

6.2 已由实测否定或推翻的原有结论

1. **"DeepLabV3+ 显著优于自研模型 (+0.0720) "不成立。** 该比较中 DeepLabV3+ 带 ImageNet 预训练主干; 从零对照下两者**不可分辨** ($\Delta=+0.0039$, 0.78σ) , 而参数量相差 6.5 倍 (§5.6.6) 。
2. **"DeepLabV3+ 架构的学习效率更高"被推翻。** 达 Kappa 0.5 所需累计学习量: 从零 DeepLabV3+ **75.9%** vs 自研 **59.7%**——**从零条件下它更慢**; 原先的 30.3% 完全来自预训练 (§5.2) 。
3. **"五个设计模块均无可测量的独立贡献"需要修正表述。** 准确说法是: **这些模块在实现上并未执行其声明的功能** (FPN 的多尺度融合被丢弃、Transformer 无位置编码、解码器无跳连) , 因此移除它们没有影响 (§5.6.2–5.6.5) 。这是**实现缺陷**, 不是"模块设计无效"的证据。
4. **"标签碎片化 (93% 像素在边界) "是错的, 真实边界像素占 2.4%** (§5.6.8) ; 且原论证方向相反。

6.3 方法学结论 (对后续工作最有价值)

1. **先建立误差底线, 再谈差异。** $\sigma_{\text{seed}} = 0.0050$ 使本项目能对每个结论给出 分级 (§5.11) , 而不是罗列一堆无法比较的 ΔKappa 。
2. **消融实验必须先验证"模块是否在工作"。** 如果直接做消融而跳过 §5.6 那样的 数值检验, 本项目会把"移除无效计算无影响"误读为"模块冗余"——这正是早期 报告的错误来源。
3. **归因必须排除混淆变量。** 预训练混淆事件说明: **只验证自己假设的那个参数** 是不够的 (当时只看了 `weights=` , 漏掉了 `weights_backbone=`) 。可靠的做法是找**可证伪的观测量** (此处用"新初始化 BN 的 weight 必为 1.0" 与"权重逐张量比对官方文件") 。

7. 局限、疏漏与教训

7.1 研究区选择的疏漏

早期选用 GF-1 影像 + 内蒙古根河市 (2.4 m GSD) , 其类别体系与分辨率不匹配: 大量类别在 2.4 m 下光谱与空间不可分, 且无公开可核验的逐像素标注。 **教训:** 数据集选择应由**分类体系的可分性与标注的可核验性**决定, 而不是由手头有什么影像决定。

7.2 类别体系核对的疏漏

官方约定 0 为 no-data、1 - 7 为类别, 早期实现误将 0 当作背景参与训练与评估, 使指标虚高约 0.007-0.009 Kappa。 **教训:** 类别体系必须以**官方文档**为准逐条核对, 不能凭直觉假设。

7.3 当前局限 (含 §5.6.11 的全部声明)

- 1. σ_{seed} 的种子数仅 4 (文献建议 ≥ 10) $\rightarrow$ 只支持量级判断。
- 2. 等效性检验 (TOST) 未完成 $\rightarrow$ 严格意义上的"无差异"尚需补齐。
- 3. 数据集为 LoveDA 单一来源 (0.3 m 航空正射、城市/乡村两类场景) , 结论向其他传感器/分辨率/地域的外推性未验证。
- 4. 未使用预训练特征 (§8.1 列为后续方向) , 故不能回答"自研架构 + 预训练" 的上限。
- 5. 架构缺陷尚未修复: §5.6 的三处缺陷在结论中已如实标注, 但**修复后的重评 尚未进行**。
- 6. 标签质量上限只有提示性证据 (§5.3 的独立性限定) 。

7.4 质量控制措施 (本次新增)

措施	作用
误差底线 σ_{seed}	给全部差异提供统一判据
管线世代隔离	不同数据投递后端的结果禁止跨世代比较
权重级取证	用逐张量比对代替"读代码下结论"
推送前审核	自动检查本机路径、内部语境词、大文件
索引与事实单一来源	<code>experiments_index.json</code> / <code>FACTS.json</code> 为唯一数据源, 报告与 README 均由其生成
PDF 内容自检	27 项关键词守卫, 防止报告回退为已否证的结论

8. 后续工作

8.1 预训练方向（本次实验中收益最大的方向）

§5.6.6 已量化：**预训练主权重的贡献 (+0.054 ~ +0.154) 远大于任何架构改动**。因此这是后续最值得投入的方向，具体两条路径：

(1) 换用预训练主干 把自研 EMR 编码器替换为可获取预训练权重的骨干（如 ImageNet 预训练的 ResNet / ConvNeXt / Swin），保留本项目的 FPN-Transformer-解码器结构。可回答的问题：“**自研架构 + 预训练特征**”能否超过“**标准架构 + 预训练特征**”？（本项目已具备公平对照的全部条件：同管线、同协议、 σ_{seed} 已知。）

(2) 域内预训练（自监督或跨区监督） 用 LoveDA 影像本身做预训练，避免 ImageNet 与遥感影像的域差：
- **自监督**：MAE / SimCLR / DINO 等在无标注影像上预训练编码器；
- **跨区监督**：官方数据集的另一分区（官方 val 区 1,669 张**带标注**）作为预训练集，本项目的 1,768 张作为微调集——两者天然不重叠，无泄漏风险。

注意：这两条都需**重新设计数据预算的对照**（预训练用掉的数据不能同时用于微调），否则会重演“数据量 vs 预训练无法分离”的混淆。

8.2 多光谱与高光谱适配（下一个阶段的核心方向）

本项目使用的是 3 波段 RGB。后续计划针对**多光谱 (>4 波段) 与高光谱**影像设计模型，三个具体方向：

1. **三方向池化**：现有 ECSAM 只做水平/垂直两个**空间**方向的池化。对多光谱数据，应扩展为**光谱维 / 空间维 / 通道维**的三方向池化，使注意力同时感知波段相关性。
2. **模块适配**：现有 FPN 的横向连接假设各层通道数相近，多光谱输入下需重新设计光谱-空间特征的融合方式；Transformer 的 patch embedding 也需适配波段数。
3. **验证协议**：建立高光谱数据集上的**从零训练基准**与误差底线，以避免重演本项目早期的归因错误。

8.3 其他

- **补齐 TOST 等效性检验**，把“无差异”从“未达显著”升级为“统计等效”。
 - **修复 §5.6 的三处缺陷后重评**，届时消融实验才具备可解释性。
 - **扩大种子数至 ≥ 10** ，使 σ_{seed} 可用于精确检验。
 - **跨传感器/分辨率验证**（含 GF-1 同域微调），检验结论的外推性。
-

9. 个人工作与能力体现

9.1 数据工程

完成 LoveDA 官方训练区的全量获取与清洗：**MD5 去重** (2,821 张池)、**no-data $\leq 10\%$ 筛选** (剔除 312 张)、**8:1:1 分层划分**，并建立**泄漏防控校验** (三集两两互斥 + test_clean 与历史训练集零重叠)。实现**预解码 memmap** 数据集，把每张图的训练成本由 ≈ 170 ms 降到 ≈ 24 ms。

9.2 模型训练与工程

搭建统一训练入口 (OneCycle + EMA + 类别加权 CE + Kappa 早停)，支持 12 类模型/变体的**同协议对比**。实现**断点续跑队列** (按 history 轮数判定完成)、**OOM 自动降 batch**、**队列互斥与无窗口后台执行**。把 GPU 利用率由 49.9% 提升到 84.3%，同时**零性能损失** (\$5.5)。

9.3 实验设计与分析

设计并执行 **7 基线对比 + 8 消融 + 4 架构变体 + 3 档数据阶梯 + 3 组裁剪策略 + 15 轮预算攻击 + 多种子重复**，共 40+ 次独立训练。建立**累计学习量**方法分离调度效应与架构效应 (并据此推翻了一条原有结论)。建立**Kappa 归属 (oracle) 分析**量化指标的可见空间。

9.4 问题定位与修复

- **发现并证明三处架构实现缺陷** (FPN 死支路 / 无跳连 / 无位置编码)，全部给出**可复现的数值验证** (输出逐位不变、置换等变至 $7e-07$)。
- **发现并更正一处严重的公平性缺陷**： `weights=None` 未关闭主干预训练，导致基线被误认为从零训练。用**权重级逐张量比对**取证，并重跑从零对照。
- **发现并更正一处统计错误**：边界像素比例 $93\% \rightarrow 2.4\%$ (跨图求差分的缺陷)，结论方向随之反转。
- 定位并修复训练基础设施瓶颈 (PNG 解码、EMA 实现、进程同步)。

9.5 工具与产出

可复现性基建： `paths.py` 路径集中 (脚本内零绝对路径)、 `experiments_index.json` 实验索引 (参数量直读张量)、 `FACTS.json` 事实单一来源、 `verify/pre_push_audit.py` 推送前审核、

report/make_pdf.py 报告内容自检。 **分析工具**：严格性评估（配对 bootstrap / TOST）、Kappa 归属分解、 解码器伪影分析（FFT 周期检测）、随机种子噪声底线。 **报告与图**：全部图表由 viz/make_report_figures.py 从权威数据源生成，**无手改数据**。

附录 A：复现指引

A.1 环境与运行

```
cd loveda                                # 运行目录 = 仓库根
export LDA_DATA_ROOT=<数据根目录>        # 或写入 .env（不入库）
python prep/resplit_filtered.py           # 数据筛选 + 去重 + 划分
python prep/build_fast_dataset.py         # 预解码 memmap（强烈建议）
python prep/build_ladder_memmap.py        # 阶梯子集 memmap（跑阶梯前需停队列）
python queues/run_queue_new.py            # 对比(7) + 消融(8) + 主模型
python queues/run_queue_arch.py           # 架构变体 D1-D4 + 预算攻击 + 数据阶梯
python analysis/eval_rigor.py --infer     # 逐类 IoU / 配对 bootstrap / TOST
python analysis/convergence_amount.py     # 累计学习量（调度 vs 架构）
python analysis/seed_variance.py          #  $\sigma_{\text{seed}}$  与可分辨性
python viz/make_report_figures.py         # 全部报告图
python report/build_index.py              # 实验索引（参数量直读张量）
python report/build_facts.py              # 事实汇总 → FACTS.json
python report/make_report_v3.py           # 本报告 HTML
python report/make_pdf.py                 # HTML → PDF（含 27 项内容自检）
python verify/pre_push_audit.py           # 推送前审核（必须通过）
```

A.2 训练管线世代（禁止跨世代比较 Kappa）

世代	数据投递	num_workers	实验前缀
P-PNG	每样本解码两张 1024 ² PNG	0	nd_* lg_*
P-MEM-DET	memmap + 确定性增强	8	lgF_* (✗ 已否决, Kappa -0.0246)
P-MEM-ROLL	memmap + 原始增强	0	lgR_* sd*_*

两代后端差异实测为 **+0.0008** (同配置 0.6320 vs 0.6312) , 故两组结论可**互相印证**, 但**不得混合求统计量**。

附录 B：文件与目录说明

根目录只保留： `paths.py` 与 4 个核心模块、文档、`figures/` (报告图)、 三项权威事实 (`FACTS.json` / `experiments_index.json` / `seed_variance.json`) 、 本报告 PDF。

脚本按用途分 7 个子目录： `queues/` (实验队列)、 `analysis/` (评估与分析)、 `verify/` (核验与审核)、 `prep/` (数据准备)、 `viz/` (图表)、 `report/` (汇总与报告)、 `mapping/` (制图管线) 。

产物集中在 `results/` : `checkpoints/` (权重与训练历史)、 `fast_dataset/` (memmap)、 `consensus_analysis/` `overfit_diag/` `ladder_eval/` `fulltile_eval/` `tta_eval/` `heldout_test/` (各阶段评估)、 `artifacts/` (中间分析产物) 。

本地归档 (不入库)： `_local_archive/` (历史数据集与旧图)、 `backups/` (覆盖前备份) 。

目录整理与路径适配的完整记录见 `docs/整理记录_20260913.md` ; 本报告的问题审查与逐条修正见 `docs/报告问题研究_20260913.md` 。